

APOSTILA

Probabilidade & Estatística

Teoria, exemplos resolvidos e exercícios com aplicações em computação

9 de outubro de 2026

Sumário

Módulo 1: Teoria Fundamental da Probabilidade

- 1.1 Experimento Aleatório, Espaço Amostral e Eventos
- 1.2 Axiomas de Kolmogorov e Propriedades Fundamentais
- 1.3 Probabilidade Condicional e Regra da Multiplicação
- 1.4 Independência Estatística
- 1.5 Teorema da Probabilidade Total
- 1.6 Teorema de Bayes e Atualização de Crenças
- 1.7 Confiabilidade e Disponibilidade de Sistemas Computacionais
- 1.8 Técnicas de Contagem para Espaços Equiprováveis
- 1.9 Probabilidades a partir de Tabelas de Contingência
- 1.10 Roteiro com Árvore de Probabilidades

Módulo 2: Variáveis Aleatórias Discretas (VAD)

- 2.1 Conceito de Variável Aleatória Discreta
- 2.2 Função de Probabilidade (FP / PMF)
- 2.3 Função de Distribuição Acumulada (FDA / CDF)
- 2.4 Esperança Matemática (Média / Valor Esperado)
- 2.5 Variância e Desvio Padrão
- 2.6 Medidas de Posição e Percentis para VAD
- 2.7 Soma e Diferença de Variáveis Independentes
- 2.8 Funções Não Lineares e Decisão por Valor Esperado

Módulo 3: Modelos Discretos de Probabilidade

- 3.1 Distribuição Uniforme Discreta
- 3.2 Ensaio de Bernoulli e Distribuição Binomial
- 3.3 Distribuição de Poisson
- 3.4 Teorema de Aproximação da Binomial pela Poisson
- 3.5 Como Escolher o Modelo
- 3.6 "Pelo Menos Um" e Dimensionamento de Testes
- 3.7 Estimando a Taxa de Poisson a partir de $P(X = 0)$

Módulo 4: Variáveis Aleatórias Contínuas (VAC)

- 4.1 Conceito de Continuidade e Propriedade Pontual Nula
- 4.2 Função Densidade de Probabilidade (FDP / PDF)
- 4.3 Função de Distribuição Acumulada (FDA) e o Teorema Fundamental
- 4.4 Esperança e Variância no Caso Contínuo
- 4.5 Medidas de Posição: Mediana e Percentis
- 4.6 Trabalhando a partir da FDA
- 4.7 Quartis e Amplitude Interquartil de uma VAC

Módulo 5: Modelos Contínuos de Probabilidade

- 5.1 Distribuição Uniforme Contínua $U(a, b)$
- 5.2 Distribuição Normal (Gaussiana) $N(\mu, \sigma^2)$
- 5.3 Padronização e a Tabela Normal Padrão $Z \sim N(0, 1)$
- 5.4 Distribuição Exponencial $Exp(\lambda)$
- 5.5 Confiabilidade e a Propriedade de Falta de Memória
- 5.6 Problema Inverso: Percentis da Normal
- 5.7 Soma de Normais Independentes (Orçamento de Latência)
- 5.8 Aproximação Normal da Binomial
- 5.9 Sistemas em Série com Componentes Exponenciais

Módulo 6: Estatística Descritiva

- 6.1 Classificação de Variáveis e Representação Gráfica
- 6.2 Medidas de Tendência Central
- 6.3 Medidas de Dispersão e Variabilidade
- 6.4 Medidas Separatrizes e Construção do Boxplot de Tukey
- 6.5 Tabelas de Frequência e Histogramas
- 6.6 Medidas para Dados Agrupados

Módulo 7: Estimação e Teorema Central do Limite (TCL)

- 7.1 Fundamentos de Inferência Estatística
- 7.2 Distribuição Amostral da Média e Erro Padrão
- 7.3 O Teorema Central do Limite (TCL)
- 7.4 Intervalos de Confiança (IC)
- 7.5 Eficiência e Erro Quadrático Médio
- 7.6 Distribuições Amostrais no Caso Normal
- 7.7 Intervalo de Confiança para a Variância
- 7.8 Tamanho de Amostra para Proporção

Módulo 8: Testes de Hipótese

- 8.1 Lógica dos Testes de Hipóteses
- 8.2 Matriz de Decisão e Erros Tipo I e Tipo II
- 8.3 Regra de Decisão pelo p-valor (Nível Descritivo)
- 8.4 Testes Paramétricos para a Média
- 8.5 Teste Qui-Quadrado (χ^2) de Aderência
- 8.6 Regiões Críticas e p-valor por Tipo de Hipótese
- 8.7 Teste para a Variância
- 8.8 Teste para Proporção
- 8.9 Poder do Teste
- 8.10 Aderência com Parâmetros Estimados

Módulo 9: Controle Estatístico de Processo (CEP / SPC)

- 9.1 Filosofia do CEP e Tipos de Variabilidade
- 9.2 Estrutura Geral dos Gráficos de Controle de Shewhart
- 9.3 Gráficos de Controle por Variáveis: $\bar{X}$ e R
- 9.4 Gráfico de Controle por p (Fração com Falha)
- 9.5 Análise de Capacidade do Processo C_p e C_{pk}
- 9.6 Gráficos $\bar{X} - S$ e S^2 (Variância)
- 9.7 Estimando σ do Processo
- 9.8 Gráficos np e c
- 9.9 Regras de Sensibilidade e Fases do CEP

Módulo 1: Teoria Fundamental da Probabilidade

Experimentos aleatórios em sistemas computacionais, espaço amostral, axiomas de Kolmogorov, probabilidade condicional, independência, probabilidade total, Bayes (spam, detecção de intrusão), disponibilidade de sistemas e contagem (senhas, colisões de hash).

Este módulo constrói a linguagem usada no resto do curso. Tudo o que vem depois (variáveis aleatórias, distribuições, estimação, testes e monitoramento) é a mesma ideia aplicada a perguntas cada vez mais ricas: atribuir números a eventos de forma consistente e atualizar esses números quando chega informação. Ao longo do módulo acompanhamos sistemas concretos (um enlace que perde pacotes, um balanceador de carga, um detector de intrusão) e vemos que poucas regras, todas deduzidas de três axiomas, resolvem problemas de redes, segurança, confiabilidade e análise de algoritmos.

1.1 Experimento Aleatório, Espaço Amostral e Eventos

Um programa determinístico, executado duas vezes com a mesma entrada, produz o mesmo resultado. Sistemas reais não se comportam assim. O mesmo pacote enviado duas vezes pode chegar numa e se perder na outra; a mesma consulta ao banco leva 3 ms agora e 300 ms daqui a pouco, porque o cache esfriou ou outro processo disputou o disco. Às vezes a aleatoriedade é colocada de propósito: o quick-sort sorteia o pivô para que nenhuma entrada seja sistematicamente ruim, e um teste de primalidade sorteia testemunhas. Chamamos de **experimento aleatório** ($\mathcal{E}$) qualquer processo cujo resultado não pode ser previsto com certeza, mesmo repetido nas mesmas condições.

A primeira decisão ao modelar um experimento é listar *o que pode acontecer*. Essa lista é o espaço amostral, e os fatos sobre os quais queremos perguntar são subconjuntos dela:

Definições Fundamentais:

- **Espaço Amostral** (Ω): conjunto de todos os resultados possíveis. Pode ser *discreto finito* (resultado de 3 pacotes: $\{EEE, EEP, \dots, PPP\}$, com E = entregue e P = perdido), *discreto infinito* (número de retransmissões até o primeiro sucesso: $\{1, 2, 3, \dots\}$) ou *contínuo* (latência de uma requisição: $t \in [0, \infty)$ ms).
- **Evento** ($A \subseteq \Omega$): qualquer subconjunto do espaço amostral. O evento A "ocorre" se o resultado do experimento pertencer a A . Ex.: $A = \text{"pelo menos um pacote perdido"} = \Omega \setminus \{EEE\}$.
- **Evento Certo**: o próprio Ω ($P(\Omega) = 1$). **Evento Impossível**: o conjunto vazio $\emptyset$ ($P(\emptyset) = 0$).
- **Eventos Mutuamente Exclusivos (Disjuntos)**: $A \cap B = \emptyset$, não podem ocorrer juntos. Ex.: "a requisição retornou 200" e "a requisição retornou 500".

INTUIÇÃO Um evento é um predicado

"Pelo menos um pacote perdido" é uma função que recebe uma sequência como EPE e devolve verdadeiro ou falso; o evento é o conjunto de sequências em que ela vale. Por isso as operações com eventos são as operações lógicas que você já usa em código:

Conjuntos	Código	Leitura
$A \cup B$	<code>a b</code>	pelo menos um ocorre
$A \cap B$	<code>a && b</code>	os dois ocorrem
A^c	<code>!a</code>	A não ocorre
$(A \cup B)^c = A^c \cap B^c$	<code>!(a b) == !a && !b</code>	lei de De Morgan

Essa correspondência vai ser usada o tempo todo. "Pelo menos um servidor caiu" é o complemento de "todos ficaram de pé", e esta segunda forma costuma ser muito mais fácil de calcular, porque vira um produto.

O mesmo sistema admite espaços amostrais diferentes, e escolher bem é parte do trabalho. Se a pergunta é "quantos dos 3 pacotes chegaram?", basta $\Omega = \{0, 1, 2, 3\}$. Se a pergunta é "o segundo pacote chegou?", essa versão não serve, porque o resultado "2 chegaram" não diz quais; é preciso guardar a ordem, $\Omega = \{E, P\}^3$, com 8 sequências. A regra é que Ω precisa distinguir tudo o que a pergunta distingue. Passar de um Ω detalhado para um resumo numérico ("número de perdas") é exatamente o que uma variável aleatória faz.

CAUIDADO Listar resultados não é atribuir probabilidades

Se cada pacote se perde com probabilidade 0.1, a sequência *EEE* tem probabilidade $0.9^3 = 0.729$ e *PPP* só 0.001. As 8 sequências estão longe de ser igualmente prováveis, e "casos favoráveis sobre casos possíveis" daria respostas erradas. O exemplo resolvido abaixo mostra a diferença: $P(\text{exatamente um perdido}) = 0.243$, e não $3/8$.

Quando Ω é contínuo, como a latência em $[0, \infty)$, há outra dificuldade: cada valor exato (200.000... ms) tem probabilidade zero. Os eventos que fazem sentido passam a ser intervalos, como "demorou mais de 200 ms" $= (200, \infty)$, e as probabilidades vêm de áreas sob uma densidade.

CONEXÕES

- 1.2** como atribuir probabilidades de forma coerente; o complemento torna "pelo menos um" fácil.
- 2.1** variável aleatória: a função que resume Ω num número.
- 4.1** espaços contínuos e por que pontos têm probabilidade zero.

▼ Entendendo a fórmula, termo a termo

$$P(A) = \frac{\#A}{\#\Omega}$$

#A ← Número de resultados que fazem *A* acontecer (casos favoráveis).

#Ω ← Número total de resultados possíveis (casos possíveis).

Hipótese ← Todos os resultados de Ω têm a **mesma** probabilidade. Sem isso, a fórmula não vale.

De onde vem, passo a passo

1. Se Ω tem N resultados equiprováveis, cada um tem probabilidade q .
2. Os resultados são disjuntos e cobrem Ω ; pelos axiomas 2 e 3, $N \cdot q = P(\Omega) = 1$, logo $q = 1/N$.
3. *A* é a união de $\#A$ desses resultados disjuntos; pelo axioma 3, $P(A) = \#A \cdot \frac{1}{N} = \frac{\#A}{\#\Omega}$.

A fórmula clássica é uma consequência dos axiomas em um caso particular, não a definição geral de probabilidade.

EXEMPLO RESOLVIDO**Três pacotes num enlace com perdas**

Um cliente envia 3 pacotes por um enlace sem fio. Cada pacote chega (E, entregue) ou se perde (P), e cada um se perde com probabilidade 0.1, independentemente dos outros.

DADOS

- 3 pacotes, 2 resultados possíveis por pacote
- $P(P) = 0.1$, logo $P(E) = 1 - 0.1 = 0.9$
- perdas independentes

O QUE SE PEDE

(a) o espaço amostral Ω ; (b) os eventos A = "exatamente um perdido" e B = "pelo menos dois perdidos"; (c) $P(A)$.

RESOLUÇÃO PASSO A PASSO**1 Montar o espaço amostral**

Cada resultado é uma sequência de 3 letras. O 1º pacote tem 2 possibilidades, o 2º tem 2 e o 3º tem 2. Pelo princípio multiplicativo, há $2 \times 2 \times 2 = 2^3 = 8$ resultados:

$$\Omega = \{EEE, EEP, EPE, PEE, EPP, PEP, PPE, PPP\}$$

2 Escrever os eventos como subconjuntos

Um evento é o conjunto de resultados que satisfazem a frase. Basta percorrer Ω e separar:

- A = "exatamente um perdido" = $\{EEP, EPE, PEE\}$ (3 resultados)
- B = "pelo menos dois perdidos" = $\{EPP, PEP, PPE, PPP\}$ (4 resultados)

Nenhum resultado está nos dois, logo $A \cap B = \emptyset$: os eventos são **mutuamente exclusivos**.

3 Calcular a probabilidade de um resultado

Como as perdas são independentes, a probabilidade de uma sequência é o produto das probabilidades de cada posição:

$$P(EEP) = \underbrace{0.9}_{1^\circ \text{ chega}} \times \underbrace{0.9}_{2^\circ \text{ chega}} \times \underbrace{0.1}_{3^\circ \text{ se perde}} = 0.081$$

EPE e PEE têm as mesmas letras em outra ordem, então também valem 0.081.

4 Somar os resultados do evento

A probabilidade de um evento é a soma das probabilidades dos resultados que o compõem:

$$P(A) = P(EEP) + P(EPE) + P(PEE) = 3 \times 0.081 = 0.243$$

5 Conferir pelo total

Os eventos "nenhum perdido", "exatamente um perdido" e "pelo menos dois perdidos" cobrem todo o Ω , então devem somar 1:

$$P(EEE) = 0.9^3 = 0.729, \quad P(B) = 3(0.9)(0.1)^2 + 0.1^3 = 0.027 + 0.001 = 0.028$$

$$0.729 + 0.243 + 0.028 = 1 \checkmark$$

RESPOSTA $P(A) = 0.243$, e não $3/8 = 0.375$.

Erro comum: contar casos ($\#A/\#\Omega = 3/8$) só vale quando os resultados são *igualmente prováveis*. Aqui EEE (0.729) é muito mais provável que PPP (0.001). Em espaços contínuos, como a latência de uma requisição $\Omega = [0, \infty)$ ms, os resultados nem podem ser listados: os eventos passam a ser intervalos, como "demorou mais de 200 ms" = $(200, \infty)$.

Exercício 1.1 • Espaço Amostral Equiprovável

Dois dados honestos são lançados (por exemplo, num jogo que simula os dados com um gerador pseudoaleatório). Qual a probabilidade de a soma das faces ser exatamente 5?

Espaço para cálculo

1.2 Axiomas de Kolmogorov e Propriedades Fundamentais

Que números podemos atribuir aos eventos? Durante séculos houve definições concorrentes: a clássica (casos favoráveis sobre possíveis), que só vale com resultados igualmente prováveis; a frequentista (limite da frequência relativa em muitas repetições), que não se aplica a eventos que não se repetem; e a subjetiva (grau de crença). Em 1933, Andrei Kolmogorov resolveu a disputa de outro modo: em vez de dizer o que a probabilidade é, ele listou as regras que qualquer atribuição precisa obedecer. As três interpretações satisfazem essas regras, e todos os teoremas valem para qualquer uma delas.

AXIOMAS DE KOLMOGOROV

$$\text{Axioma 1: } P(A) \geq 0, \quad \forall A \subseteq \Omega$$

$$\text{Axioma 2: } P(\Omega) = 1$$

$$\text{Axioma 3: Se } A_1, A_2, \dots \text{ são mutuamente exclusivos, então } P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

▼ Equação desmontada, variável por variável

$$P(A) \geq 0$$

$P(A)$ ← probabilidade do evento A (ex.: A = "pacote perdido")

≥ 0 ← nunca negativa

$$P(\Omega) = 1$$

Ω ← espaço amostral: todos os resultados possíveis

$= 1$ ← algum resultado sempre ocorre (100%)

$$P\left(\bigcup_i A_i\right) = \sum_i P(A_i)$$

A_i ← eventos mutuamente exclusivos (nunca ocorrem juntos), $i = 1, 2, \dots$

$\bigcup_i A_i$ ← união: "algum dos A_i ocorre"

$\sum_i P(A_i)$ ← soma das probabilidades individuais (ex.: $0.2 + 0.1 = 0.3$)

O conteúdo dos axiomas é pequeno: probabilidades não são negativas, o total é 1, e pedaços que não se sobrepõem se somam. A força está em que todo o resto é consequência. Destes argumentos derivam as regras operacionais:

- **Complementar:** $P(A^c) = 1 - P(A)$
- **Regra da Adição Geral:** $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
- **Para três eventos:** $P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(A \cap B) - P(A \cap C) - P(B \cap C) + P(A \cap B \cap C)$
- **Monotonicidade:** se $A \subseteq B$, então $P(A) \leq P(B)$.

DEDUÇÃO Complemento e adição a partir dos axiomas

- 1. Complemento:** A e A^c são disjuntos e juntos formam Ω . Pelo axioma 3, $P(A) + P(A^c) = P(\Omega)$, que vale 1 pelo axioma 2. Daí também saem $P(\emptyset) = 0$ e $P(A) \leq 1$.
- 2. Adição:** escreva $A \cup B$ como pedaços disjuntos, A e $B \cap A^c$. Como $B = (B \cap A) \cup (B \cap A^c)$, vale $P(B \cap A^c) = P(B) - P(A \cap B)$. Somando, $P(A \cup B) = P(A) + P(B) - P(A \cap B)$: a subtração existe porque a parte comum entrou duas vezes.
- 3. Inclusão-exclusão:** o padrão da fórmula de três eventos (somar os simples, tirar os pares, devolver o trio) se estende a n eventos alternando sinais.

Quando as interseções são difíceis de obter, abre-se mão da igualdade e fica-se com a desigualdade que sobra ao jogar fora os termos negativos da inclusão-exclusão:

$$P\left(\bigcup_i A_i\right) \leq \sum_i P(A_i)$$

Esse **limitante da união** (desigualdade de Boole) vale sempre, sem nenhuma hipótese sobre dependência entre os eventos. É uma estimativa grosseira, mas tem a enorme vantagem de não exigir que se saiba como os eventos se relacionam.

NA COMPUTAÇÃO O limitante da união em algoritmos e tabelas hash

Se um algoritmo randomizado executa n passos e cada passo pode falhar com chance no máximo ε , a chance de alguma falha é no máximo $n\varepsilon$, mesmo sem saber como as falhas se relacionam. É assim que se provam garantias "com alta probabilidade".

Ao dimensionar uma tabela hash com m posições e n chaves, cada um dos $\binom{n}{2}$ pares colide com chance $1/m$. Logo a chance de haver alguma colisão é no máximo $\binom{n}{2}/m$, e para mantê-la abaixo de 1% é preciso m da ordem de $50n^2$. A conta exata é o paradoxo do aniversário.

CUIDADO Números que não podem coexistir

Um relatório diz que um servidor tem $P(\text{falha de disco}) = 0.5$, $P(\text{falha de memória}) = 0.6$ e $P(\text{ambas}) = 0.05$. A regra da adição daria $P(A \cup B) = 1.05$, o que é impossível: algum número está errado. A forma mais comum de errar em probabilidade não é na conta, e sim em números que não podem coexistir. Antes de calcular, confira se os dados respeitam os axiomas. O exemplo abaixo usa exatamente essa ideia.

CONEXÕES

- 1.8 a conta exata das colisões de hash: paradoxo do aniversário.
- 7.4 a correção de Bonferroni para muitos intervalos é o limitante da união.
- 9.9 usar várias regras de alarme soma as taxas de alarme falso, pelo mesmo limitante.

▼ Entendendo a fórmula, termo a termo

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

$P(A) + P(B)$ ← Soma as duas regiões do diagrama de Venn, mas a interseção entra duas vezes.

$-P(A \cap B)$ ← Desconta a interseção uma vez, para que ela seja contada uma única vez.

Caso disjunto ← Se $A \cap B = \emptyset$, o termo some e vale o axioma 3: $P(A \cup B) = P(A) + P(B)$.

De onde vem, passo a passo

1. Escreva $A \cup B$ como união disjunta: $A \cup B = A \cup (B \cap A^c)$.
2. Pelo axioma 3: $P(A \cup B) = P(A) + P(B \cap A^c)$.
3. Também $B = (B \cap A) \cup (B \cap A^c)$, disjuntos, então $P(B \cap A^c) = P(B) - P(A \cap B)$.
4. Substituindo: $P(A \cup B) = P(A) + P(B) - P(A \cap B)$. O complementar sai do mesmo jeito: $A \cup A^c = \Omega$ dá $P(A) + P(A^c) = 1$.

EXEMPLO RESOLVIDO

Consistência de dados de falha de um servidor

O histórico de um servidor indica a chance de cada tipo de falha de hardware em um ano de operação.

DADOS

- A = falha de disco, $P(A) = 0.3$
- B = falha de memória, $P(B) = 0.2$
- $P(A \cup B) = 0.4$ (pelo menos uma das falhas)

O QUE SE PEDE

(a) $P(A \cap B)$; (b) probabilidade de nenhuma falha; (c) só falha de disco; (d) exatamente um tipo de falha.

RESOLUÇÃO PASSO A PASSO

1 Ambas as falhas: regra da adição

Ao somar $P(A) + P(B)$, os anos com as duas falhas são contados duas vezes. A regra da adição desconta essa sobreposição:

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Isolando a interseção:

$$P(A \cap B) = 0.3 + 0.2 - 0.4 = 0.1$$

2 Nenhuma falha: complemento

"Nenhuma falha" é o contrário de "pelo menos uma falha". Pela lei de De Morgan, $A^c \cap B^c = (A \cup B)^c$:

$$P(A^c \cap B^c) = 1 - P(A \cup B) = 1 - 0.4 = 0.6$$

3 Só disco: separar o evento em partes

Os anos com falha de disco se dividem em dois grupos sem sobreposição: com falha de memória ($A \cap B$) e sem ela ($A \cap B^c$). Logo:

$$P(A \cap B^c) = P(A) - P(A \cap B) = 0.3 - 0.1 = 0.2$$

Da mesma forma, só memória: $P(A^c \cap B) = 0.2 - 0.1 = 0.1$.

4 Exatamente um tipo

"Exatamente um" é "só disco" ou "só memória", que são disjuntos, então as probabilidades se somam:

$$0.2 + 0.1 = 0.3$$

5 Conferir: as quatro regiões somam 1

Ambas + só A + só B + nenhuma = $0.1 + 0.2 + 0.1 + 0.6 = 1 \checkmark$

RESPOSTA (a) 0.1; (b) 0.6; (c) 0.2; (d) 0.3.

Os axiomas também detectam dados errados. Se um painel de monitoramento disser $P(A) = 0.5$, $P(B) = 0.6$ e $P(A \cap B) = 0.05$, então $P(A \cup B) = 0.5 + 0.6 -$

$0.05 = 1.05 > 1$, o que é impossível. Algum dos números está errado (métrica duplicada, janela de tempo diferente etc.).

Exercício 1.2 • Regra da Adição

Em uma requisição a uma API, A = "timeout no banco de dados" e B = "erro de autenticação" têm $P(A) = 0.22$, $P(B) = 0.32$ e $P(A \cap B) = 0.1$. Qual a probabilidade de ocorrer pelo menos uma das falhas?

Espaço para cálculo

1.3 Probabilidade Condicional e Regra da Multiplicação

Probabilidades mudam quando aprendemos algo. A chance de uma requisição falhar é uma; a chance de ela falhar *sabendo que* o banco de dados está sob carga alta é outra. Saber que B ocorreu elimina todos os resultados fora de B : o novo universo é B , e dentro dele só a parte $A \cap B$ de A continua possível. Para que as probabilidades dentro do novo universo somem 1, divide-se por $P(B)$:

PROBABILIDADE CONDICIONAL E REGRA DO PRODUTO

$$P(A|B) = \frac{P(A \cap B)}{P(B)} \implies P(A \cap B) = P(B) \cdot P(A|B) = P(A) \cdot P(B|A)$$

▼ Equação desmontada, variável por variável

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

$P(A|B)$ ← o que se calcula: probabilidade de A **dado que** B ocorreu

A ← evento de interesse (ex.: commit com bug)

B ← condição conhecida (ex.: commit do desenvolvedor X)

$P(A \cap B)$ ← probabilidade de A e B juntos (ex.: $10/200 = 0.05$)

$P(B)$ ← probabilidade da condição (ex.: $50/200 = 0.25$); precisa ser > 0

$$P(A \cap B) = P(B) \cdot P(A|B)$$

$P(A \cap B)$ ← o que se calcula: chance dos dois juntos

$P(B)$ ← chance do primeiro evento

$P(A|B)$ ← chance do segundo, sabendo que o primeiro ocorreu

EXEMPLO Mesma célula, universos diferentes

De 200 commits, 50 são do desenvolvedor X; 20 introduziram bug, 10 deles de X.

- $P(\text{bug}|X) = 10/50 = 0.20$: entre os commits de X, a fração com bug.
- $P(X|\text{bug}) = 10/20 = 0.50$: entre os commits com bug, a fração de X.

O numerador é a mesma célula; o que muda é o universo em que se olha, isto é, o denominador.

Essa diferença entre $P(A|B)$ e $P(B|A)$ parece óbvia escrita assim, mas é a origem de alguns dos erros de raciocínio mais caros em segurança, medicina e direito: "95% dos ataques disparam o alarme" não quer dizer que 95% dos alarmes são ataques. O nome do erro é falácia da condicional transposta, e o Teorema de Bayes é a forma correta de ir de uma condicional para a outra.

Duas propriedades fazem da condicional uma ferramenta, e não só uma definição. Primeiro, $P(\cdot|B)$ é ela mesma uma probabilidade: satisfaz os três axiomas dentro de B , então complemento, adição e tudo o mais valem condicionados, como $P(A^c|B) = 1 - P(A|B)$. Segundo, lida ao contrário, a definição

vira a **regra do produto**, que monta probabilidades de eventos conjuntos por etapas. Repetida, ela dá a regra da cadeia:

$$P(A_1 \cap A_2 \cap \dots \cap A_n) = P(A_1) P(A_2|A_1) P(A_3|A_1 \cap A_2) \dots P(A_n|A_1 \cap \dots \cap A_{n-1})$$

Cada fator responde à pergunta "dado tudo o que já aconteceu, qual a chance do próximo passo?".

NA COMPUTAÇÃO A regra da cadeia em ação

- **Amostragem sem reposição:** a chance de sortear 3 arquivos íntegros de um lote com alguns corrompidos é um produto de condicionais, porque o lote muda a cada retirada. É a origem da hipergeométrica.
- **Modelos de linguagem:** a probabilidade de uma frase é o produto das probabilidades de cada palavra dado o prefixo.
- **Árvores de probabilidade:** cada caminho da raiz a uma folha é um produto desse tipo.

CUIDADO A definição exige $P(B) > 0$

Em variáveis contínuas, "dado que a latência foi 120 ms" condiciona a um evento de probabilidade zero, e a fórmula não se aplica; o conceito correto é a densidade condicional. Condicionar a um intervalo funciona normalmente: a falta de memória da exponencial, $P(T > s + t \mid T > s)$, é calculada exatamente com esta definição.

CONEXÕES

- 1.6** Bayes: a forma correta de ir de $P(B|A)$ para $P(A|B)$.
- 1.9** tabela de contingência: as duas condicionais lado a lado.
- 1.8** regra da cadeia sem reposição: hipergeométrica.
- 1.10** cada caminho da árvore é um produto de condicionais.
- 5.5** falta de memória da exponencial.

▼ Entendendo a fórmula, termo a termo

$$P(A|B) = \frac{P(A \cap B)}{P(B)}, \quad P(B) > 0$$

$P(A \cap B)$ ← A parte de A que está *dentro* de B : só ela continua possível depois de saber que B ocorreu.

$P(B)$ ← O novo "universo". Dividir por ele renormaliza para que $P(B|B) = 1$.

$P(B) > 0$ ← Não faz sentido condicionar a um evento impossível (divisão por zero).

De onde vem, passo a passo

1. Em N repetições, B ocorreu n_B vezes, e A e B juntos n_{AB} vezes.
2. Entre as vezes em que B ocorreu, a fração com A é n_{AB}/n_B .
3. Dividindo numerador e denominador por N : $\frac{n_{AB}/N}{n_B/N} \rightarrow \frac{P(A \cap B)}{P(B)}$.
4. Multiplicando os dois lados por $P(B)$ obtém-se a regra do produto: $P(A \cap B) = P(B) P(A|B)$.

EXEMPLO RESOLVIDO

Commits, bugs e a regra do produto

Um repositório recebeu 200 commits no mês. 50 vieram do desenvolvedor X e o resto de outros desenvolvedores. Dos 20 commits que introduziram bug, 10 são de X.

DADOS

- total: 200 commits
- do desenvolvedor X: 50
- com bug (D): 20, dos quais 10 de X

O QUE SE PEDE

(a) $P(D|X)$; (b) $P(X|D)$; (c) $P(X \cap D)$ pela regra do produto; (d) chance de, testando 3 de 10 chaves de API (2 delas revogadas), sem repetir, as 3 serem válidas.

RESOLUÇÃO PASSO A PASSO

1 Organizar os dados em tabela

	BUG (D)	SEM BUG	TOTAL
X	10	40	50
OUTROS	10	140	150
TOTAL	20	180	200

As células que não foram dadas saem por subtração ($50 - 10 = 40$, $20 - 10 = 10$, ...).

2 $P(D|X)$: restringir o universo a X

A barra "|" significa "sabendo que". Saber que o commit é de X troca o universo de 200 para os 50 commits de X:

$$P(D|X) = \frac{\#(D \cap X)}{\#X} = \frac{10}{50} = 0.20$$

Leitura: entre os commits de X, 20% introduzem bug.

3 $P(X|D)$: restringir o universo aos commits com bug

Agora a informação é "o commit tem bug", e o universo vira os 20 commits com bug:

$$P(X|D) = \frac{10}{20} = 0.50$$

Mesma célula (10) no numerador; o que muda é o **denominador**. São perguntas diferentes: "quão arriscados são os commits de X?" contra "quanto dos bugs vem de X?".

4 Regra do produto

Da definição $P(D|X) = P(X \cap D)/P(X)$ sai a regra do produto:

$$P(X \cap D) = P(X) P(D|X) = \frac{50}{200} \times 0.20 = 0.25 \times 0.20 = 0.05$$

Conferindo direto na tabela: $10/200 = 0.05$ ✓.

5 Encadeando condicionais (sem reposição)

10 chaves de API, 2 revogadas, logo 8 válidas. A cada chave testada (e descartada), o conjunto diminui, e a próxima probabilidade depende do que já saiu:

$$P(3 \text{ válidas}) = \underbrace{\frac{8}{10}}_{1^{\text{a}} \text{ válida}} \cdot \underbrace{\frac{7}{9}}_{2^{\text{a}} \text{ válida, dado } 1^{\text{a}} \text{ válida}} \cdot \underbrace{\frac{6}{8}}_{3^{\text{a}} \text{ válida, dadas } 2 \text{ válidas}} = \frac{336}{720} = 0.4667$$

RESPOSTA (a) 0.20; (b) 0.50; (c) 0.05; (d) 0.4667.

Ponte para 1.4: $P(D) = 20/200 = 0.10$, mas $P(D|X) = 0.20$. Saber o autor muda a chance de bug, então D e X *não* são independentes. Isso não prova que X programa pior: X pode trabalhar nos módulos mais difíceis (variável de confusão).

Exercício 1.3 • Regra do Produto sem Reposição

Uma pasta tem 20 arquivos de backup, dos quais 2 estão corrompidos. Um script de verificação sorteia 2 arquivos, um após o outro, sem repetir. Qual a probabilidade de ambos estarem corrompidos?

Espaço para cálculo

1.4 Independência Estatística

Às vezes a informação nova não muda nada: saber que o pacote 1 se perdeu não altera a chance de o pacote 2 se perder, se as perdas forem causadas por ruído aleatório no enlace. Nesse caso $P(A|B) = P(A)$, e a regra do produto se simplifica para a forma simétrica que serve de definição:

$$P(A \cap B) = P(A) \cdot P(B) \iff P(A|B) = P(A) \quad (\text{com } P(B) > 0)$$

▼ Equação desmontada, variável por variável

$$P(A \cap B) = P(A) \cdot P(B)$$

$P(A \cap B)$ ← chance de A e B juntos

$P(A)$ ← chance de A (ex.: réplica 1 cair = 0.1)

$P(B)$ ← chance de B (ex.: réplica 2 cair = 0.1)

$P(A) \cdot P(B)$ ← produto, só válido se A e B forem independentes (ex.: $0.1 \times 0.1 = 0.01$)

Atenção Conceitual Crítica: não confunda eventos *mutuamente exclusivos* ($A \cap B = \emptyset$) com eventos *independentes* ($P(A \cap B) = P(A)P(B)$). Se dois eventos têm probabilidade não nula e são mutuamente exclusivos, eles são **dependentes**: se um ocorre, o outro certamente não ocorre ($P(A|B) = 0 \neq P(A)$).

A independência é o que torna as contas tratáveis: em vez de uma cadeia de condicionais, multiplicam-se probabilidades simples. Foi ela que permitiu escrever $P(EEP) = 0.9 \times 0.9 \times 0.1$ no enlace de 1.1; é ela que transforma "número de perdas em n pacotes" na distribuição binomial; e está por trás de quase todos os resultados de estimação, porque "amostra aleatória" significa observações independentes e com a mesma distribuição, e é por isso que a variância da média cai como σ^2/n .

CAUIDADO Independentes aos pares não basta

Para mais de dois eventos, a definição exige que a regra do produto valha para *todos* os subconjuntos. Lance duas moedas e defina A = "1ª cara", B = "2ª cara", C = "as duas iguais". Cada par é independente, mas $P(A \cap B \cap C) = 1/4 \neq 1/8$, porque conhecer dois desses eventos determina o terceiro. É o mesmo fenômeno do XOR: três bits em que o terceiro é o XOR dos outros dois são independentes dois a dois, e é essa estrutura que um esquema de paridade como o RAID 5 explora para reconstruir um disco perdido.

O ponto mais importante na prática é que independência é uma *hipótese de modelagem*, e frequentemente falsa. A tabela separa os casos em que ela falha dos casos em que é garantida por projeto:

NA COMPUTAÇÃO Quando a hipótese falha e quando é construída

Falsa: falhas de causa comum	Garantida por projeto
Réplicas no mesmo datacenter caem juntas numa falta de energia.	Um algoritmo de Monte Carlo que erra com chance ε , repetido k vezes com sementes independentes, erra em todas com chance ε^k .
O mesmo deploy com o mesmo bug derruba todas as instâncias.	O teste de Miller-Rabin com k rodadas declara primo um composto com chance no máximo 4^{-k} .
Requisições do mesmo usuário são correlacionadas.	Hashing universal sorteia funções que se comportam como independentes.

Na coluna da esquerda, a conta com produtos subestima o risco em ordens de grandeza, como mostra o exemplo abaixo. Na da direita, a conta é confiável porque a independência foi construída.

Com dados, a independência se verifica comparando $P(A|B)$ com $P(A)$, ou $P(A \cap B)$ com $P(A)P(B)$. Diferenças pequenas podem ser acaso; decidir se a diferença observada é grande demais para isso é o papel do teste qui-quadrado.

CONEXÕES

- 1.7** confiabilidade em paralelo depende de falhas independentes.
- 3.2** binomial: sucessos em ensaios independentes.
- 7.2** erro padrão $\sigma/\sqrt{n}$.
- 8.5** teste qui-quadrado de independência.

▼ Entendendo a fórmula, termo a termo

$$P(A \cap B) = P(A) P(B)$$

$P(A \cap B)$ ← Probabilidade de os dois eventos ocorrerem juntos.

$P(A) P(B)$ ← O produto só vale quando saber de um não muda a chance do outro.

Equivalente ← $P(A|B) = P(A)$ e $P(B|A) = P(B)$.

De onde vem, passo a passo

1. Definição intuitiva: A é independente de B se $P(A|B) = P(A)$.
2. Pela definição de condicional: $\frac{P(A \cap B)}{P(B)} = P(A)$.
3. Multiplicando por $P(B)$: $P(A \cap B) = P(A)P(B)$. A forma do produto é simétrica, então também vale $P(B|A) = P(B)$.
4. Para três ou mais eventos, a igualdade do produto deve valer para **todos** os subconjuntos (pares, trios, ...): é a independência mútua.

EXEMPLO RESOLVIDO

O perigo de supor independência entre réplicas

Um serviço roda em duas réplicas redundantes: ele só sai do ar se as duas caírem na mesma janela de manutenção.

DADOS

- A = réplica 1 cai, $P(A) = 0.1$
- B = réplica 2 cai, $P(B) = 0.1$
- cenário 2: as réplicas estão na mesma zona de disponibilidade (mesma energia e rede), e $P(B|A) = 0.6$

O QUE SE PEDE

Probabilidade de o serviço sair do ar, $P(A \cap B)$, nos dois cenários.

RESOLUÇÃO PASSO A PASSO

1 Cenário 1: independência

Independência significa que a queda de uma réplica não muda a chance da outra: $P(B|A) = P(B)$. A regra do produto vira o produto simples:

$$P(A \cap B) = P(A) P(B) = 0.1 \times 0.1 = 0.01$$

Disponibilidade do serviço: $1 - 0.01 = 0.99$.

2 Cenário 2: causa comum

Na mesma zona, uma falha de energia ou de rede derruba as duas. Saber que a réplica 1 caiu torna a queda da 2 muito mais provável. Use a regra do produto *geral*:

$$P(A \cap B) = P(A) P(B|A) = 0.1 \times 0.6 = 0.06$$

Disponibilidade do serviço: $1 - 0.06 = 0.94$.

3 Comparar

$0.06/0.01 = 6$: o risco real é **6 vezes** o calculado supondo independência.

Teste formal: $P(B|A) = 0.6 \neq P(B) = 0.1$, logo A e B são dependentes.

RESPOSTA Independentes: 0.01. Com causa comum: 0.06.

Lição de arquitetura: redundância só protege se as falhas forem realmente independentes. Mesma zona, mesmo deploy com o mesmo bug, mesmo provedor de DNS: tudo isso cria *falhas de causa comum*. Espalhar réplicas por zonas e regiões é o que torna a independência plausível. **Não confunda** independentes com mutuamente exclusivos: eventos exclusivos com probabilidade positiva são sempre dependentes, porque se um ocorre o outro fica impossível.

Exercício 1.4 • Teste de Independência

Em um serviço web, A = "requisição lenta (acima de 1 s)" e B = "requisição vinda de celular". Registros indicam $P(A) = 0.6$, $P(B) = 0.6$ e $P(A \cap B) = 0.32$. Os eventos são independentes?

Espaço para cálculo

- ☐ Não é possível concluir sem $P(A \cup B)$.
- ☐ Sim, pois $P(A \cap B) > 0$.
- ☐ Não, pois $P(A \cap B) \neq P(A)P(B)$.
- ☐ Não, pois são mutuamente exclusivos.

1.5 Teorema da Probabilidade Total

Muitas probabilidades são difíceis de obter diretamente, mas ficam fáceis se soubermos em que "cenário" estamos. A taxa de erro de uma requisição qualquer é difícil de dizer; a taxa de erro de uma requisição que foi para o servidor A, não. A estratégia é dividir Ω numa **partição** de cenários $\{A_1, A_2, \dots, A_k\}$, mutuamente exclusivos e que juntos cobrem tudo ($\bigcup A_i = \Omega$, $A_i \cap A_j = \emptyset$ para $i \neq j$), resolver cada cenário e juntar:

TEOREMA DA PROBABILIDADE TOTAL

$$P(B) = \sum_{i=1}^k P(A_i \cap B) = \sum_{i=1}^k P(A_i) \cdot P(B|A_i)$$

▼ Equação desmontada, variável por variável

$$P(B) = \sum_{i=1}^k P(A_i) \cdot P(B|A_i)$$

$P(B)$ ← o que se calcula: chance total de B (ex.: requisição com erro)

A_i ← cada origem possível (ex.: servidor i); juntas cobrem todos os casos

k ← número de origens (ex.: 3 servidores)

$P(A_i)$ ← peso da origem i (ex.: servidor 1 recebe 50% = 0.5)

$P(B|A_i)$ ← taxa de B dentro da origem i (ex.: 2% de erro no servidor 1)

$P(A_i) \cdot P(B|A_i)$ ← contribuição da origem i (ex.: $0.5 \times 0.02 = 0.01$)

$\sum_{i=1}^k$ ← soma das contribuições de todas as origens

O teorema é só o axioma 3 combinado com a regra do produto: os pedaços $B \cap A_i$ não se sobrepõem e juntos formam B , e cada pedaço vale $P(A_i)P(B|A_i)$. A leitura que importa é outra: $P(B)$ é uma **média ponderada** das probabilidades condicionais, com pesos iguais à chance de cada cenário.

EXEMPLO Taxa de erro atrás de um balanceador

Servidor	Fração do tráfego	Taxa de erro	Contribuição
A	0.60	1%	0.0060
B	0.25	3%	0.0075
C	0.15	6%	0.0090
Taxa global			0.0225

A taxa global é 2.25%, e não a média simples de 3.33%: o servidor pior pesa pouco porque recebe pouco tráfego. Mudar os pesos, isto é, a política de balanceamento, muda a taxa global sem mexer em nenhum servidor.

Essa ideia, condicionar no cenário e fazer a média, é uma das técnicas mais gerais da probabilidade. Aplicada a valores esperados em vez de probabilidades, ela vira a lei da esperança total, $E[X] =$

$$\sum_i P(A_i) E[X|A_i].$$

NA COMPUTAÇÃO **Análise do quicksort randomizado**

O número esperado de comparações do quicksort randomizado é obtido condicionando na posição do pivô: cada uma das n posições tem chance $1/n$, e em cada caso o problema se divide em dois subproblemas de tamanhos conhecidos. A média ponderada desses casos dá uma recorrência cuja solução é $\approx 1.39 n \log_2 n$.

CUIDADO **A partição precisa ser partição**

Um quarto servidor esquecido, ou requisições contadas em dois servidores (por um retry que mudou de destino), fazem a soma sair errada. A verificação mínima é conferir que $\sum P(A_i) = 1$.

CONEXÕES

- 1.6** o denominador de Bayes é exatamente este $P(B)$.
- 2.4** a esperança é a mesma média ponderada, agora de valores.
- 6.6** média de dados agrupados em classes.
- 9.7** a variância total se decompõe por cenários.

▼ Entendendo a fórmula, termo a termo

$$P(B) = \sum_{i=1}^k P(A_i) P(B|A_i)$$

$A_1, \dots, A_k$ ← Partição: eventos disjuntos que cobrem Ω (as possíveis "origens").

$P(A_i)$ ← Peso de cada origem (participação na produção, por exemplo).

$P(B|A_i)$ ← Taxa de B dentro de cada origem.

$\sum$ ← Média ponderada das taxas, com pesos $P(A_i)$.

De onde vem, passo a passo

1. Como os A_i cobrem Ω : $B = (B \cap A_1) \cup \dots \cup (B \cap A_k)$.
2. Os pedaços são disjuntos porque os A_i são. Pelo axioma 3: $P(B) = \sum P(B \cap A_i)$.
3. Regra do produto em cada termo: $P(B \cap A_i) = P(A_i)P(B|A_i)$.

EXEMPLO RESOLVIDO

Taxa de erro atrás de um balanceador de carga

Um balanceador distribui as requisições entre três servidores com versões e hardware diferentes. Uma requisição é escolhida ao acaso nos logs.

DADOS

- fração do tráfego: $P(A) = 0.60$, $P(B) = 0.25$, $P(C) = 0.15$
- taxa de erro de cada servidor: $P(D|A) = 0.01$, $P(D|B) = 0.03$, $P(D|C) = 0.06$

O QUE SE PEDE

(a) $P(D)$, a taxa global de erro; (b) que fração dos erros vem de cada servidor.

RESOLUÇÃO PASSO A PASSO

1

Verificar a partição

O Teorema da Probabilidade Total exige que as "causas" não se sobreponham e cubram tudo. Cada requisição vai para exatamente um servidor, e $0.60 + 0.25 + 0.15 = 1$ ✓.

2 Calcular cada caminho

Cada termo é "chance de ir para o servidor" $\times$ "chance de erro, indo para ele" (regra do produto):

- A: $0.60 \times 0.01 = 0.0060$
- B: $0.25 \times 0.03 = 0.0075$
- C: $0.15 \times 0.06 = 0.0090$

3 Somar os caminhos

$$P(D) = \sum_i P(S_i) P(D|S_i) = 0.0060 + 0.0075 + 0.0090 = 0.0225$$

2.25% das requisições falham.

4 Quem gera os erros

Dividindo cada caminho pelo total (é o Teorema de Bayes, seção 1.6):

- A: $0.0060/0.0225 = 26.7\%$
- B: $0.0075/0.0225 = 33.3\%$
- C: $0.0090/0.0225 = 40.0\%$

RESPOSTA $P(D) = 0.0225$. O servidor C, com só 15% do tráfego, gera 40% dos erros.

Intuição: $P(D)$ é uma *média ponderada* das taxas, com pesos iguais às frações de tráfego. A média simples $(1 + 3 + 6)/3 = 3.33\%$ superestima o resultado, porque o pior servidor recebe pouco. Mandar mais tráfego para C (por exemplo, numa troca de pesos do balanceador) pioraria a taxa global mesmo sem mudar nenhum servidor.

Exercício 1.5 • Teorema da Probabilidade Total

Um balanceador de carga envia 20%, 60% e 20% das requisições a três servidores, com taxas de erro de 2%, 1.5% e 1.5%. Uma requisição é sorteada dos logs. Qual a probabilidade de ela ter falhado?

Espaço para cálculo

1.6 Teorema de Bayes e Atualização de Crenças

Em diagnóstico, o conhecimento disponível costuma estar na direção errada. Sabemos como cada causa produz efeitos (um ataque dispara o detector com probabilidade 0.95; uma conexão normal dispara com 0.05), mas, ao ver um alarme, queremos a direção inversa: dado o efeito, qual a causa? O Teorema de Bayes faz essa inversão juntando as duas peças anteriores, a regra do produto no numerador e a probabilidade total no denominador:

TEOREMA DE BAYES

$$P(A_j|B) = \frac{P(A_j \cap B)}{P(B)} = \frac{P(A_j) \cdot P(B|A_j)}{\sum_{i=1}^k P(A_i) \cdot P(B|A_i)}$$

▼ Equação desmontada, variável por variável

$$P(A_j|B) = \frac{P(A_j) \cdot P(B|A_j)}{\sum_i P(A_i) \cdot P(B|A_i)}$$

$P(A_j B)$	← o que se calcula: chance de a origem ser A_j depois de observar B (a posteriori)
A_j	← a origem que se quer avaliar (ex.: servidor 3)
$P(A_j)$	← chance da origem antes de observar B (a priori)
$P(B A_j)$	← chance de observar B se a origem for A_j
numerador	← contribuição da origem A_j
denominador	← $P(B)$: soma das contribuições de todas as origens (probabilidade total)

Os termos têm nomes porque cada um tem um papel. $P(A_j)$ é a *priori*, a crença antes da evidência; $P(B|A_j)$ é a *verossimilhança*, quão compatível a evidência é com cada causa; $P(A_j|B)$ é a *posteriori*. O denominador não depende de j e só normaliza, então a essência é: $\text{posteriori} \propto \text{priori} \times \text{verossimilhança}$. Uma evidência forte não basta se a causa é rara.

EXEMPLO Detector de intrusão em frequências naturais

Com 1% de conexões maliciosas, entre 10 000 conexões:

- 100 ataques geram 95 alarmes verdadeiros;
- 9 900 conexões normais geram 495 alarmes falsos;
- $P(\text{ataque}|\text{alarme}) = 95/590 = 16\%$.

O detector é bom; o problema é a **taxa-base** baixa, que faz os 5% de falsos positivos agirem sobre uma população 99 vezes maior.

Equipes de segurança chamam o resultado de fadiga de alertas, e a mesma conta explica por que um classificador com 99% de acurácia pode ser inútil num problema desbalanceado. No Módulo 8, os 5% de falso alarme recebem o nome de α e os 95% de detecção, de poder; a pergunta de Bayes ("dado que o teste acusou, qual a chance de ser real?") é a mesma que se faz sobre resultados "significativos" quando se testam muitas hipóteses.

DEDUÇÃO Forma de chances: encadear evidências

Dividindo Bayes para A e para A^c , o denominador some:

$$\frac{P(A|B)}{P(A^c|B)} = \frac{P(A)}{P(A^c)} \cdot \frac{P(B|A)}{P(B|A^c)}$$

1. Priori 1:99 e razão de verossimilhança $0.95/0.05 = 19$: posteriori 19:99, ou $19/118 = 16\%$.
2. Um segundo detector, independente do primeiro dado o estado real, também dispara: multiplica-se de novo por 19, chegando a 361:99, ou 78%.

A posteriori de uma etapa vira a priori da seguinte, e é por isso que confirmar um alerta com uma fonte independente vale tanto.

NA COMPUTAÇÃO Filtro de spam Naive Bayes

Para um e-mail com palavras $w_1, \dots, w_n$, compara-se $P(\text{spam}) \prod_i P(w_i|\text{spam})$ com o mesmo produto para "não spam", supondo as palavras condicionalmente independentes dada a classe. A hipótese é falsa (palavras aparecem em grupos), mas a *ordenação* entre as duas classes costuma sair certa mesmo com probabilidades mal calibradas. Na implementação, somam-se logaritmos, porque o produto de centenas de números pequenos estoura para zero em ponto flutuante.

CONEXÕES

- 1.10** atualização sequencial numa árvore.
- 8.2** α , poder e a fração de resultados significativos falsos.
- 8.3** p-valor é $P(\text{dados}|H_0)$, não $P(H_0|\text{dados})$.
- 7.5** encolhimento usa a média geral como priori.

▼ Entendendo a fórmula, termo a termo

$$P(A_j|B) = \frac{P(A_j) P(B|A_j)}{\sum_i P(A_i) P(B|A_i)}$$

$P(A_j)$ ← **A priori**: chance da causa A_j antes de observar qualquer coisa.

$P(B|A_j)$ ← **Verossimilhança**: quão provável é o efeito observado se a causa for A_j .

Numerador ← $P(A_j \cap B)$: o "caminho" da árvore que passa por A_j e termina em B .

Denominador ← $P(B)$ pela probabilidade total: soma de todos os caminhos que terminam em B .

$P(A_j|B)$ ← **A posteriori**: chance atualizada da causa depois de observar B .

De onde vem, passo a passo

1. Definição de condicional, invertendo os papéis: $P(A_j|B) = \frac{P(A_j \cap B)}{P(B)}$.
2. Numerador pela regra do produto "na outra ordem": $P(A_j \cap B) = P(A_j)P(B|A_j)$.
3. Denominador pela probabilidade total (1.5).
4. Resultado: inverte-se o condicionamento, de "efeito dada a causa" (que se conhece dos ensaios) para "causa dado o efeito" (que se quer saber).

EXEMPLO RESOLVIDO

Detector de intrusão e frequências naturais

Um sistema de detecção de intrusão (IDS) analisa conexões de rede. Uma conexão disparou o alarme. Qual a chance de ela ser realmente um ataque?

DADOS

- priori (prevalência de ataques): $P(D) = 0.01$
- sensibilidade: $P(+|D) = 0.95$
- falso alarme: $P(+|D^c) = 0.05$

O QUE SE PEDE

(a) $P(D|+)$; (b) o mesmo se 10% das conexões fossem ataques; (c) $P(D|+)$ após um segundo detector, independente, também alarmar.

RESOLUÇÃO PASSO A PASSO

1 Imaginar 10 000 conexões

Trocar probabilidades por contagens deixa o raciocínio visível:

- ataques: $10\,000 \times 0.01 = 100$, dos quais $100 \times 0.95 = 95$ disparam o alarme;
- normais: 9 900, das quais $9\,900 \times 0.05 = 495$ disparam o alarme (falso positivo).

2 Restringir aos alarmes

Sabemos que houve alarme, então o universo vira os $95 + 495 = 590$ alarmes:

$$P(D|+) = \frac{95}{590} = 0.161$$

3 Mesma conta pela fórmula de Bayes

$$P(D|+) = \frac{P(+|D) P(D)}{P(+|D) P(D) + P(+|D^c) P(D^c)} = \frac{0.95 \times 0.01}{0.95 \times 0.01 + 0.05 \times 0.99} = \frac{0.0095}{0.059}$$

O numerador é o caminho "ataque e alarme"; o denominador é $P(+)$, a soma de todos os caminhos que dão alarme.

4 Mudando a priori para 10%

Em 10 000 conexões: 1000 ataques, 950 alarmes verdadeiros; 9000 normais, 450 alarmes falsos.

$$P(D|+) = \frac{950}{950 + 450} = 0.679$$

5 Segundo detector: a posteriori vira a nova priori

Depois do 1º alarme, a chance de ataque é 0.161. Ela entra como priori no 2º detector:

$$P(D|++) = \frac{0.95 \times 0.161}{0.95 \times 0.161 + 0.05 \times 0.839} = \frac{0.1530}{0.1949} = 0.785$$

RESPOSTA (a) 0.161; (b) 0.679; (c) 0.785.

Só 16% dos alarmes são ataques reais, mesmo com 95% de sensibilidade, porque as conexões normais são muito mais numerosas. É a origem da "fadiga de alertas" em

centros de operação de segurança. **O resultado depende fortemente da priori**, e correlacionar com um segundo sinal independente é a forma prática de resolver isso.

Exercício 1.6 • Teorema de Bayes na Detecção de Malware

Um antivírus analisa os arquivos enviados a um servidor. 3% dos arquivos contêm malware. O antivírus detecta 98% dos arquivos maliciosos e dá falso alarme em 5% dos limpos. Dado que ele acusou malware, qual a probabilidade $P(T|+)$ de o arquivo ser realmente malicioso?

Espaço para cálculo

1.7 Confiabilidade e Disponibilidade de Sistemas Computacionais

Confiabilidade é a primeira aplicação em que todas as regras anteriores trabalham juntas. Seja R_i a probabilidade de o componente i funcionar durante o período considerado (ou sua disponibilidade, a fração do tempo em que está no ar). A estrutura do sistema traduz-se diretamente em operações com eventos: "funciona se todos funcionam" é uma interseção; "funciona se algum funciona" é uma união, calculada pelo complemento.

- **Sistema em Série:** funciona só se *todos* funcionarem (ex.: requisição que passa por gateway, autenticação e banco de dados). Com independência:

$$R_{\text{série}} = \prod_{i=1}^n R_i$$

- **Sistema em Paralelo (redundância ativa):** funciona se *pelo menos um* funcionar (ex.: réplicas atrás de um balanceador). Com independência:

$$R_{\text{paralelo}} = 1 - \prod_{i=1}^n (1 - R_i)$$

- **Diagnóstico com Bayes:** monitores de saúde (health checks) e alertas têm falsos positivos e falsos negativos; Bayes dá a chance real de o serviço estar fora do ar dado que o alerta disparou.

As duas fórmulas puxam em sentidos opostos. Em série, cada componente só pode piorar o total, porque o produto de números menores que 1 diminui. Em paralelo, o que se multiplica são as *falhas*, e o total melhora muito rápido.

EXEMPLO Série contra paralelo, em números

	Série	Paralelo
Sistema	10 microsserviços de 99.9% em cadeia	2 réplicas de 99%
Conta	$0.999^{10} \approx 99.0\%$	$1 - 0.01^2 = 99.99\%$
Efeito	"três noves" (8.8 h fora por ano) viram dois (3.65 dias)	dois noves viram quatro com uma máquina extra

É o argumento quantitativo contra arquiteturas com muitas dependências síncronas, e a razão de padrões como timeouts, filas e degradação graciosa, que tornam uma dependência em série mais tolerante.

DEDUÇÃO Onde colocar a redundância

Três estágios de 0.95 em série, com o mesmo número de máquinas extras:

- duplicar cada estágio: $(1 - 0.05^2)^3 = 0.9925$;
- duplicar a cadeia inteira: $1 - (1 - 0.95^3)^2 = 0.9797$.

Redundância por componente rende mais porque, nesse arranjo, uma falha no estágio 1 de uma cópia pode ser compensada pelo estágio 1 da outra, independentemente do que acontece no estágio 2.

Muitos sistemas reais não são nem série nem paralelo puros, e sim "*k* de *n*". Um cluster com consenso (Raft, Paxos) e 5 réplicas segue operando se pelo menos 3 estiverem vivas; um código de apagamento que divide um arquivo em 10 fragmentos de dados e 4 de paridade sobrevive se 10 dos 14 fragmentos sobreviverem. A probabilidade de "pelo menos *k* de *n*" é uma soma de termos binomiais. E quando a confiabilidade depende do tempo de missão, R_i deixa de ser um número e vira uma função $R(t) = P(T > t)$, cuja forma mais comum é a exponencial, $e^{-\lambda t}$.

CUIDADO Tudo depende da independência

Réplicas na mesma zona de disponibilidade, a mesma versão de software, a mesma dependência externa ou o mesmo certificado expirando criam falhas de causa comum, e então R_{paralelo} é otimista demais. Espalhar réplicas por zonas e regiões, e fazer deploys graduais em vez de simultâneos, são formas de engenharia de tornar a hipótese de independência mais próxima da verdade.

CONEXÕES

- 1.4 falhas de causa comum.
- 3.2 "pelo menos k de n " com a binomial.
- 5.4 confiabilidade exponencial $R(t) = e^{-\lambda t}$.
- 5.9 série e paralelo com componentes exponenciais.

▼ Entendendo a fórmula, termo a termo

$$R_{série} = \prod_{i=1}^n R_i, \quad R_{paralelo} = 1 - \prod_{i=1}^n (1 - R_i)$$

R_i ← Probabilidade de o componente i funcionar.

$1 - R_i$ ← Probabilidade de o componente i falhar.

$\prod$ ← Produto: vem da independência entre componentes.

$1 - \prod(1 - R_i)$ ← Complemento de "todos falham".

De onde vem, passo a passo

1. Série funciona $\iff$ todos funcionam: evento $\bigcap_i \{i \text{ funciona}\}$. Com independência, a probabilidade é o produto dos R_i .
2. Paralelo falha $\iff$ todos falham: $P = \prod(1 - R_i)$.
3. Paralelo funciona é o complemento: $R_{par} = 1 - \prod(1 - R_i)$.
4. Sistemas mistos: reduza blocos internos a um R equivalente e repita.

EXEMPLO RESOLVIDO

Por que pipelines longos precisam de redundância

Uma requisição atravessa 3 microsserviços em série (gateway, autenticação, banco de dados): se qualquer um estiver fora, a requisição falha. Cada serviço está disponível com probabilidade 0.95, independentemente dos outros.

DADOS

- $R = 0.95$ por serviço
- 3 serviços em série
- opção 1: duas réplicas de cada serviço (2 em paralelo por etapa)

- opção 2: duplicar o pipeline inteiro (2 pipelines em paralelo)

O QUE SE PEDE

Disponibilidade do pipeline original e das duas opções de redundância.

RESOLUÇÃO PASSO A PASSO

1 Série: multiplicar disponibilidades

A requisição só funciona se os 3 serviços funcionarem (evento "e"), e a independência permite multiplicar:

$$R_{sis} = R^3 = 0.95^3 = 0.857$$

Cada serviço parece ótimo (95%), mas o pipeline falha em 14% do tempo.

2 Paralelo: multiplicar as falhas

Uma etapa com duas réplicas só falha se as duas estiverem fora:

$$R_{etapa} = 1 - (1 - R)^2 = 1 - 0.05^2 = 0.9975$$

3 Opção 1: três etapas replicadas em série

$$R_{sis} = 0.9975^3 = 0.9925$$

4 Opção 2: dois pipelines inteiros em paralelo

Cada pipeline vale 0.857; o sistema falha só se os dois pipelines falharem:

$$R_{sis} = 1 - (1 - 0.857)^2 = 1 - 0.1426^2 = 0.9797$$

5 Escala do problema

Uma aplicação que depende de 10 serviços em série, cada um com $R = 0.99$: $R_{sis} = 0.99^{10} = 0.904$. Quase 10% de indisponibilidade.

RESPOSTA

Original: 0.857. Réplicas por serviço: 0.9925. Pipeline duplicado: 0.9797.

Intuição: em série a disponibilidade é o produto e cai a cada dependência acrescentada; em paralelo é a *indisponibilidade* que vira produto e cai rápido. Com o mesmo número de máquinas extras, replicar **cada serviço** rende mais que duplicar o pipeline inteiro, porque uma réplica de autenticação pode atender o gateway de qualquer lado.

Exercício 1.7 • Disponibilidade Série-Paralelo

Duas réplicas independentes de um servidor web em paralelo ($R_1 = 0.8$, $R_2 = 0.87$) estão em série com um banco de dados ($R_V = 0.97$). Qual a disponibilidade do sistema?

Espaço para cálculo

1.8 Técnicas de Contagem para Espaços Equiprováveis

Quando todos os resultados de Ω são igualmente prováveis, vale a **definição clássica** $P(A) = \frac{\#A}{\#\Omega}$. Ela não é um axioma novo: se N resultados disjuntos têm a mesma probabilidade q e somam 1 (axiomas 2 e 3), então $q = 1/N$, e um evento com $\#A$ resultados vale $\#A/N$. A condição de equiprobabilidade é a parte que costuma ser esquecida. Quando ela vale, como em sorteios feitos por um gerador uniforme, em chaves criptográficas ou em hashes bem distribuídos, o problema de probabilidade vira um problema de contagem:

PRINCÍPIO MULTIPLICATIVO, ARRANJOS E COMBINAÇÕES

Etapas sucessivas: $n_1 \cdot n_2 \cdots n_k$ maneiras

$$A_{n,k} = \frac{n!}{(n-k)!} \text{ (a ordem importa),} \quad \binom{n}{k} = \frac{n!}{k!(n-k)!} \text{ (a ordem não importa)}$$

▼ Equação desmontada, variável por variável

$$n_1 \cdot n_2 \cdots n_k$$

n_1 ← opções da 1ª etapa (ex.: 3 tamanhos de instância)

n_2 ← opções da 2ª etapa (ex.: 4 regiões de nuvem)

k ← número de etapas

$\cdot$ ← multiplica: cada opção de uma etapa combina com todas da outra (ex.: $3 \times 4 = 12$)

$$A_{n,k} = \frac{n!}{(n-k)!}$$

$A_{n,k}$ ← o que se calcula: seleções em que a **ordem importa**

n ← total de itens disponíveis (ex.: 10 dígitos)

k ← itens escolhidos (ex.: 4)

$n!$ ← $n \times (n-1) \times \cdots \times 1$ (ex.: $10! = 3\,628\,800$)

$(n-k)!$ ← ordenações dos não escolhidos, que são descontadas

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

$\binom{n}{k}$ ← o que se calcula: grupos em que a **ordem não importa** (lê-se "n escolhe k")

$k!$ ← ordenações dos escolhidos, descontadas porque a ordem não importa

ex. ← $\binom{8}{3} = \frac{8!}{3!5!} = 56$

As fórmulas respondem a duas perguntas sobre o sorteio de k elementos de n : a ordem distingue resultados? Pode repetir? Com ordem e sem repetição, o primeiro tem n opções, o segundo $n-1$, e as-

sim por diante, o que dá o arranjo. Sem ordem, cada grupo foi contado $k!$ vezes (uma por ordenação), e dividir por $k!$ dá a combinação. Errar a escolha entre os casos é o erro de contagem mais comum:

INTUIÇÃO Os quatro modos de sortear k de n

	Com repetição	Sem repetição
A ordem importa	n^k : senhas de k caracteres	$\frac{n!}{(n-k)!}$: pódio, PIN de dígitos distintos
A ordem não importa	$\binom{n+k-1}{k}$: k requisições idênticas em n servidores	$\binom{n}{k}$: escolher revisores ou features

Contagem mede o tamanho de espaços de busca, e por isso aparece em segurança e em complexidade de algoritmos. O crescimento exponencial que protege uma senha é o mesmo que condena um algoritmo de força bruta.

NA COMPUTAÇÃO Senhas e complexidade

- **Senhas:** 8 caracteres de 62 símbolos (a–z, A–Z, 0–9) dão $62^8 \approx 2.18 \times 10^{14}$ possibilidades, ou $\log_2(62^8) \approx 47.6$ bits de entropia. A 10^{10} tentativas por segundo, a busca exaustiva leva cerca de 6 horas; com 12 caracteres, cerca de 10 mil anos.
- **Força bruta:** há 2^n subconjuntos e $n!$ permutações de n elementos, o que inviabiliza enumerar soluções de problemas como o caixeiro-viajante.
- **Pares:** $\binom{n}{2} = n(n-1)/2$ é de onde vem o custo $O(n^2)$ de comparar todos contra todos.

Uma conta clássica junta contagem com a regra da cadeia: o **paradoxo do aniversário**. Com n chaves espalhadas uniformemente em m posições, a chance de *nenhuma* colisão é o produto das chances de cada nova chave cair numa posição livre:

$$\frac{m}{m} \cdot \frac{m-1}{m} \cdots \frac{m-n+1}{m} = \frac{m!}{(m-n)!m^n} \approx e^{-n(n-1)/(2m)}$$

A aproximação usa $1-x \approx e^{-x}$, a mesma que levará da binomial à Poisson. Com 23 pessoas e 365 dias, a chance de colisão já passa de 50%, porque o que cresce não é o número de pessoas e sim o de pares, $\binom{23}{2} = 253$.

NA COMPUTAÇÃO Colisões de hash

Para um hash de b bits ($m = 2^b$), colisões ficam prováveis com cerca de $2^{b/2}$ itens. Por isso um hash de 128 bits dá só 64 bits de resistência a colisões, e funções criptográficas modernas usam 256 bits.

Quando se sorteia *sem reposição* de um conjunto com itens de dois tipos, a contagem produz uma distribuição com nome próprio. **Amostragem sem reposição (hipergeométrica):** um conjunto tem N itens, D deles "marcados" (arquivos corrompidos, chaves revogadas, testes que falham). Sorteando n sem reposição, a probabilidade de exatamente k marcados é

$$P(X = k) = \frac{\binom{D}{k} \binom{N-D}{n-k}}{\binom{N}{n}}$$

Ex.: $N = 20$ arquivos, $D = 4$ corrompidos, auditoria de $n = 3$, $k = 1$: $P = \frac{4 \times 120}{1140} = 0.4211$. Cada retirada altera o que sobrou, então as retiradas *não* são independentes. Para conjuntos grandes ($n/N < 0.05$) a binomial com $p = D/N$ é boa aproximação.

DEDUÇÃO Hipergeométrica contra binomial

	Hipergeométrica (sem reposição)	Binomial (com reposição)
Média	np , com $p = D/N$	np
Variância	$np(1-p) \cdot \frac{N-n}{N-1}$	$np(1-p)$

Sem reposição, cada item marcado retirado torna o próximo menos provável, e isso puxa os resultados para perto da média: a variância é menor. O mesmo fator de correção aparece no erro padrão de uma média amostrada de população finita: auditar 100% do lote tem erro zero.

CONEXÕES

- 1.3** regra da cadeia, usada no paradoxo do aniversário.
- 3.2** binomial, a versão com reposição.
- 3.4** $1 - x \approx e^{-x}$ leva da binomial à Poisson.
- 7.2** correção de população finita no erro padrão.

▼ Entendendo a fórmula, termo a termo

$$\binom{n}{k} = \frac{n!}{k!(n-k)!}$$

 $n!$ ← Todas as ordenações possíveis dos n itens. $(n-k)!$ ← Ordenações dos itens *não* escolhidos: irrelevantes, então dividimos. $k!$

← Ordenações dos itens escolhidos: em uma combinação a ordem não importa, então dividimos de novo.

De onde vem, passo a passo

1. Escolher k itens em ordem: n opções para o 1º, $n-1$ para o 2º, ..., $n-k+1$ para o k -ésimo (princípio multiplicativo).
2. Esse produto é $A_{n,k} = \frac{n!}{(n-k)!}$.
3. Cada grupo de k itens aparece $k!$ vezes nessa contagem (uma para cada ordem). Dividindo: $\binom{n}{k} = \frac{A_{n,k}}{k!}$.
4. Na hipergeométrica, $\binom{D}{k} \binom{N-D}{n-k}$ conta as amostras favoráveis (escolhas independentes de itens marcados e não marcados) e $\binom{N}{n}$ todas as amostras.

EXEMPLO RESOLVIDO PINs e revisores de código

Dois problemas de contagem: um PIN de acesso e a escolha de revisores para um pull request.

DADOS

- PIN: 4 dígitos distintos, escolhidos de 0 a 9
- revisão: 3 revisores escolhidos ao acaso entre 8 desenvolvedores, incluindo Ana e Bruno

O QUE SE PEDE

- (a) quantos PINs; (b) quantos trios de revisores; (c) chance de Ana e Bruno estarem juntos; (d) chance de pelo menos um dos dois estar.

RESOLUÇÃO PASSO A PASSO

1 A ordem importa? (PIN)

No PIN, 1234 e 4321 são códigos diferentes: **ordem importa**, é arranjo. Há 10 opções para o 1º dígito, 9 para o 2º (sem repetir), 8 e 7:

$$A_{10,4} = \frac{10!}{(10-4)!} = 10 \cdot 9 \cdot 8 \cdot 7 = 5040$$

Um chute acerta com probabilidade $1/5040$. Por isso sistemas bloqueiam após poucas tentativas: com 3 tentativas, a chance de acerto é só $3/5040$.

2 A ordem importa? (revisores)

No trio de revisores, {Ana, Bruno, Caio} é o mesmo que {Caio, Ana, Bruno}: **ordem não importa**, é combinação. Contando com ordem há $8 \cdot 7 \cdot 6 = 336$ listas, mas cada grupo aparece em $3! = 6$ ordens:

$$\binom{8}{3} = \frac{336}{6} = \frac{8!}{3!5!} = 56$$

3 Ana e Bruno juntos

Fixe os dois no trio. Falta escolher 1 vaga entre os 6 restantes:

$$P = \frac{\binom{2}{2}\binom{6}{1}}{\binom{8}{3}} = \frac{6}{56} = 0.107$$

Numerador: trios favoráveis. Denominador: todos os trios, igualmente prováveis num sorteio.

4 Pelo menos um: usar o complemento

"Pelo menos um" é o contrário de "nenhum". Sem Ana e sem Bruno, os 3 saem dos 6 restantes:

$$P = 1 - \frac{\binom{6}{3}}{\binom{8}{3}} = 1 - \frac{20}{56} = 0.643$$

RESPOSTA (a) 5040; (b) 56; (c) 0.107; (d) 0.643.

Pergunta-chave: trocar a ordem dos itens produz um resultado diferente? Se sim, arranjo; se não, combinação. Ao calcular probabilidades, use o mesmo critério no numerador e no denominador. Se o PIN pudesse repetir dígitos, seriam $10^4 = 10\,000$ códigos.

Exercício 1.8 • Amostragem sem Reposição (Contagem)

Um backup tem 25 arquivos, dos quais 5 estão corrompidos. Uma auditoria sorteia 4 arquivos ao acaso, **sem reposição**. Qual a probabilidade de a amostra conter exatamente 1 corrompido?

Espaço para cálculo

1.9 Probabilidades a partir de Tabelas de Contingência

Na prática, as probabilidades raramente são dadas: elas são estimadas a partir de contagens em logs. Quando cada observação é classificada por dois critérios ao mesmo tempo, as contagens formam uma tabela de contingência, e as três probabilidades das seções anteriores (conjunta, marginal e condicional) são três formas de ler a mesma tabela. Com N observações no total, por exemplo requisições por versão do app e resultado:

VERSÃO	SUCESSO	ERRO	TOTAL
v1 (antiga)	570	30	600
v2 (nova)	360	40	400
Total	930	70	1000

- **Conjunta** (célula / total geral): $P(E \cap v2) = 40/1000 = 0.04$.
- **Marginal** (total da linha ou coluna / total geral): $P(E) = 70/1000 = 0.07$.
- **Condicional** (célula / total da linha ou coluna da condição): $P(E|v2) = 40/400 = 0.10$, enquanto $P(v2|E) = 40/70 = 0.571$.

Como $P(E|v2) = 0.10 \neq P(E) = 0.07$, erro e versão **não** são independentes: a v2 merece investigação antes do rollout completo. $P(E|v2)$ e $P(v2|E)$ respondem a perguntas diferentes, e o denominador é o que muda.

INTUIÇÃO Os teoremas do módulo, lidos na tabela

- **Probabilidade total:** $P(E) = 0.6 \times 0.05 + 0.4 \times 0.10 = 0.07$, a média das taxas de erro das versões ponderada pelo tráfego de cada uma.
- **Bayes:** a condicional "ao contrário", $P(v2|E)$, lida diretamente das contagens.
- **Independência:** se versão e erro fossem independentes, a célula (v2, Erro) teria $N \cdot P(v2) \cdot P(E) = 1000 \times 0.4 \times 0.07 = 28$ requisições. Observamos 40.

A pergunta "12 a mais é muito, ou pode ser acaso?" não tem resposta com o que vimos até aqui: ela exige saber quanto uma contagem varia naturalmente. É respondida pelo teste qui-quadrado de independência, que compara observado e esperado em todas as células.

CUIDADO Paradoxo de Simpson

A v2 pode ter taxa de erro menor que a v1 no Android e também no iOS e, ainda assim, maior no total, se a v2 foi liberada principalmente para a plataforma que já tem mais erros. Pela probabilidade total, a taxa agregada de cada versão é uma média ponderada das taxas por plataforma, e as versões usam pesos diferentes: a variável escondida (plataforma) confunde a comparação. Num teste A/B, sorteia-se quem recebe cada versão justamente para que os pesos sejam iguais nos dois grupos.

NA COMPUTAÇÃO Matriz de confusão de um classificador

A tabela classe real $\times$ classe prevista é uma tabela de contingência, e suas métricas são condicionais com denominadores diferentes:

Métrica	Condicional	Na tabela
Revocação (recall)	$P(\text{previsto} + \text{real} +)$	célula $\div$ linha
Precisão	$P(\text{real} + \text{previsto} +)$	a mesma célula $\div$ coluna

A relação entre as duas é Bayes, e a falácia da taxa-base é o motivo de um classificador com recall alto ter precisão baixa quando a classe positiva é rara.

CONEXÕES

- 1.5** a marginal como probabilidade total.
- 1.6** a condicional invertida como Bayes.
- 8.5** qui-quadrado de independência.
- 8.1** o sorteio do teste A/B contra Simpson.

▼ Entendendo a fórmula, termo a termo

$$P(A|B) = \frac{n_{AB}}{n_B}, \quad E_{AB} = \frac{n_A n_B}{N}$$

 n_{AB}

← Contagem da célula (os dois critérios ao mesmo tempo).

 n_B ← Total da linha ou coluna da condição B . N

← Total geral.

 E_{AB} ← Contagem esperada na célula se A e B fossem independentes.

De onde vem, passo a passo

1. $P(A \cap B) = n_{AB}/N$ e $P(B) = n_B/N$.
2. Razão: $\frac{n_{AB}/N}{n_B/N} = \frac{n_{AB}}{n_B}$; o N se cancela.
3. Sob independência, $P(A \cap B) = \frac{n_A}{N} \cdot \frac{n_B}{N}$; multiplicando por N : $E_{AB} = \frac{n_A n_B}{N}$.

EXEMPLO RESOLVIDO

Versões do app e destino das requisições

Um mês de requisições de duas versões de um app (v1 e v2, em teste A/B) foi classificado pelo resultado.

DADOS

	SUCESSO	RETRY	ERRO	TOTAL
V1	450	30	20	500
V2	270	20	10	300
TOTAL	720	50	30	800

O QUE SE PEDE

(a) $P(\text{Erro})$; (b) $P(v1 \cap \text{Erro})$; (c) $P(\text{Erro}|v1)$ e $P(\text{Erro}|v2)$; (d) $P(v1|\text{Erro})$; (e) erro e versão são independentes?

RESOLUÇÃO PASSO A PASSO

1 Marginal: total da coluna / total geral

$$P(\text{Erro}) = \frac{30}{800} = 0.0375$$

2 Conjunta: célula / total geral

$$P(v1 \cap \text{Erro}) = \frac{20}{800} = 0.025$$

3 Condicional: célula / total da condição

"Dado v1" restringe o universo à linha v1 (500 requisições):

$$P(\text{Erro}|v1) = \frac{20}{500} = 0.040, \quad P(\text{Erro}|v2) = \frac{10}{300} = 0.033$$

4 Inverter a condição

"Dado erro" restringe à coluna Erro (30 requisições):

$$P(v1|\text{Erro}) = \frac{20}{30} = 0.667$$

A v1 gera 2/3 dos erros, mas também atende 5/8 do tráfego: o peso maior vem do volume, não de uma taxa muito pior.

5 Testar independência

Se fossem independentes, $P(v1 \cap \text{Erro}) = P(v1) P(\text{Erro})$:

$$\frac{500}{800} \times 0.0375 = 0.625 \times 0.0375 = 0.0234 \implies 0.0234 \times 800 = 18.75 \text{ requisições esp}$$

Observamos 20. A diferença é pequena.

RESPOSTA

(a) 0.0375; (b) 0.025; (c) 0.040 e 0.033; (d) 0.667; (e) não exatamente, mas a diferença (20 contra 18.75) é pequena.

"Observado contra esperado sob independência" é exatamente o que o teste qui-quadrado (Módulo 8) quantifica, para decidir se a diferença é grande demais para ser acaso. Repare também que a fração *sem sucesso* é igual nas duas versões: $50/500 = 30/300 = 0.10$.

Exercício 1.9 • Condicional Invertida em Tabela de Contingência

A tabela cruza o período do dia e o resultado de 1327 requisições a uma API. Uma requisição é sorteada ao acaso.

PERÍODO	SUCESSO	ERRO	TOTAL
Manhã	600	17	617
Tarde	480	28	508
Noite	160	42	202
Total	1240	87	1327

Sabendo que a requisição deu erro, qual a probabilidade de ela ser do período da Noite?

Espaço para cálculo

1.10 Roteiro com Árvore de Probabilidades

Uma árvore de probabilidades é a forma gráfica de organizar a regra da cadeia, a probabilidade total e Bayes num mesmo raciocínio. Cada nível representa uma etapa do experimento, cada ramo carrega a probabilidade condicional daquela etapa dado o caminho até ali, e cada folha é um resultado completo.

1. Primeiro nível: a partição de "causas" $B_1, \dots, B_k$ (servidores, provedores, versões, estados do sistema), com $\sum P(B_i) = 1$.
2. Segundo nível: o "efeito" dentro de cada causa, $P(A|B_i)$.
3. Cada caminho vale $P(B_i)P(A|B_i)$. Somar os caminhos que terminam em A dá $P(A)$; dividir um caminho por essa soma dá $P(B_j|A)$.

Falácia da taxa-base: com prevalência baixa, mesmo um detector sensível gera mais alarmes falsos do que verdadeiros. Por isso $P(\text{ataque}|\text{alarme})$ costuma ser muito menor que $P(\text{alarme}|\text{ataque})$.

INTUIÇÃO Cada passo da árvore é um teorema

Passo na árvore	Teorema
multiplicar ao longo de um caminho	regra do produto e da cadeia
somar os caminhos que terminam no mesmo efeito	probabilidade total
dividir um caminho por essa soma	Bayes

Árvores com mais níveis são a regra da cadeia completa: cada nível condiciona no caminho até ali, $P(\text{caminho}) = P(B_i) P(C_j|B_i) P(A|B_i \cap C_j)$. A retransmissão de um pacote é uma árvore com um nível por tentativa, em que cada tentativa perde com probabilidade p ou chega com $1 - p$, e o caminho termina no primeiro sucesso. O caminho até o k -ésimo nível vale $p^{k-1}(1 - p)$, e a distribuição do número de tentativas que sai daí é a geométrica, versão discreta da exponencial.

NA COMPUTAÇÃO A mesma estrutura em outros lugares

- **Árvores de jogo:** no expectiminimax (jogos com dados), cada nó de acaso vale a média ponderada dos filhos, que é a probabilidade total aplicada recursivamente.
- **Redes bayesianas:** generalizam a árvore para grafos, permitindo que um efeito tenha várias causas que se combinam.

EXEMPLO Frequências naturais

Para calcular à mão, troque probabilidades por contagens numa população imaginária: imagine 10 000 requisições e escreva quantas seguem cada ramo. A falácia da taxa-base fica visível (os 495 alarmes falsos aparecem lado a lado com os 95 verdadeiros), e Bayes vira uma divisão entre contagens. Estudos com médicos e juízes mostram que o erro de inverter condicionais cai drasticamente quando os mesmos dados são apresentados assim. É também a forma como os dados chegam na prática: contagens de logs, como na tabela de contingência.

CONEXÕES

- 1.3 regra do produto e da cadeia.
- 1.5 probabilidade total.
- 1.6 Bayes e atualização sequencial.
- 1.9 contagens de logs em tabela.
- 3.5 geométrica.
- 5.4 exponencial.

▼ Entendendo a fórmula, termo a termo

$$P(\text{caminho}) = P(B_i) P(A|B_i), \quad P(A) = \sum_{\text{caminhos até } A} P(\text{caminho})$$

Ramo do 1º nível ← $P(B_i)$: probabilidades não condicionais (somam 1).

Ramo do 2º nível ← $P(A|B_i)$: condicional à causa do 1º nível (em cada nó, os ramos que saem somam 1).

Multiplicar ao longo ← Regra do produto: percorrer um caminho é a interseção dos eventos.

Somar entre caminhos ← Caminhos diferentes são disjuntos (axioma 3).

De onde vem, passo a passo

1. Desenhe os ramos das causas com suas probabilidades.
2. De cada causa, desenhe os ramos dos efeitos com as condicionais.
3. Multiplique ao longo de cada caminho e confira: a soma de *todos* os caminhos deve dar 1.
4. Para Bayes, divida o caminho de interesse pela soma dos caminhos que terminam no efeito observado.

EXEMPLO RESOLVIDO

Árvore com dois provedores de CDN

Um site distribui seus arquivos estáticos por dois provedores de CDN. Cada requisição vai a um deles, e pode ser servida com sucesso ou falhar.

DADOS

- $P(A) = 0.70$, $P(B) = 0.30$ (fração do tráfego)
- $P(\text{ok}|A) = 0.98$, $P(\text{ok}|B) = 0.90$

O QUE SE PEDE

(a) $P(\text{ok})$; (b) $P(B|\text{falha})$.

RESOLUÇÃO PASSO A PASSO

1 Desenhar a árvore

1º nível: para qual provedor vai a requisição (A ou B). 2º nível: o resultado, dado o provedor. Os ramos de falha são os complementos: $P(\text{falha}|A) = 0.02$ e $P(\text{falha}|B) = 0.10$.

2 Multiplicar ao longo de cada caminho

CAMINHO	CONTA	PROBABILIDADE
A e ok	0.7×0.98	0.686
A e falha	0.7×0.02	0.014
B e ok	0.3×0.90	0.270
B e falha	0.3×0.10	0.030

Os 4 caminhos somam 1 ✓.

3 Somar os caminhos que terminam no evento

$$P(\text{ok}) = 0.686 + 0.270 = 0.956, \quad P(\text{falha}) = 0.014 + 0.030 = 0.044$$

4 Dividir um caminho pela soma (Bayes)

$$P(B|\text{falha}) = \frac{0.030}{0.044} = 0.682$$

RESPOSTA (a) 0.956; (b) 0.682.

Interpretação: B atende só 30% do tráfego, mas responde por 68% das falhas. É o provedor a renegociar ou trocar; enquanto isso, reduzir o peso de B no roteamento já melhora a taxa global.

Exercício 1.10 • Árvore em Dois Estágios (Bayes Sequencial)

Um detector de fraude sinaliza 96% das contas comprometidas e dá falso alarme em 2% das contas normais; 4% das contas estão comprometidas. Uma conta foi sinalizada por **dois** detectores independentes. Qual a probabilidade de estar comprometida?

Espaço para cálculo

Exercícios de Fixação com Soluções Comentadas

3 Questões Resolvidas

Exercício 1.1: Disponibilidade de Arquitetura Mista (Série-Paralelo)

Uma API de pagamentos depende de dois componentes. Na entrada há dois servidores de aplicação independentes S_1 e S_2 atrás de um balanceador (em paralelo), com disponibilidades $R(S_1) = 0.90$ e $R(S_2) = 0.85$. Em série com esse par existe o banco de dados U , com disponibilidade $R(U) = 0.98$. Calcule a disponibilidade total da API R_{api} e a probabilidade de ela estar fora do ar.

Espaço para cálculo

Exercício 1.2: Antivírus e o Teorema de Bayes

Em um repositório de pacotes, sabe-se que 2% dos arquivos enviados contêm malware ($P(D) = 0.02$). Um antivírus baseado em assinaturas e heurísticas analisa cada envio. Ele detecta corretamente 98% dos arquivos maliciosos ($P(+|D) = 0.98$), mas tem taxa de falso positivo de 3% em arquivos limpos ($P(+|D^c) = 0.03$). Um arquivo é analisado e o antivírus acusa malware (+). Qual é a probabilidade real de que ele seja malicioso, $P(D|+)$?

Espaço para cálculo

Exercício 1.3: Origem de Builds Quebrados

Três runners de integração contínua (L_1 , L_2 e L_3) executam os builds de um projeto. L_1 executa 40% dos builds, L_2 35% e L_3 os 25% restantes. As taxas históricas de falha por problema de ambiente (não do código) são 1.5% em L_1 , 2.0% em L_2 e 4.0% em L_3 . Um build escolhido ao acaso falhou por problema de ambiente. Qual a probabilidade de ele ter rodado no runner L_3 ?

Espaço para cálculo

Módulo 2: Variáveis Aleatórias Discretas (VAD)

Variáveis aleatórias discretas como funções sobre resultados, FP, FDA, esperança (análise de caso médio, linearidade com indicadoras), variância, percentis (p99, SLOs), soma de latências e funções não lineares (Jensen).

No Módulo 1, cada pergunta exigia descrever eventos como conjuntos e calcular probabilidades caso a caso. Este módulo troca eventos por números. Ao associar um número a cada resultado, ganhamos as ferramentas da aritmética: média, dispersão, percentis, somas. Usamos como fio condutor o enlace de 1.1, em que cada um de 3 pacotes se perde com probabilidade 0.1, de forma independente. As mesmas ideias, com somas trocadas por integrais, voltam no Módulo 4, e as fórmulas de soma de variáveis deste módulo são a base de toda a estatística dos Módulos 6 a 9.

2.1 Conceito de Variável Aleatória Discreta

No enlace de 3 pacotes, o espaço amostral tem 8 sequências ($EEE, EEP, \dots, PPP$), mas raramente queremos saber a sequência inteira. Queremos saber *quantos* pacotes se perderam, ou *em qual* tentativa veio o primeiro erro, ou se houve *algum* erro. Cada uma dessas perguntas é uma regra que lê o resultado e devolve um número.

Uma **Variável Aleatória (V.A.)** X é uma *função* que associa a cada resultado ω do espaço amostral um número real: $X : \Omega \rightarrow \mathbb{R}$. Ela transforma perguntas sobre eventos ("quais pacotes se perderam?") em perguntas sobre números ("quantos se perderam?"), o que permite falar de média, variância e gráficos.

INTUIÇÃO Nem variável, nem aleatória: uma função

Uma variável aleatória é uma função determinística; a aleatoriedade está na entrada ω , que o experimento sorteia. A analogia com programação é direta: o experimento sorteia a entrada, e X é uma função pura aplicada a ela. Sobre o mesmo Ω podem ser definidas várias funções ("número de perdas", "posição da primeira perda", "1 se houve perda"), e, por estarem definidas sobre o mesmo sorteio, elas podem ser combinadas e comparadas. É isso que dá sentido a somas $X + Y$ e a dizer que duas variáveis são dependentes.

Escrever $\{X = 1\}$ é uma abreviação para o evento $\{\omega : X(\omega) = 1\} = \{EEP, EPE, PEE\}$, a pré-imagem do valor 1. Assim, toda probabilidade sobre X é uma probabilidade sobre eventos do Módulo 1, calculada com as mesmas regras. A variável não acrescenta aleatoriedade; ela organiza a que já existia.

Uma V.A. é **discreta** quando seu conjunto de valores possíveis (o *suporte* R_X) é finito ou infinito enumerável: contagens como número de pacotes perdidos em 100 enviados, número de requisições na fila, número de comparações feitas por um algoritmo, número de tentativas até um login dar certo.

INTUIÇÃO Discreta, contínua ou mista

Tipo	Exemplos	Ferramenta
Discreta	contagens: perdas, retries, itens na fila	função de probabilidade (este módulo)
Contínua	medições: latência, temperatura	densidade (Módulo 4)
Mista	tempo de espera numa fila: exatamente 0 com probabilidade positiva (servidor livre), contínuo no resto	FDA

A variável discreta mais simples é a **indicadora** de um evento: $I_A = 1$ se A ocorre e 0 se não. Ela parece trivial, mas é a peça com que se constroem as contagens.

NA COMPUTAÇÃO Contagens como somas de indicadoras

O número de pacotes perdidos é $X = I_1 + I_2 + I_3$, em que I_i indica a perda do pacote i . O número de requisições com erro entre n é a soma de n indicadoras. Essa decomposição, junto com a linearidade da esperança, resolve problemas de análise de algoritmos que seriam muito difíceis atacando a distribuição de X diretamente, e é exatamente como a binomial será construída.

CONEXÕES

- 1.1 resumir Ω num número.
- 2.4 linearidade da esperança com indicadoras.
- 2.7 somas de variáveis definidas sobre o mesmo sorteio.
- 3.2 binomial como soma de indicadoras.

▼ Entendendo a fórmula, termo a termo

$$p(x) = P(X = x) = P(\{\omega \in \Omega : X(\omega) = x\})$$

 ω

← Um resultado concreto do experimento (ex.: "CN").

 $X(\omega)$

← O número que a variável associa a esse resultado (ex.: 1 requisição com falha).

 $\{\omega : X(\omega) = x\}$ ← O *evento* formado por todos os resultados que levam ao valor x .

De onde vem, passo a passo

1. Liste os resultados de Ω e suas probabilidades.
2. Aplique a regra X a cada um.
3. Agrupe os resultados por valor de x e some suas probabilidades: isso é $p(x)$.

Uma VA transforma perguntas sobre eventos ("requisições OF ou FO") em perguntas sobre números (" $X = 1$ "), o que permite usar média, variância e gráficos.

EXEMPLO RESOLVIDO

Das requisições ao número

Um cliente faz 2 requisições a um servidor instável. Cada uma falha (F) com probabilidade 0.1 ou dá certo (O, ok), independentemente. Define-se X = número de requisições que falharam.

DADOS

- $P(F) = 0.1, P(O) = 0.9$
- 2 requisições independentes

O QUE SE PEDE

A função de probabilidade de X e o valor esperado $E[X]$.

RESOLUÇÃO PASSO A PASSO

1 Listar os resultados e suas probabilidades

Pela independência, multiplica-se a chance de cada requisição:

RESULTADO ω	OO	OF	FO	FF
$P(\omega)$	$0.9^2 = 0.81$	$0.9 \times 0.1 = 0.09$	$0.1 \times 0.9 = 0.09$	$0.1^2 = 0.01$

2 Aplicar a regra X a cada resultado

A variável aleatória é uma *função*: ela recebe um resultado e devolve um número (quantos F há nele).

ω	OO	OF	FO	FF
$X(\omega)$	0	1	1	2

3 Agrupar resultados com o mesmo valor

OF e FO levam ao mesmo $x = 1$, então suas probabilidades se somam:

$$p(0) = 0.81, \quad p(1) = 0.09 + 0.09 = 0.18, \quad p(2) = 0.01$$

Conferência: $0.81 + 0.18 + 0.01 = 1 \checkmark$.

4 Valor esperado

$$E[X] = \sum x p(x) = 0(0.81) + 1(0.18) + 2(0.01) = 0.20$$

Em média, 0.2 falha por par de requisições, que é 2×0.1 : pela linearidade, $X = I_1 + I_2$ (indicadoras de falha) e $E[X] = 0.1 + 0.1$.

RESPOSTA $p(0) = 0.81, p(1) = 0.18, p(2) = 0.01; E[X] = 0.2$.

Discreta ou contínua? "Número de falhas" é contagem (discreta); "latência" ou "tempo até o próximo crash" são medições (contínuas). Este é o primeiro caso da binomial (seção 3.2), com $n = 2$ e $p = 0.1$.

Exercício 2.1 • Esperança a partir do Experimento

Os dois discos de um espelhamento RAID 1 falham num dia, independentemente, com probabilidades 0.2 e 0.05. Seja X o número de discos que falham no dia ($X \in \{0, 1, 2\}$). Calcule $E[X]$.

Espaço para cálculo

2.2 Função de Probabilidade (FP / PMF)

Uma vez definida X , a primeira pergunta é com que probabilidade ela assume cada valor. A resposta é uma tabela (ou fórmula), que funciona como a "assinatura" completa da variável:

FUNÇÃO DE PROBABILIDADE (FP)

$$p(x) = P(X = x)$$

Condições Obrigatórias: $p(x) \geq 0, \quad \forall x$ e $\sum_{x \in R_X} p(x) = 1$

▼ Equação desmontada, variável por variável

$$p(x) = P(X = x)$$

 X

← variável aleatória (ex.: nº de crashes por dia)

 x

← um valor que ela pode assumir (ex.: 2)

 $p(x)$ ← probabilidade de X valer exatamente x (ex.: $p(2) = 0.3$)

$$p(x) \geq 0, \quad \sum_{x \in R_X} p(x) = 1$$

 R_X ← todos os valores possíveis de X (ex.: $\{0, 1, 2, 3\}$) $\sum_{x \in R_X}$

← soma sobre todos esses valores

 $= 1$

← as probabilidades somam 100%

As duas condições são os axiomas de Kolmogorov reescritos: os eventos $\{X = x\}$ para valores diferentes são disjuntos e juntos cobrem Ω , então suas probabilidades não são negativas e somam 1.

EXEMPLO O enlace, valor a valor

x (perdas)	Sequências	$p(x)$
0	<i>EEE</i>	$0.9^3 = 0.729$
1	3 sequências	$3(0.9)^2(0.1) = 0.243$
2	3 sequências	$3(0.9)(0.1)^2 = 0.027$
3	<i>PPP</i>	0.001

Os valores somam 1. Toda pergunta sobre X sozinha vira uma soma de valores da FP: $P(X \geq 1) = 1 - p(0) = 0.271$.

Frequentemente conhecemos só a *forma* da FP, $p(x) = c \cdot g(x)$, e a constante sai da condição de soma 1: $c = 1 / \sum g(x)$. Quando o suporte é infinito, essa condição é uma série que precisa convergir.

DEDUÇÃO Suporte infinito: a geométrica soma 1

O número de tentativas até o primeiro sucesso, com sucesso p em cada uma, tem $p(k) = (1 - p)^{k-1}p$, $k = 1, 2, \dots$ (cada termo é um caminho da árvore de retransmissões). A soma é uma série geométrica:

$$\sum_{k=1}^{\infty} (1 - p)^{k-1} p = p \cdot \frac{1}{1 - (1 - p)} = 1$$

Essa é a distribuição geométrica, que modela retransmissões, tentativas de login e o número de execuções de um algoritmo de Las Vegas até ele terminar.

NA COMPUTAÇÃO Softmax e FP empírica

- **Softmax:** em aprendizado de máquina, transforma pontuações e^{z_i} em probabilidades dividindo pela soma, exatamente a normalização $c = 1 / \sum g(x)$.
- **FP empírica:** em sistemas reais, a FP é estimada de logs: conta-se quantas vezes cada valor apareceu e divide-se pelo total. A FP teórica descreve o mecanismo, a empírica descreve os dados, e com muitos dados a segunda se aproxima da primeira.

CUIDADO Frequência zero não é probabilidade zero

Com poucos dados, valores raros aparecem com frequência zero na FP empírica. Isso não significa que sejam impossíveis: significa apenas que a amostra foi pequena demais para vê-los. A regra de três de 3.6 dá um limite superior para a probabilidade de algo que nunca foi observado.

CONEXÕES

- 1.2** axiomas por trás das condições.
- 1.10** geométrica como caminhos de uma árvore.
- 3.5** geométrica entre os modelos discretos.
- 6.5** frequências relativas: FP empírica.

▼ Entendendo a fórmula, termo a termo

$$p(x) \geq 0, \quad \sum_{x \in R_X} p(x) = 1, \quad c = \frac{1}{\sum_x g(x)}$$

$$p(x) \geq 0$$

← Vem do axioma 1: probabilidades não são negativas.

$$\sum p(x) = 1$$

← Os eventos $\{X = x\}$ são disjuntos e cobrem Ω ; pelo axioma 2, a soma é 1.

$$c$$

← Constante de normalização quando $p(x) = c g(x)$: escala a "forma" g para somar 1.

De onde vem, passo a passo

1. Se $p(x) = c g(x)$, imponha $\sum_x c g(x) = 1$.
2. c sai da soma (é constante): $c \sum_x g(x) = 1$.
3. Logo $c = 1 / \sum_x g(x)$. Verifique também $g(x) \geq 0$ em todo o suporte.

EXEMPLO RESOLVIDO Essa função é uma FP válida?

Três propostas de função de probabilidade (FP) para o número de bugs encontrados numa revisão de código.

DADOS

- (i) $p(x) = x/10$ para $x = 1, 2, 3, 4$
- (ii) $p(x) = (x - 1)/5$ para $x = 0, 1, 2, 3$
- (iii) $p(x) = 0.5^x$ para $x = 1, 2, 3, \dots$

O QUE SE PEDE

Decidir quais são válidas e, para a (i), calcular $P(X \geq 3)$.

RESOLUÇÃO PASSO A PASSO

1 As duas condições

Uma FP é válida se (1) $p(x) \geq 0$ para todo x e (2) $\sum p(x) = 1$. Basta uma falhar para a função ser inválida. (Num código, seriam os dois *asserts* antes de usar o vetor de probabilidades.)

2 Função (i)

Valores: 0.1, 0.2, 0.3, 0.4, todos ≥ 0 . Soma: $\frac{1+2+3+4}{10} = \frac{10}{10} = 1$. **Válida.**

3 Função (ii)

$p(0) = (0 - 1)/5 = -0.2 < 0$. **Inválida:** probabilidade negativa não existe. A soma também falha: $(-1 + 0 + 1 + 2)/5 = 0.4 \neq 1$.

4 Função (iii)

Todos os termos são positivos. A soma é uma série geométrica de razão $r = 0.5$:

$$\sum_{x=1}^{\infty} 0.5^x = \frac{0.5}{1 - 0.5} = 1$$

Válida: uma VAD pode ter infinitos valores, desde que enumeráveis. (É a geométrica: número de tentativas até o 1º sucesso com $p = 0.5$.)

5 $P(X \geq 3)$ na função (i)

$$P(X \geq 3) = p(3) + p(4) = 0.3 + 0.4 = 0.7$$

RESPOSTA

(i) e (iii) são válidas; (ii) não. Na (i), $P(X \geq 3) = 0.7$.

Exercício 2.2 • Constante de Normalização de uma FP

O número X de tickets de suporte por hora tem $p(x) = c(x + 1)$ para $x = 0, 1, \dots, 4$. Determine c .

Espaço para cálculo

2.3 Função de Distribuição Acumulada (FDA / CDF)

As perguntas mais comuns sobre uma variável não são "qual a chance de exatamente k ?", e sim "qual a chance de no máximo k ?" (o buffer aguenta?) ou "de passar de k ?" (vai estourar o timeout?). A FDA responde diretamente a essas perguntas, acumulando a FP:

FUNÇÃO DE DISTRIBUIÇÃO ACUMULADA (FDA)

$$F(x) = P(X \leq x) = \sum_{t \leq x} p(t)$$

▼ Equação desmontada, variável por variável

$$F(x) = P(X \leq x) = \sum_{t \leq x} p(t)$$

$F(x)$ ← o que se calcula: probabilidade acumulada até x

$P(X \leq x)$ ← chance de X ser menor ou igual a x

t ← cada valor possível que não passa de x

$p(t)$ ← probabilidade de cada um desses valores

ex. ← $F(1) = p(0) + p(1) = 0.5 + 0.3 = 0.8$

Propriedades da FDA em VAD:

- $F(x)$ é uma função em degraus (escada), não decrescente e contínua à direita.
- Limites: $\lim_{x \rightarrow -\infty} F(x) = 0$ e $\lim_{x \rightarrow +\infty} F(x) = 1$.
- A altura do degrau no ponto x_k é a probabilidade pontual: $P(X = x_k) = F(x_k) - F(x_k^-)$.
- Intervalos: $P(a < X \leq b) = F(b) - F(a)$ e $P(X > a) = 1 - F(a)$.

EXEMPLO A escada do enlace

$F(0) = 0.729$, $F(1) = 0.972$, $F(2) = 0.999$ e $F(3) = 1$. Entre esses pontos a função fica parada, porque não há valores possíveis no meio: $F(1.5) = F(1)$.

Cada propriedade da caixa tem uma razão simples. F não decresce porque o evento $\{X \leq a\}$ está contido em $\{X \leq b\}$ quando $a < b$ (monotonicidade). Ela salta exatamente nos valores possíveis, e a altura do salto é a FP, de modo que FP e FDA contêm a mesma informação, e uma se obtém da outra.

CAUIDADO $<$ e $\leq$ não são a mesma coisa no discreto

$P(X < 2) = F(1) = 0.972$, enquanto $P(X \leq 2) = F(2) = 0.999$. A diferença é o degrau $p(2)$. Em variáveis contínuas essa diferença some, porque um ponto isolado tem probabilidade zero.

Essa é uma das vantagens da FDA: ela é definida da mesma forma para variáveis discretas, contínuas e mistas, e é a ferramenta comum a todos os módulos seguintes. Em monitoramento, a FDA empírica da latência ("que fração das requisições terminou em até t ms?") é provavelmente o gráfico mais informativo que existe, e lê-la "de lado" dá os percentis.

NA COMPUTAÇÃO Transformada inversa: como o computador sorteia

1. Sorteie U uniforme em $[0, 1)$.
2. Devolva o menor x com $F(x) \geq U$. No enlace: se $U < 0.729$ devolve 0; se $0.729 \leq U < 0.972$ devolve 1; e assim por diante.
3. Cada valor é devolvido com probabilidade igual ao comprimento do seu degrau, que é $p(x)$.

Em código, é uma busca (linear ou binária) no vetor de probabilidades acumuladas: é o que fazem `random.choices` com pesos e a amostragem de tokens num modelo de linguagem.

CONEXÕES

- 2.6 percentis lidos na escada.
- 4.3 FDA contínua, sem degraus.
- 5.4 transformada inversa contínua gera exponenciais.

▼ Entendendo a fórmula, termo a termo

$$F(x) = \sum_{t \leq x} p(t), \quad P(a < X \leq b) = F(b) - F(a)$$

$\sum_{t \leq x}$ ← Soma das probabilidades de todos os valores possíveis até x , inclusive.

$F(b) - F(a)$ ← Tudo até b menos tudo até a : sobra o intervalo $(a, b]$.

Saltos ← F sobe em degraus; a altura do degrau em x_k é $p(x_k)$.

De onde vem, passo a passo

1. $\{X \leq b\} = \{X \leq a\} \cup \{a < X \leq b\}$, eventos disjuntos.
2. Axioma 3: $F(b) = F(a) + P(a < X \leq b)$.
3. Isolando: $P(a < X \leq b) = F(b) - F(a)$. Atenção aos extremos: em VAD, incluir ou não a muda o resultado.

EXEMPLO RESOLVIDO Construindo e lendo a FDA

O número X de reinicializações não planejadas (crashes) de um serviço em um dia tem a FP abaixo.

DADOS

- $p(0) = 0.5, p(1) = 0.3, p(2) = 0.2$

O QUE SE PEDE

(a) a FDA $F(x)$; (b) $P(X \leq 1.7)$; (c) $P(X < 1)$ e $P(X \leq 1)$; (d) $P(X = 1)$ a partir da FDA.

RESOLUÇÃO PASSO A PASSO**1 Acumular as probabilidades**

$F(x) = P(X \leq x)$ soma tudo o que está à esquerda de x , inclusive o próprio x :

- $F(0) = 0.5$
- $F(1) = 0.5 + 0.3 = 0.8$
- $F(2) = 0.8 + 0.2 = 1$

Em código, é a soma acumulada (cumsum) do vetor de probabilidades.

2 Escrever por partes

Entre dois valores possíveis nada se acumula, então F fica constante (degraus):

$$F(x) = \begin{cases} 0, & x < 0 \\ 0.5, & 0 \leq x < 1 \\ 0.8, & 1 \leq x < 2 \\ 1, & x \geq 2 \end{cases}$$

3 Ler valores não inteiros

1.7 está no degrau $1 \leq x < 2$, logo $P(X \leq 1.7) = F(1.7) = 0.8$. Faz sentido: $X \leq 1.7$ é o mesmo que $X \in \{0, 1\}$.

4 < não é ≤ em variável discreta

$P(X < 1)$ exclui o 1: só sobra $X = 0$, logo vale $F(0) = 0.5$. Já $P(X \leq 1) = F(1) = 0.8$. A diferença é exatamente $p(1)$. Erro clássico de "off-by-one", agora em probabilidade.

5 Probabilidade pontual = altura do salto

$$P(X = 1) = F(1) - F(1^-) = 0.8 - 0.5 = 0.3$$

$F(1^-)$ é o valor do degrau logo antes de 1.

RESPOSTA (b) 0.8; (c) 0.5 e 0.8; (d) 0.3.

Exercício 2.3 • Probabilidade de Intervalo pela FDA

O número X de reexecuções (retries) por job tem a FP abaixo.

x	0	1	2	3
$P(X = x)$	0.3	0.4	0.15	0.15

Calcule $P(0 < X \leq 3)$ usando a FDA.

Espaço para cálculo

2.4 Esperança Matemática (Média / Valor Esperado)

A FP descreve a variável inteira, mas muitas vezes precisamos de um único número que a resuma. Se o experimento for repetido muitas vezes, a frequência relativa de cada valor x se aproxima de $p(x)$, e a média aritmética dos resultados se aproxima de $\sum x p(x)$. Esse limite é a esperança $E[X]$ (ou μ_X), o centro de gravidade da distribuição:

ESPERANÇA DE VAD

$$E[X] = \mu = \sum_{x \in R_X} x \cdot p(x)$$

Para uma função $g(X)$: $E[g(X)] = \sum_{x \in R_X} g(x) \cdot p(x)$

▼ Equação desmontada, variável por variável

$$E[X] = \mu = \sum_x x \cdot p(x)$$

$E[X]$	← o que se calcula: valor esperado (média teórica)
μ	← outro nome para a mesma média
x	← cada valor possível (ex.: 0, 1, 2 crashes)
$p(x)$	← peso de cada valor
$x \cdot p(x)$	← contribuição do valor (ex.: $2 \times 0.3 = 0.6$)
$\sum_x$	← soma das contribuições

$$E[g(X)] = \sum_x g(x) \cdot p(x)$$

$g(X)$	← uma função de X (ex.: custo = $250X + 100$)
$g(x)$	← valor da função em cada x (ex.: $g(2) = 600$)
$p(x)$	← mesmo peso de antes

Propriedades (linearidade):

- $E[c] = c$, para qualquer constante c .
- $E[aX + b] = aE[X] + b$.
- $E[X + Y] = E[X] + E[Y]$ (válido mesmo se X e Y forem dependentes!).

EXEMPLO O enlace, de dois jeitos

- **Pela FP:** $E[X] = 0(0.729) + 1(0.243) + 2(0.027) + 3(0.001) = 0.3$ pacote perdido por rajada de 3.
- **Pela linearidade:** $X = I_1 + I_2 + I_3$ e cada indicadora tem $E[I_i] = P(\text{perda}) = 0.1$, logo $E[X] = 3 \times 0.1 = 0.3$.

A primeira conta tem a mesma forma da probabilidade total: uma média ponderada, agora de valores em vez de probabilidades condicionais.

Esse atalho (escrever uma contagem como soma de indicadoras e somar as esperanças) é uma das técnicas mais poderosas da análise de algoritmos, porque a linearidade *não* exige independência.

NA COMPUTAÇÃO Análise de caso médio com indicadoras

- **Pontos fixos de uma permutação aleatória:** cada item fica no lugar com chance $1/n$, então o número esperado de itens na posição original é $n \cdot (1/n) = 1$, para qualquer n , embora as indicadoras sejam dependentes e a distribuição exata seja complicada.
- **Quicksort randomizado:** $\approx 1.39 n \log_2 n$ comparações em média.
- **Tabela hash:** tempo esperado de busca $O(1)$.
- **Colecionador:** o número esperado de requisições aleatórias até atingir todos os n servidores de um pool é $n(1 + \frac{1}{2} + \dots + \frac{1}{n}) \approx n \ln n$.

CUIDADO Média de longo prazo não é valor típico

- A esperança pode nem ser um valor possível (0.3 pacote).
- Pode ser dominada por eventos raros e enormes: um serviço com latência média de 50 ms pode ter 1% das requisições acima de 2 s. Por isso a média vem sempre acompanhada de uma medida de dispersão e de percentis.
- Em distribuições de cauda muito pesada (tamanhos de arquivo, popularidade de páginas), a soma que define $E[X]$ pode divergir; nesses casos a média amostral nunca se estabiliza, e os resultados de estimação deixam de valer.

CONEXÕES

- 1.5** a mesma média ponderada da probabilidade total.
- 2.5** dispersão em torno da média.
- 2.6** percentis, para o que a média esconde.
- 7.1** média amostral como estimador de $E[X]$.

▼ Entendendo a fórmula, termo a termo

$$E[X] = \sum_x x p(x)$$

 x

← Cada valor possível da variável.

 $p(x)$

← Peso desse valor: com que frequência ele aparece no longo prazo.

 $\sum x p(x)$

← Média ponderada: o centro de massa da distribuição.

De onde vem, passo a passo

1. Repita o experimento N vezes. O valor x aparece cerca de $N p(x)$ vezes.
2. A média aritmética dos N resultados é $\frac{\sum_x x \cdot N p(x)}{N}$.
3. Cancelando N : $\sum_x x p(x)$. Analogia física: massas $p(x)$ nas posições x de uma régua; $E[X]$ é o ponto de equilíbrio.

EXEMPLO RESOLVIDO

Escolhendo provedor pelo valor esperado

Dois provedores de hospedagem têm históricos diferentes de incidentes graves por mês. Cada incidente custa 2000 reais (horas de engenharia e créditos devolvidos a clientes).

DADOS

- Provedor A: $p(0) = 0.6, p(1) = 0.3, p(2) = 0.1$
- Provedor B: $p(0) = 0.8, p(3) = 0.2$
- custo: $C = 2000 X$ reais

O QUE SE PEDE

Custo mensal esperado de cada provedor e qual escolher.

RESOLUÇÃO PASSO A PASSO

1

Valor esperado de A

Cada valor é ponderado pela sua probabilidade:

$$E[X_A] = 0(0.6) + 1(0.3) + 2(0.1) = 0 + 0.3 + 0.2 = 0.5 \text{ incidente/mês}$$

2 Valor esperado de B

$$E[X_B] = 0(0.8) + 3(0.2) = 0.6 \text{ incidente/mês}$$

3 Passar para custo

Pela linearidade, $E[2000X] = 2000 E[X]$:

$$E[C_A] = 2000 \times 0.5 = 1000 \text{ reais}, \quad E[C_B] = 2000 \times 0.6 = 1200 \text{ reais}$$

4 Interpretar

B tem mais meses sem incidente (80% contra 60%), mas quando falha, falha em cascata (3 incidentes). No longo prazo, A custa 200 reais a menos por mês.

RESPOSTA A: 1000 reais/mês; B: 1200 reais/mês. Pelo custo médio, A.

$E[X] = 0.5$ nunca é observado em um mês: a esperança é a média de muitos meses, não um valor típico. O próximo exemplo mostra o que a média esconde.

Exercício 2.4 • Esperança de uma VAD

O número X de crashes por dia de um serviço tem a FP abaixo.

x	0	1	2	3
$P(X = x)$	0.15	0.25	0.15	0.45

Calcule $E[X]$.

Espaço para cálculo

2.5 Variância e Desvio Padrão

Duas variáveis com a mesma média podem se comportar de modo totalmente diferente: um servidor que responde sempre em 50 ms e outro que responde em 10 ms ou 90 ms com igual chance têm a mesma média, mas o segundo dispara timeouts e enche filas. Para medir quanto X se afasta da média, não basta a média dos desvios, que é sempre zero ($E[X - \mu] = 0$). Elevar ao quadrado torna todos os desvios positivos e dá peso maior aos grandes:

VARIÂNCIA E DESVIO PADRÃO

$$\text{Var}(X) = \sigma^2 = E[(X - \mu)^2] = \sum_x (x - \mu)^2 \cdot p(x)$$

$$\text{Fórmula Computacional: } \text{Var}(X) = E[X^2] - (E[X])^2$$

$$\text{Desvio Padrão: } \sigma = \sqrt{\text{Var}(X)}$$

▼ Equação desmontada, variável por variável

$$\text{Var}(X) = \sigma^2 = \sum_x (x - \mu)^2 \cdot p(x)$$

$\text{Var}(X)$ ← o que se calcula: variância (dispersão)

σ^2 ← outro nome para a variância (unidade ao quadrado)

$x - \mu$ ← distância de cada valor até a média (ex.: $3 - 1.3 = 1.7$)

$(x - \mu)^2$ ← distância ao quadrado: sempre positiva

$p(x)$ ← peso de cada valor

$$\text{Var}(X) = E[X^2] - (E[X])^2$$

$E[X^2]$ ← média dos quadrados: $\sum x^2 p(x)$ (ex.: 2.5)

$(E[X])^2$ ← quadrado da média (ex.: $1.3^2 = 1.69$)

diferença ← variância (ex.: $2.5 - 1.69 = 0.81$)

$$\sigma = \sqrt{\text{Var}(X)}$$

σ ← desvio padrão, na mesma unidade de X (ex.: $\sqrt{0.81} = 0.9$)

Propriedades:

- $\text{Var}(X) \geq 0$, e $\text{Var}(X) = 0$ só se X for constante.
- $\text{Var}(c) = 0$, para qualquer constante c .
- $\text{Var}(aX + b) = a^2 \text{Var}(X)$: somar uma constante não muda a dispersão; multiplicar a escala multiplica a variância pelo quadrado.

DEDUÇÃO Fórmula computacional, aplicada ao enlace

Expandindo o quadrado: $E[(X - \mu)^2] = E[X^2] - 2\mu E[X] + \mu^2 = E[X^2] - \mu^2$.

No enlace, $E[X^2] = 1(0.243) + 4(0.027) + 9(0.001) = 0.36$, logo $Var(X) = 0.36 - 0.3^2 = 0.27$ e $\sigma = 0.52$.

A variância está em unidades ao quadrado ("pacotes²"), por isso se reporta o desvio padrão, que volta à unidade original. A preferência pelo quadrado em vez do desvio absoluto $E|X - \mu|$ não é arbitrária: só com o quadrado as variâncias de variáveis independentes se somam, e é essa propriedade que sustenta o erro padrão, os intervalos de confiança e os testes dos Módulos 7 e 8.

CUIDADO A fórmula computacional é perigosa em código

Quando a média é grande em relação ao desvio (latências em torno de 1 000 000 μ s variando poucos μ s), $E[X^2]$ e μ^2 são números enormes quase iguais, e a subtração em ponto flutuante perde quase todos os dígitos significativos (cancelamento catastrófico), podendo até dar variância negativa. Bibliotecas numéricas usam o algoritmo de Welford, que atualiza média e soma dos quadrados dos desvios a cada novo dado, numa única passada.

A variância também dá garantias sem que se conheça a distribuição. A **desigualdade de Chebyshev** diz que, para qualquer variável com variância finita, $P(|X - \mu| \geq k\sigma) \leq 1/k^2$.

INTUIÇÃO Quanto vale conhecer a forma

Fora de	Chebyshev (qualquer distribuição)	Normal
$\pm 2\sigma$	no máximo 25%	4.6%
$\pm 3\sigma$	no máximo 11%	0.27%

Chebyshev é fraca mas universal, e é usada em análise de algoritmos para provar que um tempo de execução fica perto da média "com alta probabilidade". A diferença entre as colunas mede quanto vale saber que a distribuição é normal.

CONEXÕES

- 2.7** variâncias de independentes se somam.
- 5.2** regra 68-95-99.7 da normal.
- 6.3** variância amostral e Welford.

▼ Entendendo a fórmula, termo a termo

$$\text{Var}(X) = E[(X - \mu)^2] = E[X^2] - \mu^2$$

$$X - \mu$$

← Desvio de cada valor em relação à média.

$$(\cdot)^2$$

← O quadrado impede que desvios positivos e negativos se cancelem e penaliza desvios grandes.

$$E[\cdot]$$

← Média dos desvios quadráticos, ponderada pelas probabilidades.

$$\sigma = \sqrt{\text{Var}}$$

← Volta à unidade original de X para poder interpretar.

De onde vem, passo a passo

1. Expanda o quadrado: $(X - \mu)^2 = X^2 - 2\mu X + \mu^2$.
2. Aplique a esperança termo a termo (linearidade): $E[X^2] - 2\mu E[X] + \mu^2$.
3. Como $E[X] = \mu$: $E[X^2] - 2\mu^2 + \mu^2 = E[X^2] - \mu^2$.
4. Para $\text{Var}(aX + b)$: o desvio vira $a(X - \mu)$ (o b some), e o quadrado dá a^2 .

EXEMPLO RESOLVIDO

Mesma ordem de média, riscos diferentes

Continuação do exemplo 2.4 (provedores A e B, 2000 reais por incidente).

DADOS

- A: $p(0) = 0.6, p(1) = 0.3, p(2) = 0.1, E[X_A] = 0.5$
- B: $p(0) = 0.8, p(3) = 0.2, E[X_B] = 0.6$

O QUE SE PEDE

Variância e desvio padrão dos incidentes e do custo de cada provedor.

RESOLUÇÃO PASSO A PASSO

1

Calcular $E[X^2]$

Eleva-se cada valor ao quadrado *antes* de ponderar:

$$E[X_A^2] = 0^2(0.6) + 1^2(0.3) + 2^2(0.1) = 0.7, \quad E[X_B^2] = 3^2(0.2) = 1.8$$

2 Fórmula de atalho da variância

$$Var(X) = E[X^2] - (E[X])^2$$

$$Var(X_A) = 0.7 - 0.5^2 = 0.45, \quad Var(X_B) = 1.8 - 0.6^2 = 1.44$$

3 Desvio padrão (mesma unidade de X)

$$\sigma_A = \sqrt{0.45} = 0.67 \text{ incidente}, \quad \sigma_B = \sqrt{1.44} = 1.2 \text{ incidente}$$

4 Passar para custo

Multiplicar X por 2000 multiplica o desvio por 2000 (e a variância por 2000^2):

$$\sigma_{C,A} = 2000 \times 0.67 = 1342 \text{ reais}, \quad \sigma_{C,B} = 2000 \times 1.2 = 2400 \text{ reais}$$

RESPOSTA A: $\sigma = 0.67$ incidente (1342 reais). B: $\sigma = 1.2$ incidente (2400 reais).

B é mais imprevisível: em 20% dos meses custa 6000 reais, valor que A nunca atinge (máximo 4000). Se o orçamento de operação for rígido, ou se 3 incidentes no mesmo mês quebrarem o SLA com um cliente grande, a variância pesa tanto quanto a média.

Exercício 2.5 • Variância de uma VAD

O número X de crashes por dia de um serviço tem a FP abaixo.

x	0	1	2	3
$P(X = x)$	0.15	0.15	0.5	0.2

Calcule $Var(X)$.

Espaço para cálculo

2.6 Medidas de Posição e Percentis para VAD

Média e desvio padrão resumem a distribuição em dois números, mas respondem mal a perguntas sobre extremos: "qual valor só é ultrapassado em 1% das vezes?". Essa é a pergunta do percentil. O percentil de ordem p ($0 < p < 1$), x_p , é o menor valor do suporte cuja probabilidade acumulada atinge ou supera p :

$$P(X \leq x_p) \geq p \quad \text{e} \quad P(X \geq x_p) \geq 1 - p$$

▼ Equação desmontada, variável por variável

$$P(X \leq x_p) \geq p \quad \text{e} \quad P(X \geq x_p) \geq 1 - p$$

x_p ← o que se procura: percentil de ordem p

p ← fração desejada (ex.: 0.5 para a mediana, 0.9 para o percentil 90)

$P(X \leq x_p) \geq p$ ← pelo menos a fração p fica em ou abaixo de x_p

$P(X \geq x_p) \geq 1 - p$ ← pelo menos $1 - p$ fica em ou acima de x_p

A **Mediana** é o percentil 50 ($p = 0.50$). O primeiro quartil é $Q_1 = x_{0.25}$ e o terceiro é $Q_3 = x_{0.75}$.

O percentil é a FDA lida ao contrário: em vez de dar um valor e perguntar a probabilidade acumulada, dá-se a probabilidade e pergunta-se o valor. Graficamente, anda-se na horizontal na altura p até bater num degrau da escada.

EXEMPLO Lendo a escada do enlace

Percentil	Leitura	Valor
Mediana	$F(0) = 0.729 \geq 0.5$	0
p95	$F(1) = 0.972 \geq 0.95$	1
p99	$F(1) < 0.99 \leq F(2)$	2

As duas condições da definição são necessárias porque, numa escada, quase nunca existe um valor com acumulada *exatamente* p .

NA COMPUTAÇÃO SLOs, dimensionamento e fan-out

- **SLOs:** um acordo de nível de serviço raramente fala em média; ele diz "p99 da latência abaixo de 300 ms", isto é, 99% das requisições terminam em até 300 ms.
- **Dimensionamento:** com s unidades de recurso (servidores reserva, conexões num pool, discos sobressalentes), a demanda X é atendida quando $X \leq s$, com probabilidade $F(s)$. Escolher $s = x_{0.95}$ garante atendimento em 95% dos períodos; dimensionar pela média deixa a demanda descoberta em quase metade deles.
- **Fan-out:** se uma página faz 100 chamadas em paralelo e espera todas, e cada uma passa do seu p99 com chance 1%, a página fica lenta com chance $1 - 0.99^{100} = 63\%$. O p99 de cada serviço vira o comportamento típico do todo. Por isso sistemas grandes monitoram o p99.9, e técnicas como requisições redundantes atacam diretamente a cauda.

INTUIÇÃO Mediana contra média

	Mediana	Média
Valores extremos	não se move	é puxada pela cauda
Descreve	o caso típico	o total (custo de 1 milhão de requisições = 1 milhão × média)

Em distribuições assimétricas, como latências e tamanhos de arquivo, as duas se separam, e a distância entre elas é um sinal de assimetria.

CONEXÕES

- 1.4 fan-out: complemento e independência.
- 4.5 percentis contínuos.
- 5.6 percentis da normal.
- 6.4 quartis amostrais e boxplot.
- 9.5 o SLO como limite de especificação.

▼ Entendendo a fórmula, termo a termo

$$x_p = \min\{x : F(x) \geq p\}$$

$F(x) \geq p$ ← Valores de x que já acumulam pelo menos a fração p .

$\min$ ← O primeiro desses valores.

Por que não $F(x) = p$? ← A FDA discreta anda em degraus e pode pular por cima de p sem nunca valer exatamente p .

De onde vem, passo a passo

1. Ordene os valores e acumule as probabilidades.
2. Percorra a FDA até o primeiro valor que atinge ou ultrapassa p .
3. Verifique as duas condições da definição: $P(X \leq x_p) \geq p$ e $P(X \geq x_p) \geq 1 - p$.

EXEMPLO RESOLVIDO

Quantos discos sobressalentes manter

A equipe de um datacenter quer decidir quantos discos de reposição manter em estoque por semana, para trocar imediatamente os que falham.

DADOS

- falhas de disco por semana: $p(0) = 0.20$, $p(1) = 0.35$, $p(2) = 0.25$, $p(3) = 0.15$, $p(4) = 0.05$

O QUE SE PEDE

Mediana, Q_3 , P_{90} e o estoque que cobre as falhas em pelo menos 90% das semanas.

RESOLUÇÃO PASSO A PASSO

1 Montar a FDA

x	0	1	2	3	4
$F(x)$	0.20	0.55	0.80	0.95	1

2 Regra do percentil discreto

O percentil q é o **primeiro** x com $F(x) \geq q$. Percorra a tabela da esquerda para a direita até passar de q (em código, uma busca binária no vetor acumulado).

3 Aplicar

- Mediana ($q = 0.5$): $F(0) = 0.20 < 0.5$, $F(1) = 0.55 \geq 0.5$, logo $Md = 1$.
- Q_3 ($q = 0.75$): $F(2) = 0.80 \geq 0.75$, logo $Q_3 = 2$.
- P_{90} ($q = 0.90$): $F(2) = 0.80 < 0.90$, $F(3) = 0.95 \geq 0.90$, logo $P_{90} = 3$.

4 Traduzir em decisão

Com s discos em estoque, as falhas são cobertas quando $X \leq s$, o que ocorre com probabilidade $F(s)$. Precisa-se $F(s) \geq 0.90$, ou seja, $s = P_{90} = 3$ discos (cobre 95% das semanas).

RESPOSTA $Md = 1$, $Q_3 = 2$, $P_{90} = 3$. Manter 3 discos.

A média $E[X] = 0(0.2) + 1(0.35) + 2(0.25) + 3(0.15) + 4(0.05) = 1.5$ não serve para isso: estocar 2 discos cobre só 80% das semanas. Dimensionamento de recursos (discos, servidores reserva, conexões) se faz por percentil.

Exercício 2.6 • Percentil de uma VAD

O número X de discos que falham por semana num datacenter tem a FP abaixo. Determine o percentil 75 (menor x com $F(x) \geq 0.75$).

x	0	1	2	3	4
$P(X = x)$	0.15	0.2	0.2	0.15	0.3

Espaço para cálculo

2.7 Soma e Diferença de Variáveis Independentes

Em computação, tempos se somam o tempo todo: a latência de uma requisição é rede + fila + processamento + banco de dados; o tempo de um pipeline é a soma de suas etapas; o erro de um relógio é a soma de vários desvios pequenos. Conhecendo média e variância de cada parcela, o que se pode dizer da soma? Para X e Y **independentes**:

PROPAGAÇÃO DE VARIÂNCIA

$$E[X \pm Y] = E[X] \pm E[Y], \quad \text{Var}(X \pm Y) = \text{Var}(X) + \text{Var}(Y)$$

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y)$$

▼ Equação desmontada, variável por variável

$$E[X \pm Y] = E[X] \pm E[Y]$$

X, Y ← duas variáveis (ex.: tempo de processamento e de rede)

$E[X] \pm E[Y]$ ← médias se somam ou subtraem normalmente (ex.: $20 + 15 = 35$ ms)

$$\text{Var}(X \pm Y) = \text{Var}(X) + \text{Var}(Y)$$

$\text{Var}(X), \text{Var}(Y)$ ← variâncias de cada uma (ex.: $3^2 = 9$ e $4^2 = 16$)

$+$ ← sempre soma, mesmo na diferença (exige independência)

ex. ← $9 + 16 = 25$, logo $\sigma = 5$

$$\text{Var}(aX + bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y)$$

a, b ← constantes que multiplicam cada variável (ex.: custo por hora)

a^2, b^2 ← entram ao quadrado; o sinal negativo desaparece

Mesmo na diferença as variâncias se **somam**: incertezas nunca se cancelam. Os desvios padrão **não** se somam diretamente: $\sigma_{X+Y} = \sqrt{\sigma_X^2 + \sigma_Y^2} < \sigma_X + \sigma_Y$. Ex.: duas etapas com $\sigma = 3$ ms e $\sigma = 4$ ms dão tempo total com $\sigma = 5$ ms, não 7.

DEDUÇÃO De onde vem, e onde entra a independência

A regra das médias é a linearidade e vale sempre. A das variâncias aparece ao expandir o quadrado:

$$\text{Var}(X + Y) = E[(X - \mu_X + Y - \mu_Y)^2] = \text{Var}(X) + \text{Var}(Y) + 2 \text{Cov}(X, Y)$$

em que $\text{Cov}(X, Y) = E[(X - \mu_X)(Y - \mu_Y)]$ mede se as duas tendem a estar acima da média ao mesmo tempo. A independência zera a covariância, e sobra a soma simples. Na diferença, o termo cruzado troca de sinal, mas as variâncias continuam somando, porque $\text{Var}(-Y) = (-1)^2 \text{Var}(Y)$.

INTUIÇÃO Desvios se combinam como catetos

O desvio padrão da soma se comporta como a hipotenusa de um triângulo retângulo: desvios independentes são "ortogonais", e 3 com 4 dá 5. A covariância normalizada, $Cov/(\sigma_X\sigma_Y)$, é o coeficiente de correlação, a medida de dependência linear usada em análise de dados.

CUIDADO Quando há dependência

Covariância	Exemplo	Efeito
positiva	duas etapas leem do mesmo disco sobrecarregado e ficam lentas juntas	variância total <i>maior</i> que a soma; supor independência subestima a variabilidade de ponta a ponta, e com ela o p99
negativa	uma etapa compensa a outra (hedge, estimadores com erros opostos)	variância total menor

Como são os *quadrados* que se somam, a parcela mais variável domina a variância total.

EXEMPLO Quem domina a variância

Etapas com desvios 2, 3 e 6 ms: o total tem $\sigma = \sqrt{4 + 9 + 36} = 7$ ms, e a terceira etapa responde por $36/49 = 73\%$ da variância. Eliminar completamente a primeira etapa reduziria o desvio total só de 7 para 6.7 ms. Para tornar um sistema mais previsível, ataca-se primeiro a etapa mais *variável*, que não é necessariamente a mais lenta em média.

A consequência mais importante aparece com muitas parcelas:

n PARCELAS INDEPENDENTES, VARIÂNCIA σ^2	VARIÂNCIA	DESVIO
Soma	$n\sigma^2$	$\sigma\sqrt{n}$
Média (soma $\div n$)	σ^2/n	$\sigma/\sqrt{n}$

O desvio da soma cresce, mas mais devagar que a própria soma (que cresce como n), de modo que a dispersão *relativa* cai como $1/\sqrt{n}$. Esse $\sigma/\sqrt{n}$ é o erro padrão, a peça central de toda a estimação. Saber média e variância da soma ainda não diz a *forma* da sua distribuição; a resposta, surpreendentemente universal, é o Teorema Central do Limite.

NA COMPUTAÇÃO Por que o agregado é previsível

O tráfego total de milhares de usuários independentes é muito mais previsível que o de cada um, porque a dispersão relativa cai com $1/\sqrt{n}$. É o mesmo princípio que faz a média de uma amostra estimar bem a média da população, e o que permite dimensionar um cluster pela soma das demandas.

CONEXÕES

- 1.4 independência.
- 5.7 soma de normais continua normal; orçamento de latência.
- 7.2 erro padrão $\sigma/\sqrt{n}$.
- 7.3 a forma da soma: TCL.
- 8.4 teste pareado: covariância a favor.

▼ Entendendo a fórmula, termo a termo

$$\text{Var}(X \pm Y) = \text{Var}(X) + \text{Var}(Y) \pm 2 \text{Cov}(X, Y)$$

$\text{Var}(X) + \text{Var}(Y)$ ← Contribuição de cada fonte de variação.

$\text{Cov}(X, Y)$ ← Covariância: mede se X e Y tendem a variar juntos. Vale 0 se forem independentes.

$\pm 2\text{Cov}$ ← Termo cruzado que aparece ao expandir o quadrado.

De onde vem, passo a passo

1. $\text{Var}(X + Y) = E[(X - \mu_X) + (Y - \mu_Y)]^2$.
2. Expanda: $E[(X - \mu_X)^2] + E[(Y - \mu_Y)^2] + 2E[(X - \mu_X)(Y - \mu_Y)]$.
3. O último termo é $2\text{Cov}(X, Y)$, que é zero sob independência.
4. Para a diferença, Y entra com coeficiente -1 , e $(-1)^2 = 1$: as variâncias continuam se somando.

EXEMPLO RESOLVIDO Latência de três chamadas em sequência

Para montar uma página, o servidor faz três chamadas em sequência (autenticação, catálogo e preços). A latência total é a soma das três, que são independentes.

DADOS

- latências médias 10, 20 e 30 ms
- desvios padrão $\sigma_1 = 2$, $\sigma_2 = 3$, $\sigma_3 = 6$ ms

O QUE SE PEDE

Média e desvio padrão da latência total, e o efeito de reduzir a variabilidade da chamada de preços para 3 ms.

RESOLUÇÃO PASSO A PASSO

1 Média: soma direta

A esperança da soma é sempre a soma das esperanças: $10 + 20 + 30 = 60$ ms.

2 Variância: somam-se as variâncias

Para variáveis **independentes**, $Var(X_1 + X_2 + X_3) = Var(X_1) + Var(X_2) + Var(X_3)$:

$$\sigma_{total}^2 = 2^2 + 3^2 + 6^2 = 4 + 9 + 36 = 49$$

3 Voltar para desvio padrão

$$\sigma_{total} = \sqrt{49} = 7 \text{ ms}$$

Somar os desvios ($2 + 3 + 6 = 11$) superestimaria em 57%.

4 Quem domina a variação

A chamada de preços contribui com $36/49 = 73\%$ da variância. Reduzindo seu desvio para 3 ms (por exemplo, com cache):

$$\sigma_{total} = \sqrt{4 + 9 + 9} = \sqrt{22} = 4.69 \text{ ms}$$

RESPOSTA

Total: 60 ms com $\sigma = 7$ ms; com a melhoria, $\sigma = 4.69$ ms (33% menor).

Para reduzir a variação de ponta a ponta, ataque primeiro a etapa mais variável: as variâncias se somam ao quadrado, então a maior domina. Se as chamadas fossem feitas em *paralelo*, a latência seria o máximo das três, não a soma, e a análise muda.

Exercício 2.7 • Variância de uma Soma (Tempo Total)

Uma requisição passa por processamento no servidor (média 25 ms, desvio padrão 4.5 ms) e por transmissão na rede (média 18 ms, desvio padrão 3 ms), com tempos independentes. Qual o desvio padrão do tempo total?

Espaço para cálculo

2.8 Funções Não Lineares e Decisão por Valor Esperado

A linearidade da esperança tem um limite. Para g não linear, em geral $E[g(X)] \neq g(E[X])$: é preciso aplicar g a cada valor *antes* de ponderar pelas probabilidades. Substituir a variável pela sua média e então aplicar a função é um dos erros mais comuns em planejamento de capacidade, e o exemplo a seguir mostra o tamanho do erro.

Exemplo (capacidade reservada): a demanda diária X por instâncias de GPU tem $p(0) = 0.1$, $p(1) = 0.3$, $p(2) = 0.4$, $p(3) = 0.2$. Uma empresa reserva 2 instâncias por dia a 30 reais cada (pagas mesmo sem uso) e cobra 80 reais por instância usada. O uso é $\min(X, 2)$, logo

$$E[\text{lucro}] = 80 E[\min(X, 2)] - 60 = 80(0 \cdot 0.1 + 1 \cdot 0.3 + 2 \cdot 0.6) - 60 = 60 \text{ reais}$$

Usar $g(E[X]) = 80 \min(1.7, 2) - 60 = 76$ reais superestimaria o lucro, porque ignora os dias de demanda baixa.

INTUIÇÃO Desigualdade de Jensen

Forma de g	Exemplos	Resultado
convexa (curvada para cima)	x^2, e^x , tempo de fila $\approx 1/(1 - \rho)$	$E[g(X)] \geq g(E[X])$
côncava (curvada para baixo)	$\log x, \min(x, s)$	$E[g(X)] \leq g(E[X])$

A média de pontos sobre uma curva convexa fica acima da curva. A capacidade usada, $\min(X, 2)$, é côncava, porque a demanda acima de 2 se perde; trocá-la pela média superestima o uso. O tamanho da diferença cresce com a variabilidade de X : se a demanda fosse sempre 1.7, não haveria diferença.

Para $g(x) = x^2$, a diferença é exatamente a variância, $E[X^2] - (E[X])^2 = \text{Var}(X)$: a fórmula computacional da variância vista de outro ângulo.

NA COMPUTAÇÃO Jensen em sistemas

- **Algoritmo quadrático com entrada de tamanho aleatório N :** $E[N^2] = \text{Var}(N) + (E[N])^2$. Entradas variáveis custam mais que entradas fixas de mesmo tamanho médio.
- **Filas:** o tempo de resposta cresce de forma convexa com a utilização, aproximadamente como $1/(1 - \rho)$. Uma carga que oscila entre 50% e 90% produz tempo médio muito pior que uma carga constante de 70%.
- **Estimação:** s subestima σ mesmo com s^2 sem viés, porque a raiz é côncava.

CUIDADO Quando decidir só pela média não basta

Escolher a opção de maior lucro esperado é a regra racional quando a decisão se repete muitas vezes e as perdas individuais são toleráveis, porque no longo prazo a média é o que se acumula. Quando uma única perda é catastrófica (perder um banco de dados inteiro, violar um contrato com multa alta), entram variância, percentis e pior caso. A mesma tensão aparece ao escolher o nível de significância de um teste: o custo dos dois tipos de erro raramente é o mesmo.

CONEXÕES

- 2.5** $E[X^2] - (E[X])^2 = \text{Var}(X)$.
- 5.4** fila M/M/1 e sua forma convexa.
- 7.5** viés de s como estimador de σ .
- 8.2** custos diferentes para os dois tipos de erro.

▼ Entendendo a fórmula, termo a termo

$$E[g(X)] = \sum_x g(x) p(x), \quad E[aX + b] = aE[X] + b$$

 $g(x)$ ← Consequência (custo, lucro, potência) associada a cada valor x . $p(x)$ ← Probabilidade de cada valor: o peso não muda ao aplicar g . $g(E[X])$ ← Aplicar g à média: só coincide com $E[g(X)]$ se g for linear.

De onde vem, passo a passo

1. $Y = g(X)$ vale $g(x)$ exatamente quando $X = x$, o que ocorre com probabilidade $p(x)$.
2. Pela definição de esperança aplicada a Y : $E[Y] = \sum_x g(x) p(x)$.
3. Se $g(x) = ax + b$: $\sum (ax + b)p(x) = a \sum x p(x) + b \sum p(x) = aE[X] + b$.
4. Se g é convexa (como x^2), $E[g(X)] \geq g(E[X])$ (desigualdade de Jensen).

EXEMPLO RESOLVIDO

Tempo de um algoritmo quadrático com entrada aleatória

Um algoritmo de complexidade quadrática leva $T = 10n^2$ ms para processar uma entrada de n mil registros. O tamanho da entrada é 1 mil ou 3 mil registros, com igual probabilidade.

DADOS

- $P(n = 1) = P(n = 3) = 0.5$ (em milhares)
- $g(n) = 10n^2$ ms

O QUE SE PEDE

O tempo médio $E[T]$.

RESOLUÇÃO PASSO A PASSO

1

O atalho errado

$E[n] = 0.5(1) + 0.5(3) = 2$ mil. Aplicar a função na média dá $g(E[n]) = 10 \times 2^2 = 40$ ms. Isso não é $E[T]$.

2 Aplicar g a cada valor

O jeito certo: calcule $g(n)$ para cada valor e pondere pelas probabilidades:

$$E[g(n)] = \sum g(x) p(x) = 10(1^2)(0.5) + 10(3^2)(0.5) = 5 + 45 = 50 \text{ ms}$$

3 Conferir pela variância

$E[n^2] = \text{Var}(n) + (E[n])^2$. Aqui $\text{Var}(n) = 1$ (os valores estão a 1 da média), logo $E[n^2] = 1 + 4 = 5$ e $E[T] = 10 \times 5 = 50 \text{ ms}$ ✓.

RESPOSTA $E[T] = 50 \text{ ms}$, e não 40 ms.

Para funções convexas (como n^2), $E[g(X)] \geq g(E[X])$ (desigualdade de Jensen). A diferença é $10 \cdot \text{Var}(n)$: quanto mais o tamanho da entrada varia, mais o atalho erra. Estimar capacidade de um sistema pelo "tamanho médio de entrada" subestima o tempo de CPU.

Exercício 2.8 • Lucro Esperado com Estoque ($E[g(X)]$)

A demanda diária X de clientes por instâncias de GPU tem a distribuição abaixo. Uma empresa reserva 2 instâncias por dia a 25 reais cada (pagas mesmo sem uso) e cobra 75 reais por instância usada. Qual o lucro diário esperado?

DEMANDA x	0	1	2	3
$P(X = x)$	0.3	0.25	0.25	0.2

Espaço para cálculo

Exercícios de Fixação com Soluções Comentadas

3 Questões Resolvidas

Exercício 2.1: Determinação de Constante e Esperança de VAD

A quantidade X de pacotes corrompidos que um switch de rede recebe a cada milissegundo tem função de probabilidade dada por: $P(X = x) = c \cdot (4 - x)$, para $x \in \{0, 1, 2, 3\}$, e $P(X = x) = 0$ caso contrário.

- (a) Encontre a constante de normalização c .
- (b) Calcule o número médio esperado de pacotes corrompidos $E[X]$.

Espaço para cálculo

Exercício 2.2: Construção da FDA e Percentis

Com base na distribuição do Exercício 2.1 ($p(0) = 0.4, p(1) = 0.3, p(2) = 0.2, p(3) = 0.1$):

- (a) Construa analiticamente a FDA $F(x)$.
- (b) Determine $P(1 \leq X \leq 2)$.
- (c) Encontre a Mediana e o 80º percentil.

Espaço para cálculo

Exercício 2.3: Variância e Custo Operacional Linearizado

Para a mesma V.A. X das questões anteriores ($E[X] = 1.0$):

- (a) Calcule a variância $Var(X)$ e o desvio padrão σ_X .
- (b) Suponha que o custo diário de retransmissão de pacotes seja dado pela relação linear $C = 50X + 120$ reais. Calcule o custo médio esperado $E[C]$ e o desvio padrão do custo σ_C .

Espaço para cálculo

Módulo 3: Modelos Discretos de Probabilidade

Uniforme discreta (sorteios, viés do módulo, hashing), Bernoulli e binomial (perda de pacotes, quórum, códigos corretores), geométrica, Poisson (chegadas de requisições, superposição), aproximação binomial-Poisson, escolha de modelo e dimensionamento de testes.

No Módulo 2, a FP do número de pacotes perdidos foi montada à mão, somando sequências. Este módulo mostra que poucas situações se repetem tanto que suas distribuições ganharam nome e fórmula fechada: sorteio justo (uniforme), contagem de sucessos em tentativas independentes (binomial), contagem de eventos raros ao longo do tempo (Poisson) e espera pelo primeiro sucesso (geométrica). Reconhecer a situação poupa as contas, mas o ponto principal é outro: cada modelo é uma lista de hipóteses sobre o sistema, e saber quais hipóteses estão sendo feitas é o que permite perceber quando o modelo não serve. Esses modelos voltam no Módulo 5, onde cada um tem um parente contínuo, e no Módulo 9, onde binomial e Poisson dão os limites dos gráficos de controle por atributos.

3.1 Distribuição Uniforme Discreta

O modelo mais simples é o de ignorância simétrica: não há razão para preferir nenhum resultado. A variável X assume k valores inteiros equiprováveis no intervalo $[a, b]$, com $k = b - a + 1$. É o modelo de um sorteio justo: um dado, a escolha de um servidor ao acaso num pool, um índice aleatório num vetor, um `randint(a, b)`.

DISTRIBUIÇÃO UNIFORME DISCRETA $U(a, b)$

$$P(X = x) = \frac{1}{k} = \frac{1}{b - a + 1}, \quad \forall x \in \{a, a + 1, \dots, b\}$$

$$E[X] = \frac{a + b}{2}, \quad \text{Var}(X) = \frac{(b - a + 1)^2 - 1}{12} = \frac{k^2 - 1}{12}$$

▼ Equação desmontada, variável por variável

$$P(X = x) = \frac{1}{k} = \frac{1}{b - a + 1}$$

 a

← menor valor possível (ex.: 1)

 b

← maior valor possível (ex.: 6)

 $k = b - a + 1$ ← quantidade de valores (ex.: $6 - 1 + 1 = 6$) $\frac{1}{k}$

← cada valor tem a mesma chance (ex.: 1/6)

$$E[X] = \frac{a + b}{2}, \quad Var(X) = \frac{k^2 - 1}{12}$$

 $\frac{a+b}{2}$

← média: ponto do meio (ex.: 3.5)

 $k^2 - 1$

← cresce com o quadrado do número de valores

12

← constante da dedução (ex.: $(36 - 1)/12 = 2.917$)**DEDUÇÃO Média e variância**

A média é o ponto do meio, por simetria. Para a variância, aplica-se a fórmula computacional a $\{1, \dots, k\}$, com $E[X^2] = \frac{(k+1)(2k+1)}{6}$ (soma dos quadrados):

$$Var = \frac{(k+1)(2k+1)}{6} - \frac{(k+1)^2}{4} = \frac{k^2 - 1}{12}$$

Deslocar o intervalo para $[a, b]$ não muda nada, porque somar uma constante não altera a dispersão. O denominador 12 reaparece na uniforme contínua, que é o limite desta quando os valores ficam muito próximos.

A uniforme discreta é a matéria-prima de toda a aleatoriedade em software, e por isso é onde erros sutis custam caro. Dois erros clássicos de implementação mostram como a contagem do Módulo 1 serve para provar que um algoritmo está errado:

CUIDADO Sorteios que parecem uniformes e não são

	<code>rand() % n</code>	Embaralhamento ingênuo
O que faz	sorteia de 0 a $n - 1$ pelo resto da divisão	para cada posição, troca com um índice sorteado em $\{0, \dots, n - 1\}$
Problema	se o alcance M do <code>rand</code> não é múltiplo de n , os restos não se dividem igualmente. Com $M = 32768$ e $n = 10\,000$, os valores 0 a 2767 aparecem 4 vezes por ciclo e os demais 3: alguns servidores recebem 33% mais tráfego	gera n^n sequências de sorteio; como n^n não é múltiplo de $n!$, é impossível que todas as permutações saiam com a mesma frequência
Correção	rejeição: descartar os valores do "resto" incompleto e sortear de novo; o número de tentativas é geométrico	Fisher-Yates: na posição i , de trás para frente, sorteia em $\{0, \dots, i\}$; cada permutação sai com probabilidade $1/n!$

NA COMPUTAÇÃO O ideal de uma função de hash

Uma boa função de hash espalha as chaves como se cada uma caísse num balde uniforme e independente. Essa suposição ("hashing uniforme simples") é o que dá tempo esperado $O(1)$ às tabelas hash e sustenta as contas de colisão do paradoxo do aniversário. Verificar se dados que deveriam ser uniformes de fato são (as faces de um dado virtual, a distribuição de chaves entre shards) é uma aplicação direta do teste qui-quadrado de aderência.

CONEXÕES

- 1.8** contagem e paradoxo do aniversário.
- 3.5** geométrica: tentativas da rejeição.
- 5.1** uniforme contínua.
- 8.5** testar se dados são uniformes.

▼ Entendendo a fórmula, termo a termo

$$E[X] = \frac{a+b}{2}, \quad \text{Var}(X) = \frac{k^2 - 1}{12}$$

$$\frac{a+b}{2}$$

← Ponto médio: a distribuição é simétrica em torno dele.

$$k = b - a + 1$$

← Quantidade de valores inteiros entre a e b .

$$k^2 - 1$$

← Cresce com o quadrado do número de valores: mais valores, mais dispersão.

De onde vem, passo a passo

1. Basta fazer o caso $X \in \{1, \dots, k\}$, porque somar uma constante não muda a variância.
2. $E[X] = \frac{1}{k} \sum x = \frac{k+1}{2}$ e $E[X^2] = \frac{1}{k} \sum x^2 = \frac{(k+1)(2k+1)}{6}$.
3. $\text{Var} = \frac{(k+1)(2k+1)}{6} - \frac{(k+1)^2}{4} = \frac{(k+1)[2(2k+1)-3(k+1)]}{12} = \frac{(k+1)(k-1)}{12}$.

EXEMPLO RESOLVIDO

Balanceador aleatório entre 20 servidores

Um balanceador envia cada requisição a um de 20 servidores numerados de 1 a 20, escolhido ao acaso com probabilidades iguais.

DADOS

- $a = 1, b = 20$

O QUE SE PEDE

(a) $P(X \leq 5)$, a chance de a requisição cair nos 5 primeiros servidores (que ficam numa zona de disponibilidade separada); (b) $E[X]$ e $\text{Var}(X)$; (c) os mesmos para um dado comum.

RESOLUÇÃO PASSO A PASSO

1

Contar os valores

$k = b - a + 1 = 20 - 1 + 1 = 20$. O "+1" inclui as duas pontas (o clássico erro de cerca, ou *off-by-one*). Cada valor tem probabilidade $1/k = 1/20 = 0.05$.

2 Probabilidade de uma faixa

$X \leq 5$ inclui os valores 1, 2, 3, 4, 5, ou seja, 5 valores de 20:

$$P(X \leq 5) = \frac{5}{20} = 0.25$$

3 Média e variância

$$E[X] = \frac{a+b}{2} = \frac{1+20}{2} = 10.5, \quad \text{Var}(X) = \frac{k^2-1}{12} = \frac{400-1}{12} = 33.25$$

$$\sigma = \sqrt{33.25} = 5.77 \text{ servidores.}$$

4 Dado comum ($k = 6$)

$$E[X] = \frac{1+6}{2} = 3.5, \quad \text{Var}(X) = \frac{36-1}{12} = 2.917$$

RESPOSTA (a) 0.25; (b) 10.5 e 33.25; (c) 3.5 e 2.917.

Quando usar: só quando há razão para equiprobabilidade (sorteio justo, simetria). E o sorteio tem que ser feito direito: `rand() % 20` com um gerador de faixa não múltipla de 20 introduz viés (veja o aprofundamento de 3.1).

Exercício 3.1 • Uniforme Discreta: Variância

Um gerador seleciona ao acaso um endereço inteiro de memória entre 1 e 6 (inclusive), todos equiprováveis. Calcule a variância do endereço sorteado.

Espaço para cálculo

3.2 Ensaio de Bernoulli e Distribuição Binomial

O enlace dos Módulos 1 e 2 tem uma estrutura que se repete em toda parte: várias tentativas, cada uma com dois desfechos, todas com a mesma chance e sem influência entre si. Um **ensaio de Bernoulli** tem só dois desfechos: "sucesso" com probabilidade p e "fracasso" com probabilidade $q = 1 - p$. Um pacote chega ou se perde; uma requisição dá certo ou falha; um bit é transmitido certo ou invertido.

A **Distribuição Binomial** $B(n, p)$ conta o número de sucessos X em n ensaios de Bernoulli *independentes* e com o *mesmo* p :

DISTRIBUIÇÃO BINOMIAL $X \sim B(n, p)$

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k} = \frac{n!}{k!(n-k)!} p^k (1 - p)^{n-k}, \quad k \in \{0, 1, 2, \dots, n\}$$

$$E[X] = np, \quad \text{Var}(X) = np(1 - p) = npq$$

▼ Equação desmontada, variável por variável

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

$P(X = k)$ ← o que se calcula: probabilidade de exatamente k sucessos

$\binom{n}{k}$ ← combinação: $n!/(k!(n-k)!)$, quantas sequências têm k sucessos

n ← nº de ensaios (ex.: 10 requisições)

k ← nº de sucessos desejado (ex.: 2)

p ← probabilidade de sucesso em 1 ensaio (ex.: 0.05)

p^k ← os k sucessos acontecendo

$1 - p$ ← probabilidade de fracasso

$(1 - p)^{n-k}$ ← os $n - k$ fracassos acontecendo

$$E[X] = np, \quad \text{Var}(X) = np(1 - p)$$

np ← nº médio de sucessos (ex.: $10 \times 0.05 = 0.5$)

$np(1 - p)$ ← variância (ex.: $0.5 \times 0.95 = 0.475$)

DEDUÇÃO De onde vem a fórmula

1. Uma sequência específica com k sucessos e $n - k$ fracassos tem probabilidade $p^k q^{n-k}$, pela independência.
2. Todas as sequências com o mesmo k têm essa mesma probabilidade, e há $\binom{n}{k}$ delas: escolher as posições dos sucessos.
3. Pelo axioma 3, soma-se: $\binom{n}{k} p^k q^{n-k}$.

O enlace com 3 pacotes era $B(3, 0.1)$, e os números 0.729, 0.243, 0.027 e 0.001 saem direto da fórmula.

DEDUÇÃO Média e variância sem nenhuma soma

Pela decomposição em indicadoras, $X = I_1 + \dots + I_n$, cada I_i com média p e variância $p - p^2 = p(1 - p)$. Pela linearidade, $E[X] = np$; pela soma de variâncias de independentes, $Var(X) = np(1 - p)$. A variância é máxima em $p = 0.5$ (incerteza máxima em cada ensaio) e vai a zero quando p se aproxima de 0 ou 1.

Dividindo X por n , a proporção de sucessos $\hat{p} = X/n$ tem média p e variância $p(1 - p)/n$. Esse resultado é a base do intervalo de confiança para proporções, do teste de proporção e dos limites do gráfico p : os três usam este mesmo $\sqrt{p(1 - p)/n}$.

NA COMPUTAÇÃO Quórum e códigos corretores: " k de n "

- **Quórum:** um cluster com 5 réplicas, cada uma no ar com probabilidade 0.99, mantém quórum se pelo menos 3 estiverem vivas: $P(X \geq 3) = \sum_{k=3}^5 \binom{5}{k} 0.99^k 0.01^{5-k} \approx 0.99999$.
- **Códigos corretores:** um bloco de n bits num canal com taxa de erro p por bit tem número de erros $B(n, p)$, e um código que corrige até t erros falha com probabilidade $P(X > t)$. Com $n = 1000$ e $p = 10^{-3}$, $P(X > 1) \approx 0.26$, mas $P(X > 4) \approx 0.004$: poucos bits de redundância a mais reduzem a falha em ordens de grandeza, porque a cauda da binomial cai muito rápido.

CUIDADO As três hipóteses, e quando falham

Hipótese	Violação típica	Consequência
n fixo	não se sabe quantas tentativas houve	usar Poisson
independência	perdas em rajadas num enlace congestionado	variância real maior que npq (superdispersão); modelos como o de Gilbert-Elliott, com estados "bom" e "ruim", tratam isso condicionando no estado
p constante	servidores com taxas de erro diferentes	a contagem deixa de ser binomial

CONEXÕES

- 1.7 confiabilidade " k de n ".
- 2.2 a conta feita à mão no enlace.
- 5.8 aproximação normal para n grande.
- 7.4 IC para proporção.
- 8.8 teste de proporção.
- 9.4 gráfico p .

▼ Entendendo a fórmula, termo a termo

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

 p^k ← Probabilidade de k sucessos específicos (independentes). $(1 - p)^{n-k}$ ← Probabilidade dos $n - k$ fracassos restantes. $\binom{n}{k}$ ← Número de maneiras de posicionar os k sucessos entre os n ensaios.

De onde vem, passo a passo

1. Uma sequência específica, como S S F F F com $k = 2$ e $n = 5$, tem probabilidade $p \cdot p \cdot q \cdot q \cdot q = p^2 q^3$ (independência).
2. Qualquer outra sequência com k sucessos tem a mesma probabilidade $p^k q^{n-k}$.
3. As sequências são disjuntas e há $\binom{n}{k}$ delas: some-as.
4. Média e variância: X é a soma de n indicadoras de Bernoulli, cada uma com média p e variância $p(1 - p)$; somando (independência), $E = np$ e $Var = np(1 - p)$.

EXEMPLO RESOLVIDO

Distribuição completa de uma binomial

Um cliente faz 5 requisições independentes a um serviço que falha em 10% das requisições.

DADOS

- $n = 5$ ensaios
- $p = 0.1$ (sucesso = a requisição falhar)

- requisições independentes, p constante

O QUE SE PEDE

(a) $P(X = 1)$ explicando cada termo; (b) a tabela completa; (c) $P(X \geq 2)$; (d) $E[X]$ e $Var(X)$.

RESOLUÇÃO PASSO A PASSO

1 Conferir as hipóteses da binomial

Número fixo de ensaios ($n = 5$), dois desfechos (falha ou não), p constante e ensaios independentes. As quatro valem. (Em "sucesso", a palavra só indica o evento contado, mesmo que ele seja uma falha.)

2 Uma sequência específica

A sequência FOOOO (1ª falha, as outras ok) tem probabilidade

$$0.1 \times 0.9 \times 0.9 \times 0.9 \times 0.9 = 0.1^1 \times 0.9^4 = 0.06561$$

3 Quantas sequências dão $X = 1$

A falha pode estar em qualquer uma das 5 posições: $\binom{5}{1} = 5$ sequências, todas com a mesma probabilidade. Logo:

$$P(X = 1) = \binom{5}{1}(0.1)^1(0.9)^4 = 5 \times 0.06561 = 0.32805$$

4 Tabela completa

k	0	1	2	3	4	5
$\binom{5}{k}$	1	5	10	10	5	1
$P(X = k)$	0.59049	0.32805	0.07290	0.00810	0.00045	0.00001

5 "Pelo menos 2": complemento

$$P(X \geq 2) = 1 - P(0) - P(1) = 1 - 0.59049 - 0.32805 = 0.08146$$

6 Média e variância

$$E[X] = np = 5(0.1) = 0.5, \quad Var(X) = np(1 - p) = 5(0.1)(0.9) = 0.45$$

RESPOSTA (a) 0.32805; (c) 0.08146; (d) 0.5 e 0.45.

Quando NÃO usar: se as falhas vêm em rajadas (o serviço cai por um minuto e todas as requisições desse minuto falham), elas não são independentes e a binomial subestima a chance de várias falhas juntas. Um *retry* imediato contra um serviço em pane costuma falhar de novo pelo mesmo motivo.

Exercício 3.2 • Binomial: Tolerância a Perdas

Cada pacote se perde, independentemente, com $p = 0.09$. Enviam-se $n = 11$ pacotes; $X \sim B(11, 0.09)$ é o número de perdas. Um código corretor recupera a rajada sem retransmissão se $X \leq 1$. Qual a probabilidade de recuperação?

Espaço para cálculo

3.3 Distribuição de Poisson

A binomial exige saber n , o número de tentativas. Muitas contagens não têm um n natural: quantas requisições chegam a um servidor no próximo segundo? Há milhões de usuários que *poderiam* enviar uma requisição, cada um com chance minúscula de fazê-lo naquele segundo. A Distribuição de Poisson conta ocorrências de eventos que acontecem de forma independente ao longo de um contínuo (tempo, espaço, volume de dados), a uma taxa média constante: requisições chegando a um servidor por segundo, erros de leitura por terabyte lido, mensagens numa fila por minuto, crashes por semana.

DISTRIBUIÇÃO DE POISSON $X \sim \text{Poisson}(\lambda)$

$$P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}, \quad k \in \{0, 1, 2, 3, \dots\}$$

$$E[X] = \lambda, \quad \text{Var}(X) = \lambda, \quad \sigma_X = \sqrt{\lambda}$$

▼ Equação desmontada, variável por variável

$$P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

$P(X = k)$ ← o que se calcula: probabilidade de exatamente k ocorrências

λ ← número médio de ocorrências no intervalo (ex.: 2 chamadas/hora)

k ← número de ocorrências desejado (ex.: 3)

$e^{-\lambda}$ ← probabilidade de zero ocorrências (ex.: $e^{-2} = 0.1353$)

λ^k ← peso de ter k ocorrências (ex.: $2^3 = 8$)

$k!$ ← fatorial de k (ex.: $3! = 6$)

$$E[X] = \lambda, \quad Var(X) = \lambda, \quad \sigma_X = \sqrt{\lambda}$$

λ ← é ao mesmo tempo a média e a variância

$\sqrt{\lambda}$ ← desvio padrão (ex.: $\sqrt{2} = 1.41$)

Propriedades do Processo de Poisson:

- **Estacionariedade:** a probabilidade de uma ocorrência num subintervalo Δt depende só da duração: $\lambda \Delta t + o(\Delta t)$.
- **Independência:** as contagens em intervalos disjuntos são independentes.
- **Ordem única:** duas ou mais ocorrências no mesmo instante infinitesimal têm probabilidade desprezível.
- **Aditividade:** se $X_1 \sim \text{Poisson}(\lambda_1)$ e $X_2 \sim \text{Poisson}(\lambda_2)$ são independentes, $X_1 + X_2 \sim \text{Poisson}(\lambda_1 + \lambda_2)$.

INTUIÇÃO As propriedades geram a fórmula

1. Divida o intervalo em n pedaços minúsculos.
2. Pela ordem única, cada pedaço tem no máximo uma ocorrência; pela estacionariedade, cada um tem ocorrência com a mesma probabilidade λ/n ; pela independência, os pedaços não se influenciam.
3. Isso é uma binomial $B(n, \lambda/n)$, e fazendo $n \rightarrow \infty$ obtém-se a Poisson.

Por isso a Poisson é o modelo natural sempre que muitos agentes independentes, cada um com chance pequena de agir, são somados.

O único parâmetro, λ , é ao mesmo tempo a média e a variância, e ele se escala com o intervalo. Fluxos de Poisson podem ser combinados e divididos sem sair do modelo:

NA COMPUTAÇÃO Operações com fluxos de requisições

Operação	Regra	Exemplo
Escala de tempo	taxa r por segundo dá Poisson(rt) em t segundos	escala a taxa, não a probabilidade: $P(\geq 1 \text{ em } 2s) = 1 - e^{-2r}$, não o dobro de $1 - e^{-r}$
Superposição	fluxos independentes somados dão Poisson com taxas somadas	vários clientes chegando ao mesmo balanceador
Afinamento	manter cada evento com probabilidade p dá Poisson($p\lambda$)	só as requisições com erro; um balanceador aleatório divide um fluxo em fluxos independentes

É o modelo padrão de chegadas em teoria de filas (M/M/1, M/M/c), em dimensionamento de servidores e em simulações de carga.

Contar eventos e medir o tempo entre eles são duas faces do mesmo modelo. "Nenhum evento em t " é $P(X = 0) = e^{-\lambda t}$, que é exatamente a chance de o tempo até o próximo evento passar de t . Esse tempo segue a distribuição exponencial com média $1/\lambda$, e as propriedades da caixa acima são o que dá à exponencial a falta de memória.

CUIDADO Média igual à variância: um teste rápido

Em dados de contagem, compare média e variância amostrais. Variância muito maior que a média indica que alguma hipótese falhou: tráfego em rajadas, picos de horário (taxa não constante) ou eventos que disparam outros (um erro gerando retries, que violam a independência). Tráfego real de redes costuma ser assim em escalas de tempo longas, o que motivou os modelos de "tráfego autossimilar". A mesma superdispersão faz os limites do gráfico c ficarem estreitos demais no monitoramento.

CONEXÕES

3.4 a conta do limite binomial $\rightarrow$ Poisson.

5.4 tempo entre eventos: exponencial.

5.5 falta de memória.

6.3 média e variância amostrais.

9.8 superdispersão no gráfico c .

▼ Entendendo a fórmula, termo a termo

$$P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}$$

λ

$\leftarrow$ Número médio de ocorrências no intervalo.

$e^{-\lambda}$

$\leftarrow$ Probabilidade de zero ocorrências; também normaliza a soma para 1.

$\lambda^k/k!$

$\leftarrow$ Peso relativo de observar exatamente k ocorrências.

De onde vem, passo a passo

1. Divida o intervalo em n pedaços minúsculos; em cada um ocorre um evento com probabilidade λ/n (no máximo um). Isso é uma $B(n, \lambda/n)$.
2. $P(X = k) = \binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k}$.
3. Quando $n \rightarrow \infty$: $\binom{n}{k}/n^k \rightarrow 1/k!$, $\left(1 - \frac{\lambda}{n}\right)^n \rightarrow e^{-\lambda}$ e $\left(1 - \frac{\lambda}{n}\right)^{n-k} \rightarrow 1$.
4. Resultado: $\frac{\lambda^k e^{-\lambda}}{k!}$. A soma é 1 porque $\sum \lambda^k/k! = e^\lambda$ (série de Taylor).

EXEMPLO RESOLVIDO**Capacidade de um worker de fila**

Jobs chegam a uma fila de forma aleatória e independente, e um worker consegue processar no máximo 3 jobs por minuto. O excedente acumula na fila.

DADOS

- média: $\lambda = 2$ jobs por minuto
- capacidade: 3 por minuto

O QUE SE PEDE

(a) a probabilidade de 0 a 3 jobs chegarem num minuto; (b) a chance de o worker ficar sobrecarregado.

RESOLUÇÃO PASSO A PASSO

1 Escolher o modelo

Contagem de eventos num intervalo de tempo, sem máximo natural, ocorrendo de forma independente a uma taxa constante: **Poisson** com $\lambda = 2$.

2 Calcular os termos

$$P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}, \quad e^{-2} = 0.1353$$

- $P(0) = 0.1353 \times 1/1 = 0.1353$
- $P(1) = 0.1353 \times 2/1 = 0.2707$
- $P(2) = 0.1353 \times 4/2 = 0.2707$
- $P(3) = 0.1353 \times 8/6 = 0.1804$

Atalho (e o jeito certo de programar, sem fatoriais gigantes): cada termo é o anterior vezes λ/k .

3 Sobrecarga: complemento

Sobrecarga é $X \geq 4$, um conjunto infinito. Use o complemento:

$$P(X \geq 4) = 1 - (0.1353 + 0.2707 + 0.2707 + 0.1804) = 1 - 0.8571 = 0.143$$

RESPOSTA O worker fica sobrecarregado em cerca de 14% dos minutos.

Mesmo com capacidade 50% acima da média (3 contra 2), a sobrecarga é frequente. Variabilidade, não só média, define o dimensionamento, e é por isso que sistemas de fila são provisionados com folga e com autoscaling.

Exercício 3.3 • Poisson: Contagem em um Intervalo

Requisições com erro chegam a um servidor segundo Poisson com taxa $\lambda = 2/h$. Qual a probabilidade de exatamente 2 erros em 3 h?

Espaço para cálculo

3.4 Teorema de Aproximação da Binomial pela Poisson

A construção da Poisson a partir de pedaços minúsculos sugere o enunciado formal: uma binomial com muitas tentativas e chance pequena em cada uma é praticamente uma Poisson. Quando o número de ensaios n é grande ($n \geq 20$, idealmente $n \geq 100$) e p é muito pequeno ($p \leq 0.05$), com $np = \lambda$ moderado ($np \leq 10$), a Binomial converge para a Poisson:

$$\lim_{n \rightarrow \infty, p \rightarrow 0} \binom{n}{k} p^k (1-p)^{n-k} = \frac{e^{-\lambda} \lambda^k}{k!}, \quad \text{onde } \lambda = np$$

▼ Equação desmontada, variável por variável

$$\binom{n}{k} p^k (1-p)^{n-k} \approx \frac{e^{-\lambda} \lambda^k}{k!}, \quad \lambda = np$$

lado esquerdo ← binomial exata

lado direito ← Poisson aproximada

 n ← nº de ensaios, grande (ex.: 500) p ← probabilidade de sucesso, pequena (ex.: 0.004) $\lambda = np$ ← mesma média nos dois modelos (ex.: 2)**DEDUÇÃO** A prova em duas linhas

1. Com $p = \lambda/n$: $\binom{n}{k} p^k = \frac{n(n-1)\cdots(n-k+1)}{n^k} \cdot \frac{\lambda^k}{k!}$, e a fração tende a 1 para k fixo.

2. $(1 - \lambda/n)^{n-k} \rightarrow e^{-\lambda}$, pelo limite fundamental $(1 + x/n)^n \rightarrow e^x$.

É o mesmo limite que transforma juros compostos em juros contínuos, e a mesma aproximação $1 - x \approx e^{-x}$ do paradoxo do aniversário.

NA COMPUTAÇÃO A lei dos eventos raros

- **Unifica situações:** bits invertidos num arquivo de vários gigabytes, cliques num anúncio entre milhões de exibições, falhas de disco num datacenter com milhares de discos. Em todas, a contagem é aproximadamente Poisson com $\lambda = np$, e só o produto np importa.
- **Colisões:** o número de pares de chaves que colidem numa tabela hash é aproximadamente Poisson com $\lambda = \binom{n}{2}/m$, e $P(\text{nenhuma colisão}) \approx e^{-\lambda}$ é a fórmula do aniversário vista pela Poisson.
- **Evita contas impossíveis:** com $n = 10^9$, calcular $\binom{n}{k}$ estoura a precisão numérica; a Poisson dá a resposta com uma exponencial.

CUIDADO O que importa é p pequeno, não só n grande

	Binomial	Poisson
Média	np	np
Variância	$np(1 - p)$	np

As variâncias coincidem quando $1 - p \approx 1$. O erro total entre as duas distribuições é limitado por cerca de np^2 (desigualdade de Le Cam): com $n = 200$ e $p = 0.01$, no máximo 0.02. Quando p não é pequeno mas n é grande, a aproximação adequada é outra, a normal.

CONEXÕES

- 1.8** paradoxo do aniversário.
- 5.8** aproximação normal da binomial.
- 7.3** TCL, de onde vem a normal.

▼ Entendendo a fórmula, termo a termo

$$B(n, p) \approx \text{Poisson}(\lambda = np)$$

- $\lambda = np$ ← Mantém a mesma média nos dois modelos.
- n grande ← Muitas oportunidades de ocorrência.
- p pequeno ← Cada oportunidade é rara; então $1 - p \approx e^{-p}$.

De onde vem, passo a passo

- Para p pequeno, $\ln(1 - p) \approx -p$, logo $(1 - p)^n \approx e^{-np} = e^{-\lambda}$.
- Para k pequeno frente a n , $\binom{n}{k} p^k \approx \frac{n^k}{k!} p^k = \frac{\lambda^k}{k!}$.
- Juntando: $\binom{n}{k} p^k (1 - p)^{n-k} \approx \frac{\lambda^k e^{-\lambda}}{k!}$.
- Note que as variâncias diferem: $np(1 - p)$ contra np . Elas são próximas justamente quando p é pequeno.

EXEMPLO RESOLVIDO Quão boa é a aproximação?

Um lote de 200 pacotes atravessa um enlace em que cada pacote é corrompido com probabilidade 1%, independentemente. Queremos $P(X = 3)$.

DADOS

- $n = 200, p = 0.01$

O QUE SE PEDE

Comparar a binomial exata com a aproximação de Poisson.

RESOLUÇÃO PASSO A PASSO

1 Conferir as condições

n grande (≥ 50) e p pequeno (≤ 0.1): a aproximação deve funcionar. Parâmetro: $\lambda = np = 200 \times 0.01 = 2$.

2 Binomial exata

$$\binom{200}{3} (0.01)^3 (0.99)^{197} = 1\,313\,400 \times 10^{-6} \times 0.1381 = 0.18136$$

3 Poisson

$$\frac{e^{-2} 2^3}{3!} = \frac{0.1353 \times 8}{6} = 0.18045$$

4 Comparar

Erro absoluto: $0.18136 - 0.18045 = 0.0009$, ou 0.5% do valor.

RESPOSTA Binomial 0.18136; Poisson 0.18045.

A aproximação dispensa $\binom{200}{3}$ e potências de 197. Com n na casa dos milhões (bits de um arquivo), o cálculo exato estouraria a precisão de ponto flutuante, e a Poisson é o caminho prático.

Exercício 3.4 • Aproximação da Binomial pela Poisson

Um backup tem $n = 375$ arquivos, cada um com probabilidade $p = 0.004$ de corrupção silenciosa. Use a aproximação de Poisson para estimar $P(X = 0)$.

Espaço para cálculo

3.5 Como Escolher o Modelo

Diante de um problema real, a pergunta não é "qual fórmula usar", e sim "que mecanismo gera estes números". Cada modelo do módulo corresponde a um mecanismo, e a tabela abaixo organiza a escolha pelas perguntas que o distinguem:

PERGUNTA	MODELO	EXEMPLO EM COMPUTAÇÃO
Há n tentativas independentes, cada uma sucesso/fracasso com o mesmo p ?	Binomial	falhas em 20 requisições a um serviço com taxa de erro estável
Conta-se ocorrências ao longo de um contínuo (tempo, espaço, volume de dados), sem máximo natural?	Poisson	requisições por segundo, erros de leitura por TB
Retiradas sem reposição de um conjunto pequeno?	Hipergeométrica (seção 1.8)	auditar 3 de 12 servidores, 2 deles mal configurados
Todos os k valores inteiros são equiprováveis?	Uniforme discreta	servidor sorteado num pool, índice aleatório
Conta-se tentativas até o primeiro sucesso?	Geométrica	retransmissões até o pacote chegar

INTUIÇÃO Itens contra ocorrências

"Quantos arquivos estão corrompidos?"	"Quantos bits errados há no arquivo?"
cada arquivo é sim ou não; há no máximo n	um mesmo arquivo pode ter vários erros, sem máximo prático
binomial; no controle estatístico, gráfico p ou np	Poisson; no controle estatístico, gráfico c

Essa é a distinção mais importante na escolha: estou contando *itens* com uma propriedade ou *ocorrências* de um evento?

A geométrica, que ainda não tinha aparecido com nome, inverte a pergunta da binomial: em vez de fixar n tentativas e contar sucessos, fixa-se o primeiro sucesso e conta-se o número de tentativas N . A FP $P(N = k) = q^{k-1}p$ é o caminho da árvore de retransmissões, e a média é $E[N] = 1/p$.

EXEMPLO Retransmissões e falta de memória

Com perda de 20%, um pacote leva em média $1/0.8 = 1.25$ transmissões. A geométrica é a única distribuição discreta sem memória: depois de m fracassos, o número de tentativas que ainda faltam tem a mesma distribuição de antes, porque as tentativas são independentes. A exponencial é sua versão contínua e herda a mesma propriedade.

CUIDADO Modelos vizinhos que se confundem

Entre	O que muda	Regra prática
hipergeométrica e binomial	a reposição; sem ela, a variância é multiplicada por $\frac{N-n}{N-1}$, porque cada item auditado dá informação sobre o que sobrou	se $n/N < 5\%$, a binomial basta (auditar 100 de 1 milhão de registros)
binomial e Poisson	se n é conhecido e se p é pequeno	n grande e p pequeno: Poisson com $\lambda = np$

Escolher o modelo é uma hipótese, não uma certeza, e hipóteses se verificam com dados. O procedimento padrão é ajustar o modelo pelos dados (para a Poisson, $\hat{\lambda}$ = média amostral), calcular as frequências que ele prevê e compará-las com as observadas. A comparação formal é o teste qui-quadrado de aderência, e estimar o parâmetro a partir dos dados custa um grau de liberdade. Para a Poisson, comparar média e variância já é um bom primeiro filtro.

CONEXÕES

- 1.8 hipergeométrica.
- 1.10 geométrica como caminho da árvore.
- 5.5 falta de memória contínua.
- 8.5 teste de aderência.
- 8.10 graus de liberdade com parâmetro estimado.
- 9.8 gráficos np e c .

▼ Entendendo a fórmula, termo a termo

$$\text{Modelo} = f(\text{suporte, independência, reposição, taxa})$$

Suporte limitado ($0..n$)? ← Há um número máximo de sucessos: Binomial ou Hipergeométrica.

Com ou sem reposição? ← Com reposição (ou conjunto enorme) mantém p constante: Binomial. Sem reposição num conjunto pequeno: Hipergeométrica.

Suporte ilimitado ($0, 1, 2, \dots$)? ← Contagem em um contínuo com taxa constante: Poisson.

Equiprovável? ← Valores igualmente prováveis por simetria: Uniforme discreta.

De onde vem, passo a passo

1. Identifique o que é contado (itens com uma propriedade? ocorrências de um evento? valores?).
2. Pergunte se existe um máximo natural.
3. Verifique independência e se p (ou a taxa) é constante.
4. Confira a escolha pela média: Binomial tem $Var < E$; Poisson tem $Var = E$. Dados com $Var \gg E$ indicam que nenhum dos dois serve bem.

EXEMPLO RESOLVIDO Um sistema, três modelos

Três perguntas sobre a mesma infraestrutura, cada uma pedindo um modelo diferente.

DADOS

- (i) requisições com erro numa amostra de 20, de um serviço com taxa de erro estável
- (ii) erros de leitura por terabyte lido de um disco
- (iii) servidores mal configurados ao auditar 3 de um cluster de 12, dos quais 2 estão mal configurados

O QUE SE PEDE

Escolher o modelo de cada caso e, no caso (iii), calcular $P(X = 1)$.

RESOLUÇÃO PASSO A PASSO**1 Caso (i)**

Há máximo (20), cada requisição é "sim/não" e a taxa estável mantém p constante: **Binomial**.

2 Caso (ii)

Contagem ao longo de um volume de dados, sem máximo natural: **Poisson**.

3 Caso (iii): por que não binomial

Sem reposição de um conjunto pequeno: o 1º servidor auditado está mal configurado com chance $2/12$, mas o 2º já depende do que saiu. p não é constante: **Hipergeométrica**.

4 Calcular a hipergeométrica

Escolher 1 dos 2 mal configurados e 2 dos 10 corretos, dividido por todas as amostras de 3:

$$P(X = 1) = \frac{\binom{2}{1} \binom{10}{2}}{\binom{12}{3}} = \frac{2 \times 45}{220} = 0.409$$

5 Comparar com a binomial (errada aqui)

$$\binom{3}{1} \left(\frac{1}{6}\right) \left(\frac{5}{6}\right)^2 = 0.347$$

Erro de 15%: com o conjunto tão pequeno, a diferença importa.

RESPOSTA

(i) Binomial; (ii) Poisson; (iii) Hipergeométrica, com $P(X = 1) = 0.409$.

Distinção sutil: "arquivo corrompido" (sim ou não, binomial) é diferente de "bits corrompidos no arquivo" (pode haver vários, Poisson).

Exercício 3.5 • Escolha do Modelo Discreto

Qual modelo descreve melhor a variável abaixo?

Número de handshakes bem-sucedidos em 17 tentativas independentes de conexão, cada uma com 90% de sucesso.

Espaço para cálculo

☐ Hipergeométrica

☐ Binomial

☐ Poisson

☐ Uniforme discreta

3.6 "Pelo Menos Um" e Dimensionamento de Testes

A pergunta "qual a chance de acontecer pelo menos uma vez?" é a mais comum em testes e confiabilidade, e é também a que mais se calcula errado, somando probabilidades como se os eventos fossem disjuntos. "Pelo menos um" resolve-se pelo complementar, porque "nenhum" é um produto simples: $P(X \geq 1) = 1 - P(X = 0)$, com $P(X = 0) = (1 - p)^n$ na binomial e $e^{-\mu}$ na Poisson. Isso permite **dimensionar** quantas vezes rodar um teste, quantos itens auditar ou quanto tempo monitorar:

MENOR n PARA DETECTAR AO MENOS UMA OCORRÊNCIA COM CONFIANÇA c

$$1 - (1 - p)^n \geq c \iff n \geq \frac{\ln(1 - c)}{\ln(1 - p)}$$

▼ Equação desmontada, variável por variável

$$n \geq \frac{\ln(1 - c)}{\ln(1 - p)}$$

n	← o que se calcula: nº mínimo de tentativas (execuções do teste)
c	← confiança desejada de ver pelo menos uma ocorrência (ex.: 0.95)
p	← chance de ocorrência em cada tentativa (ex.: 0.05)
$1 - c$	← chance aceitável de não achar nenhum (ex.: 0.05)
$1 - p$	← chance de uma execução não mostrar o bug (ex.: 0.95)
$\ln$	← logaritmo natural; ex.: $\ln 0.05 / \ln 0.95 = 58.4 \rightarrow 59$

Ex.: um bug intermitente aparece em 5% das execuções ($p = 0.05$) e quer-se 95% de chance de vê-lo ($c = 0.95$): $n \geq \ln 0.05 / \ln 0.95 = 58.4$, logo $n = 59$ execuções.

DEDUÇÃO Regra de $3/p$ e regra de três

A desigualdade inverte de sentido ao isolar n porque $\ln(1 - p)$ é negativo. Para p pequeno, $\ln(1 - p) \approx -p$, e a fórmula vira $n \approx -\ln(1 - c)/p$. Para $c = 95\%$, $-\ln 0.05 \approx 3$:

- **Regra de $3/p$:** são necessárias cerca de $3/p$ tentativas; 300 para um bug que aparece em 1% das execuções.
- **Regra de três (ao contrário):** se um evento não apareceu em n tentativas independentes, um limite superior de 95% de confiança para sua probabilidade é cerca de $3/n$. Rodar um teste de carga 1000 vezes sem nenhuma falha não prova que a falha é impossível, só que $p \lesssim 0.003$.

A regra de três é um primeiro contato com a ideia de intervalo de confiança, e com o fato de que "não observar" não é "provar que não existe": a mesma assimetria que leva a dizer "não rejeitamos H_0 " em vez de "aceitamos H_0 ".

NA COMPUTAÇÃO Pequenas chances se acumulam, contra e a favor

Contra você	A seu favor
200 testes que falham aleatoriamente em 1% das execuções: a suíte inteira passa com chance $0.99^{200} = 13\%$, e a equipe para de confiar na integração contínua	um algoritmo de Monte Carlo que erra com probabilidade ε , repetido k vezes de forma independente, erra em todas com probabilidade ε^k
20 testes estatísticos a 5%: pelo menos um falso positivo com chance $1 - 0.95^{20} = 64\%$	vários detectores independentes confirmando um alerta

É o mesmo cálculo do fan-out de latência e dos sistemas em série.

CONEXÕES

- 1.7** sistemas em série: o mesmo produto.
- 2.6** fan-out e cauda de latência.
- 7.4** intervalos de confiança.
- 8.3** comparações múltiplas e "não rejeitar".

▼ Entendendo a fórmula, termo a termo

$$1 - (1 - p)^n \geq c \iff n \geq \frac{\ln(1 - c)}{\ln(1 - p)}$$

$(1 - p)^n$ ← Probabilidade de *nenhuma* ocorrência em n tentativas.

$1 - (1 - p)^n$ ← Probabilidade de pelo menos um.

c ← Confiança exigida de detectar.

$\ln$ ← Tira n do expoente.

De onde vem, passo a passo

1. $1 - (1 - p)^n \geq c \iff (1 - p)^n \leq 1 - c$.
2. Aplique $\ln$ (função crescente, mantém o sentido): $n \ln(1 - p) \leq \ln(1 - c)$.
3. Divida por $\ln(1 - p)$, que é **negativo**: o sentido da desigualdade se inverte, $n \geq \frac{\ln(1 - c)}{\ln(1 - p)}$.
4. Arredonde para cima, pois n é inteiro e precisa satisfazer a desigualdade.

EXEMPLO RESOLVIDO Quanto tempo rodar um teste de estresse

Num teste de estresse prolongado (soak test), um bug de concorrência aparece segundo um processo de Poisson. Quanto tempo rodar para observá-lo pelo menos uma vez com 95% de probabilidade?

DADOS

- taxa: 0.2 ocorrência por hora
- em t horas: $\lambda = 0.2 t$

O QUE SE PEDE

O menor t com $P(X \geq 1) \geq 0.95$.

RESOLUÇÃO PASSO A PASSO

1 Escrever "pelo menos uma"

$$P(X \geq 1) = 1 - P(X = 0) = 1 - e^{-0.2t}$$

2 Montar a desigualdade

$$1 - e^{-0.2t} \geq 0.95 \iff e^{-0.2t} \leq 0.05$$

3 Isolar t com logaritmo

Aplicando $\ln$ (a desigualdade inverte ao multiplicar por -1):

$$-0.2t \leq \ln 0.05 \iff t \geq \frac{-\ln 0.05}{0.2} = \frac{\ln 20}{0.2} = 14.98 \text{ h}$$

4 Conferir

Com $t = 15$: $1 - e^{-3} = 0.950 \checkmark$.

RESPOSTA Rodar o teste por 15 horas.

Mesma lógica do "pelo menos um" da binomial, agora com tempo contínuo. Repare no "3": para 95%, é preciso esperar cerca de $3/\lambda$, ou seja, três vezes o tempo médio entre ocorrências.

Exercício 3.6 • Dimensionando um Teste ("Pelo Menos Um")

Um bug intermitente (condição de corrida) se manifesta em 8% das execuções de um teste, independentemente. Quantas execuções, no mínimo, são necessárias para que a probabilidade de o bug aparecer pelo menos uma vez seja de no mínimo 99%?

Espaço para cálculo

3.7 Estimando a Taxa de Poisson a partir de $P(X = 0)$

Às vezes não se conta quantas vezes algo aconteceu, só se aconteceu: um teste diz passou ou falhou, um monitor guarda só o primeiro alerta da janela, um cache reporta apenas se houve algum erro. A

Poisson permite recuperar a taxa a partir dessa informação parcial, porque a probabilidade de zero ocorrências depende só de λ . Se num intervalo t a probabilidade de nenhuma ocorrência é q , então $e^{-\lambda t} = q$ e $\lambda = -\ln(q)/t$. Ex.: 80% dos plantões de 8 h passam sem nenhum alerta de produção, logo $\lambda = -\ln 0.8/8 = 0.0279$ alertas/h e $P(\text{exatamente 1 alerta no plantão}) = 0.8 \times 0.2231 = 0.1785$.

Uma vez estimado λ , a distribuição inteira fica determinada, e por isso a fração de janelas "limpas" basta para responder sobre 1, 2 ou mais alertas. Esse é o poder de um modelo paramétrico, e também o seu risco.

CUIDADO A estimativa só vale se o modelo valer

- **Rajadas:** se os alertas vêm em rajadas, há mais janelas com zero do que a Poisson prevê para a mesma média, e a taxa estimada pelos zeros sai menor que a real.
- **Fragilidade numérica:** se q for estimado de poucas janelas, o logaritmo amplifica o erro quando q está perto de 0 (quase nenhuma janela limpa); e há pouca informação quando q está perto de 1 (quase nada acontece).

NA COMPUTAÇÃO Contagem probabilística de distintos

1. Espalhe os identificadores de usuários por hash em m posições de um vetor de bits.
2. Com n distintos, cada posição recebe em média n/m chaves, aproximadamente Poisson, e fica vazia com probabilidade $e^{-n/m}$.
3. Medindo a fração de posições vazias, obtém-se $n \approx -m \ln(\text{fração vazia})$.

É o método "linear counting", parente do HyperLogLog usado em bancos de dados e sistemas de análise para contar distintos sem guardar a lista.

CONEXÕES

- 3.3** hipóteses da Poisson.
- 3.4** Poisson como limite em hashing.
- 7.2** quanto uma estimativa varia de amostra para amostra.

▼ Entendendo a fórmula, termo a termo

$$\lambda = \frac{-\ln q}{t}, \quad q = P(X = 0)$$

q ← Fração observada de intervalos sem ocorrências.

$-\ln q$ ← Número médio $\mu = \lambda t$ de ocorrências no intervalo (positivo, pois $\ln q < 0$).

t ← Duração do intervalo; dividir por ela dá a taxa por unidade de tempo.

De onde vem, passo a passo

1. Na Poisson, $P(X = 0) = e^{-\lambda t}$.
2. Iguale ao observado: $e^{-\lambda t} = q$.
3. Aplique $\ln$: $-\lambda t = \ln q$, logo $\lambda = -\ln q / t$.

EXEMPLO RESOLVIDO Estimando a taxa de falha por máquina

Uma equipe de operações relata que 90% dos deploys em 20 servidores terminam sem nenhuma máquina falhando no health check. Qual a probabilidade de falha por máquina?

DADOS

- $n = 20$ máquinas por deploy
- $P(X = 0) = 0.90$

O QUE SE PEDE

Estimar p .

RESOLUÇÃO PASSO A PASSO

1 Escrever $P(X = 0)$ da binomial

Zero falhas significa as 20 máquinas passando: $P(X = 0) = (1 - p)^{20}$.

2 Igualar ao dado

$$(1 - p)^{20} = 0.90$$

3 Isolar p

Tire a raiz 20ª dos dois lados:

$$1 - p = 0.90^{1/20} = 0.99475 \implies p = 0.00525$$

RESPOSTA $p \approx 0.5\%$ de falha por máquina.

É a mesma ideia de "inverter $P(X = 0)$ ". Note como 10% de deploys com problema corresponde a uma taxa por máquina 19 vezes menor: em sistemas grandes, falhas raras por componente viram falhas frequentes no conjunto.

Exercício 3.7 • Poisson a partir de $P(X=0)$

Registros mostram que 90% dos plantões de 8 h transcorrem sem nenhum alerta de produção. Admita alertas segundo um processo de Poisson. Qual a probabilidade de um plantão ter exatamente um alerta?

Espaço para cálculo

Exercícios de Fixação com Soluções Comentadas

3 Questões Resolvidas

Exercício 3.1: Perda de Pacotes com Distribuição Binomial

Um enlace sem fio perde pacotes a uma taxa estável de 4% ($p = 0.04$), de forma independente. Um cliente envia uma rajada de $n = 8$ pacotes.

- (a) Qual é a probabilidade de exatamente 1 pacote se perder?
- (b) O protocolo consegue recuperar a rajada sem retransmissão se no máximo 1 pacote se perder (há um pacote de paridade). Qual a probabilidade $P(X \leq 1)$?

Espaço para cálculo

Exercício 3.2: Erros de Leitura em Disco por Processo de Poisson

Um disco apresenta, em média, 0.4 erro de leitura irrecuperável a cada 100 TB lidos ($\lambda = 0.4$ erros/100 TB).

- (a) Na reconstrução de um volume RAID que lê 500 TB, qual o número esperado de erros?
- (b) Qual é a probabilidade de exatamente 2 erros nessa leitura de 500 TB?
- (c) Qual a probabilidade de haver pelo menos 1 erro (o que pode comprometer a reconstrução)?

Espaço para cálculo

Exercício 3.3: Aproximação Poisson para Transações Fraudulentas

Num sistema de pagamentos, a probabilidade de uma transação ser fraudulenta é $p = 0.002$. Em um lote de $n = 1500$ transações:

- (a) Justifique a aplicabilidade da aproximação de Poisson.
- (b) Calcule a probabilidade aproximada de encontrar exatamente 4 transações fraudulentas.

Espaço para cálculo

Módulo 4: Variáveis Aleatórias Contínuas (VAC)

Variáveis contínuas para medições (latência, tempo de execução, vazão): densidade, FDA e sobrevivência, esperança e variância por integrais, caudas pesadas (Pareto), percentis de latência e transformada inversa para gerar amostras.

Os Módulos 2 e 3 tratavam de contagens. Mas boa parte do que se mede em computação é tempo, tamanho e taxa: latência, duração de um job, vazão de um enlace. Essas grandezas variam continuamente, e o aparato discreto precisa ser reconstruído. A boa notícia é que quase nada muda de ideia, só de ferramenta: somas viram integrais, a função de probabilidade vira densidade, e a FDA, que já existia, passa a ser o objeto central. Cada seção deste módulo é a versão contínua de uma seção do Módulo 2, e os modelos contínuos com nome (uniforme, normal, exponencial) vêm no Módulo 5.

4.1 Conceito de Continuidade e Propriedade Pontual Nula

Uma **Variável Aleatória Contínua (VAC)** pode assumir qualquer valor real num intervalo. Em computação, é o modelo natural para medições: latência de uma requisição, tempo de execução de uma consulta, tempo até a próxima falha, vazão de um enlace, uso de CPU como fração do tempo. A diferença em relação ao caso discreto aparece logo na primeira pergunta. No enlace do Módulo 2 havia 4 valores possíveis, cada um com sua probabilidade. Numa latência entre 0 e 100 ms há infinitos valores, e se cada um tivesse probabilidade positiva, por menor que fosse, a soma passaria de 1, violando os axiomas. A única saída é que cada valor isolado tenha probabilidade zero. Como há uma infinidade não enumerável de valores possíveis:

Propriedade Crucial: a probabilidade de uma VAC assumir exatamente um valor isolado é zero:

$$P(X = c) = 0, \quad \forall c \in \mathbb{R}$$

Por isso, em variáveis contínuas, tanto faz usar desigualdade estrita ou não:

$$P(a \leq X \leq b) = P(a < X \leq b) = P(a \leq X < b) = P(a < X < b)$$

INTUIÇÃO Probabilidade como areia espalhada

Probabilidade zero não significa impossível. Alguma latência exata vai acontecer (digamos 37.2914... ms), embora aquele valor exato tivesse probabilidade zero. O paradoxo some quando se troca a imagem de "contar casos" pela de "massa espalhada": a probabilidade se distribui ao longo do eixo como areia, e um ponto, que não tem largura, não carrega areia. Só intervalos carregam. É a mesma razão pela qual, no caso discreto, a diferença entre $<$ e $\leq$ era um degrau da FDA: no contínuo não há degraus, e a diferença desaparece.

O modelo contínuo é uma idealização, e o computador é discreto. Mesmo assim, ele é usado porque troca uma soma sobre milhões de valores por uma integral, que costuma ter forma fechada.

NA COMPUTAÇÃO Contínuo no papel, discreto na máquina

- Um timestamp tem resolução finita (1 ms, 1 μ s, 1 ns), e um `double` representa uma quantidade finita de números. Quando um log registra "latência = 5.0 ms" com resolução de 0.1 ms, o evento real é $X \in [4.95, 5.05)$, que tem probabilidade positiva.
- A discretização volta ao comparar o modelo com dados (histogramas) e ao aproximar uma variável discreta por uma contínua, quando a correção de continuidade faz exatamente a conversão "valor inteiro k = intervalo $[k - 0.5, k + 0.5]$ ".
- `Math.random()` devolve um entre cerca de 2^{52} valores, mas se comporta como uniforme contínua para quase todos os fins, e é a partir dele que se geram amostras de qualquer distribuição contínua.

CONEXÕES

- 1.2** axiomas que forçam probabilidade zero nos pontos.
- 2.3** o degrau que some.
- 4.6** gerar amostras a partir da uniforme.
- 5.8** correção de continuidade.

▼ Entendendo a fórmula, termo a termo

$$P(X = c) = \lim_{\varepsilon \rightarrow 0} \int_{c-\varepsilon}^{c+\varepsilon} f(x) dx = 0$$

$[c - \varepsilon, c + \varepsilon]$ ← Intervalo cada vez mais estreito em torno de c .

$\int f$ ← Área sob a densidade nesse intervalo.

$\lim = 0$ ← Um ponto tem largura zero, logo área zero.

De onde vem, passo a passo

1. Para ε pequeno, a área é quase um retângulo de base 2ε e altura $f(c)$.
2. Área $\approx 2\varepsilon f(c)$.
3. Quando $\varepsilon \rightarrow 0$, a área vai a zero, qualquer que seja $f(c)$.
4. Consequência: $P(a \leq X \leq b) = P(a < X < b)$; incluir ou não os extremos não muda nada.

EXEMPLO RESOLVIDO O que significa "o timestamp diz 5.0 ms"

O atraso X que um escalonador introduz antes de disparar uma tarefa é uniforme entre 0 e 10 ms.

DADOS

- $f(x) = 1/10$ para $0 \leq x \leq 10$

O QUE SE PEDE

(a) $P(X = 5)$; (b) $P(4.99 < X < 5.01)$; (c) a probabilidade de um log com resolução de 0.1 ms registrar "5.0".

RESOLUÇÃO PASSO A PASSO**1****Probabilidade é área**

Em variável contínua, $P(a < X < b) = \int_a^b f(x) dx$. Um ponto isolado tem largura zero, logo área zero: $P(X = 5) = 0$.

2 Intervalo estreito

Área de um retângulo de base 0.02 e altura $1/10$:

$$P(4.99 < X < 5.01) = 0.02 \times \frac{1}{10} = 0.002$$

3 O que o log registra de fato

Registrar "5.0" com resolução 0.1 significa $X \in [4.95; 5.05)$, um intervalo de largura 0.1:

$$P = 0.1 \times \frac{1}{10} = 0.01$$

RESPOSTA (a) 0; (b) 0.002; (c) 0.01.

Probabilidade positiva exige intervalo. Por isso, em contínuas, $P(X < a) = P(X \leq a)$. E todo timestamp real é, na verdade, um intervalo do tamanho da sua resolução.

Exercício 4.1 • Probabilidade Pontual em VAC

O atraso X (ms) que um escalonador introduz antes de disparar uma tarefa é uniforme em $[0, 9]$. Quanto vale $P(X = 4)$?

Espaço para cálculo

☐ 0

☐ $1 - 4/9$

☐ 1

☐ $f(4) = 1/9$

4.2 Função Densidade de Probabilidade (FDP / PDF)

Se pontos não carregam probabilidade, precisamos de uma função que diga onde a "areia" está mais concentrada. Essa função é a densidade: a probabilidade de um intervalo é a área sob a curva da Função Densidade de Probabilidade $f(x)$:

FUNÇÃO DENSIDADE DE PROBABILIDADE (FDP)

$$P(a \leq X \leq b) = \int_a^b f(x) dx$$

Condições Obrigatórias: $f(x) \geq 0, \forall x$ e $\int_{-\infty}^{+\infty} f(x) dx = 1$

▼ Equação desmontada, variável por variável

$$P(a \leq X \leq b) = \int_a^b f(x) dx$$

$P(a \leq X \leq b)$ ← o que se calcula: chance de X cair entre a e b

$f(x)$ ← densidade: altura da curva em x (não é probabilidade)

a, b ← limites do intervalo (ex.: 0 e 0.5 s)

$\int_a^b \dots dx$ ← área sob a curva entre a e b

$$f(x) \geq 0, \quad \int_{-\infty}^{+\infty} f(x) dx = 1$$

$f(x) \geq 0$ ← a curva nunca fica abaixo do eixo

$\int_{-\infty}^{+\infty}$ ← área total sob a curva

$= 1$ ← a área total vale 100%

As condições são, mais uma vez, os axiomas de Kolmogorov, agora com integral no lugar de soma. A diferença conceitual está no significado de $f(x)$: ela não é uma probabilidade, e sim probabilidade *por*

unidade de x .

CAUIDADO Densidade não é probabilidade

- Para um intervalo pequeno, $P(x \leq X \leq x + dx) \approx f(x) dx$, como densidade de massa vezes volume dá massa.
- Por isso f pode passar de 1: um atraso uniforme entre 0 e 0.5 ms tem $f(x) = 2$ por ms em todo o intervalo, e a área continua sendo $2 \times 0.5 = 1$.
- As unidades de f são o inverso das de X (1/ms, 1/GB), e mudar a unidade de X muda os valores de f .

Como no caso discreto, muitas vezes se conhece só a forma da densidade, e a constante sai da condição de área 1.

EXEMPLO O job que acompanha o módulo

O tempo de um job de processamento em lote com timeout rígido de 2 s tem densidade proporcional a $x(2 - x)$ em $[0, 2]$: nula nas bordas, máxima no meio. Como $\int_0^2 x(2 - x) dx = 4/3$, a densidade é $f(x) = \frac{3}{4}x(2 - x)$.

Calcular a constante de normalização é fácil aqui, mas em estatística bayesiana e em aprendizado de máquina costuma ser o passo mais difícil, porque a integral é sobre milhares de dimensões; métodos como MCMC existem para amostrar de densidades conhecidas "a menos de uma constante".

A densidade tem uma contraparte empírica: o histograma com altura igual a frequência relativa dividida pela largura da classe. Dividir pela largura é o que transforma frequência em densidade, e é por isso que a *área* de cada barra, e não a altura, é a fração dos dados. Com mais dados e classes mais estreitas, o histograma converge para f ; estimadores por núcleo (KDE) suavizam o histograma somando um pequeno "sino" em cada observação. Quando a integral que dá uma probabilidade não tem primitiva em forma fechada, como acontece com a normal, ela se calcula numericamente (trapézio, Simpson) ou se consulta numa tabela.

CONEXÕES

- 2.2 FP discreta.
- 5.3 normal, sem primitiva elementar.
- 6.5 histogramas.

▼ Entendendo a fórmula, termo a termo

$$P(a \leq X \leq b) = \int_a^b f(x) dx, \quad \int_{-\infty}^{\infty} f(x) dx = 1$$

$f(x)$

← Densidade: probabilidade por unidade de comprimento perto de x .

$f(x) dx$

← Probabilidade de uma fatia infinitesimal $[x, x + dx]$.

$\int_a^b$

← Soma de todas as fatias entre a e b .

$= 1$

← A área total é a probabilidade de Ω .

De onde vem, passo a passo

1. Imagine um histograma de frequências relativas com classes de largura h .
2. Para que a área de cada barra seja a probabilidade da classe, a altura deve ser probabilidade dividida por largura.
3. Com $h \rightarrow 0$, as alturas formam a curva $f(x)$ e a soma das áreas vira uma integral.
4. Por isso f pode ser maior que 1: é uma razão (probabilidade/largura), não uma probabilidade.

EXEMPLO RESOLVIDO Normalizando e integrando uma densidade

O tempo X (s) que um job de processamento em lote leva tem densidade proporcional a $x(2 - x)$ entre 0 e 2 s (há um limite rígido de 2 s, imposto por timeout).

DADOS

- $f(x) = c x(2 - x) = c(2x - x^2), 0 \leq x \leq 2$

O QUE SE PEDE

(a) a constante c ; (b) $P(X < 0.5)$.

RESOLUÇÃO PASSO A PASSO

1 Condição de normalização

A área total sob uma densidade é 1:

$$\int_0^2 c(2x - x^2) dx = 1$$

2 Integrar

Primitiva termo a termo: $\int 2x dx = x^2$ e $\int x^2 dx = x^3/3$.

$$c \left[x^2 - \frac{x^3}{3} \right]_0^2 = c \left(4 - \frac{8}{3} \right) = c \cdot \frac{4}{3}$$

3 Resolver para c

$$c \cdot \frac{4}{3} = 1 \implies c = \frac{3}{4} = 0.75$$

4 Probabilidade = integral no intervalo

$$P(X < 0.5) = 0.75 \left[x^2 - \frac{x^3}{3} \right]_0^{0.5} = 0.75 \left(0.25 - \frac{0.125}{3} \right) = 0.75(0.25 - 0.0417) = 0.$$

RESPOSTA (a) $c = 0.75$; (b) 0.156 .

Densidade pode passar de 1: $f(x) = 4$ em $[0; 0.25]$ é válida, porque a área $4 \times 0.25 = 1$. O que não pode passar de 1 é a *área*.

Exercício 4.2 • Constante de Normalização de uma FDP

O erro absoluto X (ms) de sincronização do relógio de um servidor tem densidade $f(x) = k(9 - x^2)$ para $0 \leq x \leq 3$, e zero fora. Determine k .

Espaço para cálculo

4.3 Função de Distribuição Acumulada (FDA) e o Teorema Fundamental

A FDA do Módulo 2, $F(x) = P(X \leq x)$, tem a mesma definição aqui. O que muda é como se calcula: em vez de somar a FP até x , integra-se a densidade, acumulando a área sob $f(t)$ desde $-\infty$ até x :

RELAÇÃO FUNDAMENTAL ENTRE FDP E FDA

$$F(x) = P(X \leq x) = \int_{-\infty}^x f(t) dt$$

$$f(x) = \frac{d}{dx} F(x) = F'(x) \quad (\text{nos pontos onde } f \text{ é contínua})$$

▼ Equação desmontada, variável por variável

$$F(\textcolor{brown}{x}) = P(X \leq \textcolor{brown}{x}) = \int_{-\infty}^{\textcolor{brown}{x}} f(\textcolor{blue}{t}) dt$$

$F(\textcolor{brown}{x})$ ← o que se calcula: área acumulada até x

$f(\textcolor{blue}{t})$ ← densidade

$\textcolor{blue}{t}$ ← variável de integração que percorre de $-\infty$ até x

$\textcolor{brown}{x}$ ← limite superior da área (ex.: 1.5 s)

$$f(x) = \frac{d}{dx} F(x) = F'(\textcolor{blue}{x})$$

$\frac{d}{dx}$ ← derivada em relação a x

$F'(\textcolor{blue}{x})$ ← taxa com que a área acumulada cresce = altura da densidade

A segunda linha é o Teorema Fundamental do Cálculo: a derivada da área acumulada é a altura da curva. A relação entre densidade e FDA é a mesma que entre FP e FDA no caso discreto, com derivada no lugar de "altura do degrau". A FDA contínua não tem saltos, vai de 0 a 1 e nunca decresce; sobe rápido onde f é alta e fica plana onde $f = 0$.

EXEMPLO FDA do job e uma probabilidade sem nova integral

$F(x) = \int_0^x \frac{3}{4}t(2-t) dt = \frac{3x^2-x^3}{4}$ em $[0, 2]$, e derivando volta-se a f .

$$P(X > 1.5) = 1 - F(1.5) = 1 - 0.844 = 0.156.$$

Com a FDA em mãos, nenhuma probabilidade de intervalo exige nova integral: $P(a < X \leq b) = F(b) - F(a)$. É por isso que bibliotecas e tabelas fornecem a FDA (a função cdf) e não a área de cada intervalo: qualquer intervalo sai de duas consultas. A tabela da normal padrão é exatamente uma tabela de FDA.

NA COMPUTAÇÃO Função de sobrevivência

O complemento da FDA, $S(x) = 1 - F(x) = P(X > x)$, é a forma preferida em duas áreas:

Área	Leitura de $S(x)$
Confiabilidade	$R(t) = S(t)$: chance de um componente durar mais que t ; é a versão dependente do tempo dos R_i de 1.7
Latência	fração de requisições que ainda não terminaram após x ms

Plotada em escala logarítmica, a sobrevivência revela caudas pesadas que a FDA esconde perto de 1: uma cauda exponencial vira uma reta, e uma cauda de Pareto cai bem mais devagar.

CONEXÕES

- 1.7** confiabilidade.
- 2.3** FDA discreta.
- 4.6** Pareto e caudas pesadas.
- 5.3** tabela normal.
- 5.4** sobrevivência exponencial.

▼ Entendendo a fórmula, termo a termo

$$F(x) = \int_{-\infty}^x f(t) dt, \quad f(x) = F'(x)$$

$$\int_{-\infty}^x$$

← Área acumulada desde o início do suporte até x .

$$t$$

← Variável de integração ("muda"), para não confundir com o limite x .

$$F'(x)$$

← Taxa de crescimento da área acumulada: é a própria altura da curva.

De onde vem, passo a passo

1. $F(x) = P(X \leq x)$ é a área sob f até x .
2. Ao avançar de x para $x + dx$, a área cresce $\approx f(x) dx$.
3. Logo $\frac{F(x+dx) - F(x)}{dx} \rightarrow f(x)$: o Teorema Fundamental do Cálculo.
4. Como $f \geq 0$, F nunca decresce; vai de 0 (em $-\infty$) a 1 (em $+\infty$). Escreva F por partes: 0 antes do suporte, a integral dentro, 1 depois.

EXEMPLO RESOLVIDO Da densidade à FDA (e de volta)

Mesmo job do exemplo 4.2.

DADOS

- $f(x) = 0.75x(2 - x), 0 \leq x \leq 2$

O QUE SE PEDE

(a) a FDA $F(x)$; (b) $P(0.5 < X < 1.5)$.

RESOLUÇÃO PASSO A PASSO

1 FDA = integral até x

$F(x) = \int_{-\infty}^x f(t) dt$. Abaixo de 0 a densidade é zero; dentro do suporte, integra-se de 0 até x :

$$F(x) = 0.75 \left(x^2 - \frac{x^3}{3} \right), \quad 0 \leq x \leq 2$$

2 Escrever por partes

$$F(x) = \begin{cases} 0, & x < 0 \\ 0.75 \left(x^2 - \frac{x^3}{3} \right), & 0 \leq x \leq 2 \\ 1, & x > 2 \end{cases}$$

3 Conferir as pontas

$F(0) = 0$ e $F(2) = 0.75(4 - 8/3) = 1$ ✓. A FDA tem que ir de 0 a 1.

4 Usar a FDA: uma subtração

$$P(0.5 < X < 1.5) = F(1.5) - F(0.5) = 0.84375 - 0.15625 = 0.6875$$

Sem nova integral.

5 De volta: derivar

$$F'(x) = 0.75(2x - x^2) = f(x) \text{ ✓.}$$

RESPOSTA (b) 0.6875.

Exercício 4.3 • Obtendo a FDA de uma VAC

O tempo X (s) de execução de uma consulta ao banco de dados tem densidade

$$f(x) = \frac{3}{1}x^2, \quad 0 \leq x \leq 1.$$

Obtenha $F(x)$ e calcule $P(X \leq 0.4)$.

Espaço para cálculo

4.4 Esperança e Variância no Caso Contínuo

A esperança discreta era $\sum x p(x)$. Corte o eixo em fatias de largura dx : cada fatia tem valor aproximadamente x e probabilidade aproximadamente $f(x) dx$, então a soma vira $\sum x f(x) dx$, que no limite é uma integral. No caso contínuo, as somas viram integrais ponderadas pela densidade:

ESPERANÇA E VARIÂNCIA CONTÍNUAS

$$E[X] = \mu = \int_{-\infty}^{+\infty} x \cdot f(x) dx$$

$$E[g(X)] = \int_{-\infty}^{+\infty} g(x) \cdot f(x) dx$$

$$\text{Var}(X) = \sigma^2 = \int_{-\infty}^{+\infty} (x - \mu)^2 \cdot f(x) dx = E[X^2] - (E[X])^2$$

$$\text{onde } E[X^2] = \int_{-\infty}^{+\infty} x^2 \cdot f(x) dx$$

▼ Equação desmontada, variável por variável

$$E[X] = \mu = \int_{-\infty}^{+\infty} x \cdot f(x) dx$$

$E[X]$ ← o que se calcula: média

x ← cada valor possível

$f(x) dx$ ← probabilidade de uma fatia fininha em torno de x

$\int$ ← soma de todas as fatias

$$E[g(X)] = \int_{-\infty}^{+\infty} g(x) \cdot f(x) dx$$

$g(x)$ ← função de interesse (ex.: x^2 , custo)

$$\text{Var}(X) = \int (x - \mu)^2 f(x) dx = E[X^2] - (E[X])^2$$

$(x - \mu)^2$ ← distância ao quadrado até a média

$E[X^2]$ ← média dos quadrados: $\int x^2 f(x) dx$

$(E[X])^2$ ← quadrado da média

Como a construção é a mesma, todas as propriedades do Módulo 2 continuam valendo sem nova prova: linearidade, $\text{Var}(aX + b) = a^2 \text{Var}(X)$, soma de variâncias de independentes, Jensen.

EXEMPLO Média e variância do job

A densidade é simétrica em torno de 1, então $E[X] = 1$ s sem integrar. $E[X^2] = \int_0^2 x^2 \cdot \frac{3}{4}x(2-x) dx = 1.2$, logo $\text{Var}(X) = 0.2$ e $\sigma \approx 0.45$ s.

INTUIÇÃO Placa em equilíbrio

$E[X]$ é o ponto de equilíbrio de uma placa com o formato de f , e $Var(X)$ é o seu momento de inércia em torno desse ponto. Para variáveis não negativas, como tempos, há uma forma alternativa: $E[X] = \int_0^\infty P(X > x) dx$, a média é a área sob a curva de sobrevivência. Em confiabilidade, é assim que se obtém o tempo médio até a falha (MTTF) a partir de $R(t)$: para $R(t) = e^{-\lambda t}$, a área é $1/\lambda$.

CUIDADO Quando a integral não existe

Cauda da densidade	Consequência
decai como $1/x^3$	variância infinita
decai como $1/x^2$	até a média diverge

Isso não é patologia matemática: tamanhos de arquivos, durações de sessão e tempos de jobs costumam ter caudas assim (Pareto, log-normal). Com variância infinita, o erro padrão não existe, a média amostral converge muito devagar, e o Teorema Central do Limite na forma usual deixa de valer. Medianas e percentis, que sempre existem, passam a ser as medidas confiáveis.

CONEXÕES

- 2.4** esperança discreta.
- 2.7** soma de variâncias.
- 2.8** Jensen.
- 5.4** MTTF exponencial.
- 7.3** TCL e variância finita.

▼ Entendendo a fórmula, termo a termo

$$E[X] = \int x f(x) dx, \quad \text{Var}(X) = \int (x - \mu)^2 f(x) dx = E[X^2] - \mu^2$$

 x

← Valor de cada fatia.

 $f(x) dx$

← Peso (probabilidade) da fatia.

 $\int$ ← Substitui a soma $\sum$ do caso discreto.

De onde vem, passo a passo

1. Corte o suporte em fatias de largura dx ; cada uma tem valor $\approx x$ e probabilidade $\approx f(x) dx$.
2. A média ponderada discreta $\sum x \cdot f(x) dx$ vira, no limite, $\int x f(x) dx$.
3. A variância segue o mesmo raciocínio, e a fórmula $E[X^2] - \mu^2$ se deduz exatamente como no caso discreto (2.5).
4. Unidades: se X está em ms, $E[X]$ está em ms e $\text{Var}(X)$ em ms^2 .

EXEMPLO RESOLVIDO

Média e variância pela integral

Mesmo job dos exemplos 4.2 e 4.3.

DADOS

- $f(x) = 0.75(2x - x^2), 0 \leq x \leq 2$

O QUE SE PEDE

$$E[X], \text{Var}(X) \text{ e } \sigma.$$

RESOLUÇÃO PASSO A PASSO

1 Média: integral de $x \cdot f(x)$

É a versão contínua de $\sum x p(x)$:

$$\begin{aligned} E[X] &= \int_0^2 x \cdot 0.75(2x - x^2) dx = 0.75 \int_0^2 (2x^2 - x^3) dx = 0.75 \left[\frac{2x^3}{3} - \frac{x^4}{4} \right]_0^2 \\ &= 0.75 \left(\frac{16}{3} - 4 \right) = 0.75 \cdot \frac{4}{3} = 1 \text{ s} \end{aligned}$$

2 $E[X^2]$: integral de $x^2 \cdot f(x)$

$$E[X^2] = 0.75 \int_0^2 (2x^3 - x^4) dx = 0.75 \left[\frac{x^4}{2} - \frac{x^5}{5} \right]_0^2 = 0.75(8 - 6.4) = 1.2$$

3 Variância e desvio

$$\text{Var}(X) = E[X^2] - (E[X])^2 = 1.2 - 1^2 = 0.2, \quad \sigma = \sqrt{0.2} = 0.447 \text{ s}$$

RESPOSTA $E[X] = 1 \text{ s}$, $\text{Var}(X) = 0.2 \text{ s}^2$, $\sigma = 0.447 \text{ s}$.

$E[X] = 1$ era previsível: f é simétrica em torno de 1 (uma parábola com vértice em $x = 1$).

Exercício 4.4 • Esperança de uma VAC

O tempo X (s) de execução de uma consulta ao banco de dados tem densidade

$$f(x) = \frac{2}{1}x^1, \quad 0 \leq x \leq 1.$$

Calcule $E[X]$.

Espaço para cálculo

4.5 Medidas de Posição: Mediana e Percentis

No caso discreto, o percentil exigia duas condições porque a FDA saltava por cima de p . Aqui a FDA é contínua e passa por todos os valores entre 0 e 1, então o percentil x_p de uma VAC é simplesmente o ponto onde a área acumulada à esquerda vale exatamente p :

$$F(x_p) = \int_{-\infty}^{x_p} f(t) dt = p \implies x_p = F^{-1}(p)$$

▼ Equação desmontada, variável por variável

$$F(x_p) = \int_{-\infty}^{x_p} f(t) dt = p \implies x_p = F^{-1}(p)$$

 x_p

← o que se procura: percentil

 p

← área desejada à esquerda (ex.: 0.5 para a mediana)

 F^{-1} ← inversa da FDA: dá x a partir da área

- **Mediana (m):** ponto com $F(m) = 0.50$, que divide a área em duas metades.
- **Moda ($\hat{x}$):** valor em que a densidade $f(x)$ é máxima ($f'(\hat{x}) = 0$ com $f''(\hat{x}) < 0$, ou numa borda do suporte).

Encontrar um percentil é resolver uma equação, e nem sempre há fórmula fechada. Para o job, $F(x) = 0.9$ é a cúbica $3x^2 - x^3 = 3.6$.

NA COMPUTAÇÃO Resolvendo $F(x) = p$ numericamente

Método	Como	Observação
Bisseção	corta o intervalo pela metade a cada passo	sempre funciona, porque F é monótona: é uma busca binária no eixo real
Newton-Raphson	usa a derivada, que é a própria densidade	converge mais rápido
Bibliotecas	ppf ou quantile	a tabela normal lida "de dentro para fora" faz o mesmo

As três medidas de centro (média, mediana e moda) coincidem em distribuições simétricas e unimodais, como o job ou a normal. Em distribuições com cauda longa à direita, como latências, costuma valer $\text{moda} < \text{mediana} < \text{média}$: a cauda puxa a média para cima, e uma "latência média" pode ser bem maior que a experiência típica de um usuário.

CUIDADO Percentis não se combinam por média

Em monitoramento, percentis de latência (p50, p95, p99, p99.9) são estimados continuamente de milhões de medições com estruturas compactas (histogramas com classes logarítmicas, t-digest, HDR Histogram), que guardam uma aproximação da FDA e a invertem. O p99 de um cluster não é a média dos p99 das máquinas, porque o percentil depende da FDA inteira do conjunto. O correto é somar os histogramas e calcular o percentil do resultado.

CONEXÕES

- 2.6** percentis discretos.
- 5.6** percentis da normal.
- 6.2** a mesma ordem nos dados.
- 6.6** percentis a partir de histogramas.

▼ Entendendo a fórmula, termo a termo

$$F(x_p) = p, \quad F(Md) = 0.5, \quad f'(Mo) = 0, \quad f''(Mo) < 0$$

$F(x_p) = p$ ← O percentil deixa área p à esquerda.

Md ← Divide a área total ao meio.

$f'(Mo) = 0$ ← Moda: ponto de máximo da densidade (derivada nula, segunda derivada negativa).

De onde vem, passo a passo

1. Obtenha $F(x)$ integrando f .
2. Resolva $F(x) = p$ para x : algebricamente quando possível; senão, por tentativa ou bisseção.
3. Para a moda, derive f e iguale a zero; confira se é máximo e se está dentro do suporte (pode estar na borda).

EXEMPLO RESOLVIDO Mediana, moda e percentil numérico

Mesmo job dos exemplos anteriores.

DADOS

$$\bullet f(x) = 0.75(2x - x^2), F(x) = 0.75(x^2 - x^3/3), 0 \leq x \leq 2$$

O QUE SE PEDE

Moda, mediana e percentil 90.

RESOLUÇÃO PASSO A PASSO

1 Moda: máximo da densidade

Derive e iguale a zero:

$$f'(x) = 0.75(2 - 2x) = 0 \implies x = 1$$

2 Mediana: $F(x) = 0.5$

Por simetria, $Md = 1$. Verificação: $F(1) = 0.75(1 - 1/3) = 0.5 \checkmark$.

3 Percentil 90: montar a equação

$$0.75 \left(x^2 - \frac{x^3}{3} \right) = 0.9$$

É uma cúbica, sem solução simples. Use tentativa e erro.

4 Bisseção

x	1.5	1.6	1.61	1.608
$F(x)$	0.844	0.896	0.901	0.900

$F(1.6) < 0.9 < F(1.61)$, então a resposta está entre 1.60 e 1.61; refinando, $x \approx 1.608$.

RESPOSTA

Moda = mediana = 1 s; $x_{0.90} \approx 1.608$ s (o p90 do tempo do job).

Nem todo percentil tem fórmula fechada; métodos numéricos simples resolvem. A bisseção é uma busca binária no eixo real: cada passo divide o intervalo ao meio.

Exercício 4.5 • Mediana de uma VAC

O tempo X (s) de execução de uma consulta ao banco de dados tem densidade

$$f(x) = \frac{3}{1}x^2, \quad 0 \leq x \leq 1.$$

Determine a mediana.

Espaço para cálculo

4.6 Trabalhando a partir da FDA

Até aqui o ponto de partida foi a densidade. Mas a FDA contém a mesma informação e, em muitos problemas, é o que se conhece: um fornecedor publica a curva de sobrevivência dos seus discos, uma ferramenta de monitoramento mostra a FDA empírica da latência, um modelo de cauda pesada é definido diretamente por $P(X > x)$. Partindo da FDA, as três operações básicas não exigem nenhuma integral:

- Probabilidades saem por diferença: $P(a < X \leq b) = F(b) - F(a)$ e $P(X > c) = 1 - F(c)$, sem integrar.
- A densidade sai por derivação: $f(x) = F'(x)$.
- Percentis saem por inversão: $x_p = F^{-1}(p)$.

Exemplo (cauda pesada): o tamanho X (MB) dos arquivos enviados a um serviço de armazenamento tem $F(x) = 1 - (2/x)^3$ para $x \geq 2$ (distribuição de Pareto). Então $P(X > 4) = (2/4)^3 = 0.125$; $f(x) = 24/x^4$; e o percentil 90 sai de $(2/x)^3 = 0.1$, isto é, $x_{0.90} = 2 \cdot 0.1^{-1/3} = 4.31$ MB.

INTUIÇÃO Cauda de potência contra cauda exponencial

A sobrevivência da Pareto, $(2/x)^3$, decai como uma potência de x , e não exponencialmente. A diferença é enorme na cauda: dobrar o tamanho divide a chance por $2^3 = 8$, qualquer que seja o ponto de partida, de modo que arquivos dez ou cem vezes maiores que o típico continuam aparecendo com frequência relevante. Com expoente 3, a média existe ($E[X] = 3$ MB) e a variância também, por pouco; com expoente abaixo de 2, a variância seria infinita.

NA COMPUTAÇÃO Pareto e a regra 80/20

Distribuições de Pareto aparecem em tamanhos de arquivos, popularidade de páginas e vídeos, tamanho de repositórios e de jobs: poucos itens enormes concentram a maior parte do volume. Isso é o que justifica caches, porque os itens populares cabem na memória, e o que torna o planejamento de capacidade difícil, porque um arquivo gigante pode aparecer a qualquer momento.

A inversão da FDA tem um uso que vai além de calcular percentis: gerar amostras.

DEDUÇÃO Transformada inversa

Se U é uniforme em $(0, 1)$, então $X = F^{-1}(U)$ tem FDA exatamente F , porque $P(U \leq u) = u$ para a uniforme:

$$P(F^{-1}(U) \leq x) = P(U \leq F(x)) = F(x)$$

Distribuição	$F^{-1}(u)$	Uso
Pareto do exemplo	$2(1 - u)^{-1/3}$	gerador de carga com tamanhos de arquivo realistas
Exponencial	$-\ln(1 - u)/\lambda$	tempos entre chegadas em simuladores de filas e redes

É a versão contínua da busca em degraus do caso discreto.

A FDA também é a ponte natural entre modelo e dados. Com observações $x_1, \dots, x_n$, a FDA empírica $\hat{F}(x)$ = fração das observações $\leq x$ é uma escada com degraus de altura $1/n$. O teorema de Glivenko-Cantelli garante que ela converge para a FDA real em todos os pontos ao mesmo tempo: com dados suficientes, a distribuição empírica revela a teórica. Comparar a FDA empírica com a de um modelo candidato, medindo a maior distância vertical entre as duas, é o teste de Kolmogorov-Smirnov, uma alternativa ao qui-quadrado que não exige agrupar os dados em classes.

CONEXÕES

- 2.3** transformada inversa discreta.
- 4.4** quando a variância não existe.
- 5.1** uniforme, ponto de partida.
- 5.4** exponencial.
- 8.5** teste de aderência.

▼ Entendendo a fórmula, termo a termo

$$F(x) = 1 - \left(\frac{a}{x}\right)^k \implies x_p = a(1-p)^{-1/k}$$

$1 - F(x)$ ← Cauda: probabilidade de exceder x .

$(a/x)^k$ ← A cauda decresce como potência de x (cauda pesada).

$(1-p)^{-1/k}$ ← Inverte a potência para isolar x .

De onde vem, passo a passo

1. Imponha $F(x_p) = p$: $1 - (a/x_p)^k = p$.
2. Isole a potência: $(a/x_p)^k = 1 - p$.
3. Tire a raiz k -ésima: $a/x_p = (1-p)^{1/k}$.
4. Inverta: $x_p = a(1-p)^{-1/k}$. Densidade: $f(x) = F'(x) = k a^k x^{-k-1}$.

EXEMPLO RESOLVIDO Lendo tudo da FDA

A vazão X (Gbps) de um enlace de rede instável, medida em instantes aleatórios, tem FDA conhecida.

DADOS

- $F(x) = x^2/4$ para $0 \leq x \leq 2$

O QUE SE PEDE

(a) $P(X > 1)$; (b) a densidade $f(x)$; (c) a vazão garantida em 90% do tempo (o percentil 10).

RESOLUÇÃO PASSO A PASSO

1 Cauda superior: complemento

$$P(X > 1) = 1 - F(1) = 1 - \frac{1}{4} = 0.75$$

2 Densidade: derivar

$$f(x) = F'(x) = \frac{2x}{4} = \frac{x}{2}, \quad 0 \leq x \leq 2$$

3 Percentil 10: inverter F

"10% não suportam" significa $F(x) = 0.1$:

$$\frac{x^2}{4} = 0.1 \implies x^2 = 0.4 \implies x = \sqrt{0.4} = 0.632 \text{ Gbps}$$

RESPOSTA (a) 0.75; (b) $f(x) = x/2$; (c) 0.632 Gbps.

Para dimensionar um serviço (por exemplo, a taxa de um vídeo em streaming), o que importa é esse percentil baixo da vazão, e não a média: a média de 1.33 Gbps só existe em parte do tempo.

Exercício 4.6 • Percentil por Inversão da FDA

O tamanho X (MB) dos arquivos enviados a um serviço de armazenamento tem FDA (Pareto)

$$F(x) = 1 - \left(\frac{4}{x}\right)^2, \quad x \geq 4$$

e $F(x) = 0$ para $x < 4$. Determine o percentil 90, isto é, o tamanho que 90% dos arquivos não excedem.

Espaço para cálculo

4.7 Quartis e Amplitude Interquartil de uma VAC

O desvio padrão mede dispersão usando todos os valores, ponderados pelo quadrado da distância à média. Isso o torna muito sensível à cauda: na Pareto com expoente abaixo de 2 ele nem existe. Uma medida alternativa usa só a FDA: a largura do intervalo que contém a metade central da distribuição. Os quartis $Q_1 = x_{0.25}$ e $Q_3 = x_{0.75}$ resolvem $F(x) = 0.25$ e $F(x) = 0.75$. A amplitude interquartil $AIQ = Q_3 - Q_1$ mede a dispersão da metade central da distribuição e, ao contrário de σ , existe mesmo quando a variância é infinita (caudas muito pesadas).

EXEMPLO Quartis da Pareto e assimetria

Medida	Equação	Valor
Q_1	$(2/x)^3 = 0.75$	2.20 MB
Mediana	$(2/x)^3 = 0.5$	$2 \cdot 2^{1/3} = 2.52$ MB
Q_3	$(2/x)^3 = 0.25$	3.17 MB

A distância de Q_1 à mediana (0.32) é menor que a da mediana a Q_3 (0.65): a metade de cima é mais espalhada. Isso mede a assimetria à direita sem precisar de nenhum momento, e é a leitura que o boxplot torna visual.

A grande vantagem dos quartis é a robustez: uma única requisição que travou por 30 s muda bastante a média e o desvio padrão de mil medições, mas quase não mexe nos quartis, que dependem só da ordem dos valores.

NA COMPUTAÇÃO Detecção de anomalias com quartis

Por isso detecção de anomalias em métricas costuma usar mediana e AIQ: um valor é suspeito se cai fora de $[Q_1 - 1.5 AIQ, Q_3 + 1.5 AIQ]$, a regra de Tukey. Quando os dados são aproximadamente normais, os quartis ficam a 0.674σ da média, então $AIQ \approx 1.349\sigma$, e $AIQ/1.349$ é um estimador de σ que não é contaminado por valores discrepantes.

É um exemplo de uma ideia que volta na estimação: às vezes vale trocar um pouco de eficiência por muita proteção contra dados ruins.

CONEXÕES

5.6 percentis da normal, de onde sai o 1.349.

6.4 boxplot e regra de Tukey.

7.5 eficiência contra robustez.

▼ Entendendo a fórmula, termo a termo

$$AIQ = F^{-1}(0.75) - F^{-1}(0.25)$$

$F^{-1}(0.75)$ ← Terceiro quartil: 75% da área à esquerda.

$F^{-1}(0.25)$ ← Primeiro quartil.

Diferença ← Largura da metade central da distribuição.

De onde vem, passo a passo

1. Resolva $F(x) = 0.25$ e $F(x) = 0.75$.
2. Subtraia. Compare $Md - Q_1$ com $Q_3 - Md$: se forem diferentes, a distribuição é assimétrica para o lado maior.
3. Para a normal, $AIQ = 1.349 \sigma$; o AIQ é uma medida de dispersão robusta a caudas pesadas.

EXEMPLO RESOLVIDO

Quartis versus desvio padrão

Mesmo enlace do exemplo 4.6.

DADOS

- $f(x) = x/2, F(x) = x^2/4, 0 \leq x \leq 2$

O QUE SE PEDE

Quartis, AIQ, média e desvio padrão, e o que eles dizem sobre a forma.

RESOLUÇÃO PASSO A PASSO

1 Quartis: $F(x) = q$

$$x^2/4 = q \implies x = 2\sqrt{q}:$$

$$Q_1 = 2\sqrt{0.25} = 1, \quad Md = 2\sqrt{0.5} = 1.414, \quad Q_3 = 2\sqrt{0.75} = 1.732$$

$$AIQ = Q_3 - Q_1 = 0.732.$$

2 Média e desvio

$$E[X] = \int_0^2 x \cdot \frac{x}{2} dx = \frac{4}{3}, \quad E[X^2] = \int_0^2 x^2 \cdot \frac{x}{2} dx = 2$$

$$\sigma = \sqrt{2 - (4/3)^2} = \sqrt{2 - 1.778} = 0.471$$

3 Ler a assimetria

$Md - Q_1 = 0.414$ contra $Q_3 - Md = 0.318$: a metade inferior é mais espalhada. Também $E[X] = 1.333 < Md = 1.414$.

RESPOSTA $Q_1 = 1, Md = 1.414, Q_3 = 1.732, AIQ = 0.732; E[X] = 1.333, \sigma = 0.471$.

A cauda esquerda é mais longa (assimetria à esquerda). Os quartis revelam isso; σ sozinho não.

Exercício 4.7 • Quartil Inferior de uma VAC

O tempo X (min) de um job de backup tem densidade

$$f(x) = \frac{4}{1296}x^3, \quad 0 \leq x \leq 6.$$

Calcule o primeiro quartil.

Espaço para cálculo

Exercícios de Fixação com Soluções Comentadas

3 Questões Resolvidas

Exercício 4.1: Normalização de FDP Polinomial e Probabilidade

O erro X (em milissegundos) do relógio de um servidor após a sincronização via NTP tem função densidade dada por: $f(x) = k \cdot (1 - x^2)$ para $-1 \leq x \leq 1$, e $f(x) = 0$ para qualquer outro valor.

- (a) Determine o valor da constante k .
- (b) Calcule a probabilidade de o erro estar entre 0 e 0.5 ms ($P(0 \leq X \leq 0.5)$).

Espaço para cálculo

Exercício 4.2: Obtenção da FDA e Mediana

Para a variável com densidade $f(x) = 2(1 - x)$ no suporte $0 \leq x \leq 1$:

- (a) Encontre a expressão da FDA $F(x)$.
- (b) Calcule a mediana m da distribuição.

Espaço para cálculo

Exercício 4.3: Esperança e Variância de um Tempo de Processamento

O tempo de compilação T (em segundos) de um algoritmo embarcado tem densidade dada por $f(t) = 3t^2$ para $0 \leq t \leq 1$, e 0 fora desse intervalo. Determine o valor esperado $E[T]$ e a variância $Var(T)$.

Espaço para cálculo

Módulo 5: Modelos Contínuos de Probabilidade

Uniforme contínua (jitter, quantização, geradores), normal e padronização (z-score, benchmarks, anomalias), exponencial (tempos entre chegadas, filas), confiabilidade e falta de memória, percentis da normal, orçamento de latência, aproximação normal da binomial e frotas de servidores.

O Módulo 4 deu as ferramentas gerais para variáveis contínuas; este módulo apresenta os três modelos que resolvem a maioria dos problemas práticos. Cada um tem uma origem que explica quando usá-lo. A uniforme vem da ignorância simétrica, como sua irmã discreta. A exponencial vem do processo de Poisson: é o tempo entre os eventos que a Poisson conta. A normal vem da soma de muitos efeitos pequenos, e essa origem, formalizada no Teorema Central do Limite, é o que a coloca no centro de toda a estatística dos Módulos 7 a 9. Entender a origem de cada modelo é o que permite reconhecer quando ele *não* se aplica, e esse é o erro mais caro na prática: tratar como normal o que tem cauda pesada, ou como sem memória o que se desgasta.

5.1 Distribuição Uniforme Contínua $U(a, b)$

A densidade é constante em todo o intervalo $[a, b]$: nenhum trecho é mais provável que outro de mesmo tamanho. É o modelo de um instante "ao acaso" dentro de um período (a hora em que um evento cai dentro do ciclo de um cron), de um *jitter* aleatório, e é a matéria-prima de todo gerador de números aleatórios.

DISTRIBUIÇÃO UNIFORME CONTÍNUA $X \sim U(a, b)$

$$f(x) = \frac{1}{b-a}, \quad a \leq x \leq b$$

$$F(x) = \frac{x-a}{b-a}, \quad a \leq x \leq b$$

$$E[X] = \frac{a+b}{2}, \quad \text{Var}(X) = \frac{(b-a)^2}{12}$$

▼ Equação desmontada, variável por variável

$$f(x) = \frac{1}{b-a}$$

a, b ← menor e maior valor possível (ex.: 2 e 8 s)

$b - a$ ← largura do intervalo (ex.: 6 s)

$\frac{1}{b-a}$ ← altura constante que dá área 1 (ex.: 1/6)

$$F(x) = \frac{x-a}{b-a}$$

$x - a$ ← quanto do intervalo já foi percorrido até x

$\frac{x-a}{b-a}$ ← fração percorrida = probabilidade acumulada (ex.: $(5 - 2)/6 = 0.5$)

$$E[X] = \frac{a+b}{2}, \quad Var(X) = \frac{(b-a)^2}{12}$$

$\frac{a+b}{2}$ ← média no meio (ex.: 5 s)

$(b-a)^2$ ← largura ao quadrado (ex.: 36)

12 ← constante da integral (ex.: $36/12 = 3 \text{ s}^2$)

A densidade $1/(b-a)$ é a única constante que dá área 1, e a FDA cresce em linha reta: a probabilidade de um subintervalo é só a fração do comprimento que ele ocupa. A média é o ponto do meio. A variância sai de $E[X^2] - \mu^2$ e é o limite da variância discreta $(k^2 - 1)/12$ quando os k valores ficam cada vez mais próximos. O desvio padrão é $(b-a)/\sqrt{12} \approx 0.29(b-a)$.

NA COMPUTAÇÃO Erro de quantização

Arredondar um valor para o múltiplo mais próximo de Δ produz um erro aproximadamente $U(-\Delta/2, \Delta/2)$, com desvio $\Delta/\sqrt{12}$. Isso vale para um conversor analógico-digital, para timestamps truncados em milissegundos (desvio de 0.29 ms acrescentado a cada medida) e, em escala relativa, para o arredondamento de ponto flutuante. Como erros de quantização de etapas diferentes são aproximadamente independentes, suas variâncias se somam, e é assim que se estima o erro acumulado de um cálculo numérico longo.

NA COMPUTAÇÃO Jitter contra o efeito manada

Quando muitos clientes falham ao mesmo tempo e tentam de novo após o mesmo intervalo, voltam todos juntos e derrubam o servidor de novo. A solução é sortear a espera: no backoff exponencial com *full jitter*, cada cliente espera $U(0, b)$, com b dobrando a cada falha. A uniforme espalha as tentativas pelo intervalo inteiro e desfaz os picos sincronizados. A mesma ideia aparece nos tempos de eleição aleatórios do Raft, que evitam que dois nós se candidatem ao mesmo tempo indefinidamente.

Por fim, a uniforme em $(0, 1)$ é o ponto de partida de toda simulação. Geradores pseudoaleatórios produzem inteiros aproximadamente uniformes, e dividindo pelo máximo obtém-se $U(0, 1)$. Pela transformada inversa, qualquer distribuição contínua sai daí: $a + (b - a)U$ dá $U(a, b)$, $-\ln(1 - U)/\lambda$ dá a exponencial, e duas uniformes dão duas normais pelo método de Box-Muller.

CUIDADO Toda simulação depende da qualidade das uniformes

Se as uniformes geradas não forem de fato uniformes e independentes, todas as distribuições derivadas delas herdam o defeito. Verificar o gerador é uma aplicação direta dos testes de aderência.

CONEXÕES

- 3.1** uniforme discreta.
- 4.6** transformada inversa.
- 6.6** o mesmo $h^2/12$ ao agrupar dados.
- 8.5** testar geradores.

▼ Entendendo a fórmula, termo a termo

$$f(x) = \frac{1}{b-a}, \quad E[X] = \frac{a+b}{2}, \quad Var(X) = \frac{(b-a)^2}{12}$$

$$\frac{1}{b-a}$$

← Altura constante que faz a área do retângulo valer 1.

$$\frac{a+b}{2}$$

← Centro do intervalo (simetria).

$$(b-a)^2/12$$

← Dispersão cresce com o quadrado da largura do intervalo.

De onde vem, passo a passo

1. Densidade constante c em $[a, b]$: área $c(b-a) = 1 \implies c = 1/(b-a)$.

$$2. E[X] = \int_a^b \frac{x}{b-a} dx = \frac{b^2 - a^2}{2(b-a)} = \frac{a+b}{2}.$$

$$3. E[X^2] = \frac{b^3 - a^3}{3(b-a)} = \frac{a^2 + ab + b^2}{3}.$$

$$4. Var = \frac{a^2 + ab + b^2}{3} - \frac{(a+b)^2}{4} = \frac{4a^2 + 4ab + 4b^2 - 3a^2 - 6ab - 3b^2}{12} = \frac{(b-a)^2}{12}.$$

EXEMPLO RESOLVIDO

Espera pelo próximo ciclo de um cron

Um job de sincronização roda a cada 15 min. Um registro é gravado num instante aleatório e espera a próxima execução do job para ser replicado.

DADOS

- espera $X \sim U(0, 15)$ min
- $a = 0, b = 15$

O QUE SE PEDE

(a) $P(X > 10)$; (b) $E[X]$ e σ ; (c) o desvio do erro de arredondamento ao gravar um valor com resolução de 1 unidade.

RESOLUÇÃO PASSO A PASSO

1 Densidade

Na uniforme, a densidade é constante e igual a $1/(b-a) = 1/15$ dentro do intervalo.

2 Probabilidade = base × altura

$X > 10$ é o trecho de 10 a 15, de largura 5:

$$P(X > 10) = \frac{15 - 10}{15} = \frac{5}{15} = 0.333$$

3 Média e desvio

$$E[X] = \frac{a + b}{2} = 7.5 \text{ min}, \quad \sigma = \frac{b - a}{\sqrt{12}} = \frac{15}{3.464} = 4.33 \text{ min}$$

4 Aplicação: erro de arredondamento

Gravar com resolução 1 arredonda para o inteiro mais próximo, então o erro é $U(-0.5; 0.5)$:

$$\sigma = \frac{0.5 - (-0.5)}{\sqrt{12}} = \frac{1}{\sqrt{12}} = 0.289 \text{ unidade}$$

RESPOSTA (a) 1/3; (b) 7.5 min e 4.33 min; (c) 0.289.

É daí que vem o "erro de quantização" em conversores analógico-digitais e em timestamps truncados: resolução Δ gera incerteza $\Delta/\sqrt{12}$. E a espera média de 7.5 min é a latência média de replicação desse desenho.

Exercício 5.1 • Uniforme Contínua: Intervalo

O atraso X (s) que um cliente espera antes de tentar de novo (backoff com jitter) é uniforme em $[8, 28]$. Calcule $P(16 < X < 17)$.

Espaço para cálculo

5.2 Distribuição Normal (Gaussiana) $N(\mu, \sigma^2)$

Some muitos efeitos pequenos e independentes, de qualquer distribuição, e o resultado terá sempre a mesma forma de sino. Esse é o conteúdo do Teorema Central do Limite, e é a razão pela qual a normal é a distribuição mais importante da estatística. Ela aparece quando um valor é a soma de muitas contribuições: o ruído de uma medição (soma de muitas perturbações), o tempo total de um benchmark repetido muitas vezes, e sobretudo médias de amostras, que são somas divididas por n .

DISTRIBUIÇÃO NORMAL GAUSSIANA

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right), \quad -\infty < x < +\infty$$

$$E[X] = \mu, \quad \text{Var}(X) = \sigma^2$$

▼ Equação desmontada, variável por variável

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left[-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2\right]$$

$f(x)$

← altura do sino em x

μ

← média: centro do sino (ex.: 50 ms)

σ

← desvio padrão: largura do sino (ex.: 0.2 ms)

$\frac{x-\mu}{\sigma}$

← distância até a média em desvios padrão (z)

$\exp[\dots]$

← e elevado ao que está dentro; vale 1 no centro e cai nas pontas

$\frac{1}{\sigma\sqrt{2\pi}}$

← ajusta a altura para a área total ser 1

$$E[X] = \mu, \quad \text{Var}(X) = \sigma^2$$

μ, σ^2

← os dois parâmetros já são a média e a variância

Propriedades da Normal:

- **Simetria:** o sino é simétrico em torno de μ , então média = mediana = moda = μ .
- **Pontos de inflexão:** em $x = \mu - \sigma$ e $x = \mu + \sigma$.
- **Regra Empírica 68-95-99.7%:**
 - $P(\mu - 1\sigma \leq X \leq \mu + 1\sigma) \approx 0.6827$ (68.27%)
 - $P(\mu - 2\sigma \leq X \leq \mu + 2\sigma) \approx 0.9545$ (95.45%)
 - $P(\mu - 3\sigma \leq X \leq \mu + 3\sigma) \approx 0.9973$ (99.73%)

INTUIÇÃO Lendo a fórmula

O expoente $-\frac{1}{2}z^2$, com $z = (x - \mu)/\sigma$, faz a densidade cair com o quadrado da distância à média, medida em desvios padrão; a constante $\frac{1}{\sigma\sqrt{2\pi}}$ só garante área 1. Os dois parâmetros são exatamente a média e a variância, de modo que uma normal fica inteiramente determinada por eles. Isso explica um fato usado o tempo todo: entre todas as distribuições com média e variância dadas, a normal é a de maior entropia, isto é, a que menos supõe além desses dois números.

A regra 68-95-99.7 é a forma prática de pensar com a normal, e seus números reaparecem em vários pontos do curso:

EXEMPLO A regra empírica contra Chebyshev

Fora de	Chebyshev (qualquer distribuição)	Normal	Onde reaparece
$\pm 2\sigma$	até 25%	4.6%	$\pm 1.96\sigma$ é a origem do "95% de confiança" dos intervalos
$\pm 3\sigma$	até 11%	0.27%	taxa de alarme falso dos gráficos de controle de Shewhart

CUIDADO Caudas finas: a força e a armadilha

A queda com $e^{-z^2/2}$ é muito rápida: $P(|Z| > 5) \approx 6 \times 10^{-7}$ e $P(|Z| > 6) \approx 2 \times 10^{-9}$. Latências individuais quase nunca são normais: são positivas e têm cauda longa à direita (filas, pausas de coleta de lixo, retransmissões). Modelá-las como normais e calcular o p99 como $\mu + 2.326\sigma$ subestima muito a cauda, e alertas "a 3σ " disparam o tempo todo. Se os dados mostram eventos de "6 sigmas" com frequência, eles não são normais. A normal entra com força em *médias* de muitas medições, não nas medições individuais, e é exatamente isso que o TCL garante.

NA COMPUTAÇÃO Gerando normais: Box-Muller

De duas uniformes independentes U_1, U_2 saem duas normais padrão independentes: $Z_1 = \sqrt{-2 \ln U_1} \cos(2\pi U_2)$ e $Z_2 = \sqrt{-2 \ln U_1} \sin(2\pi U_2)$. Inicialização de pesos em redes neurais, ruído em simulações e técnicas de privacidade diferencial usam normais geradas assim.

CONEXÕES

- 2.5** Chebyshev.
- 7.3** TCL, a origem da normal.
- 7.4** o 95% dos intervalos.
- 9.2** limites de 3σ .

▼ Entendendo a fórmula, termo a termo

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right]$$

$$\frac{x - \mu}{\sigma}$$

← Distância até a média medida em desvios padrão (o escore z).

$$-\frac{1}{2}z^2$$

← Expoente negativo: a densidade cai rápido (quadraticamente) ao se afastar da média, igual dos dois lados.

$$\exp[\cdot]$$

← Vale 1 em $x = \mu$ (topo do sino) e tende a 0 nas caudas.

$$\frac{1}{\sigma\sqrt{2\pi}}$$

← Normalizador: faz a área total valer 1. Quanto maior σ , mais baixo e largo o sino.

De onde vem, passo a passo

1. O máximo está em $x = \mu$, onde o expoente é zero.
2. Os pontos de inflexão (onde a curvatura muda) ficam em $\mu \pm \sigma$: σ mede a "meia largura" visual do sino.
3. A área entre $\mu - k\sigma$ e $\mu + k\sigma$ depende só de k (68%, 95%, 99.7% para $k = 1, 2, 3$), por isso a regra empírica vale para qualquer normal.

EXEMPLO RESOLVIDO

Regra empírica num benchmark

Um benchmark é executado muitas vezes na mesma máquina, em condições controladas. O tempo de cada execução varia por ruído (cache, escalonador) e é aproximadamente normal.

DADOS

- $X \sim N(500, 5^2)$ ms, ou seja, $\mu = 500$ e $\sigma = 5$

O QUE SE PEDE

(a) as faixas de 68%, 95% e 99.7%; (b) o quão rara é uma execução de 520 ms; (c) fração abaixo de 490 ms.

RESOLUÇÃO PASSO A PASSO

1 Regra 68-95-99.7

Em qualquer normal, cerca de 68% dos valores ficam a até 1σ da média, 95% a até 2σ e 99.7% a até 3σ :

- $500 \pm 5 = [495; 505]$ ms: 68%
- $500 \pm 10 = [490; 510]$ ms: 95%
- $500 \pm 15 = [485; 515]$ ms: 99.7%

2 Quantos desvios é 520 ms

$$z = \frac{520 - 500}{5} = 4$$

$$P(X > 520) = 1 - \Phi(4) \approx 0.00003, \text{ ou } 0.003\%.$$

3 Abaixo de 490 ms

490 está a 2σ abaixo. Fora de $\pm 2\sigma$ ficam 5%, metade de cada lado:

$$P(X < 490) \approx \frac{5\%}{2} = 2.5\% \quad (\text{tabela: } \Phi(-2) = 0.0228)$$

RESPOSTA (b) cerca de 3 em 100 000; (c) 2.3%.

Se aparece uma execução de 520 ms depois de um commit, ou o código ficou mais lento (regressão de desempenho), ou o modelo está errado. É esse raciocínio que ferramentas de detecção de regressão e o CEP (Módulo 9) formalizam.

Exercício 5.2 • Regra Empírica 68-95-99,7

O tempo de um benchmark segue $N(160, 4^2)$ ms. Em 500 execuções, quantas se espera fora do intervalo $[152; 168]$ ms?

Espaço para cálculo

5.3 Padronização e a Tabela Normal Padrão $Z \sim N(0, 1)$

A densidade normal não tem primitiva elementar: não existe fórmula com funções usuais para $\int_a^b f(x) dx$. Seria preciso uma tabela para cada par (μ, σ) . A saída é a **padronização**, que leva qualquer normal à Normal Padrão Z , cuja FDA Φ está tabelada (e implementada em toda biblioteca estatística):

PADRONIZAÇÃO DA VARIÁVEL NORMAL

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

$$P(a \leq X \leq b) = P\left(\frac{a - \mu}{\sigma} \leq Z \leq \frac{b - \mu}{\sigma}\right) = \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right)$$

$$\text{Simetria de } \Phi : \quad \Phi(-z) = 1 - \Phi(z)$$

▼ Equação desmontada, variável por variável

$$Z = \frac{X - \mu}{\sigma} \sim N(0, 1)$$

Z ← o que se calcula: valor padronizado (escore z)

X ← valor original (ex.: 49.6 ms)

$X - \mu$ ← distância até a média (ex.: $49.6 - 50 = -0.4$)

$\div \sigma$ ← converte a distância em nº de desvios (ex.: $-0.4/0.2 = -2$)

$N(0, 1)$ ← normal padrão: média 0, desvio 1

$$P(a \leq X \leq b) = \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right)$$

$\Phi(z)$ ← área à esquerda de z , lida na tabela Z

$\frac{b - \mu}{\sigma}$ ← limite superior padronizado

$\frac{a - \mu}{\sigma}$ ← limite inferior padronizado

— ← área até b menos área até a

$$\Phi(-z) = 1 - \Phi(z)$$

$\Phi(-z)$ ← área à esquerda de um z negativo

$1 - \Phi(z)$ ← igual à área à direita do z positivo (simetria) (ex.: $\Phi(-1.5) = 1 - 0.9332 = 0.0668$)

DEDUÇÃO Por que a padronização funciona

1. É uma transformação linear, $Z = (X - \mu)/\sigma$: subtrair μ leva a média a 0, dividir por σ leva o desvio a 1.
2. O fato especial da normal é que a *forma* também se preserva: uma transformação linear de uma normal continua normal.
3. A segunda linha é apenas a FDA usada por diferença, e a simetria $\Phi(-z) = 1 - \Phi(z)$ permite tabelar só os z positivos.

O valor $z = (x - \mu)/\sigma$, o **z-score**, é uma medida universal: diz a quantos desvios padrão da média está um valor, sem unidade. Isso permite comparar coisas de escalas diferentes, como uma latência de 300 ms num serviço com $\sigma = 40$ ms e um uso de memória de 7 GB num serviço com $\sigma = 0.5$ GB.

NA COMPUTAÇÃO O z-score fora da tabela

- **Aprendizado de máquina:** padronizar as features coloca todas na mesma escala, o que acelera o treinamento por gradiente e impede que uma feature em bytes domine outra em contagens; a *batch normalization* aplica isso às ativações internas da rede.
- **Monitoramento:** o detector de anomalias mais simples calcula média e desvio de uma janela recente e alerta quando $|z| > 3$. Funciona se a métrica for aproximadamente normal e estável; falha com sazonalidade e caudas pesadas.
- **Testes:** o teste Z padroniza a média amostral com o seu próprio desvio, $\sigma/\sqrt{n}$, e pergunta se o resultado é improvável sob H_0 .

CUIDADO Calculando Φ em código

$\Phi(z) = \frac{1}{2} [1 + \text{erf}(z/\sqrt{2})]$, e a função erf existe em C, Python (`math.erf`) e na maioria das linguagens. Para caudas distantes, use `erfc`: calcular $1 - \Phi(z)$ por subtração perde todos os dígitos quando $\Phi(z)$ é quase 1, o mesmo cancelamento catastrófico da fórmula computacional da variância.

CONEXÕES

- 2.4** efeito de transformação linear na média.
- 2.5** efeito na variância; cancelamento catastrófico.
- 4.3** FDA por diferença.
- 8.4** teste Z.

▼ Entendendo a fórmula, termo a termo

$$Z = \frac{X - \mu}{\sigma}, \quad P(a \leq X \leq b) = \Phi\left(\frac{b - \mu}{\sigma}\right) - \Phi\left(\frac{a - \mu}{\sigma}\right)$$

$$X - \mu$$

← Centraliza: desloca a distribuição para média 0.

$$\div \sigma$$

← Muda a escala para desvio padrão 1.

$$\Phi(z)$$

← Área à esquerda de z na normal padrão (tabelada).

De onde vem, passo a passo

1. $E[Z] = \frac{E[X] - \mu}{\sigma} = 0$ e $Var(Z) = \frac{Var(X)}{\sigma^2} = 1$ (propriedades de $aX + b$).
2. Transformação linear de uma normal continua normal, logo $Z \sim N(0, 1)$.
3. Aplique a mesma operação aos três membros de $a \leq X \leq b$; como $\sigma > 0$, os sinais não se invertem.
4. A probabilidade entre os dois limites padronizados é a diferença das áreas à esquerda. Para $z < 0$: $\Phi(-z) = 1 - \Phi(z)$.

EXEMPLO RESOLVIDO

Padronizando passo a passo

O tempo de resposta de um endpoint, medido como média por janela de um minuto, segue uma normal. Qual fração das janelas fica entre 97 e 104 ms?

DADOS

- $X \sim N(100, 2^2)$ ms: $\mu = 100, \sigma = 2$

O QUE SE PEDE

$$P(97 < X < 104).$$

RESOLUÇÃO PASSO A PASSO

1

Padronizar cada limite

$z = (x - \mu)/\sigma$ mede "quantos desvios padrão" o valor está da média:

$$z_1 = \frac{97 - 100}{2} = -1.5, \quad z_2 = \frac{104 - 100}{2} = 2.0$$

2 Ler a tabela

A tabela dá $\Phi(z) = P(Z \leq z)$: $\Phi(2.0) = 0.9772$.

3 Valor negativo: simetria

A normal é simétrica em torno de 0, então a cauda abaixo de -1.5 é igual à cauda acima de $+1.5$:

$$\Phi(-1.5) = 1 - \Phi(1.5) = 1 - 0.9332 = 0.0668$$

4 Subtrair

$$P(97 < X < 104) = \Phi(2.0) - \Phi(-1.5) = 0.9772 - 0.0668 = 0.9104$$

RESPOSTA 91.0% das janelas.

A padronização transforma qualquer normal na $N(0, 1)$, e por isso basta uma única tabela.

Exercício 5.3 • Normal: Padronização

O tempo médio de resposta X (ms) de um endpoint, por janela de um minuto, segue $N(\mu = 65, \sigma = 1.5)$. Calcule $P(X > 66.88)$.

Espaço para cálculo

5.4 Distribuição Exponencial $Exp(\lambda)$

A Poisson conta quantos eventos acontecem num intervalo. A pergunta complementar é quanto tempo se espera até o próximo. Se eventos chegam como Poisson com taxa λ , "o primeiro evento demora mais que t " é o mesmo que "nenhum evento em $[0, t]$ ", que tem probabilidade $e^{-\lambda t}$. Daí $P(X > t) = e^{-\lambda t}$, que é a exponencial. Ela modela o tempo até o primeiro evento de um processo de Poisson com

taxa $\lambda > 0$: tempo entre chegadas de requisições, tempo até a próxima falha de um servidor na fase de vida útil, duração de chamadas e sessões em modelos simples de fila.

DISTRIBUIÇÃO EXPONENCIAL $X \sim \text{Exp}(\lambda)$

$$f(x) = \lambda e^{-\lambda x}, \quad x \geq 0$$

$$F(x) = 1 - e^{-\lambda x}, \quad x \geq 0$$

$$E[X] = \frac{1}{\lambda} = \text{MTTF (Mean Time To Failure)}, \quad \text{Var}(X) = \frac{1}{\lambda^2}$$

▼ Equação desmontada, variável por variável

$$f(x) = \lambda e^{-\lambda x}$$

λ ← taxa de falha (ex.: 0.0005 falha/h)

x ← tempo (ex.: 1000 h)

$e^{-\lambda x}$ ← decaimento: quanto maior o tempo, menor a densidade

$$F(x) = 1 - e^{-\lambda x}$$

$F(x)$ ← chance de falhar até x (ex.: $1 - e^{-0.5} = 0.393$)

$$E[X] = \frac{1}{\lambda}, \quad \text{Var}(X) = \frac{1}{\lambda^2}$$

$\frac{1}{\lambda}$ ← tempo médio até a falha, MTTF (ex.: 2000 h)

$\frac{1}{\lambda^2}$ ← variância; o desvio padrão é igual à média

A média $1/\lambda$ é intuitiva: com 4 requisições por segundo, espera-se 0.25 s entre elas. Ela sai da área sob a sobrevivência: $\int_0^\infty e^{-\lambda t} dt = 1/\lambda$. Como a média é o "tempo médio até falhar", em confiabilidade ela se chama MTTF.

INTUIÇÃO A versão contínua da geométrica

A geométrica conta tentativas até o primeiro sucesso; a exponencial mede tempo até o primeiro evento. Fatiando o tempo em pedaços minúsculos, uma vira a outra, assim como a binomial vira Poisson.

O desvio padrão é igual à média, de modo que o coeficiente de variação é 1. Isso faz da exponencial uma distribuição bem variável: muitos intervalos curtos e alguns muito longos. Essa variabilidade é o que gera filas mesmo quando o servidor tem folga.

NA COMPUTAÇÃO Fila M/M/1

Com chegadas Poisson de taxa λ e tempos de serviço exponenciais de taxa μ , o tempo médio no sistema é $\frac{1}{\mu - \lambda}$:

Utilização $\rho = \lambda/\mu$	50%	90%	$\rightarrow 100\%$
Tempo de resposta ÷ tempo de serviço	2×	10×	$\rightarrow \infty$

É a forma convexa da desigualdade de Jensen, e a razão pela qual servidores não devem operar perto de 100% de utilização.

NA COMPUTAÇÃO A base das simulações de eventos discretos

- **Gerar:** a exponencial sai de uma uniforme por $-\ln(1 - U)/\lambda$, e somar exponenciais sucessivas simula um processo de Poisson.
- **Mínimo de exponenciais:** se os componentes têm taxas λ_i independentes, o primeiro a falhar o faz com taxa $\sum \lambda_i$, e a chance de ser o componente i é $\lambda_i / \sum \lambda_j$. É o resultado que dá a confiabilidade de sistemas em série e a base das cadeias de Markov em tempo contínuo.

CONEXÕES

- 3.3 processo de Poisson.
- 3.5 geométrica.
- 2.8 Jensen e filas.
- 4.4 média como área sob a sobrevivência.
- 5.9 sistemas em série.

▼ Entendendo a fórmula, termo a termo

$$R(t) = P(T > t) = e^{-\lambda t}, \quad f(t) = \lambda e^{-\lambda t}, \quad E[T] = \frac{1}{\lambda}$$

 λ

← Taxa de falha: falhas por unidade de tempo.

 $e^{-\lambda t}$ ← Probabilidade de nenhuma falha até t . $1/\lambda$

← Tempo médio até a falha (MTTF).

De onde vem, passo a passo

1. $T > t$ significa zero eventos de Poisson em $[0, t]$: $P = e^{-\lambda t} (\lambda t)^0 / 0! = e^{-\lambda t}$.
2. $F(t) = 1 - e^{-\lambda t}$; derivando, $f(t) = \lambda e^{-\lambda t}$.
3. Média: $E[T] = \int_0^\infty R(t) dt = \int_0^\infty e^{-\lambda t} dt = 1/\lambda$.

EXEMPLO RESOLVIDO Só 37% chegam à vida média

O tempo T até a falha de um servidor, na fase de vida útil, segue uma exponencial.

DADOS

- $\lambda = 0.0002$ falhas/h
- $MTTF = 1/\lambda = 5000$ h

O QUE SE PEDE

(a) $P(T < 1000)$; (b) $R(5000)$; (c) a vida mediana.

RESOLUÇÃO PASSO A PASSO

1 FDA da exponencial

$$F(t) = 1 - e^{-\lambda t}, \quad R(t) = 1 - F(t) = e^{-\lambda t}$$

2 Falhar antes de 1000 h

$$\lambda t = 0.0002 \times 1000 = 0.2:$$

$$P(T < 1000) = 1 - e^{-0.2} = 1 - 0.8187 = 0.181$$

3 Sobreviver até a média

$$\lambda t = 0.0002 \times 5000 = 1:$$

$$R(5000) = e^{-1} = 0.368$$

4 Mediana: $R(t) = 0.5$

$$e^{-\lambda t} = 0.5 \implies t = \frac{\ln 2}{\lambda} = \frac{0.693}{0.0002} = 3466 \text{ h}$$

RESPOSTA (a) 18%; (b) 37%; (c) 3466 h.

Só 37% dos servidores sobrevivem até a vida *média*, e metade já falhou em 3466 h. A média é puxada por poucos itens muito duradouros. Em escala de frota, isso significa planejar trocas bem antes do MTTF.

Exercício 5.4 • Exponencial: Vida Mediana

O tempo T (h) até a falha de um disco é exponencial com $\text{MTTF} = 1/\lambda = 4750$ h. Qual a vida mediana?

Espaço para cálculo

5.5 Confiabilidade e a Propriedade de Falta de Memória

Em confiabilidade, a sobrevivência da exponencial ganha nome próprio. A **Função Confiabilidade** $R(t)$ é a probabilidade de o sistema sobreviver além do instante t :

$$R(t) = P(X > t) = 1 - F(t) = e^{-\lambda t}$$

▼ Equação desmontada, variável por variável

$$R(t) = P(X > t) = 1 - F(t) = e^{-\lambda t}$$

$R(t)$ ← o que se calcula: confiabilidade, chance de durar além de t

t ← tempo de missão (ex.: 1000 h)

$1 - F(t)$ ← complemento da chance de falhar até t

$e^{-\lambda t}$ ← fórmula direta (ex.: $e^{-0.0005 \times 1000} = 0.607$)

Propriedade de Falta de Memória (Memoryless): A exponencial é a *única* distribuição contínua com esta propriedade:

$$P(X > s + t \mid X > s) = P(X > t)$$

Significado: o tempo já decorrido não muda a chance de falha futura. Um servidor que está no ar há s horas sem falhar é probabilisticamente equivalente a um recém-ligado.

DEDUÇÃO A prova e a origem

É a definição de probabilidade condicional aplicada diretamente: como o evento $\{X > s + t\}$ está contido em $\{X > s\}$,

$$P(X > s + t \mid X > s) = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t}$$

A origem da propriedade está no processo de Poisson: as contagens em intervalos disjuntos são independentes, então o que aconteceu (ou não) até s não informa nada sobre o que vem depois. A versão discreta é a geométrica: ter falhado 10 vezes seguidas numa tentativa com chance fixa não torna a próxima mais provável, e acreditar no contrário é a falácia do apostador.

Para ver quando a propriedade vale, define-se a **taxa de falha** instantânea $h(t) = f(t)/R(t)$, a chance de falhar logo após t dado que sobreviveu até t . Na exponencial ela é constante, $h(t) = \lambda$, e essa é outra forma de dizer "sem memória". Hardware real segue a curva da banheira:

INTUIÇÃO A curva da banheira

Fase	Taxa de falha	Causa	Política
Mortalidade infantil	alta e caindo	defeitos de fabricação	<i>burn-in</i> antes de colocar servidores em produção
Vida útil	quase constante	falhas aleatórias	a exponencial vale; trocar preventivamente não aumenta a confiabilidade
Desgaste	crescente	ciclos de escrita de SSD, baterias	a troca preventiva faz sentido

A distribuição de Weibull, com um parâmetro de forma, cobre as três fases.

NA COMPUTAÇÃO Software também envelhece

Vazamentos de memória e fragmentação fazem a taxa de falha de um processo crescer com o tempo de execução. Reinícios programados (*rejuvenation*) só ajudam porque esse processo *não* é sem memória. A mesma degradação lenta é o que os gráficos de controle tentam detectar antes de virar incidente.

CONEXÕES

- 1.3** probabilidade condicional.
- 3.3** independência entre intervalos.
- 3.5** geométrica sem memória.
- 9.9** degradação lenta detectada antes do incidente.

▼ Entendendo a fórmula, termo a termo

$$P(T > s + t \mid T > s) = \frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t}$$

$T > s$ ← O componente já sobreviveu s unidades de tempo.

$T > s + t$ ← Sobrevive mais t além disso.

Resultado ← Não depende de s : o passado não importa.

De onde vem, passo a passo

1. Definição de condicional: $\frac{P(T > s+t \cap T > s)}{P(T > s)}$.
2. Quem passa de $s + t$ já passou de s , então a interseção é só $\{T > s + t\}$.
3. Substituindo R : $\frac{e^{-\lambda(s+t)}}{e^{-\lambda s}} = e^{-\lambda t}$, pela regra $e^a/e^b = e^{a-b}$.

EXEMPLO RESOLVIDO Usado ou novo, tanto faz

O servidor do exemplo 5.4 já funcionou 3000 h sem falhar. Qual a chance de durar mais 2000 h?

DADOS

- $\lambda = 0.0002/\text{h}$
- já sobreviveu: $T > 3000$

O QUE SE PEDE

$$P(T > 5000 \mid T > 3000).$$

RESOLUÇÃO PASSO A PASSO

1 Definição de condicional

Quem dura mais de 5000 h também durou mais de 3000 h, então a interseção é só $T > 5000$:

$$P(T > 5000 \mid T > 3000) = \frac{P(T > 5000)}{P(T > 3000)}$$

2 Substituir $R(t)$

$$= \frac{e^{-0.0002 \times 5000}}{e^{-0.0002 \times 3000}} = \frac{e^{-1}}{e^{-0.6}} = e^{-0.4} = 0.670$$

3 Comparar com um servidor novo

Um servidor novo durar 2000 h: $R(2000) = e^{-0.4} = 0.670$. **Idêntico.**

RESPOSTA 0.670, igual à de um servidor novo.

Falta de memória: para componentes com taxa constante, **substituição preventiva não aumenta a confiabilidade**. Para itens que se desgastam (SSDs perto do limite de escritas, baterias de nobreak), a exponencial não serve.

Exercício 5.5 • Exponencial: Falta de Memória

O tempo T (h) até a falha de um disco é exponencial com $\text{MTTF} = 1/\lambda = 1750$ h. Um disco já operou 1000 h sem falhar. Qual $P(T > 2600 \mid T > 1000)$?

Espaço para cálculo

5.6 Problema Inverso: Percentis da Normal

Até aqui a pergunta foi "dado um limite, qual a probabilidade de passar dele?". Em engenharia de sistemas, a pergunta mais comum é a inversa: "que limite garante que só uma fração p passe dele?". Qual timeout deixa só 1% das chamadas de fora? Quanta memória reservar para um contêiner estourar em no máximo 2% dos dias? Para achar x_p com $P(X \leq x_p) = p$, busque z_p na tabela e faça $x_p = \mu + z_p \sigma$. Valores úteis: $z_{0.90} = 1.282$, $z_{0.95} = 1.645$, $z_{0.99} = 2.326$ (e os negativos para $p = 0.10, 0.05, 0.01$).

Ex.: o tempo de um job noturno segue $N(5000, 400^2)$ s. Para que só 2% das execuções estourem a janela de manutenção, ela deve durar pelo menos $x = 5000 + 2.054 \times 400 = 5822$ s.

A fórmula $x_p = \mu + z_p \sigma$ é a padronização resolvida para x . Ela mostra que, numa normal, todo percentil é "média mais um número de desvios", e esse número depende só de p ; por isso a tabela de z_p serve para qualquer normal. Os valores 1.645, 1.96 e 2.576 vão reaparecer como valores críticos de intervalos de confiança e testes: um intervalo de 95% deixa 2.5% em cada cauda, então usa $z_{0.975} = 1.96$.

DEDUÇÃO Quando o limite é fixo, isola-se a média

Se o limite é dado (um SLO contratual, uma quota de memória), o que se ajusta é o processo: $\mu = x_{\text{limite}} - z_p \sigma$. A fórmula mostra a alavanca que importa: reduzir σ permite operar com a média mais perto do limite.

EXEMPLO O valor de reduzir a variabilidade

Para estouro de 1% ($z = 2.326$): com desvio de uso de memória de 400 MB, a reserva acima da média é $2.326 \times 400 = 930$ MB; com desvio de 200 MB, cai para 465 MB. Em milhares de contêineres, isso significa muitos servidores a menos. Essa relação entre limite, média e variabilidade é exatamente o que os índices de capacidade C_p e C_{pk} medem.

CUIDADO Percentis altos dependem da cauda

O cálculo é tão bom quanto a hipótese de normalidade, e o problema inverso é justamente onde ela mais pesa. Para métricas com cauda pesada, um p99 calculado como $\mu + 2.326\sigma$ pode estar muito abaixo do real; nesses casos, estima-se o percentil diretamente dos dados. Em código, a inversa de Φ é `scipy.stats.norm.ppf(p)` ou `NormalDist().inv_cdf(p)` no Python padrão; não há fórmula fechada, e as bibliotecas usam aproximações racionais com precisão de máquina.

CONEXÕES

- 4.5 percentis contínuos.
- 5.3 padronização resolvida para x .
- 6.4 percentis amostrais.
- 7.4 valores críticos dos intervalos.
- 9.5 C_p e C_{pk} .

▼ Entendendo a fórmula, termo a termo

$$x_p = \mu + z_p \sigma$$

 z_p

← Quantos desvios padrão o percentil está da média (negativo se $p < 0.5$).

 $z_p \sigma$

← Converte essa distância para a unidade de X .

 $\mu + \dots$

← Desloca a partir do centro.

De onde vem, passo a passo

1. Queremos $P(X \leq x_p) = p$.
2. Padronizando: $P\left(Z \leq \frac{x_p - \mu}{\sigma}\right) = p$, logo $\frac{x_p - \mu}{\sigma} = z_p$.
3. Isolando: $x_p = \mu + z_p \sigma$. É a padronização "ao contrário".

EXEMPLO RESOLVIDO

Quanta memória livre reservar

Um servidor de streaming precisa de pelo menos 50 MB de buffer livre; abaixo disso o vídeo engasga. A memória livre oscila em torno de uma média μ , que pode ser ajustada pelo tamanho do cache, com desvio padrão conhecido. Onde deixar a média para que só 1% do tempo fique abaixo de 50 MB?

DADOS

- $\sigma = 0.4$ MB
- limite inferior = 50 MB
- fração abaixo desejada: 1%

O QUE SE PEDE

A média μ do processo.

RESOLUÇÃO PASSO A PASSO

1

Achar o z da cauda

Procure na tabela o z com $\Phi(z) = 0.01$: $z = -2.326$. O limite tem que estar 2.326 desvios abaixo da média.

2 Montar a equação

$$\frac{50 - \mu}{0.4} = -2.326$$

3 Isolar μ

$$\mu = 50 + 2.326 \times 0.4 = 50 + 0.93 = 50.93 \text{ MB}$$

RESPOSTA Manter a média de memória livre em 50.93 MB.

É o problema inverso: dada a probabilidade, achar o valor. Usado para escolher alvos, timeouts, quotas ou margens de segurança. Reduzir σ permitiria uma média mais baixa, liberando memória para o cache.

Exercício 5.6 • Percentil da Normal (Problema Inverso)

A duração da bateria de um modelo de notebook segue $N(\mu = 3000, \sigma = 130)$ horas. Qual duração é atingida ou superada por 10% dos notebooks (ou seja, o percentil 90)?

Espaço para cálculo

5.7 Soma de Normais Independentes (Orçamento de Latência)

No Módulo 2 vimos que médias e variâncias de parcelas independentes se somam, mas isso não dizia qual é a *forma* da distribuição da soma. Para normais, a resposta é a melhor possível: a soma continua normal.

COMBINAÇÃO LINEAR DE NORMAIS

$$X_i \sim N(\mu_i, \sigma_i^2) \text{ independentes} \implies \sum a_i X_i \sim N\left(\sum a_i \mu_i, \sum a_i^2 \sigma_i^2\right)$$

▼ Equação desmontada, variável por variável

$$\sum a_i X_i \sim N\left(\sum a_i \mu_i, \sum a_i^2 \sigma_i^2\right)$$

X_i ← cada variável normal (ex.: tempo de cada etapa do pipeline)

a_i ← coeficiente (ex.: +1 para somar, -1 para subtrair)

$\sum a_i \mu_i$ ← média do resultado (ex.: $4 \times 2 = 8$ ms)

$\sum a_i^2 \sigma_i^2$ ← variância do resultado (ex.: $4 \times 0.05^2 = 0.01$, $\sigma = 0.1$)

Ex.: uma requisição passa por 4 etapas, cada uma com tempo $N(2, 0.05^2)$ ms. O total é $N(8, 4 \times 0.05^2)$, com $\sigma_{tot} = 0.1$ ms (e não 0.2). Somar os piores casos de cada etapa é pessimista demais; o orçamento estatístico é mais realista.

INTUIÇÃO Por que a forma se preserva

Poucas distribuições são fechadas sob soma: duas uniformes somadas dão uma triangular, exponenciais somadas dão uma gama. A normal é uma das poucas "estáveis", e isso é parte da razão de ela ser o atrator do Teorema Central do Limite: se somas de muitas parcelas tendem a alguma forma, essa forma precisa continuar a mesma quando se somam mais parcelas.

A consequência mais útil é o **orçamento estatístico**. Os piores casos de várias etapas raramente acontecem juntos, e a margem necessária cresce com $\sqrt{k}$, não com k :

NA COMPUTAÇÃO Pior caso contra orçamento estatístico

	Pior caso	Estatístico
Margem para k etapas	$3k\sigma$	$3\sigma\sqrt{k}$
16 etapas	48σ	12σ (4 vezes menor)
Garantia	100%, se as hipóteses valerem; superdimensiona tudo	aceita uma chance minúscula de estouro em troca de uma margem muito menor

É o mesmo $\sqrt{k}$ que faz o tráfego agregado ser mais previsível que o de cada fonte.

CUIDADO Dependência e diferenças

A condição é a independência: se as etapas ficam lentas juntas, a covariância positiva aumenta a variância, e o orçamento calculado como se fossem independentes fica otimista. E a diferença também é uma combinação linear (com $a = 1$ e $b = -1$), cujas variâncias se somam. Isso é o que torna perigosas as "folgas" em sistemas distribuídos, como no exemplo abaixo.

EXEMPLO Uma condição de corrida em 2% das execuções

Um job de escrita termina em $N(100, 8^2)$ ms e um job de leitura começa em $N(120, 6^2)$ ms. A folga média é de 20 ms, mas a diferença tem desvio $\sqrt{64 + 36} = 10$ ms, e a leitura começa antes do fim da escrita com probabilidade $\Phi(-2) = 2.3\%$. Uma condição de corrida que aparece em 2% das execuções é exatamente o tipo de bug intermitente que exige muitas execuções para ser visto. O mesmo raciocínio, com a diferença de duas médias amostrais, é a base do teste que compara duas versões de um sistema.

CONEXÕES

- 2.7** média e variância da soma; covariância.
- 3.6** quantas execuções para ver um bug raro.
- 7.3** TCL.
- 8.4** teste de duas amostras.

▼ Entendendo a fórmula, termo a termo

$$T = \sum_{i=1}^k X_i \sim N\left(\sum \mu_i, \sum \sigma_i^2\right), \quad \sigma_T = \sigma\sqrt{k} \text{ (parcelas iguais)}$$

$$\sum \mu_i$$

← As médias se somam (linearidade da esperança).

$$\sum \sigma_i^2$$

← As variâncias se somam (independência).

$$\sigma\sqrt{k}$$

← O desvio cresce com a raiz de k , não com k .

De onde vem, passo a passo

1. $E[T] = \sum E[X_i]$, sempre.
2. $Var(T) = \sum Var(X_i)$, pela independência (2.7).
3. A soma de normais independentes é normal (propriedade reprodutiva).
4. Com k parcelas iguais: $Var(T) = k\sigma^2$, logo $\sigma_T = \sigma\sqrt{k}$. Etapas mais lentas que a média tendem a ser compensadas por outras mais rápidas.

EXEMPLO RESOLVIDO Risco de condição de corrida

Num pipeline distribuído, o job A grava um arquivo e o job B, disparado por outro agendador, lê o arquivo. Se B começar antes de A terminar, B lê dados incompletos (condição de corrida). Tempos medidos em segundos desde o início da janela.

DADOS

- fim de A $\sim N(20.00; 0.02^2)$ s
- início de B $\sim N(20.08; 0.03^2)$ s
- independentes

O QUE SE PEDE

Fração das execuções com condição de corrida.

RESOLUÇÃO PASSO A PASSO

1 Definir a folga

F = início de B – fim de A. Há corrida se $F < 0$. Combinação linear de normais independentes é normal.

2 Média da folga

$$\mu_F = 20.08 - 20.00 = 0.08 \text{ s}$$

3 Desvio da folga

Mesmo na *diferença*, as variâncias se **somam**:

$$\sigma_F = \sqrt{0.02^2 + 0.03^2} = \sqrt{0.0013} = 0.0361 \text{ s}$$

4 Padronizar e ler a tabela

$$P(F < 0) = \Phi\left(\frac{0 - 0.08}{0.0361}\right) = \Phi(-2.22) = 0.0132$$

RESPOSTA

Cerca de 1.3% das execuções: algumas vezes por mês, se o pipeline roda várias vezes ao dia.

Erro comum: subtrair as variâncias porque a operação é diferença. A incerteza nunca diminui ao combinar dois tempos variáveis. A correção de verdade é sincronizar (B espera um sinal de A), não aumentar a folga média.

Exercício 5.7 • Orçamento de Latência (Soma de Normais)

Uma requisição passa por 4 etapas independentes em sequência, cada uma com tempo $N(3.5; 0.06^2)$ ms. Qual a probabilidade de o tempo total exceder o orçamento de 14.18 ms?

Espaço para cálculo

5.8 Aproximação Normal da Binomial

A binomial é uma soma de n indicadoras independentes. Pelo Teorema Central do Limite, para n grande essa soma fica aproximadamente normal, com a mesma média np e a mesma variância $np(1 - p)$. Se $np \geq 5$ e $n(1 - p) \geq 5$, $B(n, p) \approx N(np, np(1 - p))$. Como a binomial é discreta, use a **correção de continuidade**:

CORREÇÃO DE CONTINUIDADE

$$P(X \leq k) \approx \Phi \left(\frac{k + 0.5 - np}{\sqrt{np(1 - p)}} \right), \quad P(X \geq k) \approx 1 - \Phi \left(\frac{k - 0.5 - np}{\sqrt{np(1 - p)}} \right)$$

▼ Equação desmontada, variável por variável

$$P(X \leq k) \approx \Phi \left(\frac{k+0.5 - np}{\sqrt{np(1-p)}} \right)$$

 k

← valor limite (ex.: 15)

 $+0.5$ ← correção de continuidade: vai até a borda da barra de k np

← média da binomial (ex.: 20)

 $\sqrt{np(1-p)}$

← desvio padrão da binomial (ex.: 4)

$$P(X \geq k) \approx 1 - \Phi \left(\frac{k-0.5 - np}{\sqrt{np(1-p)}} \right)$$

 -0.5 ← começa na borda inferior da barra de k $1 - \Phi$

← área à direita

INTUIÇÃO Cada inteiro vira uma barra

Cada valor inteiro k da binomial vira uma barra de largura 1, de $k - 0.5$ a $k + 0.5$, com área $P(X = k)$. " $X \leq k$ " inclui a barra inteira do k , então a área normal vai até $k + 0.5$; " $X \geq k$ " começa em $k - 0.5$. Sem a correção, perde-se meia barra em cada ponta, o que pesa quando σ é pequeno e cada barra carrega muita probabilidade.

CUIDADO Quando usar normal, quando usar Poisson

Situação	Aproximação	Por quê
$np \geq 5$ e $n(1-p) \geq 5$	normal	o sino cabe entre 0 e n
p pequeno, np moderado	Poisson	a distribuição fica espremida contra o zero e assimétrica, e o sino simétrico erra

NA COMPUTAÇÃO Contagens grandes e proporções

Essa aproximação é a forma usual de tratar contagens grandes: cliques num teste A/B, requisições com erro num dia, acertos de cache em milhões de acessos. Com n na casa dos milhões, calcular a binomial exata é inviável numericamente, e a normal dá a resposta na hora. Mais importante, dividindo por n , a proporção $\hat{p} = X/n$ fica aproximadamente $N\left(p, \frac{p(1-p)}{n}\right)$. Essa única frase é a base do intervalo de confiança para proporções, do tamanho de amostra para estimar uma taxa, do teste de proporção e dos limites do gráfico p .

CONEXÕES

- 3.2** binomial como soma de indicadoras.
- 3.4** aproximação de Poisson.
- 4.1** discreto e contínuo.
- 7.4** IC para proporção.
- 7.8** tamanho de amostra para proporção.
- 8.8** teste de proporção.
- 9.4** gráfico p .

▼ Entendendo a fórmula, termo a termo

$$P(X \leq k) \approx \Phi \left(\frac{k + 0.5 - np}{\sqrt{np(1-p)}} \right)$$

 np ← Média da binomial, usada como μ da normal. $\sqrt{np(1-p)}$ ← Desvio padrão da binomial, usado como σ . $+0.5$ ← Correção de continuidade: a barra do valor k vai de $k - 0.5$ a $k + 0.5$.

De onde vem, passo a passo

1. Desenhe a binomial como histograma: cada valor inteiro é uma barra de largura 1 centrada nele.
2. $P(X \leq k)$ é a área das barras até a de k , que termina em $k + 0.5$.
3. Aproxime essa área pela normal de mesma média e variância, integrando até $k + 0.5$.
4. Para $P(X \geq k)$, a área começa em $k - 0.5$. Exija $np \geq 5$ e $n(1-p) \geq 5$ para que a binomial seja aproximadamente simétrica.

EXEMPLO RESOLVIDO

Correção de continuidade faz diferença

Um cache tem taxa de falha (miss) de 20%. Em 100 acessos independentes, qual a chance de no máximo 15 misses?

DADOS

- $n = 100, p = 0.2$

O QUE SE PEDE

$P(X \leq 15)$ pela normal, com e sem correção, e comparar com o valor exato.

RESOLUÇÃO PASSO A PASSO

1

Conferir a condição

$np = 20 \geq 5$ e $n(1-p) = 80 \geq 5$: a normal é adequada.

2 Parâmetros da normal

$$\mu = np = 20, \quad \sigma = \sqrt{np(1-p)} = \sqrt{16} = 4$$

3 Correção de continuidade

Na binomial, " $X \leq 15$ " é a barra do histograma que vai até 15.5. Use 15.5:

$$z = \frac{15.5 - 20}{4} = -1.13, \quad \Phi(-1.13) = 0.1292$$

4 Sem correção

$$z = \frac{15 - 20}{4} = -1.25, \quad \Phi(-1.25) = 0.1056$$

5 Comparar com o exato

Binomial exata: 0.1285. Com correção o erro é 0.0007; sem correção, 0.023.

RESPOSTA Com correção 0.129 (exato 0.1285).

Regra prática: $\leq k$ vira $k + 0.5$; $< k$ vira $k - 0.5$; $\geq k$ vira $k + 0.5$.

Exercício 5.8 • Aproximação Normal da Binomial

Em $n = 80$ requisições, cada uma precisa de retry com probabilidade $p = 0.4$, independentemente. Use a aproximação normal com correção de continuidade para estimar $P(X \leq 34)$.

Espaço para cálculo

5.9 Sistemas em Série com Componentes Exponenciais

No Módulo 1, a confiabilidade de um sistema em série era o produto das confiabilidades num período fixo. Com componentes exponenciais, o período deixa de ser fixo e a conta fica ainda mais elegante. Se n componentes independentes com vida $Exp(\lambda_i)$ estão em série, o sistema falha na primeira falha. Como $R_{sis}(t) = \prod e^{-\lambda_i t} = e^{-(\sum \lambda_i)t}$, a vida do sistema também é exponencial, com $\lambda_{sis} = \sum \lambda_i$ e $MTTF_{sis} = 1 / \sum \lambda_i$.

Ex.: um servidor depende de fonte, disco e placa de rede, com MTTF de 1000, 2000 e 4000 h: $\lambda_{sis} = 0.001 + 0.0005 + 0.00025 = 0.00175/\text{h}$ e $MTTF_{sis} = 571$ h, menor que o do pior componente. A taxa constante descreve a fase de vida útil da **curva da banheira**; mortalidade infantil e desgaste exigem outros modelos (ex.: Weibull).

INTUIÇÃO Em série, somam-se as taxas

Em série somam-se as *taxas*, não os tempos médios. É a mesma superposição de processos de Poisson: cada componente produz falhas como um Poisson com sua taxa, e o sistema vê a soma dos fluxos.

EXEMPLO Frotas grandes falham o tempo todo

Num datacenter com 10 000 discos de MTTF 10^6 h cada (mais de 100 anos), a taxa total é $10^4/10^6 = 0.01$ falha/h: uma falha a cada 100 horas, ou a cada 4 dias. Em escala, falha de componente deixa de ser exceção e vira rotina, e o software precisa ser projetado para conviver com ela.

A redundância muda o modelo, e a comparação entre redundância com e sem reparo mostra onde está o ganho real:

DEDUÇÃO Duas réplicas em paralelo

	Sem reparo	Com reparo
Confiabilidade	$R(t) = 1 - (1 - e^{-\lambda t})^2$, que não é exponencial: o sistema que já perdeu uma réplica está pior que um novo, e portanto tem memória	o sistema só falha se a segunda réplica cair durante a janela de reparo da primeira
MTTF	$\frac{1}{2\lambda} + \frac{1}{\lambda} = \frac{3}{2\lambda}$: o mínimo de duas exponenciais (taxa 2λ) mais a vida da réplica que sobrou, que por falta de memória é uma exponencial nova	muito maior; encurtar a janela de reparo é o que torna a redundância eficaz
Ganho	só 50% de MTTF com o dobro de hardware	por isso sistemas de armazenamento reconstroem réplicas perdidas o mais rápido possível

NA COMPUTAÇÃO Requisições redundantes (hedging)

Enviar a mesma requisição a duas réplicas e usar a primeira resposta transforma o tempo de resposta num mínimo: se cada um fosse exponencial com taxa λ , o mínimo seria exponencial com taxa 2λ , com metade da média e uma cauda muito mais curta. É a técnica usada para cortar a cauda de latência em sistemas com fan-out. Na prática, só se dispara a segunda requisição quando a primeira passa do p95, o que limita o custo extra a uns 5% de carga.

CONEXÕES

- 1.7** série e paralelo.
- 3.3** superposição de Poisson.
- 5.4** mínimo de exponenciais.
- 5.5** curva da banheira.
- 2.6** cauda de latência em fan-out.

▼ Entendendo a fórmula, termo a termo

$$R_{sis}(t) = \prod_i e^{-\lambda_i t} = e^{-(\sum_i \lambda_i)t}$$

 $\prod_i$

← Série: todos precisam sobreviver (1.7).

 $e^{-\lambda_i t}$

← Confiabilidade exponencial de cada componente.

 $\sum \lambda_i$

← Os expoentes se somam: o sistema é exponencial com taxa total.

De onde vem, passo a passo

1. Série independente: $R_{sis} = R_1 R_2 \cdots R_n$.
2. Com $R_i = e^{-\lambda_i t}$ e a regra $e^a e^b = e^{a+b}$: $R_{sis} = e^{-(\lambda_1 + \cdots + \lambda_n)t}$.
3. É a forma da exponencial com $\lambda_{sis} = \sum \lambda_i$, logo $MTTF_{sis} = 1/\lambda_{sis}$.

EXEMPLO RESOLVIDO Redundância muda o modelo

Duas réplicas idênticas e independentes de um serviço, sem reparo: o serviço funciona enquanto pelo menos uma funcionar.

DADOS

- $\lambda = 0.001/\text{h}$ por réplica

O QUE SE PEDE

(a) $R(1000)$ do sistema; (b) o MTTF do sistema.

RESOLUÇÃO PASSO A PASSO

1

Réplica isolada

$$R_c(1000) = e^{-0.001 \times 1000} = e^{-1} = 0.368$$

2

Paralelo: falha só se os dois falharem

$$R(t) = 1 - (1 - e^{-\lambda t})^2 \implies R(1000) = 1 - (1 - 0.368)^2 = 1 - 0.400 = 0.600$$

3 MTTF do sistema

Até a 1ª falha há duas réplicas ativas (taxa 2λ , tempo médio $1/(2\lambda)$); depois sobra uma (tempo médio $1/\lambda$):

$$MTTF = \frac{1}{2\lambda} + \frac{1}{\lambda} = 500 + 1000 = 1500 \text{ h}$$

RESPOSTA (a) 0.600 (contra 0.368 de um só); (b) 1500 h.

A redundância aumenta o MTTF em 50%, mas o sistema deixa de ser exponencial: um serviço que já perdeu uma réplica está pior que um novo, então a falta de memória não vale mais. Com reparo (subir uma réplica nova logo após a falha), o ganho é muito maior.

Exercício 5.9 • Confiabilidade de Sistema em Série (Exponencial)

Um servidor depende de três componentes em série (fonte, disco e placa de rede), com vidas exponenciais independentes e MTTF de 1750, 2500 e 3500 h. Qual a confiabilidade do sistema em 200 h?

Espaço para cálculo

Exercícios de Fixação com Soluções Comentadas

3 Questões Resolvidas

Exercício 5.1: SLO de Latência com a Normal Padrão

O tempo médio de resposta de um serviço, medido por janela de um minuto, segue distribuição Normal com média $\mu = 25.00$ ms e desvio padrão $\sigma = 0.05$ ms. O acordo de nível de serviço considera a janela saudável se o tempo estiver entre 24.92 ms (abaixo disso, suspeita de respostas vazias por erro) e 25.10 ms.

Dados da Normal Padrão: $\Phi(1.60) = 0.9452$ e $\Phi(2.00) = 0.9772$.

- (a) Calcule a proporção de janelas saudáveis.
- (b) Qual a porcentagem de janelas abaixo do limite mínimo?

Espaço para cálculo

Exercício 5.2: Vida de Servidores e Falta de Memória

O tempo até a falha T (em meses) de servidores de uma frota segue uma distribuição exponencial com taxa de falha $\lambda = 0.05$ falha/mês (vida média MTTF = 20 meses).

- (a) Calcule a probabilidade de um servidor durar mais de 10 meses ($R(10)$).
- (b) Se um servidor já está operando sem problemas há 15 meses, qual a probabilidade de que ele opere por pelo menos mais 10 meses?

Espaço para cálculo

Exercício 5.3: Distribuição Uniforme em Sistemas Automatizados

O tempo de resposta Y (em segundos) de uma chamada de API distribuída distribui-se uniformemente entre 2 e 8 segundos ($Y \sim U(2, 8)$). Calcule:

- (a) A média e o desvio padrão de Y .
- (b) A probabilidade de o tempo de resposta exceder 6.5 segundos.

Espaço para cálculo

Módulo 6: Estatística Descritiva

Tipos de variáveis em logs e métricas, média, mediana e moda (médias ponderadas, harmônica e geométrica), dispersão e algoritmo de Welford, CV, boxplot e detecção robusta de anomalias, histogramas e buckets de monitoramento, percentis a partir de dados agrupados.

Os Módulos 1 a 5 partiram de um modelo conhecido e calcularam o que os dados deveriam mostrar. A partir daqui o caminho se inverte: temos dados (logs, métricas, traces) e queremos descobrir o modelo. A estatística descritiva é o primeiro passo dessa inversão. Cada medida deste módulo é a versão amostral de um conceito já visto: a média amostral imita $E[X]$, a variância amostral imita $Var(X)$, o histograma imita a densidade, os quartis da amostra imitam os percentis. O Módulo 7 responde a pergunta que este módulo deixa no ar: quão perto essas imitações ficam dos valores verdadeiros?

6.1 Classificação de Variáveis e Representação Gráfica

Antes de calcular qualquer coisa, é preciso saber que operações fazem sentido com cada dado. Um log de requisições tem campos de natureza muito diferente: o código de status, o nível de log, o número de retries, a latência. Em computação, os dados vêm de logs, métricas, traces e bancos de dados, e o primeiro passo é saber que tipo de variável cada campo é:

- **Qualitativas Nominais:** categorias sem ordem (ex.: código de status HTTP, sistema operacional, região da nuvem, tipo de erro).
- **Qualitativas Ordinais:** categorias com ordem (ex.: nível de log DEBUG < INFO < WARN < ERROR, severidade de incidente, prioridade de ticket).
- **Quantitativas Discretas:** contagens (ex.: número de retries, requisições por segundo, linhas alteradas num commit).
- **Quantitativas Contínuas:** medições (ex.: latência, uso de CPU, tamanho de resposta em bytes tratado como contínuo, temperatura do processador).

A classificação não é burocracia; ela decide quais operações são válidas, como um sistema de tipos decide quais funções aceitam um argumento.

INTUIÇÃO O que cada tipo permite

Tipo	Operações válidas	Medidas	Gráfico
Nominal	contar, comparar igualdade	moda, proporções	barras ordenadas pela frequência (Pareto)
Ordinal	+ comparar ordem	+ mediana, percentis	barras na ordem natural
Discreta	+ somas e diferenças	+ média, variância	barras por valor
Contínua	+ somas e diferenças	+ média, variância	histograma, boxplot, FDA empírica

Em ordinais, diferenças não têm significado: a "distância" entre WARN e ERROR não é a mesma que entre DEBUG e INFO.

CUIDADO Número não é quantidade

Código HTTP 404, ID de usuário e porta TCP são escritos com números, mas são nominais: a média de 200 e 500 não é um código de status. Um teste prático é perguntar se somar dois valores dá algo interpretável. Em aprendizado de máquina, tratar um ID como número faz o modelo achar padrões falsos ("usuários com ID maior compram mais"); o correto é codificá-lo como categoria (one-hot, embeddings).

A classificação também se conecta aos modelos dos módulos anteriores. Uma variável nominal com duas categorias (sucesso, erro) é uma sequência de ensaios de Bernoulli, e sua contagem é binomial; contagens por intervalo de tempo são candidatas a Poisson; medições contínuas pedem densidades. Duas variáveis qualitativas cruzadas formam uma tabela de contingência, e a pergunta sobre sua independência é respondida pelo qui-quadrado.

NA COMPUTAÇÃO Gráficos em observabilidade

Métricas ao longo do tempo pedem gráficos de linha, e em monitoramento é comum mostrar vários percentis juntos (p50, p95, p99), o que já é uma forma de gráfico de controle. Latências e tamanhos variam em ordens de grandeza, e num eixo linear a cauda vira uma linha colada ao zero; histogramas com classes logarítmicas (1, 2, 4, 8, ... ms) e eixos log são o padrão em ferramentas de observabilidade.

CONEXÕES

- 1.9 tabela de contingência.
- 3.2 binomial.
- 3.3 Poisson.
- 8.5 qui-quadrado de independência.
- 9.2 gráficos de controle.

▼ Entendendo a fórmula, termo a termo

Tipo da variável $\Rightarrow$ medidas e gráficos permitidos

Nominal	← Só contagens, proporções e moda. Gráficos de barras e de Pareto.
Ordinal	← Também mediana e percentis (há ordem), mas não média.
Discreta	← Todas as medidas numéricas; gráfico de barras ou histograma.
Contínua	← Todas as medidas; histograma, boxplot, ramo-e-folhas.

De onde vem, passo a passo

1. O valor resulta de **contar** ou **medir**? Se sim, é quantitativa; senão, qualitativa.
2. Quantitativa: valores isolados (contagem) é discreta; qualquer valor num intervalo (medição) é contínua.
3. Qualitativa: as categorias têm ordem natural? Se sim, ordinal; senão, nominal.
4. Teste final: "a média faria sentido?". Para nominais e ordinais, não.

EXEMPLO RESOLVIDO

Classificando os campos de um log

Cada linha do log de acesso de uma API tem quatro campos. Classifique cada um antes de escolher gráficos e métricas.

RESOLUÇÃO PASSO A PASSO

1 Perguntar: é rótulo ou número de verdade?

Se fazer contas com o valor não tem sentido, a variável é **qualitativa**, mesmo que escrita com números.

2 Qualitativa: tem ordem?

Se as categorias têm ordem natural, é **ordinal**; se não, **nominal**.

3 Quantitativa: conta ou mede?

Contagem dá **discreta**; medição em escala contínua dá **contínua**.

4 Aplicar

CAMPO	TIPO	POR QUÊ
ID da requisição (ex.: 4471)	Qualitativa nominal	É um rótulo: a "média dos IDs" não faz sentido.
Nível do log (INFO, WARN, ERROR)	Qualitativa ordinal	Tem ordem de gravidade, mas não é medida.
Número de retries	Quantitativa discreta	Contagem.
Latência (ms)	Quantitativa contínua	Medição.

Armadilha: ser escrito com números não torna uma variável quantitativa. O tipo decide o gráfico (barras ou histograma) e as medidas que fazem sentido (moda, mediana ou média). Um código HTTP 404 também é nominal, apesar de numérico.

Exercício 6.1 • Classificação de Variáveis

Classifique a variável: **Temperatura do processador.**

Espaço para cálculo

☐ Quantitativa contínua

☐ Qualitativa ordinal

☐ Quantitativa discreta

☐ Qualitativa nominal

6.2 Medidas de Tendência Central

A primeira pergunta sobre um conjunto de medições é "qual o valor típico?". Há três respostas, que coincidem só em distribuições simétricas e diferem justamente nos casos interessantes:

MÉDIA, MEDIANA E MODA

$$\text{Média Amostral: } \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Mediana ($\tilde{x}$) : Elemento central após ordenação (percentil 50)

Moda ($\hat{x}$) : Valor com maior frequência observada

▼ Equação desmontada, variável por variável

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

 $\bar{x}$

← o que se calcula: média da amostra

 x_i

← cada observação (ex.: 60, 64, 62 ms)

 n

← número de observações (ex.: 5)

 $\sum x_i$

← soma de todas (ex.: 310)

 $\frac{1}{n}$

← divide pelo número (ex.: 310/5 = 62)

 $\tilde{x}$ = valor central após ordenar $\tilde{x}$

← mediana: metade dos dados abaixo, metade acima

 $\hat{x}$ = valor mais frequente $\hat{x}$

← moda (ex.: em 2, 3, 3, 4 a moda é 3)

Assimetria da Distribuição:

- **Simétrica:** $\bar{x} = \tilde{x} = \hat{x}$.
- **Assimétrica Positiva (à Direita):** $\bar{x} > \tilde{x} > \hat{x}$. A média é puxada para a direita por valores atipicamente altos (típico de latência e de tempo de resolução de incidentes).
- **Assimétrica Negativa (à Esquerda):** $\bar{x} < \tilde{x} < \hat{x}$. A média é puxada por valores atipicamente baixos.

A média amostral é a esperança calculada sobre a distribuição empírica, em que cada observação tem peso $1/n$. Por isso herda as propriedades da esperança: é linear (converter ms para s divide a média por 1000) e é o ponto de equilíbrio dos dados, o que a torna sensível a valores extremos. A mediana, por depender só da ordem, não se move.

EXEMPLO Um valor extremo

Uma única requisição de 30 s entre mil de 50 ms move a média de 50 para 80 ms. A mediana continua em 50 ms. A média descreve o total (custo, capacidade); a mediana descreve o caso típico (experiência do usuário).

CAUIDADO Combinar médias de grupos exige pesos

Se um servidor atendeu 10 requisições com média 100 ms e outro atendeu 1000 com média 10 ms, a média geral é $\frac{10 \cdot 100 + 1000 \cdot 10}{1010} = 10.9$ ms, e não $(100 + 10)/2 = 55$ ms: é a lógica da probabilidade total. Com medianas e percentis é pior: o p99 do conjunto não pode ser obtido a partir dos p99 de cada servidor, porque percentis dependem da distribuição inteira. É por isso que sistemas de monitoramento guardam histogramas, que se somam, em vez de percentis.

INTUIÇÃO Qual média usar

Média	Quando	Exemplo
Aritmética	quantidades que se somam	latências, custos
Harmônica	taxas sobre o mesmo trabalho	dois enlaces transferem o mesmo arquivo a 10 e 40 MB/s: 0.1 e 0.025 s por MB, média 0.0625 s/MB, ou 16 MB/s, e não 25
Geométrica	fatores multiplicativos	speedups de vários benchmarks (como no SPEC); não depende de qual máquina é a referência

As três são casos de uma escolha mais geral: decidir em que escala os dados se somam de forma significativa.

NA COMPUTAÇÃO O custo de calcular cada medida

- **Média:** uma passada, memória constante.
- **Mediana:** exige ordenar ($O(n \log n)$) ou um algoritmo de seleção como o quickselect ($O(n)$ em média, graças ao pivô aleatório), e precisa guardar os dados. Em fluxos contínuos de métricas, usam-se aproximações (t-digest, histogramas).
- **Moda:** em dados contínuos depende das classes do histograma e é pouco estável; em dados categóricos é a medida natural ("qual o erro mais frequente?").

CONEXÕES

- 1.5 média ponderada.
- 2.4 esperança.
- 4.5 moda < mediana < média com cauda à direita.
- 6.6 percentis a partir de histogramas.

▼ Entendendo a fórmula, termo a termo

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \quad \tilde{x} = x_{(\frac{n+1}{2})}$$

$$\sum x_i$$

← Total de todas as observações.

$$\frac{1}{n}$$

← Divide igualmente entre as n observações.

$$x_{(i)}$$

← O i -ésimo valor depois de **ordenar**.

$$\frac{n+1}{2}$$

← Posição central; se não for inteira (n par), faça a média dos dois vizinhos.

De onde vem, passo a passo

1. Propriedade de equilíbrio: $\sum (x_i - \bar{x}) = \sum x_i - n\bar{x} = 0$. A média é o ponto onde os desvios se anulam.
2. Sensibilidade: se o maior valor aumentar Δ , a média sobe Δ/n , mas a mediana não muda.
3. Por isso, com valores extremos, a mediana representa melhor o "típico", e a média representa melhor o "total".

EXEMPLO RESOLVIDO

Qual medida representa o tempo de resolução de incidentes?

Tempos até a resolução dos incidentes de produção registrados em uma semana.

DADOS

- dados (h): 2, 3, 3, 4, 5, 6, 25 ($n = 7$)

O QUE SE PEDE

Média, mediana e moda, e qual usar.

RESOLUÇÃO PASSO A PASSO

1 Média

$$\bar{x} = \frac{2 + 3 + 3 + 4 + 5 + 6 + 25}{7} = \frac{48}{7} = 6.86 \text{ h}$$

2 Mediana

Dados já ordenados, $n = 7$ ímpar: a mediana é o valor na posição $(n + 1)/2 = 4$, ou seja, $Md = 4$ h.

3 Moda

Valor mais frequente: $Mo = 3$ h (aparece duas vezes).

4 Escolher

Um único incidente longo (25 h) puxa a média acima de 6 dos 7 valores. Para "quanto leva um incidente típico?", use a **mediana**. Para orçar o total de horas de plantão do ano, use a **média**, porque $n \times \bar{x}$ dá o total. (O MTTR, tempo médio de reparo, é uma média e é sensível a esses casos extremos.)

RESPOSTA $\bar{x} = 6.86 \text{ h}$, $Md = 4 \text{ h}$, $Mo = 3 \text{ h}$.

A ordem $Mo < Md < \bar{x}$ indica assimetria à direita (cauda longa para valores altos).

Exercício 6.2 • Mediana de uma Amostra

Os tempos de resposta de 5 requisições a uma API foram (ms): 74; 78; 72; 79; 77. Calcule a mediana.

Espaço para cálculo

6.3 Medidas de Dispersão e Variabilidade

Duas amostras podem ter a mesma média e comportamentos completamente diferentes. Dois servidores com latência média de 50 ms, um estável e outro oscilando entre 5 e 500 ms, oferecem experiências opostas. A dispersão amostral imita a variância da distribuição, com um ajuste no denominador:

VARIÂNCIA AMOSTRAL, DESVIO PADRÃO E CV

$$\text{Variância Amostral: } s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{\sum x_i^2 - \frac{(\sum x_i)^2}{n}}{n-1}$$

$$\text{Desvio Padrão Amostral: } s = \sqrt{s^2}$$

$$\text{Coeficiente de Variação (CV): } CV = \left(\frac{s}{\bar{x}} \right) \times 100\%$$

▼ Equação desmontada, variável por variável

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

s^2 ← o que se calcula: variância amostral

$x_i - \bar{x}$ ← desvio de cada observação (ex.: $56 - 62 = -6$)

$(x_i - \bar{x})^2$ ← desvio ao quadrado (ex.: 36)

$\sum$ ← soma dos quadrados dos desvios

$n - 1$ ← divide por $n - 1$, não por n (graus de liberdade)

$$s^2 = \frac{\sum x_i^2 - \frac{(\sum x_i)^2}{n}}{n - 1}$$

$\sum x_i^2$ ← soma dos quadrados (eleva e depois soma)

$(\sum x_i)^2$ ← quadrado da soma (soma e depois eleva): é diferente!

$$s = \sqrt{s^2}, \quad CV = \frac{s}{\bar{x}} \times 100\%$$

s ← desvio padrão, na unidade dos dados

CV ← desvio em % da média, sem unidade (ex.: $4.47/62 = 7.2\%$ (sem unidade))

Por que dividir por $(n - 1)$ em vez de n ? A divisão por $(n - 1)$ (correção de Bessel) compensa o grau de liberdade perdido ao estimar μ por $\bar{x}$, tornando s^2 um **estimador não viesado de σ^2 ($E[s^2] = \sigma^2$).**

DEDUÇÃO A razão do $n - 1$

A média $\bar{x}$ é, por construção, o valor que minimiza a soma dos quadrados dos desvios; qualquer outro centro, inclusive o verdadeiro μ , daria soma maior. Então $\sum (x_i - \bar{x})^2$ é sistematicamente menor que $\sum (x_i - \mu)^2$, e dividir por n subestimaria σ^2 . A conta exata mostra que a soma perde em média exatamente um σ^2 , e dividir por $n - 1$ compensa. Outra forma de ver: os desvios $x_i - \bar{x}$ somam zero, então só $n - 1$ deles são livres. Esses "graus de liberdade" reaparecem como parâmetro das distribuições t e qui-quadrado.

NA COMPUTAÇÃO Algoritmo de Welford

A segunda forma da variância, com $\sum x_i^2$, tem o mesmo problema numérico da fórmula computacional: quando a média é grande em relação ao desvio (timestamps em nanossegundos), os dois termos são números enormes quase iguais, e a subtração perde os dígitos significativos. O algoritmo de Welford atualiza, a cada novo valor x :

1. $n \leftarrow n + 1$; $\delta = x - \bar{x}$;
2. $\bar{x} \leftarrow \bar{x} + \delta/n$;
3. $M_2 \leftarrow M_2 + \delta(x - \bar{x})$; no fim, $s^2 = M_2/(n - 1)$.

É uma passada, memória constante e estabilidade numérica. Uma variante combina $(n, \bar{x}, M_2)$ de partes calculadas em paralelo, o que permite calcular a variância de um conjunto enorme num MapReduce ou somar estatísticas de várias máquinas.

O desvio padrão tem a unidade dos dados, o que impede comparar variabilidades em escalas diferentes: um desvio de 5 ms é enorme para um serviço de 10 ms e irrelevante para um de 2 s. O **coeficiente de variação** resolve isso medindo o desvio relativo à média. E, como a média, o desvio padrão é sensível a valores extremos, com um agravante: os desvios entram ao quadrado. Medidas alternativas cobrem esses casos:

INTUIÇÃO Dispersão relativa e robusta

Medida	Vantagem	Uso
$CV = s/\bar{x}$	sem unidade; compara escalas	em benchmarks, CV acima de alguns por cento indica medições ruidosas (frequência variável de CPU, outros processos, cache frio) e pede mais repetições; a exponencial tem $CV = 1$, e CV muito acima disso sugere cauda pesada
MAD (mediana de $ x_i - \tilde{x} $)	não muda com um único valor absurdo	para dados normais, $\sigma \approx 1.4826 \cdot \text{MAD}$
Amplitude ($\max - \min$)	a mais simples	depende só de dois valores e cresce com n ; mesmo assim, em subgrupos pequenos de tamanho fixo estima σ muito bem, e é a base do gráfico R

CONEXÕES

- 2.5** variância e cancelamento catastrófico.
- 7.5** viés de estimadores.
- 7.6** graus de liberdade em t e χ^2 .
- 7.4** quantas repetições para um benchmark.
- 9.7** σ estimado pela amplitude.

▼ Entendendo a fórmula, termo a termo

$$s^2 = \frac{\sum (x_i - \bar{x})^2}{n - 1} = \frac{\sum x_i^2 - \frac{(\sum x_i)^2}{n}}{n - 1}, \quad CV = \frac{s}{\bar{x}}$$

$x_i - \bar{x}$ ← Desvio de cada observação.

$(\cdot)^2$ ← Evita cancelamento e penaliza desvios grandes.

$n - 1$ ← Graus de liberdade: os n desvios somam zero, então só $n - 1$ são livres.

$s/\bar{x}$ ← Desvio relativo, sem unidade: permite comparar grandezas diferentes.

De onde vem, passo a passo

1. Expanda: $\sum (x_i - \bar{x})^2 = \sum x_i^2 - 2\bar{x} \sum x_i + n\bar{x}^2$.
2. Como $\sum x_i = n\bar{x}$: $\sum x_i^2 - 2n\bar{x}^2 + n\bar{x}^2 = \sum x_i^2 - n\bar{x}^2$.
3. E $n\bar{x}^2 = \frac{(\sum x_i)^2}{n}$, o que dá a fórmula computacional.
4. O porquê do $n - 1$ é demonstrado no subtópico 7.1.

EXEMPLO RESOLVIDO

Mesmo atraso médio, jitters diferentes

Uma aplicação de voz sobre IP precisa de atraso de rede perto de 10.0 ms, com variação (jitter) dentro de ± 0.5 ms. Dois enlaces foram medidos.

DADOS

- Enlace A (ms): 9.8; 10.0; 10.2; 10.0; 10.0
- Enlace B (ms): 9.0; 10.5; 11.0; 9.5; 10.0

O QUE SE PEDE

Média, desvio padrão amostral e CV de cada enlace.

RESOLUÇÃO PASSO A PASSO

1 Médias

A: $50/5 = 10.0$. B: $50/5 = 10.0$. Iguais.

2 Desvios em relação à média

A: $-0.2, 0, 0.2, 0, 0$. Quadrados somam $0.04 + 0 + 0.04 + 0 + 0 = 0.08$.

B: $-1, 0.5, 1, -0.5, 0$. Quadrados somam $1 + 0.25 + 1 + 0.25 + 0 = 2.5$.

3 Dividir por $n - 1$ e tirar a raiz

$$s_A = \sqrt{\frac{0.08}{4}} = 0.141 \text{ ms}, \quad s_B = \sqrt{\frac{2.5}{4}} = 0.791 \text{ ms}$$

Divide-se por $n - 1 = 4$ porque a média foi estimada dos próprios dados.

4 Coeficiente de variação

$$CV = \frac{s}{\bar{x}} : \quad CV_A = 1.4\%, \quad CV_B = 7.9\%$$

RESPOSTA A: $s = 0.141 \text{ ms}$; B: $s = 0.791 \text{ ms}$.

A média sozinha diria que os enlaces são iguais. Com limite de $\pm 0.5 \text{ ms}$, A atende sempre e B entrega pacotes fora (9.0 e 11.0), que viram cortes no áudio. Em voz e vídeo, o jitter importa tanto quanto o atraso médio.

Exercício 6.3 • Desvio Padrão pela Fórmula Computacional

Um agente de monitoramento guarda só três contadores por janela (nada de valores individuais): $n = 16$ requisições, $\sum x_i = 1232 \text{ ms}$ e $\sum x_i^2 = 94897.75 \text{ ms}^2$. Calcule o desvio padrão amostral s .

Espaço para cálculo

6.4 Medidas Separatrizes e Construção do Boxplot de Tukey

Os quartis amostrais são a versão empírica dos quartis teóricos: dividem os dados ordenados em quatro partes com o mesmo número de observações. O Boxplot resume a distribuição pelos "cinco números": $\{x_{\min}, Q_1, \tilde{x}, Q_3, x_{\max}\}$.

CRITÉRIO DE OUTLIERS DE JOHN TUKEY

Intervalo Interquartil (IQR): $IQR = Q_3 - Q_1$

Limite Inferior (LI): $LI = Q_1 - 1.5 \times IQR$

Limite Superior (LS): $LS = Q_3 + 1.5 \times IQR$

▼ Equação desmontada, variável por variável

$$IQR = Q_3 - Q_1$$

Q_1 ← primeiro quartil: 25% dos dados abaixo (ex.: 30 min)

Q_3 ← terceiro quartil: 75% abaixo (ex.: 60 min)

IQR ← largura da metade central (ex.: 30 min)

$$LI = Q_1 - 1.5 IQR, \quad LS = Q_3 + 1.5 IQR$$

1.5 ← fator padrão de Tukey

LI ← cerca inferior (ex.: $30 - 45 = -15$)

LS ← cerca superior (ex.: $60 + 45 = 105$); acima disso é outlier

Qualquer ponto além de $[LI, LS]$ é um **outlier (valor atípico)** e merece investigação: uma requisição que travou, um build que ficou preso, um erro de medição.

DEDUÇÃO A calibração do fator 1.5

Para dados normais, Q_1 e Q_3 ficam a 0.674σ da média, o AIQ vale 1.349σ , e as cercas ficam a $0.674 + 1.5 \times 1.349 = 2.7\sigma$ da média. Pela tabela normal, só 0.7% dos pontos caem além disso. Com dados bem comportados, quase nada é sinalizado; quando muitos pontos caem fora, ou a distribuição tem cauda pesada, ou há problemas reais. É a mesma lógica do limite de 3σ dos gráficos de controle: escolher um limite que, se nada estiver errado, quase nunca seja ultrapassado.

NA COMPUTAÇÃO Detecção robusta de anomalias

Na regra "média $\pm 3s$ ", os próprios outliers inflam s e deslocam $\bar{x}$, e acabam se escondendo dentro dos limites que eles mesmos alargaram. Quartis e mediana resistem a isso. Por isso a regra de Tukey, e a variante com MAD, é muito usada em alertas de métricas e para limpar dados antes de treinar modelos. O boxplot também mostra a assimetria: se o bigode de cima é mais longo e a mediana está mais perto de Q_1 , a cauda é à direita.

CAUIDADO Outlier não é lixo

Em sistemas, a requisição de 30 s é a que gera reclamação; o build de 2 h é o que trava a equipe. Os pontos fora da caixa são frequentemente os mais importantes, e a pergunta certa é "por que este valor aconteceu?", que pode revelar uma causa especial. Há várias convenções para calcular quartis em amostras (mediana das metades, interpolação linear, as 9 definições do R), que dão valores ligeiramente diferentes em amostras pequenas e convergem em amostras grandes.

CONEXÕES

- 4.7** quartis teóricos.
- 5.6** percentis da normal (0.674).
- 9.1** causas especiais.
- 9.2** limites de 3σ .

▼ Entendendo a fórmula, termo a termo

$$L_I = Q_1 - 1.5 AIQ, \quad L_S = Q_3 + 1.5 AIQ$$

$AIQ = Q_3 - Q_1$ ← Largura da metade central dos dados.

1.5 ← Fator convencional de Tukey.

L_I, L_S ← Cercas: valores além delas são candidatos a outlier.

De onde vem, passo a passo

1. Para dados normais: $Q_3 = \mu + 0.674\sigma$ e $AIQ = 1.349\sigma$.
2. $L_S = \mu + 0.674\sigma + 1.5(1.349\sigma) = \mu + 2.698\sigma$.
3. $P(|Z| > 2.698) \approx 0.7\%$: em dados normais, só cerca de 7 a cada 1000 valores caem fora por acaso.
4. Por isso um ponto fora das cercas merece investigação, mas não deve ser descartado sem causa identificada.

EXEMPLO RESOLVIDO Boxplot de tempos de build

Dez tempos de build de um pipeline de integração contínua, em minutos.

DADOS

- dados ordenados (min): 12, 15, 16, 18, 19, 20, 22, 23, 25, 40

O QUE SE PEDE

Mediana, quartis, AIQ, cercas e outliers.

RESOLUÇÃO PASSO A PASSO

1 Mediana

$n = 10$ é par: média dos dois valores centrais (5º e 6º): $Md = (19 + 20)/2 = 19.5$ min.

2 Quartis

Q_1 = mediana da metade inferior (12, 15, **16**, 18, 19) = 16. Q_3 = mediana da metade superior (20, 22, **23**, 25, 40) = 23.

3 Amplitude interquartil

$$AIQ = Q_3 - Q_1 = 23 - 16 = 7 \text{ min}$$

4 Cercas

$$Q_1 - 1.5 AIQ = 16 - 10.5 = 5.5, \quad Q_3 + 1.5 AIQ = 23 + 10.5 = 33.5$$

5 Outliers

$40 > 33.5$: é outlier e aparece como ponto isolado. O bigode superior vai até 25 (maior valor dentro da cerca).

RESPOSTA $Md = 19.5, Q_1 = 16, Q_3 = 23, AIQ = 7$; outlier: 40 min.

O build de 40 min merece investigação (cache de dependências perdido? runner lento?). Softwares usam métodos ligeiramente diferentes para quartis; em amostras pequenas os resultados podem diferir um pouco.

Exercício 6.4 • Cercas de Tukey

A latência de um endpoint tem $Q_1 = 18$ ms e $Q_3 = 23$ ms. Qual a cerca superior de Tukey para outliers?

Espaço para cálculo

6.5 Tabelas de Frequência e Histogramas

Medidas resumo reduzem os dados a poucos números e, ao fazer isso, escondem a forma: uma distribuição com dois picos e outra com um só podem ter a mesma média e o mesmo desvio. A tabela de frequências e o histograma preservam a forma, ao custo de agrupar os valores em classes. O roteiro de construção é:

1. **Amplitude total:** $A = x_{max} - x_{min}$.
2. **Número de classes** (Sturges): $k \approx 1 + 3.322 \log_{10} n$, ou $k \approx \sqrt{n}$.
3. **Largura da classe:** $h \approx A/k$, arredondada para cima.
4. Conte as frequências absolutas f_i , relativas f_i/n e acumuladas F_i .

O **histograma** mostra a forma (simetria, assimetria, bimodalidade); a **ogiva** (frequência acumulada) permite ler mediana e percentis; o **diagrama de Pareto** ordena categorias (tipos de erro, endpoints mais lentos) da mais à menos frequente para priorizar ações; o **ramo-e-folhas** organiza poucos dados sem perder os valores originais.

INTUIÇÃO Cada objeto tem um par teórico

Objeto dos dados	Objeto teórico	Leitura
frequências relativas	função de probabilidade	proporção em cada valor
histograma (altura = frequência relativa ÷ largura)	densidade	forma da distribuição
ogiva	FDA	lida de lado, dá percentis

Comparar o histograma com a densidade de um modelo é a forma visual do teste de aderência, que usa exatamente as frequências da tabela.

DEDUÇÃO De onde vem a regra de Sturges, e seu limite

Se os dados fossem binomiais com $k - 1$ ensaios, as frequências das k classes seriam os coeficientes binomiais, que somam $2^{k-1} = n$; daí $k = 1 + \log_2 n = 1 + 3.322 \log_{10} n$. A origem mostra a limitação: a regra supõe dados quase normais e dá poucas classes quando n é grande. A regra de Freedman-Diaconis, $h = 2 AIQ \cdot n^{-1/3}$, usa o AIQ e se comporta melhor com caudas pesadas; bibliotecas como NumPy (`bins='auto'`) combinam as duas.

CUIDADO A escolha das classes muda a história

Poucas classes escondem a forma (dois picos viram um); muitas viram ruído, porque cada classe tem poucos dados e as frequências oscilam. Escolher a largura é um compromisso entre viés (classes largas borram a forma) e variância (classes estreitas são ruidosas), o mesmo compromisso que aparece na escolha de estimadores.

A forma do histograma é diagnóstica, e em sistemas cada forma costuma ter uma causa:

NA COMPUTAÇÃO Lendo a forma de um histograma de latência

Forma	Causa provável
dois picos	dois caminhos: acerto e falha de cache, réplica local e remota, requisições com e sem consulta ao banco. É uma mistura: pela probabilidade total, a densidade é a média ponderada das densidades de cada caminho. Separar pela causa transforma uma distribuição estranha em duas simples, e o pico que se move quando a taxa de acerto do cache cai é um ótimo sinal de monitoramento
cauda longa à direita	filas ou cauda pesada
corte abrupto	um timeout

O diagrama de Pareto aplica a ideia a dados nominais: ordenar as categorias pela frequência e acumular. Em logs de erro, poucos tipos costumam responder pela maioria das ocorrências, e a curva acumulada mostra onde está o maior ganho por esforço. É a mesma concentração da distribuição de Pareto contínua, vista em categorias.

NA COMPUTAÇÃO Histogramas em sistemas de monitoramento

Prometheus, OpenTelemetry e HDR Histogram não guardam cada medição: incrementam contadores de *buckets* (classes) fixos ou exponenciais. Isso ocupa memória constante e permite somar histogramas de várias máquinas, que é exatamente a operação que percentis não permitem. O preço é que média e percentis passam a ser estimados a partir das classes, com as fórmulas da próxima seção.

CONEXÕES

- [2.2](#) FP empírica.
- [4.2](#) densidade.
- [4.6](#) FDA empírica e Pareto.
- [7.5](#) viés contra variância.
- [8.5](#) teste de aderência.

▼ Entendendo a fórmula, termo a termo

$$k = 1 + \log_2 n = 1 + 3.322 \log_{10} n, \quad h = \frac{A}{k}$$

$\log_2 n$ ← Cresce devagar: dobrar os dados acrescenta só uma classe.

$3.322 = 1/\log_{10} 2$ ← Converte o logaritmo base 2 para base 10 (das calculadoras).

h ← Largura das classes; arredonda-se para cima para cobrir toda a amplitude.

De onde vem, passo a passo

1. Mudança de base: $\log_2 n = \frac{\log_{10} n}{\log_{10} 2} = 3.322 \log_{10} n$.
2. Ideia de Sturges: dados com forma de sino são bem representados por coeficientes binomiais, e k classes de $\binom{k-1}{j}$ somam $2^{k-1} = n$ observações.
3. Poucas classes escondem a forma; muitas criam barras vazias e ruído. A regra é um ponto de partida.

EXEMPLO RESOLVIDO Montando um histograma

50 latências de uma API, entre 12.3 e 18.9 ms, precisam virar um histograma.

DADOS

- $n = 50$, mínimo 12.3, máximo 18.9 ms

O QUE SE PEDE

Número de classes, largura e limites.

RESOLUÇÃO PASSO A PASSO

1 Amplitude total

$$A = 18.9 - 12.3 = 6.6 \text{ ms}$$

2 Número de classes (Sturges)

$$k = 1 + 3.322 \log_{10} n = 1 + 3.322 \times 1.699 = 6.64 \approx 7$$

3 Largura

$h = A/k = 6.6/7 = 0.94$, arredondado *para cima* para 1.0 ms (valor fácil de ler, cobrindo todos os dados).

4 Limites

Começando em 12: $12 \vdash 13$, $13 \vdash 14$, ..., $18 \vdash 19$. O símbolo $\vdash$ inclui o limite esquerdo e exclui o direito.

RESPOSTA 7 classes de 1.0 ms, de 12 a 19 ms.

Lendo a forma: sino simétrico sugere comportamento estável; dois picos (bimodal) costumam indicar mistura de dois caminhos (acerto e falha de cache, réplica local e remota); corte abrupto num limite pode indicar um timeout descartando as requisições mais lentas.

Exercício 6.5 • Largura de Classe do Histograma

Foram registradas 80 latências, com mínimo 39 ms e máximo 101 ms. Usando Sturges para o número de classes, qual a largura inteira de cada classe (arredondada para cima)?

Espaço para cálculo

6.6 Medidas para Dados Agrupados

Quando só a tabela de frequências está disponível, como num histograma de monitoramento, os valores individuais foram perdidos. Sem os dados brutos, cada classe é representada por seu ponto médio x_i :

MÉDIA, VARIÂNCIA E MEDIANA AGRUPADAS

$$\bar{x} \approx \frac{\sum f_i x_i}{n}, \quad s^2 \approx \frac{\sum f_i (x_i - \bar{x})^2}{n - 1}$$

$$Md \approx L_i + \frac{\frac{n}{2} - F_{ant}}{f_{Md}} \cdot h$$

▼ Equação desmontada, variável por variável

$$\bar{x} \approx \frac{\sum f_i x_i}{n}$$

x_i ← ponto médio da classe i (ex.: classe 20–30 → 25)

f_i ← quantas observações caem na classe (ex.: 4)

$f_i x_i$ ← contribuição da classe (ex.: $4 \times 25 = 100$)

n ← total de observações

$$s^2 \approx \frac{\sum f_i (x_i - \bar{x})^2}{n - 1}$$

$f_i (x_i - \bar{x})^2$ ← desvio ao quadrado do ponto médio, repetido f_i vezes

$$Md \approx L_i + \frac{\frac{n}{2} - F_{ant}}{f_{Md}} \cdot h$$

L_i ← início da classe onde está a mediana (ex.: 30)

$\frac{n}{2}$ ← posição da mediana (ex.: 10)

F_{ant} ← observações antes dessa classe (ex.: 4)

f_{Md} ← observações dentro da classe (ex.: 10)

h ← largura da classe (ex.: 10)

L_i é o limite inferior da classe que contém a posição $n/2$, F_{ant} a frequência acumulada até a classe anterior e f_{Md} a frequência da classe mediana. Ex.: buckets de latência de largura 10 ms começando em 20 ms, com contagens 4, 10, 6: $n/2 = 10$ cai no 2º bucket (30 | 40), logo $Md \approx 30 + \frac{10-4}{10} \cdot 10 = 36$ ms.

INTUIÇÃO As hipóteses por trás de cada fórmula

Medida	Hipótese	Leitura
média	todos os valores no ponto médio da classe	esperança de uma variável discreta que vale x_i com probabilidade f_i/n : uma média ponderada
mediana e percentis	valores espalhados uniformemente dentro da classe	a ogiva é uma reta dentro da classe, e a fórmula é a interpolação linear que encontra onde a reta atinge $n/2$; trocando $n/2$ por $p \cdot n$, sai qualquer percentil
variância	todos no ponto médio	superestima em cerca de $h^2/12$ (correção de Sheppard), o mesmo $\Delta^2/12$ do erro de quantização: agrupar em classes é quantizar os dados

NA COMPUTAÇÃO É assim que o Prometheus calcula percentis

A função `histogram_quantile(0.99, ...)` acha o bucket onde a contagem acumulada passa de 99% e interpola linearmente dentro dele, a mesma fórmula da mediana agrupada com $0.99n$ no lugar de $n/2$.

CUIDADO Buckets largos e classes abertas

- **Buckets largos:** se o SLO é 300 ms e o p99 cai num bucket que vai de 100 a 500 ms, a interpolação pode errar o percentil em mais de 100 ms, para cima ou para baixo, e o alerta dispara (ou deixa de disparar) por um artefato da configuração. Regra prática: buckets finos perto dos limites que importam.
- **Classes abertas:** um bucket "acima de 1 s" (+Inf no Prometheus) não tem ponto médio. A média fica indefinida a partir só do histograma, e por isso esses sistemas guardam também a soma total e a contagem. Percentis que caem no bucket aberto não podem ser estimados; se for o percentil do SLO, os buckets precisam ser revistos.

Este módulo termina com um conjunto de números calculados de uma amostra: $\bar{x}$, s , quartis, histogramas. Todos eles mudariam se outra amostra fosse coletada. Quanto mudariam, e o que isso permite afirmar sobre o sistema que gerou os dados, é o objeto do Módulo 7.

CONEXÕES

- 1.5 média ponderada.
- 2.4 esperança discreta.
- 5.1 uniforme e quantização.
- 7.1 estatísticas como variáveis aleatórias.

▼ Entendendo a fórmula, termo a termo

$$Md \approx L_i + \frac{\frac{n}{2} - F_{ant}}{f_{Md}} \cdot h$$

L_i ← Início da classe que contém a posição $n/2$.

$\frac{n}{2} - F_{ant}$ ← Quantas observações ainda faltam, dentro da classe, para chegar à metade.

f_{Md} ← Quantas observações a classe tem.

$\cdot h$ ← Converte a fração da classe em comprimento.

De onde vem, passo a passo

1. Supõe-se que as observações estão espalhadas uniformemente dentro da classe.
2. Faltam $\frac{n}{2} - F_{ant}$ das f_{Md} observações da classe: isso é a fração $\frac{n/2 - F_{ant}}{f_{Md}}$ da largura.
3. Somando ao limite inferior obtém-se a mediana por interpolação linear (é ler a ogiva).

EXEMPLO RESOLVIDO Variância de dados agrupados

O sistema de monitoramento guardou só os contadores de um histograma de latência (buckets, como no Prometheus), não os valores individuais.

DADOS

•	BUCKET (MS)	20 ┊ 30	30 ┊ 40	40 ┊ 50
	f_i	4	10	6

O QUE SE PEDE

Média e desvio padrão aproximados.

RESOLUÇÃO PASSO A PASSO

1 Pontos médios

Cada classe é representada pelo seu centro: $x_i = 25, 35, 45$. Total $n = 4 + 10 + 6 = 20$.

2 Média ponderada

$$\bar{x} = \frac{\sum f_i x_i}{n} = \frac{4(25) + 10(35) + 6(45)}{20} = \frac{100 + 350 + 270}{20} = 36$$

3 Desvios ao quadrado, ponderados

$$\sum f_i (x_i - \bar{x})^2 = 4(-11)^2 + 10(-1)^2 + 6(9)^2 = 484 + 10 + 486 = 980$$

4 Variância e desvio

$$s^2 = \frac{980}{n-1} = \frac{980}{19} = 51.58, \quad s = 7.18$$

RESPOSTA $\bar{x} = 36, s = 7.18$.

Os resultados são aproximados: supõe-se que todos os valores de cada bucket estejam no ponto médio. Ferramentas de observabilidade fazem a mesma aproximação ao estimar médias e percentis a partir de buckets.

Exercício 6.6 • Média de Dados Agrupados

Os tempos de execução de jobs em lote foram agrupados em buckets na tabela abaixo (só os contadores foram guardados). Estime a média usando os pontos médios das classes.

CLASSE (MIN)	25 ┤ 34	34 ┤ 43	43 ┤ 52	52 ┤ 61
FREQUÊNCIA	9	8	15	12

Espaço para cálculo

Exercícios de Fixação com Soluções Comentadas

3 Questões Resolvidas

Exercício 6.1: Análise Completa de uma Amostra de Latências

Cinco requisições a um endpoint, feitas de um cliente de teste, tiveram tempos de resposta de: 60, 64, 62, 68, 56 ms.

- (a) Calcule a média amostral $\bar{x}$.
- (b) Calcule a variância amostral s^2 e o desvio padrão s .
- (c) Calcule o Coeficiente de Variação (CV).

Espaço para cálculo

Exercício 6.2: Identificação de Outliers pelo Critério de Tukey

Os tempos de indisponibilidade de um serviço (em minutos) por incidente forneceram os seguintes percentis: Primeiro Quartil $Q_1 = 30$ min, Mediana = 45 min, Terceiro Quartil $Q_3 = 60$ min. Um incidente recente deixou o serviço fora do ar por 110 minutos. Pelo critério do Boxplot de Tukey, essa ocorrência deve ser classificada como um outlier?

Espaço para cálculo

Exercício 6.3: Comparação de Variabilidade Relativa via CV

Uma engenheira de desempenho compara a variabilidade de dois serviços:

- Serviço A: processamento de vídeo, com tempo médio $\bar{x}_A = 20.0$ s e $s_A = 0.40$ s.
- Serviço B: API de autenticação, com tempo médio $\bar{x}_B = 10.0$ ms e $s_B = 0.50$ ms.

Qual dos dois serviços apresenta maior dispersão relativa (menor previsibilidade relativa)?

Espaço para cálculo

Módulo 7: Estimação e Teorema Central do Limite (TCL)

Inferência com amostras de telemetria e benchmarks: estimadores e viés, bootstrap, erro padrão e dados correlacionados, TCL e caudas pesadas, intervalos de confiança (Wilson, comparações múltiplas), EQM e regularização, t e qui-quadrado, IC para jitter e tamanho de amostra.

Este é o módulo em que probabilidade e estatística se encontram. O Módulo 6 calculou números a partir de uma amostra; aqui tratamos esses números como variáveis aleatórias, porque teriam saído diferentes com outra amostra, e usamos as ferramentas dos Módulos 2 a 5 para descrever quanto variam. Três resultados já vistos fazem quase todo o trabalho: a variância da soma de independentes, que dá o erro padrão; a soma de normais; e o percentil da normal, que transforma o erro padrão num intervalo. O resultado novo, o Teorema Central do Limite, explica por que a normal funciona mesmo quando os dados não são normais. Tudo o que vem nos Módulos 8 e 9 é este módulo aplicado a decisões.

7.1 Fundamentos de Inferência Estatística

Quase nunca observamos a população inteira: medimos algumas execuções de um benchmark, amostamos 1% dos traces de um sistema, testamos uma versão nova com parte dos usuários. A inferência estatística generaliza conclusões de uma **amostra aleatória** para a **população**, quantificando a incerteza dessa generalização. A palavra-chave é "quantificando": dizer que a latência média é 120 ms é uma estimativa; dizer que ela está entre 115 e 125 ms com 95% de confiança é inferência.

Conceitos Fundamentais:

- **Parâmetros populacionais:** constantes fixas e desconhecidas (ex.: latência média μ de todas as requisições, variância σ^2 , taxa de erro p).
- **Estatísticas / Estimadores:** funções dos dados da amostra, que são variáveis aleatórias (ex.: média amostral $\bar{X}$, variância amostral S^2 , proporção amostral $\hat{p}$).
- **Não tendenciosidade:** $\hat{\theta}$ é não viesado se $E[\hat{\theta}] = \theta$.
- **Consistência:** o estimador converge em probabilidade para o parâmetro quando $n \rightarrow \infty$.

INTUIÇÃO Parâmetro, estimador, estimativa

Termo	O que é	Exemplo
parâmetro	número fixo, mesmo que desconhecido	μ , a latência média verdadeira do serviço
estimador	função dos dados; como os dados são aleatórios, é uma variável aleatória	$\bar{X}$
estimativa	valor do estimador na amostra que se tem	120 ms

O estimador é uma variável aleatória no sentido exato do Módulo 2: uma função aplicada ao resultado de um sorteio, que aqui é a escolha da amostra. Por isso faz sentido perguntar qual a esperança e a variância de $\bar{X}$.

As duas propriedades da caixa descrevem o comportamento do estimador em repetições hipotéticas. Ser não viesado é acertar *em média*: $E[\bar{X}] = \frac{1}{n} \sum E[X_i] = \mu$, pela linearidade. Ser consistente é acertar *no limite*: com mais dados, a estimativa se concentra em torno do valor verdadeiro. Para a média, isso é a **lei dos grandes números**, que decorre de a variância de $\bar{X}$ ir a zero. É ela que justifica estimar uma taxa de erro pela fração observada nos logs e calcular uma integral por Monte Carlo como a média de f em pontos sorteados.

EXEMPLO Viesado, mas consistente

$\frac{1}{n} \sum (X_i - \bar{X})^2$ subestima σ^2 pelo fator $\frac{n-1}{n}$, logo é viesado; mas o fator tende a 1, logo é consistente. Com 5 execuções de benchmark o viés é de 20%; com milhões de requisições, irrelevante.

CUIDADO Viés de seleção: nenhum n corrige

Todas as garantias dependem de a amostra ser aleatória: cada elemento deve ter a chance prevista de entrar. Medir só as requisições das 14 h, só os usuários que responderam a uma pesquisa ou só os builds que terminaram (excluindo os que travaram) produz *viés de seleção*: o estimador converge para o parâmetro da população errada. É o mesmo problema do paradoxo de Simpson, com os pesos dos subgrupos na amostra diferentes dos pesos na população. Amostragem por sorteio uniforme, ou por hash do ID da requisição, é o que torna a amostra representativa.

NA COMPUTAÇÃO Bootstrap: computação no lugar de álgebra

Para estimadores sem fórmula conhecida de variância (a mediana, o p99, a razão entre duas médias):

1. reamostre a própria amostra com reposição milhares de vezes;
2. recalcule o estimador em cada reamostra;
3. use a dispersão desses valores como estimativa do erro padrão.

A ideia é tratar a distribuição empírica como se fosse a população e simular o processo de amostragem. É o padrão em análise de benchmarks e testes A/B com métricas complicadas.

CONEXÕES

- 2.1 variável aleatória como função.
- 1.9 paradoxo de Simpson.
- 4.6 FDA empírica.
- 6.3 o $n - 1$.
- 7.2 variância de $\bar{X}$.

▼ Entendendo a fórmula, termo a termo

$$\text{viés}(\hat{\theta}) = E[\hat{\theta}] - \theta, \quad E[S^2] = \sigma^2$$

$E[\hat{\theta}]$ ← Valor médio do estimador sobre todas as amostras possíveis.

θ ← Valor verdadeiro do parâmetro.

Viés zero ← O estimador acerta "em média": não tende a errar para um lado.

De onde vem, passo a passo

1. $E[\bar{X}] = \frac{1}{n} \sum E[X_i] = \frac{1}{n} \cdot n\mu = \mu$: $\bar{X}$ não tem viés.
2. Identidade: $\sum (X_i - \bar{X})^2 = \sum (X_i - \mu)^2 - n(\bar{X} - \mu)^2$.
3. Esperança: $n\sigma^2 - n \cdot \frac{\sigma^2}{n} = (n-1)\sigma^2$.
4. Logo dividir por $n-1$ dá $E[S^2] = \sigma^2$. Dividir por n daria $\frac{n-1}{n}\sigma^2$ (subestima).

EXEMPLO RESOLVIDO Estimador, estimativa e viés

Um site recebe 1 milhão de visitas por dia, com tempo médio de carregamento de página μ desconhecido. Mede-se uma amostra aleatória de 50 visitas (amostragem de telemetria).

DADOS

- amostra 1: $\bar{x} = 12.03$ s
- uma 2ª amostra daria outro valor, como 11.98 s

O QUE SE PEDE

Distinguir parâmetro, estimador e estimativa, e calcular o viés de dividir a variância por n .

RESOLUÇÃO PASSO A PASSO

1 Parâmetro

μ : número fixo da população inteira, desconhecido.

2 Estimador

A regra "média da amostra", $\bar{X}$. Antes de sortear a amostra, é uma variável aleatória.

3 Estimativa

O número obtido com a amostra sorteada: 12.03. Outra amostra dá outra estimativa.

4 Viés de dividir por n

O estimador $\hat{\sigma}^2 = \frac{1}{n} \sum (X_i - \bar{X})^2$ tem

$$E[\hat{\sigma}^2] = \frac{n-1}{n} \sigma^2$$

Com $n = 5$: $E[\hat{\sigma}^2] = 0.8 \sigma^2$, subestimando em 20% em média.

Por isso s^2 divide por $n - 1$: a correção cancela o viés exatamente.

Exercício 7.1 • Viés de um Estimador

Para estimar a latência média μ de um serviço, propõe-se $T = \frac{1X_1+1X_2+1X_3}{5}$, com X_i i.i.d. de média μ . Se na verdade $\mu = 90$, qual o viés $E[T] - \mu$?

Espaço para cálculo

7.2 Distribuição Amostral da Média e Erro Padrão

Se $\bar{X}$ é uma variável aleatória, ela tem uma distribuição: a distribuição dos valores que a média assumiria em amostras repetidas. Seus dois primeiros momentos saem diretamente do Módulo 2, sem nenhuma hipótese sobre a forma da população. Para qualquer população com média μ e desvio padrão σ , ao retirar amostras aleatórias de tamanho n :

$$E[\bar{X}] = \mu_{\bar{X}} = \mu$$

$$\text{Erro Padrão da Média: } \sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$$

▼ Equação desmontada, variável por variável

$$E[\bar{X}] = \mu$$

$\bar{X}$ ← média da amostra (muda de amostra para amostra)

μ ← média verdadeira da população

= ← em média, a média amostral acerta

$$\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$$

$\sigma_{\bar{X}}$ ← o que se calcula: erro padrão (quanto a média oscila)

σ ← desvio padrão de cada item (ex.: 6 ms)

n ← tamanho da amostra (ex.: 9)

$\sqrt{n}$ ← raiz do tamanho (ex.: 3); resultado $6/3 = 2$ g

DEDUÇÃO Duas linhas

1. A soma $X_1 + \dots + X_n$ de observações independentes tem variância $n\sigma^2$.
2. Dividir por n divide a variância por n^2 ; sobra σ^2/n . O erro padrão é a raiz disso.

Toda a precisão da estatística vem desse $\sqrt{n}$ no denominador, que existe porque desvios independentes se cancelam parcialmente ao serem somados.

O erro padrão cai com a raiz de n , não com n . Para dividir a incerteza por 2, são necessários 4 vezes mais dados; para dividir por 10, 100 vezes. Por isso medições de desempenho estabilizam rápido no começo e depois exigem muito esforço para ganhos pequenos de precisão, e fórmulas de tamanho de amostra têm n proporcional a $1/E^2$. O mesmo $\sqrt{n}$ aparece nos gráficos de controle: o gráfico de médias tem limites $3\sigma/\sqrt{n}$, mais estreitos que os de medições individuais.

CUIDADO Desvio padrão não é erro padrão

σ	$\sigma/\sqrt{n}$
quanto as requisições <i>individuais</i> variam	quanto a <i>média</i> de n requisições varia de uma amostra para outra
não diminui com mais dados	com milhões de requisições, fica minúsculo

Sabemos a média com precisão, mas cada requisição continua imprevisível. Um gráfico com barras de erro precisa dizer qual dos dois está mostrando.

NA COMPUTAÇÃO Quando as observações não são independentes

Situação	Dependência	Erro padrão real
métricas consecutivas (mesma carga, mesmo estado de cache)	positiva	maior que $\sigma/\sqrt{n}$, e a amostra "efetiva" é menor que n ; em benchmarks, espaçar as execuções e reiniciar o processo ajuda a recuperar a independência
amostragem sem reposição de população finita	negativa	menor: multiplicado por $\sqrt{(N-n)/(N-1)}$, o fator da hipergeométrica; desprezível se $n/N < 5\%$

CONEXÕES

- 2.7** soma de variâncias e covariância.
- 1.8** fator de população finita.
- 7.4** margem de erro.
- 7.8** tamanho de amostra.
- 9.3** limites do gráfico $\bar{X}$.

▼ Entendendo a fórmula, termo a termo

$$\text{Var}(\bar{X}) = \frac{\sigma^2}{n}, \quad \sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$$

 σ^2

← Variabilidade das observações individuais.

 n

← Tamanho da amostra: mais dados, média mais estável.

 $\sqrt{n}$ ← A precisão melhora com a raiz de n , não com n .

De onde vem, passo a passo

1. $\bar{X} = \frac{1}{n}(X_1 + \dots + X_n)$.
2. Constante sai ao quadrado: $\text{Var}(\bar{X}) = \frac{1}{n^2} \text{Var}(X_1 + \dots + X_n)$.
3. Independência: $\text{Var}(\sum X_i) = n\sigma^2$, logo $\text{Var}(\bar{X}) = \frac{n\sigma^2}{n^2} = \frac{\sigma^2}{n}$.

EXEMPLO RESOLVIDO

Quanto a latência média oscila

As latências de uma API têm $\sigma = 6$ ms. Quanto oscila a média de uma amostra de requisições?

DADOS

- $\sigma = 6$ ms
- $n = 9$ ou $n = 36$
- caso finito: um cluster de $N = 100$ servidores, dos quais se amostram $n = 36$ sem repetir

O QUE SE PEDE

Erro padrão $\sigma_{\bar{X}}$ em cada caso.

RESOLUÇÃO PASSO A PASSO

1

Fórmula do erro padrão

$$\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$$

2 $n = 9$

$$\sigma_{\bar{X}} = \frac{6}{\sqrt{9}} = \frac{6}{3} = 2 \text{ ms}$$

3 $n = 36$

$$\sigma_{\bar{X}} = \frac{6}{\sqrt{36}} = 1 \text{ ms}$$

Quadruplicar a amostra só divide o erro padrão por 2.

4 **População finita**

Amostrando 36 dos 100 servidores sem reposição, multiplique pelo fator de correção:

$$\sqrt{\frac{N-n}{N-1}} = \sqrt{\frac{64}{99}} = 0.80 \implies \sigma_{\bar{X}} = 0.80 \text{ ms}$$

RESPOSTA 2 ms ($n = 9$); 1 ms ($n = 36$); 0.80 ms com correção finita.

Para $n/N < 5\%$ a correção é desprezível, como ao amostrar 1000 de milhões de requisições.

Exercício 7.2 • Erro Padrão da Média

A latência de uma API tem $\sigma = 20$ ms. Qual o erro padrão da média de amostras de $n = 16$ requisições?

Espaço para cálculo

7.3 O Teorema Central do Limite (TCL)

A seção anterior deu a média e o desvio de $\bar{X}$, mas não sua forma. Sem a forma, não dá para calcular probabilidades como "qual a chance de a média amostral errar por mais de 5 ms?". Se a população for normal, a forma é normal. O resultado notável é que, com n suficientemente grande, a forma é normal *qualquer que seja* a população:

TEOREMA CENTRAL DO LIMITE (TCL)

Seja $X_1, X_2, \dots, X_n$ uma amostra aleatória i.i.d. de qualquer distribuição com média μ e v

$$\text{À medida que } n \geq 30, \quad \bar{X} \xrightarrow{d} N\left(\mu, \frac{\sigma^2}{n}\right)$$

$$\text{Padronizado: } Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0, 1)$$

▼ Equação desmontada, variável por variável

$$\bar{X} \approx N\left(\mu, \frac{\sigma^2}{n}\right) \quad (n \geq 30)$$

 $\bar{X}$

← média amostral

 $N(\cdot)$

← tem forma de sino, mesmo que os dados não tenham

 μ

← centro: a média da população

 $\frac{\sigma^2}{n}$ ← variância da média: diminui com n $n \geq 30$

← regra prática para a aproximação valer

$$Z = \frac{\bar{X} - \mu}{\sigma / \sqrt{n}}$$

 $\bar{X} - \mu$

← erro da média

 $\sigma / \sqrt{n}$

← erro padrão

 Z ← erro medido em erros padrão; segue $N(0, 1)$ **INTUIÇÃO Somar apaga os detalhes**

Uma parcela pode ser assimétrica, mas ao somar muitas, os desvios para cima de umas se compensam com os desvios para baixo de outras, e o que sobra depende só da média e da variância. A normal é o único ponto fixo desse processo: somar normais dá normal, então se as somas convergem para alguma forma, só pode ser essa. É por isso que a normal aparece onde há agregação: ruído de medição, tráfego total de muitos usuários, tempo total de muitas tarefas pequenas.

O teorema já apareceu disfarçado. A binomial é uma soma de n indicadoras, e a aproximação normal da binomial é o TCL aplicado a variáveis que só valem 0 ou 1; por isso a proporção $\hat{p}$ é aproximadamente normal. A versão para somas também é útil por si: $\sum X_i \approx N(n\mu, n\sigma^2)$, que é o que permite dimensionar a capacidade total de um cluster pela soma das demandas dos usuários.

CUIDADO " $n \geq 30$ " é regra de bolso

População	n necessário
simétrica	cerca de 10 basta
assimétrica (latência com cauda longa, receita por usuário em testes A/B)	centenas ou milhares; o erro da aproximação é proporcional à assimetria e cai só com $1/\sqrt{n}$ (Berry-Esseen). Uma transformação, como o logaritmo, ajuda
variância infinita (algumas Pareto)	o TCL clássico não vale: a média nunca fica normal

A forma prática de checar é simular: bootstrap dos próprios dados e verificar se o histograma das médias parece um sino.

O TCL é o motivo pelo qual quase toda a inferência deste curso usa a normal mesmo com dados que não são normais. Os intervalos de confiança, os testes Z e de proporção e os limites de 3σ dos gráficos de controle de médias supõem que a estatística é aproximadamente normal, e essa hipótese é justificada pelo TCL, não pela forma dos dados individuais.

CONEXÕES

- 5.7** soma de normais.
- 5.8** binomial $\approx$ normal.
- 4.4** variância infinita.
- 7.4** intervalos.
- 8.4** teste Z.
- 9.3** gráfico de médias.

▼ Entendendo a fórmula, termo a termo

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0, 1)$$

$\bar{X} - \mu$ ← Erro da média amostral.

$\sigma/\sqrt{n}$ ← Erro padrão: a escala natural desse erro (7.2).

$\xrightarrow{d} N(0, 1)$ ← A forma da distribuição se aproxima do sino, qualquer que seja a distribuição original.

De onde vem, passo a passo

1. A média e a variância de $\bar{X}$ são exatas (7.1 e 7.2); o TCL acrescenta a *forma* normal.
2. Intuição: a média soma muitos efeitos independentes; desvios para cima e para baixo se combinam de muitas formas, e as combinações "do meio" são as mais numerosas.
3. A convergência é rápida para distribuições simétricas e mais lenta para assimétricas; daí a regra prática $n \geq 30$.

EXEMPLO RESOLVIDO

O TCL em ação com dados não normais

O erro de arredondamento de um cálculo (em unidades do último dígito) é uniforme em $[0, 1]$: distribuição plana, nada parecida com um sino. Qual a chance de a média de 12 erros passar de 0.6?

DADOS

- $X \sim U(0, 1)$: $\mu = 0.5$, $\sigma = 1/\sqrt{12} = 0.2887$
- $n = 12$

O QUE SE PEDE

$$P(\bar{X} > 0.6).$$

RESOLUÇÃO PASSO A PASSO

1 TCL

Para n razoável, $\bar{X}$ é aproximadamente normal com média μ e desvio $\sigma/\sqrt{n}$, qualquer que seja a forma de X .

2 Erro padrão

$$\sigma_{\bar{X}} = \frac{0.2887}{\sqrt{12}} = 0.0833$$

3 Padronizar

$$z = \frac{0.6 - 0.5}{0.0833} = 1.2$$

4 Probabilidade

$$P(\bar{X} > 0.6) \approx 1 - \Phi(1.2) = 1 - 0.8849 = 0.115$$

RESPOSTA Cerca de 11.5%.

Para distribuições simétricas, $n \approx 10$ a 12 já basta; para muito assimétricas (como a exponencial), a regra $n \geq 30$ é mais segura.

Exercício 7.3 • Teorema Central do Limite

O tamanho das respostas de uma API tem $\mu = 55$ KB e $\sigma = 7$ KB (distribuição desconhecida, assimétrica). Qual a probabilidade de a média de 100 respostas exceder 56.4 KB?

Espaço para cálculo

7.4 Intervalos de Confiança (IC)

Juntando o TCL com os percentis da normal: $\bar{X}$ fica a menos de $1.96 \sigma / \sqrt{n}$ de μ em 95% das amostras. Essa frase pode ser lida ao contrário: em 95% das amostras, μ fica a menos de $1.96 \sigma / \sqrt{n}$ de $\bar{X}$. O intervalo $\bar{X} \pm 1.96 \sigma / \sqrt{n}$ é, portanto, um procedimento que acerta 95% das vezes. Um Intervalo de Confiança de nível $(1 - \alpha)$ é construído por um procedimento que, se repetido em muitas amostras, produz intervalos que contêm o verdadeiro parâmetro em $(1 - \alpha) \times 100\%$ das vezes.

CASO 1: MÉDIA POPULACIONAL COM σ CONHECIDO (NORMAL Z)

$$IC(\mu, 1 - \alpha) = \left[\bar{x} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} ; \bar{x} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$$

Valores críticos usuais: 90% $\Rightarrow z = 1.645$; 95% $\Rightarrow z = 1.960$; 99% $\Rightarrow z = 2.576$

▼ Equação desmontada, variável por variável

$$IC = \left[\bar{x} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} ; \bar{x} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$$

$\bar{x}$ ← centro: média da amostra (ex.: 5000 h)

$z_{\alpha/2}$ ← quantos erros padrão abrir: 1.645 (90%), 1.96 (95%), 2.576 (99%)

σ ← desvio padrão conhecido (ex.: 200 h)

$\sqrt{n}$ ← raiz do tamanho da amostra (ex.: 10)

$z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$ ← margem de erro E (ex.: $1.96 \times 20 = 39.2$ h)

α ← chance de o método errar (ex.: 0.05 para 95%)

CASO 2: MÉDIA POPULACIONAL COM σ DESCONHECIDO (t DE STUDENT)

$$IC(\mu, 1 - \alpha) = \left[\bar{x} - t_{\alpha/2, \nu} \frac{s}{\sqrt{n}} ; \bar{x} + t_{\alpha/2, \nu} \frac{s}{\sqrt{n}} \right], \quad \nu = n - 1 \text{ graus de liberdade}$$

▼ Equação desmontada, variável por variável

$$IC = \bar{x} \pm t_{\alpha/2, \nu} \frac{s}{\sqrt{n}}, \quad \nu = n - 1$$

s ← desvio padrão da amostra (substitui σ desconhecido)

$t_{\alpha/2, \nu}$ ← valor da tabela t (ex.: $t_{0.025;9} = 2.262$)

$\nu = n - 1$ ← graus de liberdade (ex.: $10 - 1 = 9$)

CASO 3: PROPORÇÃO POPULACIONAL (p) E DIMENSIONAMENTO AMOSTRAL

$$IC(p, 1 - \alpha) = \hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

Tamanho Amostral Mínimo para Média com Margem de Erro E : $n = \left(\frac{z_{\alpha/2} \cdot \sigma}{E} \right)^2$

▼ Equação desmontada, variável por variável

$$IC(p) = \hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$$

$\hat{p}$ ← proporção observada (ex.: 30/400 = 0.075)

$1 - \hat{p}$ ← proporção complementar (ex.: 0.925)

$\sqrt{\frac{\hat{p}(1 - \hat{p})}{n}}$ ← erro padrão da proporção (ex.: 0.0132)

$z_{\alpha/2}$ ← valor da normal para a confiança

$$n = \left(\frac{z_{\alpha/2} \cdot \sigma}{E} \right)^2$$

n ← o que se calcula: tamanho mínimo da amostra

σ ← desvio padrão (ex.: 0.10 s)

E ← erro máximo aceito (ex.: 0.02 s)

$(\cdot)^2$ ← ao quadrado (ex.: $(2.576 \times 0.1/0.02)^2 = 165.9 \rightarrow 166$)

INTUIÇÃO Os três casos têm a mesma estrutura

Estimativa $\pm$ valor crítico $\times$ erro padrão. O que muda é o erro padrão e de onde vem o valor crítico:

Caso	Erro padrão	Valor crítico
média, σ conhecido	$\sigma/\sqrt{n}$	normal
média, σ estimado	$s/\sqrt{n}$	t_{n-1} : a incerteza extra de estimar σ alarga o intervalo
proporção	$\sqrt{p(1-p)/n}$, porque a proporção é a média de indicadoras	normal

A fórmula de tamanho de amostra é o caso 1 resolvido para n : exige-se que a semilargura $z\sigma/\sqrt{n}$ seja no máximo E .

CUIDADO O que "95% de confiança" quer dizer

Depois de calculado, o intervalo $[115; 125]$ ou contém μ ou não contém; μ é fixo e não há mais nada aleatório. Os 95% são uma propriedade do *método*: de cada 100 intervalos construídos assim, em amostras diferentes, cerca de 95 contêm μ . A animação desta seção mostra exatamente isso. Dizer "há 95% de chance de μ estar neste intervalo" exige tratar μ como variável aleatória, que é a abordagem bayesiana, com uma priori sobre μ ; com prioris pouco informativas os números coincidem, mas significam coisas diferentes.

NA COMPUTAÇÃO Intervalos em benchmarks

Dizer "a versão nova é 3% mais rápida" não significa nada se o ruído entre execuções é de 5%. O procedimento correto:

1. rodar várias vezes cada versão;
2. calcular o IC da diferença das médias (cuja variância é a soma das variâncias);
3. declarar melhoria só se o intervalo não contiver zero, o que equivale a um teste de hipóteses bicaudal.

Ferramentas como `hyperfine` e o `criterion` do Rust fazem isso automaticamente.

CUIDADO Proporções pequenas e muitos intervalos

- **Proporções pequenas:** o intervalo de Wald (o do caso 3) depende da aproximação normal, que falha quando p está perto de 0 ou 1, como taxas de erro de 0.1%: a distribuição de $\hat{p}$ fica assimétrica e o intervalo pode até ter limite negativo. O intervalo de Wilson corrige isso. No extremo, com zero falhas em n tentativas, a regra de três dá o limite superior de cerca de $3/n$.
- **Muitos intervalos:** num painel com 20 métricas, cada uma com IC de 95%, espera-se que uma delas "erre" só por acaso. A correção de Bonferroni usa α/k para k comparações, justificada pelo limitante da união.

CONEXÕES

- 5.6 valores críticos.
- 3.6 regra de três.
- 1.2 limitante da união.
- 1.6 leitura bayesiana.
- 7.6 distribuição t .
- 8.6 IC e teste bilateral.

▼ Entendendo a fórmula, termo a termo

$$\bar{x} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \leq \mu \leq \bar{x} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$

 $\bar{x}$

← Centro do intervalo: a melhor estimativa pontual.

 $z_{\alpha/2}$

← Quantos erros padrão abrir para cada lado; define a confiança.

 $\sigma/\sqrt{n}$

← Erro padrão: a precisão da média.

 $E = z_{\alpha/2} \sigma / \sqrt{n}$

← Margem de erro.

De onde vem, passo a passo

1. Pelo TCL: $P\left(-z_{\alpha/2} \leq \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \leq z_{\alpha/2}\right) = 1 - \alpha$.
2. Multiplique por $\sigma/\sqrt{n} > 0$: $-E \leq \bar{X} - \mu \leq E$.
3. Subtraia $\bar{X}$: $-\bar{X} - E \leq -\mu \leq -\bar{X} + E$.
4. Multiplique por -1 (inverte os sinais): $\bar{X} - E \leq \mu \leq \bar{X} + E$. O que é aleatório é o intervalo, não μ .

EXEMPLO RESOLVIDO

Confiança versus largura

16 execuções de um benchmark têm média 50 ms, com $\sigma = 4$ ms conhecido de medições anteriores na mesma máquina.

DADOS

- $\bar{x} = 50, \sigma = 4, n = 16$
- proporção: 30 requisições com erro em 400

O QUE SE PEDE

IC para μ a 90%, 95% e 99%; IC 95% para a proporção.

RESOLUÇÃO PASSO A PASSO

1 Erro padrão

$$\sigma_{\bar{X}} = \frac{4}{\sqrt{16}} = 1$$

2 Margem para cada confiança

$E = z_{\alpha/2} \sigma_{\bar{X}}$, e o intervalo é $\bar{x} \pm E$:

CONFIANÇA	$z_{\alpha/2}$	E	INTERVALO
90%	1.645	1.645	[48.36; 51.64]
95%	1.960	1.960	[48.04; 51.96]
99%	2.576	2.576	[47.42; 52.58]

3 Proporção: estimativa pontual

$$\hat{p} = \frac{30}{400} = 0.075$$

4 Proporção: margem

$$E = 1.96 \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} = 1.96 \sqrt{\frac{0.075 \times 0.925}{400}} = 1.96 \times 0.0132 = 0.026$$

$$\text{IC 95\%: } 0.075 \pm 0.026 = [0.049; 0.101].$$

RESPOSTA 95% para μ : [48.04; 51.96]. Proporção: [0.049; 0.101].

Mais confiança custa mais largura. A única forma de ter as duas coisas é aumentar n (rodar mais vezes o benchmark, coletar mais requisições).

Exercício 7.4 • IC para a Média (σ conhecido)

Execuções de um benchmark nesta máquina têm $\sigma = 15$ ms conhecido. Uma amostra de 49 execuções deu $\bar{x} = 205$ ms. Qual o limite superior do IC de 95% para μ ?

Espaço para cálculo

7.5 Eficiência e Erro Quadrático Médio

Para um mesmo parâmetro há vários estimadores possíveis. O centro de uma distribuição simétrica pode ser estimado pela média, pela mediana, pela média aparada. Não ter viés é um critério, mas não basta: dois estimadores sem viés podem oscilar muito diferente em torno do alvo. Entre estimadores não tendenciosos, prefere-se o de **menor variância** (mais eficiente). Para dados normais, $\bar{X}$ é mais eficiente que a mediana amostral ($Var(\tilde{X}) \approx \frac{\pi}{2} \cdot \frac{\sigma^2}{n}$). Para comparar estimadores com viés usa-se $EQM(\hat{\theta}) = Var(\hat{\theta}) + [\text{viés}(\hat{\theta})]^2$.

INTUIÇÃO Média, mediana ou meio-termo

Dados	Melhor estimador do centro	Por quê
normais	média	a mediana precisa de $\pi/2 \approx 1.57$ vez mais dados (57% a mais) para a mesma precisão; é o preço da robustez
cauda pesada ou outliers (picos de coleta de lixo)	mediana	pode ser muito mais eficiente; a média pode nem convergir quando a variância é infinita
incerto	média aparada	descarta uma fração dos extremos de cada lado: perde pouco com dados normais e muito menos que a média com dados contaminados

DEDUÇÃO A decomposição do erro quadrático médio

Somando e subtraindo $E[\hat{\theta}]$ dentro do quadrado (a mesma álgebra da fórmula computacional da variância):

$$EQM = E[(\hat{\theta} - \theta)^2] = Var(\hat{\theta}) + \text{viés}^2$$

Ela mostra que um estimador ligeiramente viesado pode ser melhor que um sem viés, se tiver variância bem menor. Para estimar σ^2 de dados normais, dividir a soma dos quadrados por $n + 1$ dá viés, mas menor EQM que dividir por $n - 1$.

CUIDADO Viés que aparece sozinho

s^2 não tem viés para σ^2 , mas s subestima σ , pela desigualdade de Jensen, já que a raiz é côncava. A constante c_4 dos gráficos de controle corrige exatamente esse viés.

NA COMPUTAÇÃO O compromisso viés-variância

A mesma decomposição organiza o aprendizado de máquina. Modelos simples têm viés alto e variância baixa (underfitting): erram de forma sistemática, mas estável. Modelos muito flexíveis têm o contrário (overfitting): acertam em média, mas oscilam muito com a amostra de treino. Regularização (ridge, lasso) aceita um pouco de viés para cortar muita variância e baixar o erro total. A escolha do número de classes de um histograma é o mesmo compromisso.

EXEMPLO Encolhimento de muitas taxas

Ao estimar a taxa de erro de milhares de endpoints, a maioria com pouco tráfego, puxar cada estimativa um pouco em direção à média geral reduz o EQM total. Um endpoint com 1 erro em 2 requisições não tem taxa de erro de 50%: é mais provável que tenha uma taxa parecida com a dos outros e tenha tido azar. É Bayes, com a média geral fazendo o papel de priori.

CONEXÕES

6.2 média contra mediana nos dados.

2.8 Jensen.

9.7 constante c_4 .

6.5 número de classes.

1.6 Bayes e priori.

▼ Entendendo a fórmula, termo a termo

$$EQM(\hat{\theta}) = E[(\hat{\theta} - \theta)^2] = Var(\hat{\theta}) + [viés(\hat{\theta})]^2$$

$$(\hat{\theta} - \theta)^2$$

← Erro quadrático de uma estimativa.

$$Var(\hat{\theta})$$

← Parte do erro devida à oscilação entre amostras.

$$viés^2$$

← Parte devida ao desvio sistemático.

De onde vem, passo a passo

1. Some e subtraia $E[\hat{\theta}]$: $\hat{\theta} - \theta = (\hat{\theta} - E[\hat{\theta}]) + (E[\hat{\theta}] - \theta)$.
2. Eleve ao quadrado e tome a esperança: $Var + viés^2 + 2 viés \cdot E[\hat{\theta} - E\hat{\theta}]$.
3. O último termo é zero, pois $E[\hat{\theta} - E\hat{\theta}] = 0$.
4. Eficiência: entre médias ponderadas $\sum w_i X_i$ com $\sum w_i = 1$ (sem viés), $Var = \sigma^2 \sum w_i^2$, mínima com pesos iguais $w_i = 1/n$. Por isso $\bar{X}$ é a mais eficiente.

EXEMPLO RESOLVIDO

Um estimador viesado pode ser melhor

Comparando estimadores pela variância e pelo erro quadrático médio (EQM).

DADOS

- (i) $\bar{X}$ com $n = 2$ contra usar só X_1
- (ii) A: sem viés, $Var = 4$; B: viés 1, $Var = 2$

O QUE SE PEDE

Qual estimador é melhor em cada caso.

RESOLUÇÃO PASSO A PASSO

1

Eficiência

Ambos não têm viés. $Var(\bar{X}) = \sigma^2/2$ e $Var(X_1) = \sigma^2$. $\bar{X}$ tem metade da variância: é 2 vezes mais eficiente.

2 EQM junta viés e variância

$$EQM = Var + \text{viés}^2$$

3 Aplicar

$$EQM_A = 4 + 0^2 = 4, \quad EQM_B = 2 + 1^2 = 3$$

RESPOSTA (i) $\bar{X}$; (ii) B, apesar do viés.

O EQM mede o quanto o estimador erra em média, ao quadrado. Um pequeno viés pode valer a pena se reduzir muito a variância.

Exercício 7.5 • Variância de um Estimador

Com X_1, X_2, X_3 i.i.d. de variância $\sigma^2 = 8$, compara-se $\bar{X}$ com $T = \frac{3X_1 + 1X_2 + 3X_3}{7}$ (ambos não tendenciosos). Calcule $Var(T)$.

Espaço para cálculo

7.6 Distribuições Amostrais no Caso Normal

O TCL dá resultados aproximados para n grande. Muitas vezes n é pequeno: benchmarks caros (treinar um modelo, rodar uma suíte de testes de horas) costumam ter 5 a 10 repetições. Se a população for normal, há resultados exatos para qualquer n . Se $X_1, \dots, X_n$ é amostra de $N(\mu, \sigma^2)$, três resultados sustentam a inferência para pequenas amostras:

RESULTADOS EXATOS

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right) \text{ para qualquer } n \text{ (não precisa do TCL)}$$

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}, \quad \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$$

▼ Equação desmontada, variável por variável

$$\bar{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right)$$

dados normais ← aqui a média é normal para qualquer n , sem precisar do TCL

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$$

S

← desvio padrão amostral no lugar de σ

t_{n-1}

← distribuição t com $n - 1$ graus de liberdade (caudas mais largas)

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$$

S^2

← variância amostral

σ^2

← variância verdadeira

χ_{n-1}^2

← distribuição qui-quadrado (só valores positivos)

A t é simétrica com caudas mais pesadas que a normal (reflete a incerteza de estimar σ por S) e tende a $N(0, 1)$ quando $gl \rightarrow \infty$. A χ^2 só assume valores positivos e é assimétrica à direita.

DEDUÇÃO De onde vêm a qui-quadrado e a t

- **Qui-quadrado:** por definição, a soma dos quadrados de k normais padrão independentes. Como $(n-1)S^2/\sigma^2 = \sum (X_i - \bar{X})^2/\sigma^2$, ela é uma soma de quadrados de desvios padronizados; seriam n termos, mas como os desvios em torno de $\bar{X}$ somam zero, só $n-1$ são livres. Sua média é $n-1$, o que é outra forma de dizer que $E[S^2] = \sigma^2$.
- **t :** aparece ao trocar σ por S na padronização. O denominador S também varia de amostra para amostra; às vezes sai pequeno, e então a estatística fica grande. Essa fonte extra de variação torna as caudas mais pesadas que as da normal.

EXEMPLO Quanto a t alarga o intervalo

Com 4 graus de liberdade, $t_{0.025;4} = 2.776$ contra $z = 1.96$: um intervalo 42% mais largo. Com muitos graus de liberdade, S fica tão perto de σ que a t vira a normal. A distribuição foi descoberta por William Gosset, que publicava como "Student" porque trabalhava com amostras pequenas na cervejaria Guinness.

CUIDADO z no lugar de t , e normalidade

Usar z em vez de t com 5 repetições produz intervalos estreitos demais e falsas conclusões de melhoria, um erro comum em comparações de desempenho. Quanto à hipótese de normalidade, a sensibilidade é diferente para cada resultado:

t (média)	χ^2 (variância)
razoavelmente robusta a desvios moderados, porque $\bar{X}$ já tende à normal; sensível a outliers e a assimetria forte com n pequeno	muito sensível: depende da cauda da distribuição; com dados de cauda pesada, intervalos, testes e gráficos de variância podem errar muito

CONEXÕES

- 5.7** soma de normais.
- 6.3** graus de liberdade.
- 7.7** IC para variância.
- 8.7** teste para variância.
- 9.6** gráfico S^2 .

▼ Entendendo a fórmula, termo a termo

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}, \quad \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$$

S no lugar de σ ← O denominador também é aleatório; isso alarga as caudas.

$n - 1$ ← Graus de liberdade "gastos": um foi usado para estimar μ por $\bar{x}$.

χ_{n-1}^2 ← Distribuição de uma soma de $n - 1$ quadrados de normais padrão independentes.

De onde vem, passo a passo

1. Com σ conhecido, $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$ é $N(0, 1)$.
2. Trocar σ por S divide Z por S/σ , que oscila em torno de 1. Às vezes S sai pequeno e T fica grande: caudas mais pesadas.
3. Quanto maior n , mais S se aproxima de σ e mais t_{n-1} se aproxima de $N(0, 1)$.
4. O IC com t sai igual a 7.4, trocando $z_{\alpha/2}$ por $t_{\alpha/2; n-1}$ e σ por s .

EXEMPLO RESOLVIDO Quanto a t alarga o intervalo

Dez execuções de um job de treinamento de modelo (caras demais para repetir muito), com σ desconhecido.

DADOS

- $n = 10$, $\bar{x} = 12.4$ min, $s = 0.8$ min

O QUE SE PEDE

IC 95% para μ .

RESOLUÇÃO PASSO A PASSO

1 Por que t

σ é desconhecido e estimado por s . Isso acrescenta incerteza, e a t de Student, com caudas mais pesadas, compensa.

2 Graus de liberdade e valor crítico

$gl = n - 1 = 9$. Tabela: $t_{0.025; 9} = 2.262$.

3 Erro padrão estimado

$$\frac{s}{\sqrt{n}} = \frac{0.8}{\sqrt{10}} = 0.253$$

4 Margem e intervalo

$$E = 2.262 \times 0.253 = 0.572, \quad IC = 12.4 \pm 0.572 = [11.83; 12.97] \text{ min}$$

RESPOSTA [11.83; 12.97] min.

GL	4	9	29	∞
$t_{0.025}$	2.776	2.262	2.045	1.960

Com $n = 5$ o intervalo fica 42% mais largo que com z : é o preço de não conhecer σ .

Exercício 7.6 • IC com t de Student (σ desconhecido)

Um benchmark executado $n = 8$ vezes forneceu $\bar{x} = 11.1$ ms e $s = 3.6$ ms. Supondo população normal com σ desconhecido, qual a margem de erro do IC de 95% para μ ? (Use $t_{0.025; 7} = 2.365$.)

Espaço para cálculo

7.7 Intervalo de Confiança para a Variância

Em muitos sistemas, o requisito não é sobre a média, e sim sobre a variabilidade: o jitter de um enlace de voz, a variação do período de uma tarefa de tempo real, a dispersão do tempo de resposta. O intervalo sai da qui-quadrado da seção anterior, isolando σ^2 entre os dois percentis:

IC DE $100(1 - \alpha)\%$ PARA σ^2 (POPULAÇÃO NORMAL)

$$\left[\frac{(n-1)s^2}{\chi_{\alpha/2; n-1}^2}, \frac{(n-1)s^2}{\chi_{1-\alpha/2; n-1}^2} \right]$$

▼ Equação desmontada, variável por variável

$$\frac{(n-1)s^2}{\chi_{\alpha/2; n-1}^2} \leq \sigma^2 \leq \frac{(n-1)s^2}{\chi_{1-\alpha/2; n-1}^2}$$

σ^2

← o que se estima: variância da população

$(n-1)s^2$

← soma dos quadrados dos desvios da amostra (ex.: $9 \times 0.64 = 5.76$)

$\chi_{\alpha/2}^2$

← quantil grande (ex.: 19.023) → dá o limite **inferior**

$\chi_{1-\alpha/2}^2$

← quantil pequeno (ex.: 2.700) → dá o limite **superior**

$\chi_{\alpha/2}^2$ é o quantil que deixa $\alpha/2$ à *direita* (o maior). Ex.: $n = 10$ medições de jitter de um enlace, $s = 0.8$ ms, 95%, $gl = 9$: $\chi_{0.025}^2 = 19.023$ e $\chi_{0.975}^2 = 2.700$, logo $\sigma^2 \in [0.303; 2.133]$ e $\sigma \in [0.55; 1.46]$ ms. O intervalo **não** é simétrico em torno de s^2 .

INTUIÇÃO Por que o intervalo é assimétrico

Aqui σ^2 aparece num denominador: o intervalo é obtido dividindo $(n-1)s^2$ pelos dois percentis, e o *maior* percentil dá o limite *inferior*. A assimetria vem da qui-quadrado, que é assimétrica à direita: valores de s^2 muito abaixo de σ^2 são mais prováveis que valores muito acima, então o intervalo se estende mais para cima.

CUIDADO Variabilidade é muito mais difícil de medir que média

n	Precisão para σ (95%)
10	de 0.69 a 1.83 vezes o valor observado
cerca de 200	$\pm 10\%$

Isso tem consequência direta em monitoramento: limites de controle calculados com poucos dados são muito incertos, e a capacidade de um processo (C_p) calculada com 20 pontos pode estar errada por uma margem grande.

NA COMPUTAÇÃO Requisitos de teto

Quando o requisito é "o jitter não pode passar de 1 ms", a pergunta é unilateral, e o que importa é o limite superior do intervalo, não o s observado. Um $s = 0.8$ ms abaixo do teto, com $n = 10$, não demonstra nada, porque o limite superior é 1.46 ms. O teste correspondente é o teste qui-quadrado para a variância.

CONEXÕES

- 7.6** qui-quadrado.
- 8.7** teste para variância.
- 9.5** C_p com poucos dados.
- 9.9** fase I do CEP.

▼ Entendendo a fórmula, termo a termo

$$\frac{(n-1)s^2}{\chi_{\alpha/2; n-1}^2} \leq \sigma^2 \leq \frac{(n-1)s^2}{\chi_{1-\alpha/2; n-1}^2}$$

$$(n-1)s^2$$

← Soma dos quadrados dos desvios da amostra.

$$\chi_{\alpha/2}^2$$

← Quantil grande (deixa $\alpha/2$ à direita). Fica no limite **inferior**.

$$\chi_{1-\alpha/2}^2$$

← Quantil pequeno. Fica no limite **superior**.

De onde vem, passo a passo

$$1. P\left(\chi_{1-\alpha/2}^2 \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi_{\alpha/2}^2\right) = 1 - \alpha.$$

$$2. \text{ Inverta as frações (todos positivos): os sentidos das desigualdades se invertem, } \frac{1}{\chi_{\alpha/2}^2} \leq \frac{\sigma^2}{(n-1)S^2} \leq \frac{1}{\chi_{1-\alpha/2}^2}.$$

3. Multiplique por $(n-1)S^2$ e chegue ao intervalo. Para σ , tire a raiz dos dois limites.

4. Como a χ^2 é assimétrica, o intervalo não é simétrico em torno de s^2 .

EXEMPLO RESOLVIDO

Validando o jitter de um enlace

Uma aplicação de videoconferência exige que o atraso de um enlace tenha desvio padrão (jitter) $\sigma \leq 1$ ms. Dez medições deram $s = 0.8$ ms.

DADOS

- $n = 10, s = 0.8$ ms, $gl = 9$
- $\chi_{0.025;9}^2 = 19.023, \chi_{0.975;9}^2 = 2.700$

O QUE SE PEDE

IC 95% para σ e a decisão.

RESOLUÇÃO PASSO A PASSO

1 Fórmula do IC da variância

$$\frac{(n-1)s^2}{\chi_{\alpha/2}^2} \leq \sigma^2 \leq \frac{(n-1)s^2}{\chi_{1-\alpha/2}^2}$$

O maior qui-quadrado dá o limite *inferior*.

2 Substituir

$$(n-1)s^2 = 9 \times 0.64 = 5.76$$

$$\sigma^2 \in \left[\frac{5.76}{19.023}; \frac{5.76}{2.700} \right] = [0.303; 2.133]$$

3 Tirar a raiz

$$\sigma \in [0.55; 1.46] \text{ ms}$$

4 Decidir

O intervalo inclui valores acima de 1, então os dados **não garantem** o requisito.

RESPOSTA $\sigma \in [0.55; 1.46]$ ms: requisito não comprovado.

O intervalo é assimétrico em torno de 0.8 e muito largo com $n = 10$. São necessárias mais medições para estreitá-lo: o $s = 0.8$ observado, sozinho, não prova nada.

Exercício 7.7 • Limite Superior do IC para a Variância

Uma amostra de $n = 25$ medições do atraso de um enlace (população normal) deu $s = 0.4$ ms. Calcule o limite superior do IC de 95% para σ^2 . (Dados: $\chi_{0.975;24}^2 = 12.401$ e $\chi_{0.025;24}^2 = 39.364$.)

Espaço para cálculo

7.8 Tamanho de Amostra para Proporção

O caso 3 de 7.4 tem margem $z\sqrt{p(1-p)/n}$. Exigindo que essa margem seja no máximo E e isolando n :

MARGEM E PARA p

$$n = \frac{z_{\alpha/2}^2 \hat{p}(1 - \hat{p})}{E^2}$$

▼ Equação desmontada, variável por variável

$$n = \frac{z_{\alpha/2}^2 \hat{p}(1 - \hat{p})}{E^2}$$

n

← o que se calcula: tamanho mínimo da amostra

$z_{\alpha/2}^2$

← valor da normal ao quadrado (ex.: $1.96^2 = 3.84$)

$\hat{p}(1 - \hat{p})$

← variabilidade da proporção; no máximo 0.25 (com $\hat{p} = 0.5$)

E^2

← margem ao quadrado (ex.: $0.03^2 = 0.0009$)

Sem estimativa prévia, use $\hat{p} = 0.5$, que maximiza $\hat{p}(1 - \hat{p})$ e garante a margem no pior caso. Ex.: $E = 0.03$, 95%: $n = 1.96^2 \times 0.25 / 0.0009 = 1067.1$, logo $n = 1068$.

O pior caso $p = 0.5$ é o ponto de variância máxima da Bernoulli. Os fatores que mudam o n necessário são poucos, e um deles surpreende:

INTUIÇÃO O que muda o tamanho da amostra

Fator	Efeito
estimativa prévia longe de 0.5	com $p \approx 0.1$, $p(1 - p) = 0.09$ em vez de 0.25: a amostra cai para 36% do pior caso
margem de 3 para 1 ponto	amostra multiplicada por 9, porque n cresce com $1/E^2$
proporção muito pequena	margem absoluta não serve (± 1 ponto numa taxa de 0.5%); fixa-se margem relativa ($\pm 20\%$ do valor), e n fica proporcional a $1/p$, como a regra de $3/p$
detectar uma diferença com chance alta	acrescenta o termo do poder (z_β)
tamanho da população	quase nada: só a correção de população finita muda, e pouco

EXEMPLO Testes A/B com taxas pequenas

Testes A/B que querem detectar diferenças de 0.1 ponto percentual em taxas de conversão de 2% precisam de centenas de milhares de usuários por variante.

NA COMPUTAÇÃO Telemetria amostrada

Como o erro padrão depende de n e não da fração n/N , para estimar a fração de usuários numa versão do app alguns milhares de dispositivos sorteados dão margem de 1 a 2 pontos, seja a base de 10 mil ou de 10 milhões. Isso reduz custo de armazenamento e expõe menos dados pessoais. A condição, de novo, é que a amostra seja aleatória.

CONEXÕES

3.2 variância da Bernoulli.

3.6 regra de $3/p$.

7.1 amostra aleatória.

7.2 população finita.

8.9 poder.

▼ Entendendo a fórmula, termo a termo

$$E = z_{\alpha/2} \sqrt{\frac{\hat{p}(1 - \hat{p})}{n}} \iff n = \frac{z_{\alpha/2}^2 \hat{p}(1 - \hat{p})}{E^2}$$

 $\hat{p}(1 - \hat{p})$

← Variância de uma única observação 0/1 (Bernoulli).

 $/n$

← Variância da proporção amostral, que é uma média de 0s e 1s.

 E^2 ← Exigir metade da margem quadruplica n .

De onde vem, passo a passo

1. Iguale a margem desejada à fórmula de E .
2. Eleve ao quadrado: $E^2 = z^2 \frac{\hat{p}(1 - \hat{p})}{n}$.
3. Isole n : $n = \frac{z^2 \hat{p}(1 - \hat{p})}{E^2}$.
4. Pior caso: $g(p) = p(1 - p)$ tem derivada $1 - 2p = 0$ em $p = 0.5$, onde vale 0.25 (máximo).

EXEMPLO RESOLVIDO

O valor de um estudo piloto

Quer-se estimar a fração de usuários que ainda usam uma versão antiga do app, com margem de 3 pontos percentuais e 95% de confiança, coletando telemetria de uma amostra.

DADOS

- $E = 0.03$, $z = 1.96$
- piloto: $\hat{p} \approx 0.10$

O QUE SE PEDE

Tamanho de amostra com e sem o piloto.

RESOLUÇÃO PASSO A PASSO

1 Fórmula

Isolando n em $E = z \sqrt{p(1 - p)/n}$:

$$n = \frac{z^2 p(1 - p)}{E^2}$$

2 Sem informação: pior caso $p = 0.5$

$p(1 - p)$ é máximo em 0.5:

$$n = \frac{1.96^2 \times 0.25}{0.03^2} = 1067.1 \Rightarrow 1068$$

3 Com o piloto

$$n = \frac{1.96^2 \times 0.10 \times 0.90}{0.03^2} = 384.2 \Rightarrow 385$$

Sempre arredonde *para cima*, para garantir a margem.

RESPOSTA 1068 sem piloto; 385 com piloto.

Um piloto barato pode reduzir a amostra principal em quase dois terços, o que, em telemetria, significa coletar dados de menos dispositivos.

Exercício 7.8 • Tamanho de Amostra para Proporção

Deseja-se estimar a fração de usuários que clicam num novo botão com 99% de confiança e margem de erro de 3 pontos percentuais. Um estudo piloto indicou $\hat{p} \approx 0.3$. Qual o tamanho mínimo da amostra?

Espaço para cálculo

Exercícios de Fixação com Soluções Comentadas

3 Questões Resolvidas

Exercício 7.1: Aplicação do Teorema Central do Limite

O tempo de atendimento em um help-desk segue uma distribuição qualquer com média $\mu = 12$ minutos e desvio padrão $\sigma = 4$ minutos. Uma amostra de $n = 64$ chamados é observada. Qual é a probabilidade de a média amostral $\bar{X}$ ser inferior a 11.25 minutos? (Dado: $\Phi(-1.50) = 0.0668$).

Espaço para cálculo

Exercício 7.2: IC para a Vida Média de SSDs com σ Conhecido

Para avaliar a vida útil de um modelo de SSD em regime de escrita intensa, com desvio padrão conhecido $\sigma = 200$ horas, uma amostra aleatória de $n = 100$ unidades revelou média de $\bar{x} = 5000$ horas. Construa o Intervalo de Confiança de 95% para a verdadeira vida média μ (adote $z_{0.025} = 1.96$).

Espaço para cálculo

Exercício 7.3: Dimensionamento do Tamanho Amostral Mínimo

Uma equipe de infraestrutura deseja estimar o tempo médio de boot de máquinas virtuais com nível de confiança de 99% ($z = 2.576$) e erro máximo de $E = 0.02$ s. Medições preliminares apontam desvio padrão $\sigma = 0.10$ s. Quantas VMs devem ser medidas no mínimo?

Espaço para cálculo

Módulo 8: Testes de Hipótese

Testes de hipóteses para decisões em software: testes A/B, regressão de desempenho, SLAs de erro e latência, falsos positivos e negativos em alertas e classificadores, p-valor e suas armadilhas (peeking, comparações múltiplas), Welch e testes pareados, qui-quadrado para geradores aleatórios e balanceamento, poder e tamanho de amostra.

O Módulo 7 respondeu "quanto vale o parâmetro, e com que incerteza?". Este módulo responde uma pergunta de outro tipo: "os dados são compatíveis com esta afirmação?". A nova versão deixou o sistema mais lento? O provedor está violando o SLA? O gerador de números é uniforme? Em todas, há uma decisão binária a tomar com dados ruidosos, e por isso dois tipos de erro possíveis. As peças técnicas já estão prontas: a estatística de teste é a padronização aplicada a um estimador, sua distribuição vem do TCL ou dos resultados exatos da t e da qui-quadrado, e a estrutura de erros é a mesma do detector de intrusão do Módulo 1. O que é novo é a lógica da decisão e as armadilhas de interpretação, que são onde a maioria dos erros reais acontece.

8.1 Lógica dos Testes de Hipóteses

O teste de hipóteses é um procedimento de decisão baseado em evidência amostral. "A nova versão deixou o sistema mais lento?", "o novo botão aumentou a conversão?", "este gerador de números é realmente uniforme?" são perguntas de teste de hipóteses. Confrontam-se duas hipóteses mutuamente exclusivas:

- **Hipótese Nula (H_0):** a proposição de nenhum efeito, igualdade ou conformidade ($=$, $\leq$ ou $\geq$). Presumida verdadeira até prova em contrário (presunção de inocência).
- **Hipótese Alternativa (H_1 ou H_a):** a alegação de mudança ou efeito real ($\neq$, $>$ ou $<$), que é o que se quer demonstrar.

INTUIÇÃO Prova por contradição, em versão probabilística

Numa prova por contradição, supõe-se uma afirmação, deduz-se algo impossível e conclui-se que a afirmação era falsa. Aqui, supõe-se H_0 , calcula-se quão *improváveis* seriam os dados observados nesse mundo e, se forem improváveis demais, abandona-se H_0 . A diferença é que "improvável" não é "impossível", e por isso a conclusão vem com uma taxa de erro controlada.

A assimetria entre as hipóteses é deliberada. H_0 precisa ser específica o bastante para que se possa calcular a distribuição da estatística supondo-a verdadeira: " $\mu = 200$ ms" permite calcular, " $\mu \neq 200$ ms" não. Por isso a igualdade fica sempre em H_0 , e o que se quer demonstrar vai para H_1 . A consequência é que os dois desfechos não são simétricos: rejeitar H_0 é uma conclusão ("há evidência de que a latência mudou"); não rejeitar é só ausência de evidência, como um réu absolvido por falta de provas não é declarado inocente.

NA COMPUTAÇÃO Teste A/B

1. Usuários são sorteados para a versão A (controle) ou B (nova).
2. H_0 : as duas têm a mesma taxa de conversão (ou latência, ou retenção).
3. O sorteio garante que os grupos são comparáveis em tudo o mais (plataforma, região, horário), eliminando o paradoxo de Simpson; sob H_0 , qualquer diferença observada é acaso.
4. O teste mede se a diferença é grande demais para ser acaso.

Sem sorteio, como ao comparar a semana antes e depois de um deploy, qualquer outra mudança no período (uma campanha de marketing, um feriado) se confunde com o efeito da versão.

CUIDADO H_1 é escolhida antes de ver os dados

Pergunta	H_1
"a versão nova ficou <i>mais lenta</i> ?"	unilateral
"a versão nova <i>mudou</i> a taxa de erro?"	bilateral

Decidir se o teste é unilateral ou bilateral depois de olhar os números, escolhendo a forma que dá significância, dobra na prática o nível de erro declarado.

CONEXÕES

- 1.9 paradoxo de Simpson.
- 3.6 não observar não é provar.
- 8.2 taxas de erro.
- 8.6 unilateral e bilateral.

▼ Entendendo a fórmula, termo a termo

$$\text{Estatística de teste} = \frac{\text{estimativa} - \text{valor sob } H_0}{\text{erro padrão}}$$

Numerador	← O "sinal": quanto os dados se afastam do que H_0 afirma.
Denominador	← O "ruído": quanto esse afastamento varia só por acaso.
Razão	← Quantos erros padrão de distância. Valores grandes são improváveis se H_0 for verdadeira.

De onde vem, passo a passo

1. H_0 especifica um valor do parâmetro; assim a distribuição da estatística fica conhecida ($N(0, 1)$, t ou χ^2).
2. Calcule a estatística com os dados.
3. Se ela cair numa região que só teria probabilidade α sob H_0 , conclui-se que H_0 é pouco compatível com os dados.
4. É uma prova por "quase absurdo": supõe-se H_0 e mostra-se que os dados seriam muito raros.

EXEMPLO RESOLVIDO Montando as hipóteses

Um provedor de armazenamento em nuvem garante vazão média de leitura de 500 MB/s; o cliente desconfia que é menor.

O QUE SE PEDE

H_0 e H_1 , e o que cada decisão significa.

RESOLUÇÃO PASSO A PASSO

1 Identificar a alegação

O valor de referência é 500 MB/s. A desconfiança (o que se quer provar) é "menor que 500".

2 H_0 fica com a igualdade

H_0 é a alegação aceita até prova em contrário, como a presunção de inocência: $H_0 : \mu = 500$.

3 H_1 fica com o que se quer provar

$H_1 : \mu < 500$ (unilateral à esquerda). O ônus da prova está em H_1 .

4 Ler as decisões

- Rejeitar H_0 : há evidência de que a vazão é menor (base para cobrar o SLA).
- Não rejeitar H_0 : a evidência não basta. Isso **não prova** que $\mu = 500$.

RESPOSTA $H_0 : \mu = 500$ contra $H_1 : \mu < 500$.

Exercício 8.1 • Formulação das Hipóteses

Qual par de hipóteses é adequado?

O tamanho médio esperado das respostas é 48 KB; deseja-se saber se uma mudança no serializador **alterou** esse tamanho (em qualquer sentido).

Espaço para cálculo

☐ $H_0 : \mu \neq 48$ vs $H_1 : \mu = 48$

☐ $H_0 : \mu = 48$ vs $H_1 : \mu > 48$

☐ $H_0 : \mu = 48$ vs $H_1 : \mu \neq 48$

☐ $H_0 : \mu = 48$ vs $H_1 : \mu < 48$

8.2 Matriz de Decisão e Erros Tipo I e Tipo II

Como a decisão é tomada com dados ruidosos, ela pode errar de duas formas, e cruzar a decisão com a realidade dá uma tabela de contingência:

DECISÃO ESTATÍSTICA	H_0 É VERDADEIRA NA REALIDADE	H_0 É FALSA NA REALIDADE
Rejeitar H_0	Erro Tipo I (α) (Falso Positivo / Alarme falso)	Decisão Correta (Poder do Teste: $1 - \beta$)
Não Rejeitar H_0	Decisão Correta (Nível de Confiança: $1 - \alpha$)	Erro Tipo II (β) (Falso Negativo / Problema não detectado)

As duas taxas de erro são probabilidades condicionais, e com condições diferentes: $\alpha = P(\text{rejeitar} \mid H_0 \text{ verdadeira})$ e $\beta = P(\text{não rejeitar} \mid H_0 \text{ falsa})$. O teste controla α diretamente, ao escolher o valor crítico; β depende de quão falsa H_0 é, de n e de σ . Para um n fixo, as duas competem: tornar o teste mais exigente faz deixar passar mais efeitos reais.

INTUIÇÃO A mesma matriz em todo classificador

A matriz é a mesma do detector de intrusão e de todo classificador binário: α é a taxa de falso positivo, $1 - \beta$ é a sensibilidade (recall), e variar o limiar de decisão de um classificador traça a curva ROC, o conjunto de pares $(\alpha, 1 - \beta)$ possíveis.

EXEMPLO α não é a fração de resultados falsos

Se só 10% das mudanças testadas têm efeito real, com $\alpha = 5\%$ e poder de 80%, entre 1000 testes há 900 nulos que geram 45 falsos positivos e 100 reais que geram 80 verdadeiros: $45/125 = 36\%$ dos resultados "significativos" são falsos. É a falácia da taxa-base aplicada à pesquisa, e explica por que tantos resultados publicados não se reproduzem.

NA COMPUTAÇÃO O custo decide o equilíbrio

Contexto	Erro mais caro	Consequência
detector de fraude	falso negativo (fraude não detectada)	aceitam-se mais falsos positivos
alerta que acorda o plantonista às 3 h	falso positivo (fadiga)	α pequeno
CI que compara o tempo de cada commit a 5%	falso positivo	um alarme falso a cada 20 commits sem mudança real; com centenas de commits por dia, isso inunda a equipe, e as ferramentas usam α menor, repetições e confirmação
gráfico de controle	equilíbrio	3σ , ou $\alpha = 0.27\%$ por ponto

5% é convenção, não lei.

CONEXÕES

- 1.6** detector de intrusão e taxa-base.
- 1.9** matriz de confusão.
- 8.9** poder.
- 9.2** escolha de 3σ .

▼ Entendendo a fórmula, termo a termo

$$\beta = \Phi \left(z_{\alpha} - \frac{(\mu_1 - \mu_0)\sqrt{n}}{\sigma} \right)$$

 z_{α} ← Posição do valor crítico, em erros padrão a partir de μ_0 . $\frac{(\mu_1 - \mu_0)\sqrt{n}}{\sigma}$

← Tamanho do desvio real medido em erros padrão: quanto maior, mais fácil detectar.

 β ← Área da distribuição real (centrada em μ_1) que ainda cai na região de não rejeição.

De onde vem, passo a passo

1. Unilateral ($H_1 : \mu > \mu_0$): rejeita-se se $\bar{X} > c = \mu_0 + z_{\alpha}\sigma/\sqrt{n}$.
2. Se a verdade for μ_1 : $\beta = P(\bar{X} \leq c \mid \mu_1) = \Phi \left(\frac{c - \mu_1}{\sigma/\sqrt{n}} \right)$.
3. Substituindo c : $\frac{c - \mu_1}{\sigma/\sqrt{n}} = z_{\alpha} - \frac{(\mu_1 - \mu_0)\sqrt{n}}{\sigma}$.
4. Leitura: aumentar n , aumentar $\mu_1 - \mu_0$ ou diminuir σ empurra o argumento para baixo e reduz β .

EXEMPLO RESOLVIDO Calculando β de verdade

Um teste de regressão de desempenho compara a latência média de um endpoint com o valor de referência de 100 ms, com σ conhecido. Se um commit piorou a latência para 105 ms, qual a chance de o teste detectar?

DADOS

- $H_0 : \mu = 100, H_1 : \mu > 100$
- $\sigma = 10, n = 25, \alpha = 0.05$

O QUE SE PEDE

β e o poder quando $\mu = 105$.

RESOLUÇÃO PASSO A PASSO

1 Erro padrão

$$\sigma_{\bar{X}} = \frac{10}{\sqrt{25}} = 2$$

2 Região de rejeição em unidades de $\bar{x}$

Rejeita-se se $z > 1.645$, ou seja, se

$$\bar{x} > 100 + 1.645 \times 2 = 103.29$$

3 β : não rejeitar quando $\mu = 105$

Agora a distribuição de $\bar{X}$ é centrada em 105:

$$\beta = P(\bar{X} \leq 103.29 \mid \mu = 105) = \Phi\left(\frac{103.29 - 105}{2}\right) = \Phi(-0.855) = 0.196$$

4 Poder

$$1 - \beta = 1 - 0.196 = 0.804$$

RESPOSTA $\beta = 0.196$; poder = 0.804.

Analogia: um alerta de monitoramento com H_0 = "o sistema está saudável". Erro Tipo I é acordar o plantonista sem motivo; Erro Tipo II é não alertar durante uma pane real. Em segurança, aceita-se α maior para reduzir β .

Exercício 8.2 • Erros Tipo I e Tipo II

Considere H_0 : "o sistema está normal (nada mudou)". Classifique a situação: **O deploy não mudou a latência e o teste não acusou nada.**

Espaço para cálculo

- ☐ Decisão correta (poder do teste)
- ☐ Erro Tipo I
- ☐ Erro Tipo II
- ☐ Decisão correta (nível de confiança)

8.3 Regra de Decisão pelo p-valor (Nível Descritivo)

Em vez de só dizer "rejeita" ou "não rejeita" a um nível fixo, pode-se informar quão extremo foi o resultado. O **p-valor** é a probabilidade de obter uma estatística de teste tão ou mais extrema que a observada, *supondo H_0 verdadeira*:

REGRA DE OURO DA DECISÃO

Se $p\text{-valor} \leq \alpha \implies$ Rejeita-se H_0 (Resultado estatisticamente significativo)

Se $p\text{-valor} > \alpha \implies$ Não se rejeita H_0 (Evidência insuficiente)

▼ Equação desmontada, variável por variável

$$p\text{-valor} \leq \alpha \implies \text{rejeita } H_0$$

$p\text{-valor}$	← chance de um resultado tão extremo se H_0 fosse verdadeira (ex.: 0.023)
α	← nível de significância escolhido (ex.: 0.05)
H_0	← hipótese nula (ex.: $\mu = 220$ ms)
$\leq$	← se o p-valor for menor ou igual, os dados contradizem H_0

A regra é equivalente a comparar a estatística com o valor crítico: o p-valor é menor que α exatamente quando a estatística cai além do crítico. A vantagem é que o p-valor serve para qualquer α : quem lê o resultado pode aplicar seu próprio nível de exigência. Ele é uma área de cauda, calculada pela FDA.

CUIDADO Três leituras erradas do p-valor

Leitura errada	Por que está errada
"p = 0.03: 97% de chance de B ser melhor"	o p-valor é $P(\text{dados tão extremos} \mid H_0)$, não $P(H_0 \mid \text{dados})$: confundir as duas é a falácia da condicional transposta, e passar de uma à outra exige Bayes e uma priori
"p minúsculo: efeito importante"	o p-valor depende do efeito e e de n ; com milhões de requisições, uma diferença de 0.1 ms dá p minúsculo e não importa para ninguém. Reporte o tamanho do efeito com seu intervalo de confiança
"p > 0.05: não há efeito"	pode ser só falta de dados (poder baixo)

Duas práticas comuns invalidam o α declarado, e ambas são casos do "pelo menos um": cada oportunidade a mais de rejeitar é uma nova chance de falso positivo.

CUIDADO Espiar e comparar demais

	Espiar (peeking)	Comparações múltiplas
O que é	olhar o p-valor de um teste A/B todo dia e parar quando ficar abaixo de 0.05	testar 20 métricas a 5%
Efeito	com espiadas frequentes, a taxa real de falso positivo pode passar de 30%	chance de pelo menos uma "significativa" por acaso: $1 - 0.95^{20} = 64\%$
Remédio	fixar o tamanho da amostra antes, ou usar métodos sequenciais desenhados para análise contínua	Bonferroni (α/k , pelo limitante da união) ou Benjamini-Hochberg, que controla a fração de falsas descobertas e é usado em plataformas de experimentação e análises genômicas

CONEXÕES

- 1.3** condicional transposta.
- 1.2** limitante da união.
- 3.6** "pelo menos um".
- 7.4** tamanho do efeito com IC.
- 8.6** p-valor por tipo de H_1 .
- 8.9** fixar n antes.

▼ Entendendo a fórmula, termo a termo

$$p\text{-valor} = P(\text{estatística tão ou mais extrema que a observada} \mid H_0)$$

"Tão ou mais extrema" ← Na direção de H_1 (uma ou as duas caudas).

$\mid H_0$ ← Calculado supondo H_0 verdadeira.

Regra ← Rejeitar H_0 se $p \leq \alpha$.

De onde vem, passo a passo

1. O valor crítico deixa área α na cauda; o p-valor é a área além do valor observado.
2. Se o observado está além do crítico, a área além dele é menor que α , e vice-versa.
3. Logo "estatística na região crítica" $\iff$ " $p \leq \alpha$ ": as duas regras dão sempre a mesma decisão.

EXEMPLO RESOLVIDO Um p-valor, várias decisões

Um teste A/B da latência de duas versões resultou em p-valor = 0.03.

O QUE SE PEDE

Decisão para $\alpha = 0.05$ e $\alpha = 0.01$, e a interpretação correta.

RESOLUÇÃO PASSO A PASSO

1

Regra

Rejeita-se H_0 quando p-valor $\leq \alpha$.

2

$\alpha = 0.05$

$0.03 \leq 0.05$: rejeita-se H_0 .

3

$\alpha = 0.01$

$0.03 > 0.01$: não se rejeita.

4 Interpretar

Correto: se H_0 fosse verdadeira, resultados tão extremos ocorreriam em 3% das amostras.

Errado: "há 3% de chance de H_0 ser verdadeira".

O p-valor informa a decisão para *qualquer* α , por isso é preferível relatá-lo em vez de só "rejeitado". E ele não diz o tamanho da diferença: relate também o intervalo de confiança.

Exercício 8.3 • Decisão pelo p-valor

Um teste com $\alpha = 0.1$ resultou em p-valor = 0.08. Qual a decisão e qual erro se pode estar cometendo?

Espaço para cálculo

- ☐ Rejeitar H_0 ; risco de Erro Tipo II.
- ☐ Não rejeitar H_0 ; risco de Erro Tipo I.
- ☐ Não rejeitar H_0 ; risco de Erro Tipo II.
- ☐ Rejeitar H_0 ; risco de Erro Tipo I.

8.4 Testes Paramétricos para a Média

Para testar uma afirmação sobre a média, mede-se a distância entre a estimativa e o valor de H_0 em unidades de erro padrão. Se H_0 for verdadeira, essa distância padronizada segue uma distribuição conhecida, e valores muito grandes são improváveis:

ESTATÍSTICAS DE TESTE

Teste Z (σ conhecido): $z_{\text{calc}} = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$

Teste t de Student (σ desconhecido): $t_{\text{calc}} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}, \quad gl = n - 1$

▼ Equação desmontada, variável por variável

$$z_{\text{calc}} = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$$

 z_{calc}

← o que se calcula: distância em erros padrão

 $\bar{x}$

← média observada (ex.: 1008 ms)

 μ_0 ← média afirmada por H_0 (ex.: 1000 ms) $\bar{x} - \mu_0$

← diferença observada (ex.: 8 ms)

 $\sigma/\sqrt{n}$ ← erro padrão com σ conhecido (ex.: $20/5 = 4$ ms); resultado $z = 2$

$$t_{\text{calc}} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}, \quad gl = n - 1$$

 s ← desvio padrão da amostra, quando σ é desconhecido gl ← graus de liberdade para consultar a tabela t

As duas fórmulas são o z-score aplicado a $\bar{X}$, que tem média μ_0 (se H_0 for verdadeira) e desvio $\sigma/\sqrt{n}$. Pelo TCL, z_{calc} é aproximadamente $N(0, 1)$ sob H_0 ; com σ estimado por s e dados normais, t_{calc} segue exatamente a t_{n-1} .

INTUIÇÃO Distância em unidades de incerteza

A estrutura "(estimativa – valor sob H_0) / erro padrão" é a de quase toda estatística de teste. Ela explica por que uma diferença de 5 ms pode ser enorme ou irrelevante: depende de o erro padrão ser 1 ms ou 20 ms.

Na prática, o caso mais comum não compara uma média com um valor fixo, e sim duas versões entre si:

NA COMPUTAÇÃO Comparando duas versões: Welch ou pareado

	Welch (amostras independentes)	Pareado (mesmas entradas)
Estatística	$t = \frac{\bar{x}_A - \bar{x}_B}{\sqrt{s_A^2/n_A + s_B^2/n_B}}$	teste t sobre as diferenças $d_i = x_{A,i} - x_{B,i}$
Variância da diferença	soma das variâncias	$Var(X_A) + Var(X_B) - 2Cov$: muito menor, porque os tempos das duas versões na mesma entrada são fortemente correlacionados
Quando usar	padrão recomendado; não supõe variâncias iguais	mesmo benchmark, mesma máquina, mesma entrada: elimina a variação entre entradas, que costuma ser a maior fonte de ruído

CUIDADO Quando a normalidade falha

Os testes t supõem normalidade, ou n grande o bastante para o TCL agir. Para latências muito assimétricas com amostras pequenas, há alternativas que não dependem da forma:

- **Mann-Whitney:** compara postos em vez de valores; é para o teste t o que a mediana é para a média, robusto a outliers.
- **Teste de permutação:** embaralha os rótulos A e B milhares de vezes e verifica quão extrema é a diferença observada entre todas as diferenças possíveis; se H_0 é verdadeira, os rótulos são intercambiáveis. É a mesma ideia do bootstrap e se implementa em poucas linhas.

CONEXÕES

- 5.3 z-score.
- 5.7 variância da diferença.
- 2.7 covariância a favor no pareado.
- 7.3 TCL.
- 7.6 distribuição t .
- 7.1 bootstrap.

▼ Entendendo a fórmula, termo a termo

$$z_{calc} = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}, \quad t_{calc} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$$

$\bar{x} - \mu_0$ ← Distância entre o observado e o valor de H_0 .

$\sigma/\sqrt{n}$ ou $s/\sqrt{n}$ ← Erro padrão da média: conhecido (z) ou estimado (t).

Sinal ← Positivo se a amostra está acima de μ_0 ; importa nos testes unilaterais.

De onde vem, passo a passo

1. 1) Hipóteses: $H_0 : \mu = \mu_0$ e H_1 conforme a pergunta.
2. 2) Fixe α .
3. 3) Calcule a estatística (z se σ conhecido; t com $n - 1$ gl se não).
4. 4) Compare com o crítico da cauda certa (ou calcule o p-valor).
5. 5) Conclua no contexto: "há/não há evidência de que ...".

EXEMPLO RESOLVIDO Teste t completo, unilateral

Um contrato exige vazão média de 50 Mbps num enlace. Há evidência de vazão menor?

DADOS

- $n = 12$ medições, $\bar{x} = 49.2$ Mbps, $s = 1.5$ Mbps

- $\alpha = 0.05$

O QUE SE PEDE

Teste de hipótese completo.

RESOLUÇÃO PASSO A PASSO

1 Hipóteses

$H_0 : \mu = 50$ contra $H_1 : \mu < 50$ (o que se quer provar é "menor").

2 Escolher a estatística

σ desconhecido e amostra pequena: teste t com $gl = n - 1 = 11$.

3 Calcular

$$t_{calc} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}} = \frac{49.2 - 50}{1.5/\sqrt{12}} = \frac{-0.8}{0.433} = -1.848$$

4 Valor crítico

Unilateral à esquerda: $-t_{0.05; 11} = -1.796$.

5 Decidir

$-1.848 < -1.796$: cai na região de rejeição. Rejeita-se H_0 .

RESPOSTA Há evidência, a 5%, de que a vazão média está abaixo de 50 Mbps.

Num teste bilateral (crítico ± 2.201) a conclusão seria a oposta. Por isso o tipo de H_1 deve ser escolhido antes de ver os dados.

Exercício 8.4 • Teste Z para a Média

A temperatura média de uma CPU sob a carga de referência deveria ser $\mu_0 = 200$ °C, com $\sigma = 6$ °C conhecido. Depois de uma atualização do firmware, 16 leituras do sensor deram $\bar{x} = 202.25$ °C. Calcule z_{calc} para $H_1 : \mu \neq 200$.

Espaço para cálculo

8.5 Teste Qui-Quadrado (χ^2) de Aderência

Os testes de média perguntam sobre um parâmetro. Muitas vezes a pergunta é sobre a distribuição inteira: os dígitos de um gerador são uniformes? As requisições se distribuem igualmente entre os servidores? Os crashes por dia seguem uma Poisson? O teste de aderência compara as frequências observadas (O_i) em k categorias com as esperadas por uma distribuição teórica (E_i):

ESTATÍSTICA DO TESTE QUI-QUADRADO

$$\chi^2_{calc} = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}, \quad gl = k - 1 - m$$

onde m é o número de parâmetros estimados da distribuição teórica.

▼ Equação desmontada, variável por variável

$$\chi^2_{calc} = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}, \quad gl = k - 1 - m$$

 O_i ← contagem observada na categoria i (ex.: 18) E_i

← contagem esperada pelo modelo (ex.: 25)

 $(O_i - E_i)^2$

← diferença ao quadrado (ex.: 49)

 $\div E_i$ ← relativiza pelo tamanho esperado (ex.: $49/25 = 1.96$) k

← número de categorias

 m

← parâmetros estimados dos dados (0 se o modelo é dado pronto)

DEDUÇÃO Por que essa estatística

1. A contagem O_i numa categoria é aproximadamente Poisson com média E_i , portanto com variância E_i .
2. O termo $(O_i - E_i)/\sqrt{E_i}$ é um z-score, aproximadamente normal para E_i grande.
3. Somar quadrados de normais dá uma qui-quadrado. Como as contagens somam N , sabendo $k - 1$ delas a última está determinada: $k - 1$ graus de liberdade.

Valores grandes de χ^2 indicam desvios maiores do que o acaso explica, e o teste é sempre unilateral à direita. A aproximação exige $E_i \geq 5$ em cada categoria; com contagens menores, juntam-se categorias ou usam-se testes exatos.

NA COMPUTAÇÃO Geradores, balanceadores e hashes

- **Geradores aleatórios:** para checar se um gerador produz inteiros uniformes de 0 a 9, contam-se as ocorrências de cada dígito em N sorteios e compara-se com $N/10$. Baterias como Diehard, TestU01 e NIST SP 800-22 aplicam dezenas de testes desse tipo (frequência, sequências, lacunas) a geradores usados em criptografia e simulação. O viés do `rand() % n` é detectável assim com amostras grandes o bastante.
- **Balanceamento e hashing:** o mesmo teste verifica se um balanceador distribui requisições uniformemente entre servidores, ou se uma função de hash espalha chaves uniformemente pelos buckets.

A versão para tabelas de contingência testa a independência de duas variáveis categóricas, e responde à pergunta deixada em aberto no Módulo 1. Sob independência, a frequência esperada de cada célula é $E_{ij} = \frac{\text{total da linha} \times \text{total da coluna}}{N}$, que é $N \cdot P(\text{linha})P(\text{coluna})$, a regra do produto. Os graus de liberdade são $(r - 1)(c - 1)$.

EXEMPLO De volta à tabela das versões do app

Na tabela de versões do app de 1.9, a célula (v2, Erro) tinha 40 observados contra 28 esperados sob independência. O teste qui-quadrado decide se essa diferença, junto com as das outras células, é grande demais para ser acaso.

CONEXÕES

- 1.4 regra do produto.
- 1.9 tabela de contingência.
- 3.1 viés do módulo.
- 7.6 qui-quadrado.
- 8.10 parâmetros estimados.

▼ Entendendo a fórmula, termo a termo

$$\chi^2 = \sum_{i=1}^k \frac{(O_i - E_i)^2}{E_i}, \quad gl = k - 1 - m$$

$O_i - E_i$ ← Diferença entre o que se observou e o que o modelo prevê.

$(\cdot)^2$ ← Diferenças para cima e para baixo contam igual.

$\div E_i$ ← Escala: uma diferença de 5 é grande se se esperavam 10, e irrelevante se se esperavam 1000. Contagens têm variância $\approx E_i$ (Poisson).

gl ← Classes livres: -1 porque o total é fixo; $-m$ por parâmetro estimado.

De onde vem, passo a passo

1. Calcule $E_i = n \times P_i$ (probabilidade da classe pelo modelo).
2. Cada termo $\frac{(O_i - E_i)^2}{E_i}$ é o quadrado de um desvio padronizado $(\frac{O_i - E_i}{\sqrt{E_i}})$.
3. A soma de quadrados de desvios padronizados segue aproximadamente uma χ^2 , desde que todos os $E_i \geq 5$.
4. Sob H_0 , o valor esperado da estatística é gl ; valores muito acima disso indicam mau ajuste.

EXEMPLO RESOLVIDO

Aderência a proporções não uniformes

Historicamente, os erros de uma API se dividem em 50% timeout, 30% autenticação e 20% validação. O perfil mudou no último mês, depois de uma migração?

DADOS

- observados (200 erros): timeout 90, autenticação 70, validação 40
- $\alpha = 0.05$

O QUE SE PEDE

Teste qui-quadrado de aderência.

RESOLUÇÃO PASSO A PASSO

1 Hipóteses

H_0 : as proporções continuam 50/30/20. H_1 : mudaram.

2 Esperados sob H_0

$$E_i = n p_i : \quad 200(0.5) = 100, \quad 200(0.3) = 60, \quad 200(0.2) = 40$$

Todos ≥ 5 ✓.

3 Estatística

$$\chi^2_{calc} = \sum \frac{(O_i - E_i)^2}{E_i} = \frac{(90 - 100)^2}{100} + \frac{(70 - 60)^2}{60} + \frac{(40 - 40)^2}{40} = 1 + 1.667 + 0 =$$

4 Graus de liberdade e crítico

$gl = k - 1 = 3 - 1 = 2$. Tabela: $\chi^2_{0.05; 2} = 5.991$.

5 Decidir

$2.667 < 5.991$: não se rejeita H_0 .

RESPOSTA

O perfil de erros não mudou significativamente.

Exercício 8.5 • Qui-Quadrado de Aderência

Um dado foi lançado 180 vezes; frequências das faces 1 a 6: 37, 32, 40, 30, 26, 15. Calcule χ^2_{calc} para testar se é honesto.

Espaço para cálculo

8.6 Regiões Críticas e p-valor por Tipo de Hipótese

A forma de H_1 decide onde ficam os valores "extremos" da estatística. Se H_1 é "a latência mudou", valores muito altos e muito baixos contam contra H_0 , e o α se divide entre as duas caudas. Se H_1 é "a latência aumentou", só valores altos contam, e o α inteiro vai para uma cauda:

H_1	REJEITAR H_0 SE (TESTE Z)	P-VALOR
$\mu \neq \mu_0$	$ z_{calc} > z_{\alpha/2}$	$2[1 - \Phi(z_{calc})]$
$\mu > \mu_0$	$z_{calc} > z_{\alpha}$	$1 - \Phi(z_{calc})$
$\mu < \mu_0$	$z_{calc} < -z_{\alpha}$	$\Phi(z_{calc})$

Para $\alpha = 0.05$: $z_{0.025} = 1.96$ (bilateral) e $z_{0.05} = 1.645$ (unilateral). No teste t , troque por $t_{\alpha/2; n-1}$ ou $t_{\alpha; n-1}$. A hipótese unilateral deve ser escolhida *antes* de ver os dados, a partir da pergunta ("a latência aumentou?").

Os valores críticos são os percentis da normal, e os p-valores são áreas de cauda calculadas com Φ e sua simetria. O fator 2 do caso bilateral vem de contar as duas caudas: um $z_{calc} = -2.1$ é tão extremo quanto $+2.1$, e ambos entram no "tão ou mais extremo que o observado".

DEDUÇÃO Teste bilateral e intervalo de confiança são a mesma coisa

Um teste bilateral a nível α rejeita $H_0 : \mu = \mu_0$ exatamente quando μ_0 cai fora do IC de $1 - \alpha$, porque as duas afirmações dizem que $|\bar{x} - \mu_0| > z_{\alpha/2}\sigma/\sqrt{n}$.

EXEMPLO Mesma rejeição, histórias diferentes

Um IC de $[0.1; 0.3]$ ms e outro de $[2; 40]$ ms rejeitam a mesma H_0 : diferença = 0. Mas o primeiro diz que o efeito é real e minúsculo, e o segundo diz que é real e possivelmente enorme. Por isso mostrar o IC é mais informativo que só dizer "rejeitado".

INTUIÇÃO Unilateral ou bilateral

	Unilateral	Bilateral
Crítico ($\alpha = 5\%$)	1.645	1.96
Vantagem	detecta mudanças menores no sentido escolhido (mais poder)	vê as duas direções
Custo	fica cego para o sentido oposto	menos poder em cada direção
Quando	regressão de desempenho, em que só importa ficar mais lento	"a versão nova muda a taxa de erro?"; limites de controle, porque tanto um aumento quanto uma queda súbita indicam mudança

CONEXÕES

- 5.6** percentis da normal.
- 7.4** intervalos de confiança.
- 8.9** poder.
- 9.2** limites bilaterais.

▼ Entendendo a fórmula, termo a termo

$$p = 2[1 - \Phi(|z|)] \text{ (}\neq\text{)}, \quad p = 1 - \Phi(z) \text{ (}\gt\text{)}, \quad p = \Phi(z) \text{ (}\lt\text{)}$$

$1 - \Phi(z)$ ← Área na cauda direita além de z .

$\Phi(z)$ ← Área na cauda esquerda.

$2[\cdot]$ ← Bilateral: um resultado tão extremo do outro lado também conta.

De onde vem, passo a passo

1. Identifique a direção de H_1 .
2. Some a área (ou as áreas) além do valor observado, na direção de H_1 .
3. No bilateral, por simetria, as duas caudas são iguais: $2[1 - \Phi(|z|)]$.
4. Relação com o IC: $|z| \leq z_{\alpha/2} \iff \mu_0$ está dentro do IC de $1 - \alpha$.

EXEMPLO RESOLVIDO Do z ao p-valor, e a ligação com o IC

Um teste z resultou em $z_{calc} = 2.1$.

O QUE SE PEDE

p-valor bilateral e unilateral, e a relação com o IC.

RESOLUÇÃO PASSO A PASSO

1 Cauda acima de 2.1

$$P(Z > 2.1) = 1 - \Phi(2.1) = 1 - 0.9821 = 0.0179$$

2 Unilateral

Com $H_1 : \mu > \mu_0$, só a cauda direita conta: $p = 0.018$.

3 Bilateral

Com $H_1 : \mu \neq \mu_0$, um desvio tão grande para qualquer lado conta: $p = 2 \times 0.0179 = 0.036$.

RESPOSTA Bilateral 0.036; unilateral 0.018. Ambos rejeitam H_0 a 5%.

Relação com o IC: um teste bilateral com $\alpha = 0.05$ rejeita $H_0 : \mu = \mu_0$ exatamente quando μ_0 fica fora do IC de 95%. São duas leituras da mesma conta.

Exercício 8.6 • Cálculo do p-valor

Em um teste z com $H_1 : \mu \neq \mu_0$, obteve-se $z_{calc} = 0.85$. Qual o p-valor?

Espaço para cálculo

8.7 Teste para a Variância

Quando o requisito é sobre variabilidade (jitter de um enlace, estabilidade do tempo de resposta), a estatística de teste é a mesma quantidade que deu o intervalo de confiança para a variância, com σ^2 substituído pelo valor de H_0 :

ESTATÍSTICA QUI-QUADRADO (POPULAÇÃO NORMAL)

$$\chi_{calc}^2 = \frac{(n-1)S^2}{\sigma_0^2} \sim \chi_{n-1}^2 \text{ sob } H_0 : \sigma^2 = \sigma_0^2$$

▼ Equação desmontada, variável por variável

$$\chi_{calc}^2 = \frac{(n-1)S^2}{\sigma_0^2}$$

S^2 ← variância da amostra (ex.: 0.026^2)

σ_0^2 ← variância afirmada por H_0 (ex.: 0.02^2)

$n-1$ ← graus de liberdade (ex.: 19)

ex. ← $19 \times 0.000676 / 0.0004 = 32.11$

Para $H_1: \sigma^2 > \sigma_0^2$, rejeite se $\chi_{calc}^2 > \chi_{\alpha; n-1}^2$. Ex.: exige-se jitter $\sigma \leq 0.02$ ms num enlace de baixa latência; com $n = 20$ medições e $s = 0.026$ ms, $\chi_{calc}^2 = 19(0.026^2)/0.02^2 = 32.11 > \chi_{0.05; 19}^2 = 30.144$: há evidência de variabilidade excessiva.

INTUIÇÃO Lendo a estatística

A estatística compara a variância observada com a de H_0 : se $s^2 = \sigma_0^2$, ela vale $n-1$, que é a média da qui-quadrado. Valores bem acima de $n-1$ indicam variância maior que σ_0^2 , e bem abaixo, menor.

EXEMPLO Mesmo s , conclusões diferentes

n	χ_{calc}^2	Crítico	Decisão
20	32.11	30.144	rejeita
10	15.2	16.9	não rejeita

No exemplo, s é 30% maior que o limite, e com 20 medições isso já é evidência suficiente; com 10, não. Variâncias são difíceis de estimar, e testes sobre elas precisam de mais dados.

NA COMPUTAÇÃO A direção de H_1 depende de quem precisa provar o quê

Objetivo	H_1	Região crítica
demonstrar que um enlace <i>viola</i> o requisito	$\sigma^2 > \sigma_0^2$	cauda direita
demonstrar que uma otimização <i>reduziu</i> a variabilidade (menos picos depois de trocar o coletor de lixo)	$\sigma^2 < \sigma_0^2$	cauda esquerda

CUIDADO Muito sensível à normalidade

A hipótese de normalidade pesa muito mais aqui que nos testes de média. Com dados de cauda pesada, a variância amostral oscila muito mais do que a qui-quadrado prevê, e o teste rejeita com frequência muito maior que α . Comparar a variabilidade de duas versões usa a razão $F = s_A^2/s_B^2$ (teste F), igualmente sensível; o teste de Levene, baseado em desvios absolutos em torno da mediana, é a alternativa robusta, pela mesma lógica do MAD.

CONEXÕES

- 7.7** IC para variância.
- 7.6** sensibilidade da qui-quadrado.
- 6.3** MAD.
- 8.1** o que se quer demonstrar vai para H_1 .

▼ Entendendo a fórmula, termo a termo

$$\chi_{calc}^2 = \frac{(n-1)S^2}{\sigma_0^2}$$

$$S^2/\sigma_0^2$$

← Razão entre a variância observada e a afirmada; perto de 1 se H_0 for verdadeira.

$$(n-1)$$

← Coloca a razão na escala da χ_{n-1}^2 , cuja média é $n-1$.

Cauda

← Direita se $H_1 : \sigma^2 > \sigma_0^2$; esquerda se $H_1 : \sigma^2 < \sigma_0^2$.

De onde vem, passo a passo

1. Sob H_0 , $(n-1)S^2/\sigma_0^2 \sim \chi_{n-1}^2$ (7.6), com média $n-1$.
2. Se $S^2 \approx \sigma_0^2$, a estatística fica perto de $n-1$.
3. Valores muito acima (ou abaixo) do esperado indicam variância maior (ou menor) que a afirmada.
4. Ao contrário do teste t , este teste é sensível à suposição de normalidade dos dados.

EXEMPLO RESOLVIDO

Teste de variância para comprovar melhoria

Após trocar o coletor de lixo da JVM, quer-se mostrar que a variabilidade das pausas caiu abaixo de $\sigma = 1$ ms.

DADOS

- $n = 10$ medições, $s = 0.5$ ms
- $\alpha = 0.05$

O QUE SE PEDE

Teste qui-quadrado para a variância.

RESOLUÇÃO PASSO A PASSO

1

Hipóteses

$H_0 : \sigma^2 = 1$ contra $H_1 : \sigma^2 < 1$.

2 Estatística

$$\chi_{calc}^2 = \frac{(n-1)s^2}{\sigma_0^2} = \frac{9 \times 0.25}{1} = 2.25$$

3 Crítico na cauda inferior

H_1 é "menor", então a rejeição está na cauda esquerda: $\chi_{0.95; 9}^2 = 3.325$.

4 Decidir

$2.25 < 3.325$: rejeita-se H_0 .

RESPOSTA A variabilidade caiu de forma significativa: a troca do coletor funcionou.

Exercício 8.7 • Teste Qui-Quadrado para a Variância

O jitter de um enlace deve ter no máximo $\sigma_0 = 1.7$ ms. Uma amostra de $n = 20$ medições de latência deu $s = 2.21$ ms. Para testar $H_0 : \sigma^2 = 2.89$ contra $H_1 : \sigma^2 > 2.89$, calcule χ_{calc}^2 .

Espaço para cálculo

8.8 Teste para Proporção

Taxas de erro, de conversão e de acerto de cache são proporções, e testá-las é provavelmente o uso mais frequente de testes de hipóteses em software. A estatística é o teste Z aplicado à média de indicadoras, com o erro padrão calculado sob H_0 :

ESTATÍSTICA Z (AMOSTRAS GRANDES)

$$z_{calc} = \frac{\hat{p} - p_0}{\sqrt{p_0(1 - p_0)/n}}$$

▼ Equação desmontada, variável por variável

$$z_{calc} = \frac{\hat{p} - p_0}{\sqrt{p_0(1 - p_0)/n}}$$

$\hat{p}$ ← proporção observada (ex.: 0.075)

p_0 ← proporção afirmada por H_0 (ex.: 0.05)

$\sqrt{p_0(1 - p_0)/n}$ ← erro padrão calculado com p_0 (ex.: 0.0109)

n ← tamanho da amostra (ex.: 400)

O denominador usa p_0 (o valor sob H_0), e não $\hat{p}$ como no intervalo de confiança.

INTUIÇÃO Por que p_0 no denominador

O teste pergunta "como os dados se comportariam se H_0 fosse verdadeira?", e se H_0 é verdadeira, a variância de $\hat{p}$ é exatamente $p_0(1 - p_0)/n$, sem nada a estimar. O intervalo de confiança não supõe valor nenhum para p , e por isso usa a estimativa $\hat{p}$. A aproximação normal exige $np_0 \geq 5$ e $n(1 - p_0) \geq 5$.

EXEMPLO SLA de taxa de erro

"O provedor garante no máximo 0.5% de requisições com erro": $H_0 : p = 0.005$ e $H_1 : p > 0.005$. Como a taxa é pequena, a condição $np_0 \geq 5$ exige pelo menos 1000 requisições; com menos, usa-se o teste binomial exato, que soma as probabilidades da binomial diretamente, ou a aproximação de Poisson.

NA COMPUTAÇÃO O teste A/B clássico: duas proporções

1. Sob H_0 , as duas versões têm a mesma taxa, então ela é estimada juntando as amostras: $\hat{p} = \frac{x_A + x_B}{n_A + n_B}$.
2. A diferença $\hat{p}_A - \hat{p}_B$ tem variância $\hat{p}(1 - \hat{p})(1/n_A + 1/n_B)$, pela soma de variâncias.
3. $z = \frac{\hat{p}_A - \hat{p}_B}{\sqrt{\hat{p}(1 - \hat{p})(1/n_A + 1/n_B)}}$, o teste por trás da maioria das calculadoras de experimentos.

Ele é matematicamente equivalente ao qui-quadrado de independência numa tabela 2×2 ($z^2 = \chi^2$). Monitorar uma taxa de erro ao longo do tempo, em vez de testá-la uma vez, é o gráfico p , com a mesma variância $p(1 - p)/n$.

CONEXÕES

- 3.2** binomial.
- 5.8** aproximação normal.
- 7.4** IC para proporção.
- 8.5** qui-quadrado 2×2 .
- 9.4** gráfico p .

▼ Entendendo a fórmula, termo a termo

$$z_{calc} = \frac{\hat{p} - p_0}{\sqrt{p_0(1 - p_0)/n}}$$

- $\hat{p} - p_0$ ← Afastamento da proporção observada em relação à afirmada.
- $p_0(1 - p_0)/n$ ← Variância de $\hat{p}$ se H_0 for verdadeira.
- p_0 (e não $\hat{p}$) ← O teste calcula tudo supondo H_0 ; no IC, como não há H_0 , usa-se $\hat{p}$.

De onde vem, passo a passo

1. $\hat{p} = X/n$ com $X \sim B(n, p_0)$ sob H_0 .
2. $E[\hat{p}] = p_0$ e $Var(\hat{p}) = \frac{np_0(1-p_0)}{n^2} = \frac{p_0(1-p_0)}{n}$.
3. Pelo TCL (com $np_0 \geq 5$ e $n(1 - p_0) \geq 5$), padronize e compare com a normal.

EXEMPLO RESOLVIDO**Provedor acima do SLA de erros?**

O SLA de uma API admite no máximo 5% de requisições com erro. Uma amostra de logs encontrou 30 erros em 400 requisições.

DADOS

- $p_0 = 0.05, n = 400, \hat{p} = 30/400 = 0.075$
- $\alpha = 0.05$

O QUE SE PEDE

Teste de proporção.

RESOLUÇÃO PASSO A PASSO

1 Hipóteses

$H_0 : p = 0.05$ contra $H_1 : p > 0.05$.

2 Condição

$np_0 = 20 \geq 5$ e $n(1 - p_0) = 380 \geq 5$: a aproximação normal vale.

3 Erro padrão sob H_0

Usa-se p_0 (não $\hat{p}$), porque o cálculo supõe H_0 verdadeira:

$$\sqrt{\frac{0.05 \times 0.95}{400}} = 0.0109$$

4 Estatística

$$z_{calc} = \frac{0.075 - 0.05}{0.0109} = 2.29$$

5 Decidir

$2.29 > 1.645$: rejeita-se H_0 . p-valor = $1 - \Phi(2.29) = 0.011$.

RESPOSTA

Há evidência de que o provedor viola o SLA.

Exercício 8.8 • Teste z para Proporção

O SLA de um provedor exige no máximo 2% de requisições com erro. Numa amostra de 200 requisições, 6 deram erro. Calcule z_{calc} para $H_0 : p = 0.02$ vs $H_1 : p > 0.02$.

Espaço para cálculo

8.9 Poder do Teste

O nível α protege contra falsos positivos. Mas um teste que nunca rejeita tem $\alpha = 0$ e é inútil. A outra metade da qualidade de um teste é sua capacidade de detectar efeitos reais, o poder $1 - \beta$. O poder $1 - \beta$ cresce quando o desvio real $|\mu - \mu_0|$ é maior, σ é menor, n é maior ou α é maior. Reduzir α sem aumentar n aumenta β : os dois erros competem, e só mais dados reduzem ambos.

INTUIÇÃO A figura das duas normais

Sob H_0 , $\bar{X}$ é centrada em μ_0 ; sob a verdade, em μ_1 ; ambas com desvio $\sigma/\sqrt{n}$. O valor crítico fica num ponto da primeira curva determinado por α , e o poder é a área da segunda curva além desse ponto. Afastar μ_1 de μ_0 , ou estreitar as curvas (menor σ , maior n), separa as duas e aumenta o poder; reduzir α empurra o crítico para fora e diminui o poder.

DEDUÇÃO Tamanho de amostra para um poder desejado

Exigindo poder $1 - \beta$ para detectar um efeito $\delta = |\mu_1 - \mu_0|$, a distância δ precisa cobrir $z_\alpha + z_\beta$ erros padrão:

$$n = \left(\frac{(z_\alpha + z_\beta) \sigma}{\delta} \right)^2$$

É a fórmula de tamanho de amostra do intervalo de confiança com um termo a mais, z_β , que garante não só uma margem pequena, mas uma chance alta de detectar o efeito. Com $\alpha = 5\%$ unilateral e poder de 80%, $z_\alpha + z_\beta = 1.645 + 0.842 = 2.49$.

NA COMPUTAÇÃO Onde estão as alavancas num teste A/B

O n cresce com o quadrado da variabilidade e com o inverso do quadrado do efeito: detectar um efeito 2 vezes menor exige 4 vezes mais dados. Por isso reduzir σ é tão valioso quanto ter mais tráfego. Técnicas como o CUPED, que ajustam a métrica de cada usuário pelo seu comportamento no período anterior, retiram a variação entre usuários da mesma forma que o teste pareado retira a variação entre entradas, e podem reduzir pela metade o tráfego necessário.

CUIDADO Testes com pouco poder enganam duas vezes

A análise de poder é feita antes de rodar o teste, a partir do menor efeito que importa para o negócio (o MDE, efeito mínimo detectável). Sem ela, um teste com pouco tráfego quase nunca encontra efeitos pequenos e termina "sem diferença" por falta de poder, não porque as versões são iguais. E quando "dá significativo", tende a superestimar o efeito, porque só passam os casos em que o acaso exagerou a diferença; também aumenta a fração de resultados significativos que são falsos. O mesmo conceito, com outro nome, mede a rapidez com que um gráfico de controle detecta um deslocamento.

CONEXÕES

- 7.4 tamanho de amostra.
- 8.4 teste pareado.
- 8.2 fração de significativos falsos.
- 9.9 detecção de deslocamentos.

▼ Entendendo a fórmula, termo a termo

$$n = \left(\frac{(z_\alpha + z_\beta) \sigma}{\delta} \right)^2$$

$\delta = \mu_1 - \mu_0$ ← Menor desvio que importa detectar.

z_α ← Protege contra alarme falso.

z_β ← Garante o poder $1 - \beta$ desejado.

$(\cdot)^2$ ← Detectar metade do desvio exige 4 vezes a amostra.

De onde vem, passo a passo

1. O valor crítico, visto a partir de μ_0 , está em $c = \mu_0 + z_\alpha \sigma / \sqrt{n}$.
2. Para ter poder $1 - \beta$, o mesmo c visto a partir de μ_1 deve estar em $c = \mu_1 - z_\beta \sigma / \sqrt{n}$.
3. Igualando: $\delta = (z_\alpha + z_\beta) \sigma / \sqrt{n}$.
4. Isolando n chega-se à fórmula. No bilateral, troque z_α por $z_{\alpha/2}$.

EXEMPLO RESOLVIDO

Tamanho de amostra para um poder desejado

No teste de regressão do exemplo 8.2, quer-se detectar uma piora para 105 ms com poder 0.90. Quantas requisições medir?

DADOS

- $\sigma = 10$, desvio a detectar $\delta = 5$
- $\alpha = 0.05$ unilateral: $z_\alpha = 1.645$
- poder 0.90: $z_\beta = 1.282$

O QUE SE PEDE

O n necessário.

RESOLUÇÃO PASSO A PASSO

1 Fórmula

$$n = \left(\frac{(z_\alpha + z_\beta) \sigma}{\delta} \right)^2$$

2 Substituir

$$n = \left(\frac{(1.645 + 1.282) \times 10}{5} \right)^2 = (5.854)^2 = 34.3$$

3 Arredondar para cima

$$n = 35.$$

4 Efeito de n maior

Com $n = 100$: $\sigma_{\bar{X}} = 1$, crítico 101.645 e $\beta = \Phi(101.645 - 105) = \Phi(-3.36) = 0.0004$.
O poder vai a praticamente 1.

RESPOSTA $n = 35.$

Exercício 8.9 • Poder do Teste

Mantidos os demais fatores, qual situação **umenta** o poder $1 - \beta$ de um teste para a média?

Espaço para cálculo

- ☐ Reduzir o tamanho da amostra n .
- ☐ Medir num ambiente mais ruidoso (maior σ).
- ☐ Reduzir o nível de significância α .
- ☐ Reduzir o ruído das medições (menor σ), por exemplo isolando a máquina de benchmark.

8.10 Aderência com Parâmetros Estimados

No teste de aderência da seção 8.5, as frequências esperadas vinham de uma distribuição totalmente especificada (dígitos uniformes, cada um com $1/10$). Na maioria dos casos, quer-se testar uma *família* de distribuições ("os crashes seguem uma Poisson?") sem saber o parâmetro, e ele precisa ser estimado dos próprios dados. Exija $E_i \geq 5$ em cada classe, agrupando classes adjacentes se preciso. Cada parâmetro estimado dos dados consome um grau de liberdade.

Exemplo (Poisson): em 100 dias, 0, 1, 2 e ≥ 3 crashes de um serviço ocorreram em 35, 38, 18 e 9 dias. Com $\hat{\lambda} = 1.0$: $E_i = 36.8, 36.8, 18.4, 8.0$ e $\chi^2_{calc} = 0.261$, com $gl = 4 - 1 - 1 = 2$ e $\chi^2_{0.05;2} = 5.991$. O modelo de Poisson não é rejeitado.

DEDUÇÃO Por que estimar custa graus de liberdade

Ao ajustar λ pelos próprios dados, as frequências esperadas se aproximam das observadas mais do que se aproximariam de uma Poisson com o λ verdadeiro, e o χ^2 fica sistematicamente menor. É o mesmo fenômeno de $\sum (x_i - \bar{x})^2$ ser menor que $\sum (x_i - \mu)^2$: usar os dados para escolher o centro faz os dados parecerem mais próximos dele. Descontar um grau de liberdade por parâmetro compensa esse ajuste; sem o desconto, o teste rejeitaria menos do que deveria.

INTUIÇÃO O exemplo fecha um ciclo do curso

1. No Módulo 3, a Poisson foi apresentada como modelo de crashes por dia com base em hipóteses (eventos independentes, taxa constante).
2. A escolha do modelo foi descrita como uma hipótese a verificar.
3. Aqui, ela é verificada com dados.

CUIDADO "Não rejeitar" não é "provar"

Dimensionamentos baseados em Poisson (filas, capacidade de servidores, limites do gráfico c) dependem de as contagens serem de fato Poisson, e um teste de aderência em algumas semanas de dados evita projetar o sistema com o modelo errado. Mas "não rejeitar" significa que os dados são compatíveis com a Poisson, não que provam que ela é o modelo certo. Com só 100 dias, o teste tem pouco poder para detectar superdispersão moderada; comparar média e variância amostrais é um complemento útil.

NA COMPUTAÇÃO Dados contínuos: Kolmogorov-Smirnov

Para dados contínuos, agrupar em classes desperdiça informação e o resultado depende da escolha das classes. O teste de Kolmogorov-Smirnov compara a FDA empírica com a teórica diretamente, medindo a maior distância vertical entre elas. Quando os parâmetros são estimados dos dados, usa-se a variante de Lilliefors, que faz o ajuste equivalente ao desconto de graus de liberdade.

CONEXÕES

- 3.3** hipóteses da Poisson.
- 3.5** escolher o modelo.
- 6.3** graus de liberdade.
- 4.6** FDA empírica.
- 9.8** gráfico c .

▼ Entendendo a fórmula, termo a termo

$$gl = k - 1 - m, \quad E_i = n P_i(\hat{\theta})$$

k ← Número de classes (depois de agrupar as que têm $E_i < 5$).

-1 ← Os E_i são forçados a somar n .

$-m$ ← Cada parâmetro estimado dos dados aproxima artificialmente o modelo dos dados.

$P_i(\hat{\theta})$ ← Probabilidade da classe pelo modelo, usando os parâmetros estimados.

De onde vem, passo a passo

1. Estime os parâmetros ($\hat{\lambda} = \bar{x}$ na Poisson; $\bar{x}$ e s na normal).
2. Calcule P_i e $E_i = nP_i$ para cada classe; a última classe é aberta (" $\geq$ ") para que as probabilidades somem 1.
3. Agrupe classes com $E_i < 5$, calcule χ^2 e use $gl = k - 1 - m$.

EXEMPLO RESOLVIDO Graus de liberdade ao ajustar uma normal

Testa-se se as médias de latência por minuto seguem uma normal (o que justificaria limites de alerta baseados em σ). Os dados foram agrupados em 6 classes, e μ e σ foram estimados por $\bar{x}$ e s .

DADOS

- $k = 6$ classes
- $m = 2$ parâmetros estimados

O QUE SE PEDE

Graus de liberdade e valor crítico a 5%.

RESOLUÇÃO PASSO A PASSO

1

Regra

Perde-se 1 grau porque os totais têm que bater, e mais 1 por parâmetro estimado dos dados:

$$gl = k - 1 - m$$

2 Aplicar

$$gl = 6 - 1 - 2 = 3, \quad \chi^2_{0.05; 3} = 7.815$$

3 Classes pequenas

Se as classes das pontas tiverem $E_i < 5$, junte-as às vizinhas antes de calcular. Isso reduz k e, portanto, gl .

RESPOSTA $gl = 3$; crítico 7.815.

Exercício 8.10 • Frequência Esperada sob Poisson

Para testar se os crashes diários de um serviço seguem Poisson, registraram-se 80 dias com média $\hat{\lambda} = 1.9$ crashes/dia. Qual a frequência esperada E_0 de dias com exatamente 0 crashes?

Espaço para cálculo

Exercícios de Fixação com Soluções Comentadas

3 Questões Resolvidas

Exercício 8.1: Teste Z Bicaudal para a Latência Média

Um serviço de pagamentos deve responder com latência média $\mu_0 = 1000$ ms numa operação pesada. Sabe-se historicamente que $\sigma = 20$ ms. Depois de uma migração de banco de dados, uma amostra de $n = 25$ requisições resultou em média $\bar{x} = 1008$ ms. Teste se a migração alterou a latência ($H_0 : \mu = 1000$ vs $H_1 : \mu \neq 1000$) com nível de significância $\alpha = 0.05$ (valores críticos $z = \pm 1.96$).

Espaço para cálculo

Exercício 8.2: Interpretação de p-valor e Risco de Erro

Ao comparar a taxa de falha de dois algoritmos de compressão num teste t bicaudal com $\alpha = 0.01$, o software estatístico reportou $p\text{-valor} = 0.003$.

- (a) Qual a decisão estatística tomada?
- (b) Qual dos erros (Tipo I ou Tipo II) existe risco de estarmos cometendo nessa decisão?

Espaço para cálculo

Exercício 8.3: Teste Qui-Quadrado de Aderência para Distribuição Uniforme

Um gerador de números pseudoaleatórios em chip de segurança gerou 100 valores distribuídos em 4 faixas: Faixa 1: 18; Faixa 2: 32; Faixa 3: 22; Faixa 4: 28. Calcule o valor da estatística χ^2_{calc} e determine os graus de liberdade.

Espaço para cálculo

Módulo 9: Controle Estatístico de Processo (CEP / SPC)

Controle estatístico aplicado a serviços: causas comuns e especiais, tampering e autoajuste, alertas como gráficos de controle, $\bar{X}$ -R e $\bar{X}$ -S para latência, gráfico p para taxa de erro, capacidade de tarefas de tempo real, gráficos c e np (bugs por release), regras de sensibilidade, EWMA/CUSUM e linhas de base.

O último módulo junta quase tudo o que veio antes num problema que todo sistema em produção enfrenta: acompanhar uma métrica ao longo do tempo e decidir, a cada ponto, se algo mudou. Um gráfico de controle é um teste de hipóteses repetido a cada minuto, com H_0 = "o sistema continua como antes". Seus limites vêm da distribuição amostral da média e da regra 68-95-99.7; os gráficos de atributos usam a binomial e a Poisson; a estimativa de σ usa a amplitude e o desvio amostral do Módulo 6; e os índices de capacidade são o problema inverso da normal. Em computação, essas ideias sustentam o monitoramento de serviços, a engenharia de confiabilidade (SRE) e a detecção de anomalias.

9.1 Filosofia do CEP e Tipos de Variabilidade

O Controle Estatístico de Processo (CEP) nasceu com Walter Shewhart nos Bell Labs, a empresa de telefonia, nos anos 1920, e foi difundido por W. Edwards Deming. A ideia central é que toda métrica varia, mesmo quando nada está errado: a latência de um serviço oscila de minuto a minuto, a taxa de erro flutua, o uso de CPU sobe e desce. A pergunta útil não é "a métrica mudou?", porque ela sempre muda, e sim "a variação é a de sempre, ou apareceu algo novo?". Shewhart separou duas fontes de variação:

- **Causas Comuns (Aleatórias):** inerentes ao sistema como ele é: pequenas variações de carga, cache, escalonador, rede. Quando só elas atuam, o processo está **sob controle estatístico** (previsível dentro de limites).
- **Causas Especiais (Atribuíveis):** eventos específicos que mudam o comportamento: um deploy com bug, um disco falhando, uma dependência fora do ar, um pico de tráfego anormal, um ataque. Devem ser identificadas e tratadas.

"Sob controle estatístico" tem um significado preciso: as medições se comportam como sorteios independentes de uma mesma distribuição. É exatamente a hipótese de amostra aleatória que sustenta toda a inferência dos Módulos 7 e 8. Um processo sob controle é previsível no sentido probabilístico: não se sabe o próximo valor, mas se sabe sua distribuição, e portanto a faixa em que deve cair. Uma causa especial é uma mudança dessa distribuição, seja na média, na variância ou na forma.

INTUIÇÃO Os dois erros opostos

	Tratar variação comum como especial	Ignorar uma causa especial
Tipo de erro	Tipo I	Tipo II
Exemplo	abrir incidente para cada pico normal, investigar cada oscilação	achar que o aumento de erros é "ruído"
Custo	trabalho inútil e, pior, intervenções que atrapalham	o problema cresce sem que ninguém aja

O gráfico de controle é a ferramenta para separar os dois casos com taxas de erro conhecidas.

DEDUÇÃO Reagir ao ruído dobra a variância (tampering)

1. Um script de ajuste automático corrige um parâmetro a cada medição para compensar o último desvio da meta.
2. Se esse desvio era puro acaso, a correção é tão aleatória quanto o desvio que tenta compensar.
3. As duas se somam, e pela soma de variâncias de independentes, a variância do resultado *dobra*.

O exemplo desta seção mostra isso em números.

NA COMPUTAÇÃO Não reagir ao ruído

Controladores com histerese, janelas de média e limiares estatísticos existem para não reagir ao ruído. Um autoscaler que reage a cada oscilação de CPU sobe e desce máquinas à toa e piora a estabilidade.

CUIDADO Sob controle não quer dizer bom

Se o processo está sob controle mas o resultado é ruim (latência alta e estável), não adianta caçar causas especiais, porque não há nenhuma: o problema está no próprio sistema, e é preciso mudar a arquitetura, o algoritmo ou a capacidade. Esse é o ponto central de Deming: a maior parte dos problemas está no sistema, não em eventos isolados, e culpar pessoas ou incidentes por variação comum não melhora nada. Em engenharia de software, é a mesma lição das retrospectivas sem culpados (*blameless postmortems*).

CONEXÕES

- 7.1 amostra aleatória.
- 8.2 erros tipo I e II.
- 2.7 soma de variâncias.
- 6.4 outliers como pistas de causa especial.

▼ Entendendo a fórmula, termo a termo

$$x_t = \mu + \varepsilon_t \text{ (só causas comuns)}, \quad x_t = \mu + \delta + \varepsilon_t \text{ (causa especial)}$$

ε_t ← Ruído aleatório do sistema: muitas pequenas causas comuns.

δ ← Deslocamento produzido por uma causa especial identificável.

Gráfico de controle ← Decide se o que se vê é compatível só com ε_t ou se há um δ .

De onde vem, passo a passo

1. Ajuste a cada medição (tampering): o controlador corrige o alvo em $-(x_{t-1} - \mu)$.
2. Resultado: $x_t = \mu + \varepsilon_t - \varepsilon_{t-1}$.
3. Variância: $Var(\varepsilon_t) + Var(\varepsilon_{t-1}) = 2\sigma^2$. O "ajuste" dobrou a variância.
4. Conclusão: só se age sobre sinais (causas especiais); a variação comum só se reduz mudando o sistema.

EXEMPLO RESOLVIDO O custo de reagir à variação comum

Um script de autoajuste mede a latência de cada lote de requisições e muda um parâmetro do servidor (o tamanho do pool de threads) para compensar o desvio do lote anterior. O sistema só tem variação comum.

DADOS

- $\sigma = 1$ (sem ajustes)

O QUE SE PEDE

O efeito dos ajustes sobre a variabilidade.

RESOLUÇÃO PASSO A PASSO

1 O que o ajuste faz

O desvio do lote anterior era puro acaso. Compensá-lo desloca o sistema por um valor aleatório, que se soma ao ruído do próximo lote.

2 Somar variâncias

Dois erros independentes de variância 1:

$$\sigma^2 = 1 + 1 = 2 \implies \sigma = \sqrt{2} = 1.41$$

RESPOSTA A variabilidade aumenta 41%.

Esse efeito (*tampering*, ilustrado pelo experimento do funil de Deming) mostra por que o gráfico de controle existe: separar o que exige ação (causa especial) do que deve ser deixado em paz. Em controladores automáticos (autoscaling, ajuste de parâmetros), histerese e janelas de média evitam reagir ao ruído.

Exercício 9.1 • Causas Comuns vs. Especiais

Classifique a fonte de variação: **Variação normal causada por pausas curtas de coleta de lixo.**

Espaço para cálculo

- ☐ Causa especial: investigar e eliminar.
- ☐ Causa comum: deve-se reajustar o sistema a cada medição.
- ☐ Causa comum: inerente ao processo; só muda com alteração do sistema.
- ☐ Não é variação: deve ser ignorada pelo CEP.

9.2 Estrutura Geral dos Gráficos de Controle de Shewhart

Um gráfico de controle acompanha uma estatística $\bar{W}$ (média de latência por minuto, taxa de erro por hora) ao longo do tempo. Se o processo está sob controle, $\bar{W}$ tem média μ e desvio $\sigma_{\bar{W}}$ conhecidos, e o gráfico desenha três linhas:

LIMITES DE CONTROLE DE 3σ

Linha Central (LC): μ

Limite Superior de Controle (LSC): $\mu + 3\sigma_{\bar{W}}$

Limite Inferior de Controle (LIC): $\mu - 3\sigma_{\bar{W}}$

▼ Equação desmontada, variável por variável

$$LC = \mu, \quad LSC = \mu + 3\sigma_{\bar{W}}, \quad LIC = \mu - 3\sigma_{\bar{W}}$$

LC ← linha central

LSC, LIC ← limites superior e inferior de controle

μ ← valor médio da estatística plotada

$\sigma_{\bar{W}}$ ← desvio padrão da estatística plotada (para médias, $\sigma/\sqrt{n}$)

3 ← três desvios: alarme falso em só 0.27% dos pontos

Falso Alarme: com limites de 3σ , a chance de um ponto cair fora por puro acaso num processo normal sob controle é de 0.27% ($1 - 0.9973$): em média, 1 falso alarme a cada 370 pontos.

Cada ponto do gráfico é um teste Z bilateral com $H_0 =$ "o processo está como antes" e valor crítico 3 em vez de 1.96, o que corresponde a $\alpha = 0.27\%$.

DEDUÇÃO O 370 e a ARL

Se cada ponto dá alarme falso com chance $p = 0.0027$, o número de pontos até o primeiro alarme segue uma geométrica, de média $1/p = 370$. Essa média é chamada de ARL (comprimento médio de sequência), e é a medida padrão de desempenho de um gráfico: ARL alta quando o processo está sob controle (poucos falsos alarmes), ARL baixa quando há uma mudança (detecção rápida). É a tradução para séries temporais do par α e poder.

EXEMPLO Por que 3σ , e não 2σ

Limite	α por ponto	ARL sob controle	Com 1 ponto por minuto
2σ	4.6%	22	um alarme falso a cada 22 minutos
3σ	0.27%	370	a cada 6 horas por métrica; com 100 métricas, o plantão não teria descanso

É o problema das comparações múltiplas em forma operacional. Por isso alertas reais combinam limiares mais altos, duração mínima ("acima de X por 5 minutos", que exige vários pontos seguidos e reduz muito α) e várias métricas.

Todo alerta de monitoramento é, na prática, um gráfico de controle, mesmo que não seja chamado assim. Um alerta "latência p95 acima de X por 5 minutos" é uma regra de decisão sobre uma série temporal, e a escolha de X é o compromisso entre falso alarme e detecção. A diferença do gráfico de Shewhart é que os limites são calculados a partir dos dados do próprio sistema, enquanto muitos alertas usam limites fixos escolhidos por alguém.

CUIDADO Limites de controle não são SLOs

Limite de controle	SLO
vem dos dados: o que o sistema <i>faz</i>	vem do usuário: o que o sistema <i>deve</i> fazer

Um serviço pode estar sob controle e violar o SLO todo dia, ou estar fora de controle e ainda dentro do SLO. A relação entre os dois é o tema da análise de capacidade.

NA COMPUTAÇÃO Duas hipóteses que métricas de software violam

Hipótese	Violação	Remédio
estabilidade	tráfego tem sazonalidade (dia e noite, fim de semana), e a linha central muda ao longo do dia	comparar cada ponto com o mesmo horário de semanas anteriores
independência	pontos consecutivos são correlacionados; a variância de curto prazo subestima a variação real, e limites calculados como se fossem independentes disparam demais	monitorar os resíduos de um modelo de previsão: a diferença entre observado e previsto se aproxima mais de ruído independente

Para deslocamentos pequenos e persistentes, que o Shewhart demora a perceber, existem os gráficos EWMA e CUSUM.

CONEXÕES

- 5.2** regra 68-95-99.7.
- 8.4** teste Z.
- 3.5** geométrica.
- 8.3** comparações múltiplas.
- 9.5** especificação contra controle.
- 9.9** EWMA e CUSUM.

▼ Entendendo a fórmula, termo a termo

$$LSC = \mu_W + 3\sigma_W, \quad \alpha = P(|Z| > 3) = 0.0027, \quad ARL_0 = \frac{1}{\alpha} \approx 370$$

 W ← Estatística plotada ($\bar{x}$, R , s , p ...). **μ_W, σ_W** ← Média e desvio padrão de W sob controle (não os das medições individuais).**3**

← Compromisso entre alarme falso e capacidade de detecção.

 ARL_0

← Número médio de pontos até um alarme falso.

De onde vem, passo a passo

1. Sob controle e com W aproximadamente normal, $P(\text{ponto fora}) = 2[1 - \Phi(3)] = 0.0027$.
2. Cada ponto é um "ensaio" com probabilidade α de alarme; o número de pontos até o primeiro alarme é geométrico, com média $1/\alpha$.
3. Com 2σ : $\alpha = 0.0455$ e $ARL_0 \approx 22$, alarmes falsos demais.

EXEMPLO RESOLVIDO Por que 3σ , e não 2σ

Um gráfico $\bar{X}$ acompanha a latência média de 4 requisições sorteadas a cada minuto (em ms).

DADOS

- $\mu = 10, \sigma = 0.2, n = 4$

O QUE SE PEDE

Limites de controle e a taxa de alarme falso com 3σ e com 2σ .

RESOLUÇÃO PASSO A PASSO**1****Desvio da média do subgrupo**

$$\sigma_{\bar{X}} = \frac{0.2}{\sqrt{4}} = 0.1$$

2 Limites 3σ

$$LSC = 10 + 3(0.1) = 10.3, \quad LIC = 10 - 3(0.1) = 9.7$$

3 Alarme falso com 3σ

$P(|Z| > 3) = 0.0027$: um alarme falso a cada $1/0.0027 = 370$ subgrupos.

4 Alarme falso com 2σ

$P(|Z| > 2) = 0.0455$: um a cada 22 subgrupos.

RESPOSTA Limites 9.7 e 10.3. Alarme falso: 1 em 370 (3σ) contra 1 em 22 (2σ).

Com 2σ e um ponto por minuto, o alerta dispararia à toa a cada 22 minutos, e a equipe logo deixaria de confiar nele (fadiga de alertas). Uma requisição isolada de 10.35 ms é normal, mas uma *média* de 10.35 ms sinaliza mudança no sistema.

Exercício 9.2 • Limites de 3σ para Médias

Um serviço sob controle tem latência $\mu = 80$ ms e $\sigma = 2.5$ ms (requisições individuais). Plotam-se médias de subgrupos de $n = 6$ requisições. Qual o LSC do gráfico $\bar{X}$?

Espaço para cálculo

9.3 Gráficos de Controle por Variáveis: $\bar{X}$ e R

Para métricas contínuas como a latência, em vez de plotar cada medição, coletam-se **subgrupos racionais** de tamanho n (por exemplo, a latência de 5 requisições sorteadas a cada minuto) e plotam-se duas estatísticas por subgrupo: a média, que acompanha o nível, e a amplitude, que acompanha a dispersão. Os limites usam as constantes tabeladas de Shewhart (A_2, D_3, D_4):

GRÁFICO DA MÉDIA ($\bar{X}$) E GRÁFICO DA AMPLITUDE ($\bar{R}$)

$$\text{Gráfico } \bar{X} : \quad LC = \bar{X}, \quad LSC = \bar{X} + A_2\bar{R}, \quad LIC = \bar{X} - A_2\bar{R}$$

$$\text{Gráfico } R : \quad LC = \bar{R}, \quad LSC = D_4\bar{R}, \quad LIC = D_3\bar{R}$$

▼ Equação desmontada, variável por variável

$$LSC_{\bar{X}} = \bar{X} + A_2\bar{R}, \quad LIC_{\bar{X}} = \bar{X} - A_2\bar{R}$$

 $\bar{X}$

← média das médias dos subgrupos (ex.: 100.0 ms)

 $\bar{R}$

← média das amplitudes (máx - mín de cada subgrupo) (ex.: 2.4 ms)

 A_2

← constante da tabela para o tamanho n (ex.: 0.577 para $n = 5$)

 $A_2\bar{R}$

← meia largura (ex.: 1.385 ms)

$$LSC_R = D_4\bar{R}, \quad LIC_R = D_3\bar{R}$$

 D_3, D_4

← constantes da tabela (ex.: 0 e 2.114 para $n = 5$)

ex.

$$LSC_R = 2.114 \times 2.4 = 5.07 \text{ ms}$$

DEDUÇÃO As constantes só embutem contas conhecidas

1. A estatística plotada no gráfico $\bar{X}$ é a média de n medições, com desvio $\sigma/\sqrt{n}$; os limites de 3σ ficam a $3\sigma/\sqrt{n}$ da linha central.
2. σ é estimado pela amplitude média: em amostras normais de tamanho n , $E[R] = d_2\sigma$, então $\hat{\sigma} = \bar{R}/d_2$.
3. Juntando, o limite é $\bar{X} \pm \frac{3}{d_2\sqrt{n}}\bar{R}$, e $A_2 = \frac{3}{d_2\sqrt{n}}$. As constantes D_3 e D_4 fazem o mesmo para a distribuição da própria amplitude.

A amplitude é usada, em vez de s , por tradição de cálculo manual: com subgrupos pequenos ($n \leq 10$), ela é quase tão eficiente quanto s e muito mais fácil de calcular.

INTUIÇÃO Por que médias de subgrupos

- **Sensibilidade:** o desvio da média é menor, então o gráfico detecta deslocamentos menores, pelo mesmo $\sqrt{n}$ que dá precisão aos intervalos de confiança.
- **Normalidade:** pelo TCL, médias são aproximadamente normais mesmo que as latências individuais sejam assimétricas, o que torna a taxa de 0.27% mais confiável. Para latências com cauda muito pesada, $n = 5$ não basta para o TCL, e os falsos alarmes acima do LSC serão mais frequentes que o previsto.

NA COMPUTAÇÃO Subgrupo racional

As medidas de um subgrupo devem ser colhidas em condições tão iguais quanto possível (mesmo minuto, mesmo servidor), para que a variação dentro dele represente só o ruído de curto prazo; assim, diferenças *entre* subgrupos revelam mudanças reais. Misturar servidores diferentes no mesmo subgrupo infla $\bar{R}$, porque a diferença entre servidores entra como ruído, e deixa os limites largos demais para detectar qualquer coisa. É o mesmo princípio do teste pareado: comparar o que é comparável.

CUIDADO Leia o gráfico R primeiro

Os limites de $\bar{X}$ dependem de $\bar{R}$, e se a variabilidade estiver fora de controle (pontos fora no gráfico R), esses limites não valem. Em sistemas: se a dispersão das latências explodiu porque alguns servidores estão travando, olhar só a média engana, porque ela pode continuar no lugar enquanto a experiência dos usuários piora muito. Médias escondem caudas.

CONEXÕES

- 7.2** erro padrão.
- 7.3** TCL.
- 9.7** d_2 e c_4 .
- 8.4** teste pareado.
- 2.6** médias escondem caudas.

▼ Entendendo a fórmula, termo a termo

$$LSC_{\bar{X}} = \bar{\bar{x}} + A_2 \bar{R}, \quad A_2 = \frac{3}{d_2 \sqrt{n}}$$

 $\bar{\bar{x}}$ ← Estimativa de μ : linha central. $\bar{R}/d_2$ ← Estimativa de σ a partir das amplitudes. $/\sqrt{n}$ ← Passa de σ das medições individuais para σ da média.

3

← Limites de 3σ .

De onde vem, passo a passo

1. $LSC = \mu + 3 \frac{\sigma}{\sqrt{n}}$.
2. Substitua μ por $\bar{\bar{x}}$ e σ por $\bar{R}/d_2$: $LSC = \bar{\bar{x}} + \frac{3}{d_2 \sqrt{n}} \bar{R}$.
3. O fator $\frac{3}{d_2 \sqrt{n}}$ é A_2 . Para $n = 5$: $3/(2.326\sqrt{5}) = 0.577 \checkmark$.
4. De modo análogo, $D_4 = 1 + 3d_3/d_2$, onde $d_3\sigma$ é o desvio padrão de R .

EXEMPLO RESOLVIDO

Montando os gráficos $\bar{X}$ e R

Cinco subgrupos de 4 requisições (latência em ms) foram coletados, um por minuto.

DADOS

- médias: 10.2; 9.9; 10.1; 10.4; 9.9
- amplitudes: 0.4; 0.6; 0.5; 0.3; 0.7
- para $n = 4$: $A_2 = 0.729$, $D_3 = 0$, $D_4 = 2.282$

O QUE SE PEDE

Limites dos gráficos R e $\bar{X}$.

RESOLUÇÃO PASSO A PASSO

1

Linhas centrais

$$\bar{\bar{x}} = \frac{10.2 + 9.9 + 10.1 + 10.4 + 9.9}{5} = 10.1, \quad \bar{R} = \frac{0.4 + 0.6 + 0.5 + 0.3 + 0.7}{5} = 0.5$$

2 Gráfico R primeiro

$$LSC_R = D_4 \bar{R} = 2.282 \times 0.5 = 1.141, \quad LIC_R = D_3 \bar{R} = 0$$

Todas as amplitudes estão dentro: a variabilidade é estável.

3 Gráfico $\bar{X}$

$$\bar{\bar{x}} \pm A_2 \bar{R} = 10.1 \pm 0.729 \times 0.5 = 10.1 \pm 0.365 = [9.736; 10.465]$$

4 Verificar os pontos

Todas as médias estão dentro. A maior (10.4) está perto, mas dentro.

RESPOSTA R: [0; 1.141]. $\bar{X}$: [9.736; 10.465]. Serviço sob controle.

Por que R primeiro? Os limites de $\bar{X}$ usam $\bar{R}$; se a variabilidade estiver fora de controle, esses limites não valem.

Exercício 9.3 • LIC do Gráfico $\bar{X}$

25 subgrupos de $n = 8$ requisições: $\bar{\bar{x}} = 23.5$ ms, $\bar{R} = 2.6$ ms ($A_2 = 0.373$, $D_3 = 0.136$, $D_4 = 1.864$). Calcule o LIC do gráfico $\bar{X}$.

Espaço para cálculo

9.4 Gráfico de Controle por Atributos: Gráfico p (Fração com Falha)

Quando cada item é classificado como "ok" ou "com falha" (uma requisição com ou sem erro), o que se acompanha é a fração com falha em cada janela. O número de falhas numa janela de n itens é binomial, e a fração $\hat{p}$ tem média p e desvio $\sqrt{p(1-p)/n}$. Os limites de 3σ saem direto:

LIMITES DO GRÁFICO p

$$LC = \bar{p}$$

$$LSC = \bar{p} + 3\sqrt{\frac{\bar{p}(1-\bar{p})}{n}}$$

$$LIC = \max\left(0, \bar{p} - 3\sqrt{\frac{\bar{p}(1-\bar{p})}{n}}\right)$$

▼ Equação desmontada, variável por variável

$$LSC = \bar{p} + 3\sqrt{\frac{\bar{p}(1-\bar{p})}{n}}, \quad LIC = \max\left(0, \bar{p} - 3\sqrt{\frac{\bar{p}(1-\bar{p})}{n}}\right)$$

 $\bar{p}$

← fração média com falha (ex.: 0.05)

 n

← itens por subgrupo (ex.: 200)

 $\sqrt{\frac{\bar{p}(1-\bar{p})}{n}}$

← desvio padrão da fração (ex.: 0.0154)

 $\max(0, \cdot)$

← se der negativo, usa-se 0

A estrutura é a do intervalo e do teste de proporção, com 3 no lugar de 1.96. O LIC é truncado em zero porque frações não podem ser negativas; quando $\bar{p}$ é pequeno, o limite inferior calculado sai negativo, sinal de que a aproximação normal está forçada. Com $n\bar{p} < 5$, os limites de 3σ deixam de ter a taxa de 0.27%, e podem-se usar os percentis exatos da binomial.

EXEMPLO Limiar fixo erra nos dois sentidos

Cada janela tem seu próprio n , e portanto seus próprios limites: largos de madrugada (pouco tráfego), estreitos no pico.

Janela	Limites	O que um limiar fixo faz
madrugada, 20 requisições	largos	3 erros em 20 (15%) disparam o alerta, embora sejam compatíveis com uma taxa normal de 5%
pico, 100 000 requisições	estreitos	um aumento real de 5% para 6% passa despercebido, embora esteja a mais de 14 desvios padrão da linha central

NA COMPUTAÇÃO Orçamento de erros em SRE

Com SLO de 99.9% de sucesso, o "orçamento" é 0.1% de falhas no período. Alertas de *burn rate* disparam quando a taxa de erro observada consumiria o orçamento rápido demais: uma taxa 14.4 vezes acima do orçamento, sustentada por uma hora, consome 2% do orçamento mensal. É um gráfico p em que a linha central é o SLO, e não a média histórica, combinado com uma duração mínima.

CONEXÕES

- 3.2** binomial.
- 5.8** aproximação normal.
- 7.4** IC para proporção.
- 8.8** teste de proporção.

▼ Entendendo a fórmula, termo a termo

$$LSC = \bar{p} + 3\sqrt{\frac{\bar{p}(1-\bar{p})}{n}}$$

 $\bar{p}$

← Fração média com falha: linha central.

 $\sqrt{\bar{p}(1-\bar{p})/n}$ ← Desvio padrão de uma fração amostral (binomial dividida por n). n ← Com n maior, os limites se aproximam da linha central.

De onde vem, passo a passo

1. O número de itens com falha no subgrupo é $X \sim B(n, p)$.
2. $\hat{p} = X/n$ tem $Var = \frac{np(1-p)}{n^2} = \frac{p(1-p)}{n}$.
3. Aplique $LC \pm 3\sigma_W$ com p estimado por $\bar{p}$; trunque o LIC em 0.

EXEMPLO RESOLVIDO

Mesma fração, decisões diferentes

O gráfico p da taxa de erro de uma API tem $\bar{p} = 0.04$. Numa janela, 7% das requisições deram erro.

DADOS

- $\bar{p} = 0.04$
- caso 1: $n = 100$; caso 2: $n = 400$

O QUE SE PEDE

O ponto de 7% está fora de controle?

RESOLUÇÃO PASSO A PASSO

1

Fórmula do LSC

$$LSC = \bar{p} + 3\sqrt{\frac{\bar{p}(1-\bar{p})}{n}}$$

2 $n = 100$

$$LSC = 0.04 + 3\sqrt{\frac{0.04 \times 0.96}{100}} = 0.04 + 3(0.0196) = 0.099$$

$0.07 < 0.099$: dentro. Pode ser acaso.

3 $n = 400$

$$LSC = 0.04 + 3(0.0098) = 0.069$$

$0.07 > 0.069$: fora. Sinal de causa especial.

RESPOSTA Com $n = 100$, dentro; com $n = 400$, fora.

Janelas com mais tráfego estreitam os limites e detectam mudanças menores. Com tráfego variável ao longo do dia, cada ponto tem seus próprios limites: um limiar fixo de taxa de erro alarma demais de madrugada e de menos no pico.

Exercício 9.4 • LSC do Gráfico p

A taxa de erro média em janelas de $n = 50$ requisições é $\bar{p} = 0.1$. Calcule o LSC do gráfico p.

Espaço para cálculo

9.5 Análise de Capacidade do Processo (C_p e C_{pk})

Um processo sob controle é previsível, mas previsível não quer dizer bom. A análise de capacidade compara o que o processo faz com o que deveria fazer. A diferença fundamental: *limites de controle* (LSC/LIC) são a "voz do processo"; *limites de especificação* (LSE/LIE) são a "voz do cliente" (o SLO, o requisito de tempo real, o contrato).

ÍNDICES DE CAPACIDADE

$$\text{Capacidade Potencial: } C_p = \frac{LSE - LIE}{6\sigma}$$

$$\text{Capacidade Real (Centralizada): } C_{pk} = \min \left(\frac{LSE - \mu}{3\sigma}, \frac{\mu - LIE}{3\sigma} \right)$$

▼ Equação desmontada, variável por variável

$$C_p = \frac{LSE - LIE}{6\sigma}$$

LSE, LIE ← limites de especificação (ex.: 30.6 e 29.4 ms)

$LSE - LIE$ ← largura permitida (ex.: 1.2 ms)

6σ ← largura natural do processo (ex.: $6 \times 0.1 = 0.6$ ms)

ex. ← $C_p = 1.2/0.6 = 2.0$

$$C_{pk} = \min \left(\frac{LSE - \mu}{3\sigma}, \frac{\mu - LIE}{3\sigma} \right)$$

μ ← média do processo (ex.: 30.15 ms)

$LSE - \mu$ ← folga até o limite superior (ex.: 0.45)

$\mu - LIE$ ← folga até o limite inferior (ex.: 0.75)

3σ ← meia largura natural (ex.: 0.3)

min ← vale o lado mais apertado (ex.: $0.45/0.3 = 1.5$)

- $C_p, C_{pk} \geq 1.33$: processo considerado **capaz**.
- $C_{pk} < 1.0$: processo incapaz, violando a especificação com frequência relevante.

INTUIÇÃO Cabe, e está dentro?

C_p compara a largura da janela permitida com a largura natural do processo (6σ , que contém 99.73% dos valores de uma normal): mede se o processo *cabe* na especificação, sem olhar onde está centrado. C_{pk} mede a distância da média ao limite mais próximo, em unidades de 3σ : é o z-score do limite dividido por 3.

DEDUÇÃO Da capacidade à fração fora da especificação

Do lado mais próximo, a fração fora é $1 - \Phi(3C_{pk})$:

C_{pk}	Distância ao limite	Fora da especificação (um lado)
1.00	3σ	0.135%
1.33	4σ	cerca de 32 por milhão

É o problema inverso da normal lido ao contrário: lá, dada a fração aceitável, achava-se o limite; aqui, dado o limite, mede-se a folga.

NA COMPUTAÇÃO Tarefas de tempo real

Uma tarefa periódica que deve disparar a cada 10 ms com tolerância de ± 0.3 ms falha tanto se disparar cedo quanto tarde: a especificação é naturalmente bilateral. C_p diz se o jitter cabe na janela; C_{pk} diz se, com o atraso médio atual, a tarefa está de fato dentro dela.

C_p	C_{pk}	Diagnóstico	Intervenção
alto	baixo	centragem (um atraso sistemático de agendamento)	mover a média
baixo	baixo	variabilidade	reduzir σ

CUIDADO Latência não é normal

Para latência, normalmente só existe limite superior (o SLO), e usa-se só $C_{pu} = \frac{LSE - \mu}{3\sigma}$. Mas os índices supõem normalidade, e latências raramente são normais: a cauda real costuma ser muito mais pesada, e um C_{pu} confortável pode conviver com muitas violações do SLO. Para latência, é melhor medir diretamente a fração acima do SLO, ou o percentil correspondente. Além disso, com poucos dados, C_p é muito incerto, e a escolha do σ (curto ou longo prazo) muda o resultado.

O termo "seis sigma" vem daqui: um processo com LSE a 6σ da média ($C_p = 2$). A convenção da indústria supõe que a média se desloca até 1.5σ ao longo do tempo, sobrando 4.5σ até o limite, o que dá

cerca de 3.4 falhas por milhão: a mesma ordem de grandeza dos "noves" de disponibilidade, 99.9997%.

CONEXÕES

- 5.3 z-score.
- 5.6 problema inverso.
- 6.4 percentis amostrais.
- 7.7 incerteza de σ .
- 9.7 C_p e P_p .
- 1.7 nove de disponibilidade.

▼ Entendendo a fórmula, termo a termo

$$C_p = \frac{LSE - LIE}{6\sigma}, \quad C_{pk} = \frac{\min(LSE - \mu, \mu - LIE)}{3\sigma}$$

$LSE - LIE$ ← Largura permitida pelo cliente.

6σ ← Largura natural do processo (contém 99.73% da produção).

$\min(\cdot)$ ← Distância da média até o limite mais próximo: o lado crítico.

3σ ← Meia largura natural.

De onde vem, passo a passo

1. C_p compara larguras: quantas vezes o processo "cabe" na especificação, supondo-o centrado.
2. C_{pk} mede quantas meias larguras cabem entre a média e o limite mais próximo.
3. A distância em desvios padrão até esse limite é $z = 3C_{pk}$, então a fração fora daquele lado é $1 - \Phi(3C_{pk})$.
4. Sempre $C_{pk} \leq C_p$, com igualdade só se o processo estiver centrado.

EXEMPLO RESOLVIDO **C_p alto não garante prazos cumpridos**

Uma tarefa de tempo real deve disparar a cada 10 ms, com tolerância de ± 0.3 ms (cedo ou tarde demais, o controle falha). O jitter é pequeno, mas o período médio saiu do

centro.

DADOS

- especificação 10 ± 0.3 ms: $LIE = 9.7$, $LSE = 10.3$
- $\sigma = 0.05$ ms, período médio atual 10.2 ms

O QUE SE PEDE

C_p , C_{pk} e a fração fora.

RESOLUÇÃO PASSO A PASSO

1 C_p : compara larguras

$$C_p = \frac{LSE - LIE}{6\sigma} = \frac{0.6}{0.3} = 2.0$$

A tolerância cabe duas vezes na variação natural: excelente potencial.

2 C_{pk} : distância ao limite mais próximo

$$C_{pk} = \frac{\min(LSE - \mu, \mu - LIE)}{3\sigma} = \frac{\min(0.1; 0.5)}{0.15} = 0.67$$

3 Fração fora

Acima de 10.3: $z = (10.3 - 10.2)/0.05 = 2$, logo $1 - \Phi(2) = 2.3\%$. Abaixo de 9.7: $z = -10$, praticamente zero.

RESPOSTA $C_p = 2.0$, $C_{pk} = 0.67$, 2.3% fora.

Basta recentrar o período (corrigir o atraso sistemático do escalonador) para que o potencial vire realidade.

C_{pk}	1.00	1.33	1.67
FORA (UM LADO)	≈ 1350 ppm	≈ 32 ppm	≈ 0.3 ppm

Exercício 9.5 • Índice Cpk

Uma tarefa periódica de tempo real deve disparar com período dentro de $[44.5; 45.5]$ ms; o período medido tem $\mu = 45.111$ e $\sigma = 0.222$ ms. Calcule C_{pk} .

Espaço para cálculo

9.6 Gráficos $\bar{X}$ - S e S^2 (Variância)

A amplitude estima bem a dispersão em subgrupos pequenos, mas desperdiça informação nos grandes: ela olha só o mínimo e o máximo, e com n grande é dominada por um único outlier. Para subgrupos maiores ($n > 10$), o desvio padrão de cada subgrupo é mais eficiente que a amplitude:

LIMITES COM $\bar{s}$

$$LSC_S = B_4 \bar{s}, \quad LC_S = \bar{s}, \quad LIC_S = B_3 \bar{s}$$

$$LSC_{\bar{X}} = \bar{\bar{x}} + A_3 \bar{s}, \quad LIC_{\bar{X}} = \bar{\bar{x}} - A_3 \bar{s}$$

$$\text{Gráfico } S^2 : LSC = \frac{\bar{s}^2}{n-1} \chi_{\alpha/2; n-1}^2, \quad LIC = \frac{\bar{s}^2}{n-1} \chi_{1-\alpha/2; n-1}^2$$

▼ Equação desmontada, variável por variável

$$LSC_S = B_4 \bar{s}, \quad LC_S = \bar{s}, \quad LIC_S = B_3 \bar{s}$$

$\bar{s}$ ← média dos desvios padrão dos subgrupos (ex.: 0.12 ms)

B_3, B_4 ← constantes da tabela (ex.: 0.185 e 1.815 para $n = 8$)

$$LSC_{\bar{X}} = \bar{\bar{x}} \pm A_3 \bar{s}$$

A_3 ← constante da tabela (ex.: 1.099 para $n = 8$)

$$LSC_{S^2} = \frac{\bar{s}^2}{n-1} \chi_{\alpha/2; n-1}^2$$

$\bar{s}^2$ ← variância média

$\chi_{\alpha/2; n-1}^2$ ← quantil da qui-quadrado

As constantes A_3 , B_3 , B_4 , c_4 e d_2 estão na aba Formulário & Tabelas.

DEDUÇÃO Lendo as constantes

- A lógica é a mesma do gráfico $\bar{X}-R$, com s no lugar de R : A_3 embute $3/(c_4\sqrt{n})$, em que c_4 corrige o viés de s como estimador de σ .
- O gráfico S^2 é o intervalo de confiança para a variância virado ao contrário: em vez de isolar σ^2 , fixa-se σ^2 no valor de referência e calcula-se a faixa em que s^2 deve cair. Como a qui-quadrado é assimétrica, os limites também são, e o LSC fica mais longe da linha central que o LIC.

CUIDADO Sensibilidade à normalidade

A sensibilidade da qui-quadrado à forma da distribuição vale aqui: com dados de cauda pesada, gráficos de variância disparam mais que o previsto.

NA COMPUTAÇÃO Em software, subgrupos são grandes

Numa janela de um minuto, um serviço atende centenas ou milhares de requisições, e o desvio padrão (ou um percentil) da janela é muito mais informativo que a amplitude. Com n tão grande, s é estimado com muita precisão e os limites ficam estreitos; isso torna as hipóteses de independência e de estabilidade ainda mais críticas, porque qualquer variação entre janelas que não seja ruído puro aparece como fora de controle.

INTUIÇÃO O limite inferior importa

Com $n \geq 6$, o limite inferior do gráfico S é positivo, e isso permite detectar quedas de variabilidade:

Queda de variabilidade	Leitura
boa	uma otimização que eliminou picos, o que se comprova com o teste unilateral para a variância
sintoma de problema	um servidor que responde erro instantaneamente para tudo tem latência baixíssima e quase constante

Uma métrica "boa demais" merece tanta atenção quanto uma ruim.

CONEXÕES

- 7.7** IC para variância.
- 8.7** teste para variância.
- 9.2** independência e estabilidade.
- 9.7** c_4 .

▼ Entendendo a fórmula, termo a termo

$$B_4 = 1 + \frac{3\sqrt{1-c_4^2}}{c_4}, \quad B_3 = \max\left(0, 1 - \frac{3\sqrt{1-c_4^2}}{c_4}\right)$$

 $c_4\sigma$ ← Valor médio de s (o desvio amostral subestima σ em média). $\sigma\sqrt{1-c_4^2}$ ← Desvio padrão de s . $\max(0, \dots)$ ← Para $n \leq 5$ o limite inferior seria negativo e é truncado.

De onde vem, passo a passo

1. $LSC = E[s] + 3 DP(s) = c_4\sigma + 3\sigma\sqrt{1-c_4^2}$.
2. Estime σ por $\bar{s}/c_4$: $LSC = \bar{s} \left(1 + \frac{3\sqrt{1-c_4^2}}{c_4}\right) = B_4\bar{s}$.
3. Verificação para $n = 5$ ($c_4 = 0.94$): $1 + 3(0.341)/0.94 = 2.089 \checkmark$.

EXEMPLO RESOLVIDO

Gráfico S com subgrupos de 8

Um gráfico acompanha a latência de 8 requisições por minuto (em ms). Com subgrupos assim, o desvio padrão do subgrupo é melhor que a amplitude.

DADOS

- $n = 8$, $\bar{s} = 0.12$ ms, $\bar{\bar{x}} = 25.00$ ms
- para $n = 8$: $B_3 = 0.185$, $B_4 = 1.815$, $A_3 = 1.099$

O QUE SE PEDE

Limites dos gráficos S e $\bar{X}$.

RESOLUÇÃO PASSO A PASSO

1 Gráfico S

$$LIC = B_3\bar{s} = 0.185 \times 0.12 = 0.022, \quad LC = 0.12, \quad LSC = B_4\bar{s} = 1.815 \times 0.1$$

2 Gráfico $\bar{X}$

$$\bar{\bar{x}} \pm A_3 \bar{s} = 25.00 \pm 1.099 \times 0.12 = 25.00 \pm 0.132 = [24.868; 25.132] \text{ ms}$$

RESPOSTA S: [0.022; 0.218]. $\bar{X}$: [24.868; 25.132] ms.

Com $n \geq 6$ o LIC de variabilidade passa a ser positivo: o gráfico também detecta *queda* de variabilidade, que pode ser uma melhoria a manter ou um sinal de problema (um servidor que responde erro instantâneo para tudo tem latência baixa e constante).

Exercício 9.6 • Limite Superior do Gráfico S

Em 20 janelas com $n = 10$ requisições cada, o desvio padrão médio da latência foi $\bar{s} = 0.8$ ms. (Para $n = 10$: $B_3 = 0.284$, $B_4 = 1.716$.) Calcule o LSC do gráfico S .

Espaço para cálculo

9.7 Estimando σ do Processo

Gráficos e índices de capacidade dependem de σ , e há mais de uma forma de estimá-lo a partir dos dados. A escolha não é técnica: ela decide qual variabilidade se está medindo. Para calcular C_p e C_{pk} a partir dos gráficos, estima-se a variabilidade *dentro* dos subgrupos: $\hat{\sigma} = \bar{R}/d_2$ ou $\hat{\sigma} = \bar{s}/c_4$. Ex.: $n = 5$, $\bar{R} = 2.326$ ms, $d_2 = 2.326$, logo $\hat{\sigma} = 1.0$ ms. Usar o desvio padrão de todos os dados juntos mistura a variação entre subgrupos e superestima σ se o processo oscilar.

DEDUÇÃO As constantes corrigem vieses

Estimador	Comportamento em amostras normais	Correção
$\bar{R}$	a amplitude média cresce com n : $E[R] = d_2\sigma$	$\bar{R}/d_2$
$\bar{s}$	s subestima σ em média, $E[s] = c_4\sigma$ com $c_4 < 1$, mesmo que s^2 seja não viesado para σ^2 (Jensen: a raiz é côncava)	$\bar{s}/c_4$

A diferença entre os dois estimadores de σ (dentro dos subgrupos ou de todos os dados) é a diferença entre curto e longo prazo:

INTUIÇÃO Curto prazo contra longo prazo

	$\hat{\sigma}$ dentro dos subgrupos	s de todos os dados
Mede	o que o sistema faz quando nada muda, minuto a minuto	inclui oscilações entre períodos: picos de horário, deploys, manutenção
Índices	C_p, C_{pk} (capacidade potencial)	P_p, P_{pk} (desempenho real)

A decomposição é a da probabilidade total aplicada a variâncias: a variância total é a média das variâncias dentro dos grupos mais a variância das médias entre grupos. A distância entre os dois índices mostra quanto se ganharia estabilizando o sistema; se forem iguais, o processo já é estável, e melhorar exige mudar o próprio sistema.

EXEMPLO C_p bom, P_p ruim

O exemplo desta seção mostra um serviço com $C_p = 1.33$ e $P_p = 0.89$: dentro de cada minuto o comportamento é estável, mas a média oscila ao longo do dia. Reportar só o C_p seria otimista; reportar só o P_p esconderia que o problema é a oscilação entre períodos, e não o ruído de curto prazo.

CUIDADO Medidas próximas no tempo

É o mesmo cuidado com dados correlacionados da estimação: medidas próximas no tempo subestimam a variação de longo prazo.

CONEXÕES

- 7.5 s subestima σ .
- 2.8 Jensen.
- 1.5 condicionar por cenários.
- 7.2 dados correlacionados.
- 9.1 mudar o sistema.

▼ Entendendo a fórmula, termo a termo

$$\hat{\sigma} = \frac{R}{d_2} = \frac{\bar{s}}{c_4}$$

d_2 ← Para dados normais, $E[\bar{R}] = d_2\sigma$: a amplitude média é d_2 desvios padrão.

c_4 ← Para dados normais, $E[s] = c_4\sigma$.

Dentro dos subgrupos ← Mede só a variação de curto prazo (causas comuns).

De onde vem, passo a passo

1. Como $E[\bar{R}] = d_2\sigma$, dividir por d_2 dá um estimador sem viés de σ .
2. d_2 cresce com n : em subgrupos maiores, a amplitude tende a ser maior para o mesmo σ .
3. Usar o desvio de todos os dados juntos mistura a variação entre subgrupos; isso gera os índices P_p/P_{pk} , e não C_p/C_{pk} .

EXEMPLO RESOLVIDO

Cp e Pp: variação de curto e longo prazo

A latência média de um serviço oscila entre horários (pico e madrugada). Dentro de cada minuto, a variação é menor que no conjunto de todos os dados.

DADOS

- dentro dos subgrupos: $\hat{\sigma} = \bar{R}/d_2 = 1.0$ ms
- todos os dados juntos: $s = 1.5$ ms
- largura da especificação: 8 ms

O QUE SE PEDE

 C_p e P_p .

RESOLUÇÃO PASSO A PASSO

1 C_p : variação de curto prazo

$$C_p = \frac{8}{6 \times 1.0} = 1.33$$

Potencial do serviço, se as oscilações entre horários fossem eliminadas (por exemplo, com mais capacidade no pico).

2 P_p : variação total

$$P_p = \frac{8}{6 \times 1.5} = 0.89$$

Desempenho real, com as oscilações.

RESPOSTA $C_p = 1.33$; $P_p = 0.89$.

A diferença entre os dois índices mede quanto se ganha estabilizando o serviço.

Exercício 9.7 • C_p a partir do Gráfico de Controle

Um gráfico $\bar{X}-R$ com subgrupos de $n = 5$ está sob controle, com $\bar{R} = 3.3$ ms ($d_2 = 2.326$). A especificação é nominal ± 3.5 ms. Calcule C_p .

Espaço para cálculo

9.8 Gráficos np e c

O gráfico p acompanha uma fração. Há duas variações para contagens, e a escolha entre elas é a mesma distinção entre itens e ocorrências do Módulo 3:

ATRIBUTOS

$$np \text{ (nº de itens com falha, } n \text{ constante)} : LC = n\bar{p}, \quad n\bar{p} \pm 3\sqrt{n\bar{p}(1-\bar{p})}$$

$$c \text{ (nº de ocorrências por unidade, Poisson)} : LC = \bar{c}, \quad \bar{c} \pm 3\sqrt{\bar{c}}$$

▼ Equação desmontada, variável por variável

$$np : LC = n\bar{p}, \quad n\bar{p} \pm 3\sqrt{n\bar{p}(1-\bar{p})}$$

$$n\bar{p} \quad \leftarrow \text{nº médio de itens com falha por subgrupo (ex.: } 50 \times 0.06 = 3)$$

$$\sqrt{n\bar{p}(1-\bar{p})} \quad \leftarrow \text{desvio padrão binomial (ex.: 1.68)}$$

$$c : LC = \bar{c}, \quad \bar{c} \pm 3\sqrt{\bar{c}}$$

$$\bar{c} \quad \leftarrow \text{nº médio de ocorrências por unidade (ex.: 4 bugs por release)}$$

$$\sqrt{\bar{c}} \quad \leftarrow \text{desvio padrão de Poisson (ex.: 2); } LSC = 4 + 6 = 10$$

O gráfico p (e o np) conta *itens com falha* (binomial: requisições com erro em n); o gráfico c conta *ocorrências* numa unidade de observação (Poisson: crashes por dia, bugs por release, alertas por plantão). Limites inferiores negativos são truncados em zero.

INTUIÇÃO A regra de 3σ aplicada aos modelos do Módulo 3

	np	c
Conta	itens com falha	ocorrências por unidade
Modelo	binomial: média np , variância $np(1 - p)$	Poisson: média igual à variância, por isso o desvio é $\sqrt{c}$
Vantagem	é o gráfico p multiplicado por n ; com n constante, mostra contagens inteiras	um único número define o gráfico inteiro

EXEMPLO Bugs por release

Se uma equipe encontra em média 4 bugs em produção por release, o LSC é $4 + 3 \times 2 = 10$. Uma release com 11 bugs merece retrospectiva: algo mudou no processo (revisão mais fraca, prazo apertado, componente novo). Uma release com 9 bugs, ainda que pareça ruim, está dentro da variação esperada, e reagir a ela seria o erro de tratar causa comum como especial.

CUIDADO Superdispersão

O gráfico c herda a hipótese mais frágil da Poisson. Em contagens de software, a variância costuma ser maior que a média: erros vêm em rajadas, um bug causa vários alertas, um incidente gera dezenas de tickets. Com superdispersão, os limites $\bar{c} \pm 3\sqrt{\bar{c}}$ ficam estreitos demais e o gráfico dispara à toa. O diagnóstico é comparar média e variância históricas, ou um teste de aderência; o remédio é usar a variância observada nos limites, ou um modelo com variância maior que a média, como a binomial negativa.

CONEXÕES

- 3.2** binomial.
- 3.3** Poisson e superdispersão.
- 3.5** itens contra ocorrências.
- 8.10** teste de aderência.
- 9.1** causas comuns e especiais.

▼ Entendendo a fórmula, termo a termo

$$c : \bar{c} \pm 3\sqrt{\bar{c}}, \quad np : n\bar{p} \pm 3\sqrt{n\bar{p}(1-\bar{p})}$$

$$\sqrt{\bar{c}}$$

← Na Poisson, a variância é igual à média.

$$\sqrt{n\bar{p}(1-\bar{p})}$$

← Desvio padrão da binomial (contagem de itens com falha).

Truncar em 0

← Contagens não podem ser negativas.

De onde vem, passo a passo

1. Ocorrências por unidade $\sim \text{Poisson}(c)$: $\sigma = \sqrt{c}$. Aplique $LC \pm 3\sigma$ com c estimado por $\bar{c}$.
2. Itens com falha por subgrupo $\sim B(n, p)$: $\sigma = \sqrt{np(1-p)}$.
3. O gráfico np é o gráfico p multiplicado por n : mesmas conclusões, em contagens.

EXEMPLO RESOLVIDO

Gráficos c e np

Dois gráficos de atributos de uma equipe de desenvolvimento e operação.

DADOS

- c : média de 4 bugs em produção por release
- np : $n = 50$ requisições amostradas por janela, fração lenta (acima do SLO) $\bar{p} = 0.06$

O QUE SE PEDE

Limites de cada gráfico.

RESOLUÇÃO PASSO A PASSO

1

Gráfico c (Poisson)

Na Poisson, a variância é igual à média, logo $\sigma = \sqrt{\bar{c}}$:

$$LSC = 4 + 3\sqrt{4} = 10, \quad LIC = \max(0; 4 - 6) = 0$$

Uma release com 11 bugs é sinal.

2 Gráfico np (binomial)

$$LC = n\bar{p} = 3, \quad LSC = 3 + 3\sqrt{3 \times 0.94} = 3 + 5.04 = 8.04, \quad LIC = \max(0; 3)$$

Uma janela com 9 requisições lentas é sinal.

RESPOSTA c: [0; 10]. np: [0; 8.04].

O gráfico np é mais simples (conta-se itens, sem dividir), mas exige n constante, o que se obtém amostrando um número fixo de requisições por janela.

Exercício 9.8 • LIC do Gráfico c

Uma equipe conta quantos bugs chegam à produção em cada release. A média histórica é $\bar{c} = 10.5$ bugs/release. Calcule o LIC do gráfico c .

Espaço para cálculo

9.9 Regras de Sensibilidade e Fases do CEP

Um ponto fora de 3σ detecta bem mudanças grandes e súbitas. Mas muitos problemas reais são pequenos e persistentes: um deslocamento de 1σ na média raramente leva um ponto além do limite, e o gráfico pode levar dezenas de pontos para perceber. Padrões na sequência de pontos carregam informação que pontos isolados não carregam. Além de um ponto fora dos limites de 3σ , indicam causa especial (regras da Western Electric): 2 de 3 pontos consecutivos além de 2σ do mesmo lado; 4 de 5 além de 1σ do mesmo lado; 8 pontos seguidos do mesmo lado da linha central; 6 pontos seguidos crescentes ou decrescentes (ex.: vazamento de memória fazendo o uso crescer aos poucos). Cada regra extra aumenta a sensibilidade, mas também a taxa de alarme falso.

Fase I: estimar limites com dados históricos (linha de base), remover períodos com causa identificada (incidentes) e recalculá-los. **Fase II:** limites fixos para monitorar a operação corrente.

DEDUÇÃO Cada regra é uma probabilidade calculável

"8 pontos seguidos do mesmo lado" tem chance 0.5^8 para um lado, pela independência, ou $2 \times 0.5^8 = 0.0078$ contando os dois lados, comparável ao 0.0027 da regra de 3σ . As regras foram calibradas para terem taxas de alarme falso parecidas, cada uma sensível a um padrão diferente. Mas usar várias ao mesmo tempo soma as taxas, pelo limitante da união: com as quatro regras principais, o intervalo médio entre alarmes falsos cai de 370 para cerca de 90 pontos. É o problema das comparações múltiplas de novo.

As regras de sequência são o que pega degradações lentas: vazamentos de memória, crescimento gradual de uma tabela sem índice, fragmentação de disco. Nenhum ponto passa dos limites, mas a série sobe devagar e de forma persistente, a assinatura do envelhecimento de software. Dois gráficos levam a ideia de acumular evidência mais longe:

NA COMPUTAÇÃO EWMA e CUSUM

Gráfico	Como acumula evidência
EWMA	plota uma média móvel exponencialmente ponderada, $W_t = \lambda x_t + (1 - \lambda)W_{t-1}$; como média de muitos pontos, tem variância menor e detecta deslocamentos pequenos muito antes
CUSUM	soma os desvios em relação à meta e alarma quando a soma acumulada passa de um limiar

Para um deslocamento de 1σ , eles reduzem o tempo médio de detecção de dezenas de pontos para cerca de dez, com a mesma taxa de alarme falso: muito mais poder contra mudanças pequenas e persistentes. São a base de muitos detectores de anomalia em métricas.

INTUIÇÃO As duas fases são estimação e teste

	Fase I	Fase II
Tarefa	estimação: μ e σ da linha de base, removendo incidentes, porque a linha de base deve representar o sistema sem causas especiais	teste: cada novo ponto comparado com limites fixos
Cuidado	dados suficientes: limites calculados com poucos subgrupos herdam a incerteza de $\hat{\sigma}$, e uma linha de base ruim compromete toda a Fase II	rever a linha de base depois de mudanças intencionais (versão mais rápida, migração de infraestrutura)

CUIDADO Reaprender a linha de base rápido demais

Ferramentas de detecção de anomalias reaprendem a linha de base continuamente, com janelas móveis. O risco é simétrico ao do tampering: reaprender rápido demais faz o detector "aprender" uma degradação lenta como se fosse o novo normal, e ela nunca dispara alarme.

Este módulo fecha o percurso do curso. Começamos com eventos e axiomas (Módulo 1); construímos variáveis e distribuições para descrever sistemas (Módulos 2 a 5); usamos dados para estimar essas distribuições (Módulos 6 e 7); e usamos as estimativas para tomar decisões com taxas de erro controladas (Módulo 8). Um gráfico de controle é tudo isso funcionando continuamente: um modelo probabilístico do comportamento normal, estimado com dados, testado a cada novo ponto, com o custo dos dois tipos de erro pesando na escolha dos limites.

CONEXÕES

- 1.2 limitante da união.
- 8.3 comparações múltiplas.
- 5.5 envelhecimento de software.
- 8.9 poder.
- 7.7 incerteza de $\hat{\sigma}$.
- 9.1 tampering.

▼ Entendendo a fórmula, termo a termo

$$P(8 \text{ seguidos do mesmo lado}) = 2(0.5)^8 \approx 0.0078$$

0.5 ← Sob controle, cada ponto fica acima ou abaixo da LC com chance 1/2.

$(0.5)^8$ ← Oito pontos independentes do mesmo lado (acima).

$\times 2$ ← Pode ser acima ou abaixo.

De onde vem, passo a passo

1. Regra 1 (um ponto fora de 3σ): ≈ 0.0027 .
2. 2 de 3 além de 2σ do mesmo lado: com $q = 1 - \Phi(2) = 0.0228$, $P \approx 2[3q^2(1 - q) + q^3] \approx 0.0031$.
3. 6 seguidos crescentes ou decrescentes: das $6! = 720$ ordens possíveis, só 2 são monótonas, $P = 2/720 \approx 0.0028$.
4. Cada regra é calibrada para alarme falso de mesma ordem que a regra de 3σ , mas detecta padrões que a regra 1 demora a ver. Usar todas juntas aumenta os alarmes falsos.

EXEMPLO RESOLVIDO

Deslocamento pequeno, nenhum ponto fora

As médias de latência de 8 janelas, em unidades de σ a partir da linha central, depois de um deploy.

DADOS

- 0.5; 1.2; 1.4; 0.8; 1.1; 0.3; 0.9; 1.6

O QUE SE PEDE

O processo está sob controle?

RESOLUÇÃO PASSO A PASSO

1

Regra 1: ponto além de 3σ

O maior valor é 1.6. Nenhum ponto passa de 3: a regra básica não sinaliza.

2 Regra de sequência

Os 8 pontos estão do mesmo lado (acima) da linha central. Sob controle, cada ponto tem chance $1/2$ de estar acima:

$$P(8 \text{ acima}) = 0.5^8 = 0.0039$$

Raro demais para ser acaso: sinal de deslocamento da média.

RESPOSTA Fora de controle, pela regra de sequência.

Desvios pequenos e persistentes (cerca de 1σ), como uma regressão de desempenho leve, demoram muito a gerar um ponto fora de 3σ . As regras de sequência os detectam bem antes.

Exercício 9.9 • Regras de Sensibilidade (Western Electric)

A tabela mostra 9 médias consecutivas de um gráfico $\bar{X}$, em unidades de σ a partir da linha central. Que sinal aparece?

SUBGRUPO	1	2	3	4	5	6	7	8	9
DISTÂNCIA À LC (EM Σ)	0.2	-0.4	-0.2	-0.8	-0.4	-0.6	-1.0	-0.5	-0.2

Espaço para cálculo

- ☐ 6 pontos consecutivos crescentes
- ☐ Um ponto além de 3σ
- ☐ Nenhum sinal: processo sob controle
- ☐ 8 pontos consecutivos do mesmo lado da linha central

Exercícios de Fixação com Soluções Comentadas

3 Questões Resolvidas

Exercício 9.1: Determinação dos Limites de Controle $\bar{X}$ e R

Para monitorar a latência de um serviço, coletaram-se 20 subgrupos de $n = 5$ requisições (um subgrupo por minuto). Obteve-se $\bar{\bar{X}} = 100.0$ ms e $\bar{R} = 2.4$ ms. Sabendo que para $n = 5$ as constantes são $A_2 = 0.577$, $D_3 = 0$ e $D_4 = 2.114$, determine os limites de controle para os gráficos $\bar{X}$ e R .

Espaço para cálculo

Exercício 9.2: Capacidade de uma Tarefa de Tempo Real (C_p e C_{pk})

Um laço de controle de tempo real deve executar com período de 30.0 ± 0.6 ms ($LIE = 29.4$ ms e $LSE = 30.6$ ms). O período medido está estável, com média $\mu = 30.15$ ms e desvio padrão (jitter) $\sigma = 0.10$ ms.

- (a) Calcule o C_p .
- (b) Calcule o C_{pk} e interprete a diferença.

Espaço para cálculo

Exercício 9.3: Gráfico p para a Taxa de Erro de uma API

A cada hora, $n = 200$ requisições de uma API são sorteadas e verificadas. A proporção média de requisições com erro é $\bar{p} = 0.05$ (5%). Calcule os limites de controle LSC e LIC para o gráfico p .

Espaço para cálculo

Soluções dos Exercícios

Módulo 1: Teoria Fundamental da Probabilidade

Exercício 1.1 • Espaço Amostral Equiprovável

Dados do problema

- $\#\Omega = 36$: pares ordenados (dado 1, dado 2), todos equiprováveis

Fórmula usada

$$P(A) = \frac{\#A}{\#\Omega}$$

Substituição e cálculo, passo a passo

1. Os 36 pares são equiprováveis, mas as 11 somas possíveis (2 a 12) **não** são: há mais maneiras de obter 7 do que 2.
2. Liste os pares com soma 5: (1,4), (2,3), (3,2), (4,1). Logo $\#A = 4$.

$$3. \quad P = \frac{4}{36} = 0.1111$$

Resposta: 0.1111

Exercício 1.2 • Regra da Adição

Dados do problema

- $P(A) = 0.22$: probabilidade de timeout no banco de dados
- $P(B) = 0.32$: probabilidade de erro de autenticação
- $P(A \cap B) = 0.1$: probabilidade das duas falhas juntas

Fórmula usada

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

Substituição e cálculo, passo a passo

1. "Pelo menos uma" é a união $A \cup B$.

$$2. \quad P(A \cup B) = 0.22 + 0.32 - 0.1 = 0.44$$

(a interseção foi somada duas vezes em $P(A) + P(B)$; subtrai-se uma).

Resposta: 0.4400

Exercício 1.3 • Regra do Produto sem Reposição**Dados do problema**

- $N = 20$: arquivos de backup na pasta
- $D = 2$: arquivos corrompidos
- $N - D = 18$: arquivos íntegros

Fórmula usada

$$P(A_1 \cap A_2) = P(A_1) P(A_2|A_1)$$

Substituição e cálculo, passo a passo

- 1.ª retirada: $P(Q_1) = \frac{2}{20} = 0.1000$.
2. Sem reposição, restam 1 corrompidos entre 19 arquivos: $P(Q_2|Q_1) = \frac{1}{19} = 0.0526$.
3.
$$P(Q_1 \cap Q_2) = 0.1000 \times 0.0526 = 0.0053$$
4. Com reposição seria $(2/20)^2 = 0.0100$: o "sem reposição" muda a 2ª probabilidade.

Resposta: 0.0053

Exercício 1.4 • Teste de Independência**Substituição e cálculo, passo a passo**

1. Critério: A e B são independentes se e somente se $P(A \cap B) = P(A)P(B)$.
2. Calcule o produto: $P(A)P(B) = 0.6 \times 0.6 = 0.3600$.
3. Compare com o observado $P(A \cap B) = 0.32$: são diferentes, logo dependentes.
4. Interpretação: $P(A|B) = 0.32/0.6 = 0.5333 \neq P(A) = 0.6$; saber de B muda a chance de A .
5. Não são mutuamente exclusivos, pois $P(A \cap B) > 0$.

Resposta: Não, pois $P(A \cap B) \neq P(A)P(B)$.

Exercício 1.5 • Teorema da Probabilidade Total**Dados do problema**

- $P(F_1) = 0.2$: fração do tráfego no servidor 1
- $P(F_2) = 0.6$: fração do tráfego no servidor 2
- $P(F_3) = 0.2$: fração do tráfego no servidor 3
- $P(D|F_1) = 0.02$: taxa de erro do servidor 1
- $P(D|F_2) = 0.015$: taxa de erro do servidor 2
- $P(D|F_3) = 0.015$: taxa de erro do servidor 3

Fórmula usada

$$P(D) = \sum_{i=1}^3 P(F_i) P(D|F_i)$$

Substituição e cálculo, passo a passo

1. Os servidores formam uma partição: $0.2 + 0.6 + 0.2 = 1$.
2. Caminho do servidor 1: $0.2 \times 0.02 = 0.00400$.
3. Caminho do servidor 2: $0.6 \times 0.015 = 0.00900$.
4. Caminho do servidor 3: $0.2 \times 0.015 = 0.00300$.
5.
$$P(D) = 0.00400 + 0.00900 + 0.00300 = 0.01600$$
6. Erro comum: média simples das taxas (0.0167) ignora os pesos.

Resposta: 0.0160**Exercício 1.6 • Teorema de Bayes na Detecção de Malware****Dados do problema**

- $P(T) = 0.03$: fração de arquivos com malware (a priori)
- $P(+|T) = 0.98$: sensibilidade do antivírus
- $P(+|T^c) = 0.05$: taxa de falso alarme nos arquivos limpos
- $P(T^c) = 0.97$: arquivos limpos = $1 - P(T)$

Fórmula usada

$$P(+) = P(T)P(+|T) + P(T^c)P(+|T^c)$$

$$P(T|+) = \frac{P(T)P(+|T)}{P(+)}$$

Substituição e cálculo, passo a passo

1. Positivos verdadeiros: $P(T)P(+|T) = 0.03 \times 0.98 = 0.02940$.
2. Falsos positivos: $P(T^c)P(+|T^c) = 0.97 \times 0.05 = 0.04850$.
3. Total de positivos: $P(+) = 0.02940 + 0.04850 = 0.07790$.
4.
$$P(T|+) = \frac{0.02940}{0.07790} = 0.3774$$
5. Interpretação: dos alarmes, 37.74% são malware real; o resto é falso alarme, porque há muito mais arquivos limpos do que maliciosos.

Resposta: 0.3774

Exercício 1.7 • Disponibilidade Série-Paralelo**Dados do problema**

- $R_1 = 0.8$: disponibilidade da réplica 1
- $R_2 = 0.87$: disponibilidade da réplica 2
- $R_V = 0.97$: disponibilidade do banco de dados

Fórmula usada

$$R_{par} = 1 - (1 - R_1)(1 - R_2)$$

$$R_{sis} = R_{par} \cdot R_V$$

Substituição e cálculo, passo a passo

1. Indisponibilidade de cada réplica: $1 - 0.8 = 0.20$ e $1 - 0.87 = 0.13$.
2. O paralelo só cai se ambas caírem: $0.20 \times 0.13 = 0.0260$, logo $R_{par} = 0.9740$.
3. Em série com o banco:

$$R_{sis} = 0.9740 \times 0.97 = 0.9448$$

Resposta: 0.9448**Exercício 1.8 • Amostragem sem Reposição (Contagem)****Dados do problema**

- $N = 25$: arquivos no backup
- $D = 5$: arquivos corrompidos no backup
- $n = 4$: arquivos auditados
- $k = 1$: corrompidos desejados na amostra

Fórmula usada

$$P(X = k) = \frac{\binom{D}{k} \binom{N-D}{n-k}}{\binom{N}{n}}$$

Substituição e cálculo, passo a passo

1. Amostras possíveis (ordem não importa): $\binom{25}{4} = 12650$.
2. Escolher os corrompidos: $\binom{5}{1} = 5$. Escolher os íntegros: $\binom{20}{3} = 1140$.
3. Amostras favoráveis: $5 \times 1140 = 5700$ (princípio multiplicativo).

$$4. \quad P = \frac{5700}{12650} = 0.4506$$

5. A binomial com $p = 0.200$ daria 0.4096: erraria, pois sem reposição as retiradas não são independentes.

Resposta: 0.4506

Exercício 1.9 • Condicional Invertida em Tabela de Contingência**Dados do problema**

- $n_{D \cap \text{Noite}} = 42$: erros no período da Noite (célula)
- $n_{\text{Noite}} = 202$: requisições no período da Noite (linha)
- $n_D = 87$: total de erros (coluna)
- $N = 1327$: total geral

Fórmula usada

$$P(\text{período}|D) = \frac{n_{D \cap \text{período}}}{n_D}$$

Substituição e cálculo, passo a passo

1. Agora a condição é "erro": o universo é a coluna Erro, com 87 requisições.

2.
$$P(\text{Noite}|D) = \frac{42}{87} = 0.4828$$

3. Não confunda com $P(D|\text{Noite}) = 0.2079$: o numerador é o mesmo, o denominador muda.

Resposta: 0.4828

Exercício 1.10 • Árvore em Dois Estágios (Bayes Sequencial)**Dados do problema**

- $P(D) = 0.04$: contas comprometidas (a priori)
- $P(+|D) = 0.96$: sensibilidade de cada teste
- $P(+|D^c) = 0.02$: falso alarme de cada teste

Fórmula usada

$$P(D|++) = \frac{P(D) P(+|D)^2}{P(D) P(+|D)^2 + P(D^c) P(+|D^c)^2}$$

Substituição e cálculo, passo a passo

1. Testes independentes dada a condição real: as probabilidades dos dois alarmes se multiplicam ao longo do caminho.

2. Caminho D: $0.04 \times 0.96^2 = 0.04 \times 0.9216 = 0.036864$.

3. Caminho normal: $0.96 \times 0.02^2 = 0.96 \times 0.0004 = 0.000384$.

4.
$$P(D|++) = \frac{0.036864}{0.036864 + 0.000384} = 0.9897$$

5. Após um único alarme seria só 0.6667: repetir o teste é o remédio contra a falácia da taxa-base.

Resposta: 0.9897

Exercício 1.1: Disponibilidade de Arquitetura Mista (Série-Paralelo)**Resolução Passo a Passo:****1. Disponibilidade do par de servidores em paralelo (S):**

O par só fica indisponível se *ambos* os servidores caírem ao mesmo tempo.

Indisponibilidade de S_1 : $F_1 = 1 - R(S_1) = 1 - 0.90 = 0.10$.

Indisponibilidade de S_2 : $F_2 = 1 - R(S_2) = 1 - 0.85 = 0.15$.

Como os servidores são independentes, a probabilidade de ambos caírem é:

$$F_S = F_1 \times F_2 = 0.10 \times 0.15 = 0.015$$

Portanto, a disponibilidade do bloco paralelo é:

$$R(S) = 1 - F_S = 1 - 0.015 = 0.985 \quad (98.5\%)$$

2. Disponibilidade total (servidores em série com o banco U):

Para a API responder, o bloco S e o banco U precisam estar no ar:

$$R_{\text{api}} = R(S) \times R(U) = 0.985 \times 0.98 = 0.9653 \quad (96.53\%)$$

3. Probabilidade de a API estar fora do ar:

$$F_{\text{api}} = 1 - R_{\text{api}} = 1 - 0.9653 = 0.0347 \quad (3.47\%)$$

Conclusão: a redundância elevou a camada de aplicação de 85-90% para 98.5%. Agora o elo mais fraco é o banco de dados único: replicá-lo seria o próximo passo.

Exercício 1.2: Antivírus e o Teorema de Bayes**Resolução Passo a Passo:****1. Mapeamento dos eventos e probabilidades a priori:**

- D : arquivo malicioso $\implies P(D) = 0.02$
- D^c : arquivo limpo $\implies P(D^c) = 1 - 0.02 = 0.98$
- Sensibilidade (taxa de detecção): $P(+|D) = 0.98$
- Taxa de falso positivo: $P(+|D^c) = 0.03$

2. Cálculo da probabilidade total de alarme $P(+)$:

Pelo Teorema da Probabilidade Total:

$$P(+) = P(D) \cdot P(+|D) + P(D^c) \cdot P(+|D^c)$$

$$P(+) = (0.02 \times 0.98) + (0.98 \times 0.03)$$

$$P(+) = 0.0196 + 0.0294 = 0.0490 \quad (4.90\%)$$

3. Aplicação do Teorema de Bayes para calcular $P(D|+)$:

$$P(D|+) = \frac{P(D \cap +)}{P(+)} = \frac{P(D) \cdot P(+|D)}{P(+)}$$

$$P(D|+) = \frac{0.0196}{0.0490} = \frac{196}{490} = 0.4000 \quad (40.0\%)$$

Interpretação: embora o antivírus pareça "98% preciso", quando ele acusa, só há 40% de chance de o arquivo ser malicioso! A taxa base de malware (2%) é baixa em relação à de falsos positivos (3%), então há mais alarmes falsos (2.94% dos envios) do que verdadeiros (1.96%). Na prática, arquivos sinalizados vão para uma segunda análise (sandbox) antes do bloqueio definitivo.

Exercício 1.3: Origem de Builds Quebrados**Resolução Passo a Passo:****1. Definição dos termos:**

$$P(L_1) = 0.40, \quad P(L_2) = 0.35, \quad P(L_3) = 0.25$$

Probabilidades de falha condicional (D):

$$P(D|L_1) = 0.015, \quad P(D|L_2) = 0.020, \quad P(D|L_3) = 0.040$$

2. Probabilidade Total de um build falhar por ambiente $P(D)$:

$$P(D) = P(L_1)P(D|L_1) + P(L_2)P(D|L_2) + P(L_3)P(D|L_3)$$

$$P(D) = (0.40 \times 0.015) + (0.35 \times 0.020) + (0.25 \times 0.040)$$

$$P(D) = 0.0060 + 0.0070 + 0.0100 = 0.0230 \quad (2.30\%)$$

3. Probabilidade a posteriori de o build ter rodado em L_3 , $P(L_3|D)$:

$$P(L_3|D) = \frac{P(L_3)P(D|L_3)}{P(D)} = \frac{0.0100}{0.0230} = \frac{10}{23} \approx 0.4348 \quad (43.48\%)$$

Conclusão: apesar de L_3 executar só 25% dos builds, sua taxa de falha mais alta faz com que responda por 43.48% das falhas de ambiente. É o runner a investigar (imagem desatualizada, disco cheio, rede instável).

Módulo 2: Variáveis Aleatórias Discretas (VAD)**Exercício 2.1 • Esperança a partir do Experimento****Dados do problema**

- $p_1 = 0.2$: probabilidade de falha do disco 1 no dia
- $p_2 = 0.05$: probabilidade de falha do disco 2 no dia

Fórmula usada

$$E[X] = \sum_x x p(x)$$

Substituição e cálculo, passo a passo

1. $X = 0$ (nenhuma falha): $(1 - 0.2)(1 - 0.05) = 0.80 \times 0.95 = 0.7600$.
2. $X = 1$ (só a 1ª ou só a 2ª): $0.2 \times 0.95 + 0.80 \times 0.05 = 0.1900 + 0.0400 = 0.2300$.
3. $X = 2$ (ambas): $0.2 \times 0.05 = 0.0100$. Conferência: as três somam 1.

$$4. \quad E[X] = 0(0.7600) + 1(0.2300) + 2(0.0100) = 0.2500$$

5. Atalho: X é soma de duas indicadoras (1 se falha), logo $E[X] = p_1 + p_2$.

Resposta: 0.2500 discos

Exercício 2.2 • Constante de Normalização de uma FP**Dados do problema**

- $n = 4$: maior valor possível de X
- $p(x) = c(x + 1)$: forma da função de probabilidade

Fórmula usada

$$\sum_x p(x) = 1 \implies c = \frac{1}{\sum_x (x + 1)}$$

Substituição e cálculo, passo a passo

1. Condição de FP: $\sum_{x=0}^4 c(x + 1) = 1$.
2. Os termos $x + 1$ valem $1, 2, \dots, 5$, cuja soma é $1 + 2 + 3 + 4 + 5 = 15$.
3. Logo $15c = 1 \implies c = 1/15 = 0.0667$.

Resposta: 0.0667**Exercício 2.3 • Probabilidade de Intervalo pela FDA****Dados do problema**

- $p(0), p(1), p(2), p(3) = 0.3, 0.4, 0.15, 0.15$: probabilidades da tabela

Fórmula usada

$$P(a < X \leq b) = F(b) - F(a)$$

Substituição e cálculo, passo a passo

1. Acumule as probabilidades: $F(0) = 0.3$; $F(1) = 0.3 + 0.4 = 0.7$; $F(2) = 0.7 + 0.15 = 0.85$; $F(3) = 1$.
2.
$$P(0 < X \leq 3) = F(3) - F(0) = 1 - 0.3 = 0.7000$$
3. Note: o "<" em $0 < X$ exclui o valor 0, por isso subtrai-se $F(0)$.

Resposta: 0.7000**Exercício 2.4 • Esperança de uma VAD****Dados do problema**

- $x = 0, 1, 2, 3$: valores possíveis (crashes por dia)
- $p(x) = 0.15, 0.25, 0.15, 0.45$: probabilidades correspondentes

Fórmula usada

$$E[X] = \sum_x x p(x)$$

Substituição e cálculo, passo a passo

1. Multiplique cada valor pela sua probabilidade e some:

$$E[X] = 0(0.15) + 1(0.25) + 2(0.15) + 3(0.45) = 0.00 + 0.25 + 0.30 + 1.35 = 1.9000$$

2. A esperança é o centro de gravidade da distribuição; não precisa ser um valor possível de X .

Resposta: 1.9000 crashes

Exercício 2.5 • Variância de uma VAD**Dados do problema**

- $x = 0, 1, 2, 3$: valores possíveis (crashes por dia)
- $p(x) = 0.15, 0.15, 0.5, 0.2$: probabilidades correspondentes

Fórmula usada

$$\text{Var}(X) = E[X^2] - (E[X])^2$$

$$E[X^2] = \sum_x x^2 p(x)$$

Substituição e cálculo, passo a passo

1. Multiplique cada valor pela sua probabilidade e some:

$$E[X] = 0(0.15) + 1(0.15) + 2(0.5) + 3(0.2) = 0.00 + 0.15 + 1.00 + 0.60 = 1.7500$$

2. Agora com os quadrados $x^2 = 0, 1, 4, 9$:

$$E[X^2] = 0(0.15) + 1(0.15) + 4(0.5) + 9(0.2) = 3.9500$$

3. $(E[X])^2 = 1.7500^2 = 3.0625$.

4. $\text{Var}(X) = 3.9500 - 3.0625 = 0.8875$

5. Desvio padrão: $\sigma = \sqrt{0.8875} = 0.9421$ falhas.

Resposta: 0.8875

Exercício 2.6 • Percentil de uma VAD**Dados do problema**

- $p = 0.75$: fração desejada (percentil 75)
- $p(x) = 0.15, 0.2, 0.2, 0.15, 0.3$: probabilidades de $x = 0, \dots, 4$

Fórmula usada

$$x_p = \min\{x : F(x) \geq p\}$$

Substituição e cálculo, passo a passo

1. Acumule: $F(0) = 0.15$; $F(1) = 0.35$; $F(2) = 0.55$; $F(3) = 0.7$; $F(4) = 1$.
2. Procure o primeiro valor em que a FDA atinge 0.75: $F(0) = 0.15 < 0.75$, $F(1) = 0.35 < 0.75$, $F(2) = 0.55 < 0.75$, $F(3) = 0.7 < 0.75$, mas $F(4) = 1 \geq 0.75$.
3. Logo $x_{0.75} = 4$.

Resposta: 4

Exercício 2.7 • Variância de uma Soma (Tempo Total)**Dados do problema**

- $\sigma_P = 4.5$: desvio do tempo de processamento (ms)
- $\sigma_R = 3$: desvio do tempo de rede (ms)

Fórmula usada

$$\text{Var}(P + R) = \text{Var}(P) + \text{Var}(R) \quad (\text{independentes})$$

Substituição e cálculo, passo a passo

1. Transforme desvios em variâncias: $4.5^2 = 20.25$ e $3^2 = 9.00$.
2. Some as variâncias: $20.25 + 9.00 = 29.25$.
3.
$$\sigma = \sqrt{29.25} = 5.4083$$
4. Erro comum: somar os desvios padrão (7.5), o que superestima a incerteza.

Resposta: 5.4083 ms

Exercício 2.8 • Lucro Esperado com Estoque ($E[g(X)]$)**Dados do problema**

- $s = 2$: instâncias reservadas por dia
- $c = 25$: custo de reserva por instância (reais)
- $v = 75$: preço cobrado por instância usada (reais)

Fórmula usada

$$\text{lucro} = v \cdot \min(X, s) - c \cdot s$$

$$E[\text{lucro}] = v E[\min(X, s)] - c s$$

Substituição e cálculo, passo a passo

1. Não se usa mais do que se reservou: $\text{uso} = \min(X, 2)$, que valem 0, 1, 2, 2 para $x = 0, 1, 2, 3$.
2.
$$E[\min(X, 2)] = 0(0.3) + 1(0.25) + 2(0.25) + 2(0.2) = 1.1500$$
3. Custo fixo da reserva: $25 \times 2 = 50$ reais.
4.
$$E[\text{lucro}] = 75 \times 1.1500 - 50 = 36.25$$
5. Usar $E[X] = 1.35$ direto daria 51.25: $E[g(X)] \neq g(E[X])$.

Resposta: 36.25 reais

Exercício 2.1: Determinação de Constante e Esperança de VAD**Resolução Passo a Passo:****1. (a) Encontrando c pela condição de normalização $\sum p(x) = 1$:**

Substituindo os valores do suporte $x \in \{0, 1, 2, 3\}$:

$$p(0) = c(4 - 0) = 4c$$

$$p(1) = c(4 - 1) = 3c$$

$$p(2) = c(4 - 2) = 2c$$

$$p(3) = c(4 - 3) = 1c$$

Somando todas as probabilidades:

$$\sum_{x=0}^3 p(x) = 4c + 3c + 2c + 1c = 10c = 1 \implies c = \frac{1}{10} = 0.1$$

Portanto, a tabela de probabilidade é:

x	0	1	2	3
$p(x)$	0.40	0.30	0.20	0.10

2. (b) Cálculo da esperança matemática $E[X]$:

$$E[X] = \sum_{x=0}^3 x \cdot p(x) = 0(0.4) + 1(0.3) + 2(0.2) + 3(0.1)$$

$$E[X] = 0 + 0.3 + 0.4 + 0.3 = 1.0 \text{ pacote corrompido}/\mu s$$

Exercício 2.2: Construção da FDA e Percentis**Resolução Passo a Passo:****1. (a) Construção da FDA por partes:**

- Para $x < 0$: $F(x) = 0$
- Para $0 \leq x < 1$: $F(x) = p(0) = 0.40$
- Para $1 \leq x < 2$: $F(x) = p(0) + p(1) = 0.70$
- Para $2 \leq x < 3$: $F(x) = 0.70 + p(2) = 0.90$
- Para $x \geq 3$: $F(x) = 0.90 + p(3) = 1.00$

2. (b) Cálculo de $P(1 \leq X \leq 2)$:

$$P(1 \leq X \leq 2) = P(X = 1) + P(X = 2) = 0.30 + 0.20 = 0.50$$

Via FDA: $F(2) - F(0) = 0.90 - 0.40 = 0.50$.

3. (c) Mediana e 80º percentil:

- Mediana ($p = 0.50$): Como $F(0) = 0.40 < 0.50$ e $F(1) = 0.70 \geq 0.50$, o menor x com $F(x) \geq 0.50$ é $x = 1$.
- 80º percentil ($p = 0.80$): $F(1) = 0.70 < 0.80$ e $F(2) = 0.90 \geq 0.80$, logo o percentil é $x = 2$.

Exercício 2.3: Variância e Custo Operacional Linearizado**Resolução Passo a Passo:****1. (a) Cálculo de $E[X^2]$ e $Var(X)$:**

$$E[X^2] = \sum x^2 p(x) = 0^2(0.4) + 1^2(0.3) + 2^2(0.2) + 3^2(0.1)$$

$$E[X^2] = 0 + 0.3 + 0.8 + 0.9 = 2.0$$

$$Var(X) = E[X^2] - (E[X])^2 = 2.0 - (1.0)^2 = 1.0 \text{ pacote}^2$$

$$\sigma_X = \sqrt{1.0} = 1.0 \text{ pacote}$$

2. (b) Transformação Linear $C = 50X + 120$:

Aplicando a linearidade da esperança:

$$E[C] = 50 \cdot E[X] + 120 = 50(1.0) + 120 = 170.00 \text{ reais}$$

Aplicando a propriedade da variância sob escala $a = 50$:

$$Var(C) = 50^2 \cdot Var(X) = 2500 \times 1.0 = 2500 \text{ reais}^2$$

$$\sigma_C = \sqrt{Var(C)} = 50 \cdot \sigma_X = 50 \times 1.0 = 50.00 \text{ reais}$$

Note que o termo fixo (+120) desloca o custo médio, mas não tem qualquer efeito sobre a incerteza ou desvio padrão da operação.

Módulo 3: Modelos Discretos de Probabilidade**Exercício 3.1 • Uniforme Discreta: Variância****Dados do problema**

- $a = 1$: menor endereço
- $b = 6$: maior endereço

Fórmula usada

$$k = b - a + 1$$

$$Var(X) = \frac{k^2 - 1}{12}$$

Substituição e cálculo, passo a passo

1. Conte os valores: $k = 6 - 1 + 1 = 6$ (o "+1" inclui as duas pontas).
2. $k^2 = 36$.

$$3. \quad Var(X) = \frac{36 - 1}{12} = \frac{35}{12} = 2.9167$$

4. Não use $(b - a)^2 / 12 = 2.0833$: essa é a fórmula da uniforme *contínua*.

Resposta: 2.9167

Exercício 3.2 • Binomial: Tolerância a Perdas**Dados do problema**

- $n = 11$: pacotes enviados (ensaios)
- $p = 0.09$: probabilidade de perda de cada pacote
- $q = 1 - p = 0.91$: probabilidade de o pacote chegar

Fórmula usada

$$P(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}$$

$$P(X \leq 1) = P(X = 0) + P(X = 1)$$

Substituição e cálculo, passo a passo

1. $P(X = 0) = \binom{11}{0} p^0 q^{11} = 0.91^{11} = 0.3544$ (nenhuma perda).
2. $P(X = 1) = \binom{11}{1} p^1 q^{10} = 11 \times 0.09 \times 0.3894 = 0.3855$.
3. $P(X \leq 1) = 0.3544 + 0.3855 = 0.7399$

Resposta: 0.7399**Exercício 3.3 • Poisson: Contagem em um Intervalo****Dados do problema**

- $\lambda = 2$: taxa de erros por hora
- $t = 3$: duração do intervalo (h)
- $k = 2$: número de erros desejado

Fórmula usada

$$\mu = \lambda t$$

$$P(X = k) = \frac{e^{-\mu} \mu^k}{k!}$$

Substituição e cálculo, passo a passo

1. Ajuste a taxa ao intervalo: $\mu = 2 \times 3 = 6$ erros esperados em 3 h.
2. $e^{-6} = 0.0025$; $6^2 = 36.0000$; $2! = 2$.
3. $P(X = 2) = \frac{0.0025 \times 36.0000}{2} = 0.0446$
4. Erro comum: usar $\lambda = 2$ sem multiplicar por t .

Resposta: 0.0446

Exercício 3.4 • Aproximação da Binomial pela Poisson**Dados do problema**

- $n = 375$: arquivos no backup (ensaios)
- $p = 0.004$: probabilidade de corrupção de cada arquivo
- $k = 0$: número de arquivos corrompidos desejado

Fórmula usada

$$\lambda = np$$

$$P(X = k) \approx \frac{e^{-\lambda} \lambda^k}{k!}$$

Substituição e cálculo, passo a passo

1. Condições: $n = 375$ grande e $p = 0.004$ pequeno; vale a aproximação.
2. $\lambda = 375 \times 0.004 = 1.50$.
3. $e^{-1.50} = 0.2231$; $1.50^0 = 1.0000$; $0! = 1$.

$$4. \quad P(X = 0) \approx \frac{0.2231 \times 1.0000}{1} = 0.2231$$

5. O valor binomial exato seria 0.2225: diferença desprezível.

Resposta: 0.2231**Exercício 3.5 • Escolha do Modelo Discreto****Substituição e cálculo, passo a passo**

1. Pergunte: existe um número máximo de ocorrências? As tentativas são independentes, com a mesma probabilidade? Há retirada sem reposição de um conjunto pequeno?
2. Resposta: **Binomial**.
3. n ensaios independentes com mesmo p , contando sucessos (há máximo n).

Resposta: Binomial

Exercício 3.6 • Dimensionando um Teste ("Pelo Menos Um")**Dados do problema**

- $p = 0.08$: chance de o bug se manifestar em cada execução
- $c = 0.99$: probabilidade mínima de detectar

Fórmula usada

$$1 - (1 - p)^n \geq c \iff n \geq \frac{\ln(1 - c)}{\ln(1 - p)}$$

Substituição e cálculo, passo a passo

1. "Pelo menos uma" = $1 - P(\text{nenhuma}) = 1 - (1 - 0.08)^n$.
2. Exigir ≥ 0.99 equivale a $(0.92)^n \leq 0.01$.
3. Logaritmos: $\ln 0.01 = -4.6052$ e $\ln 0.92 = -0.0834$ (ambos negativos).

$$4. \quad n \geq \frac{-4.6052}{-0.0834} = 55.23$$

(ao dividir por número negativo, a desigualdade se inverte).

5. Arredonde para cima: $n = 56$ execuções.

Resposta: 56 execuções

Exercício 3.7 • Poisson a partir de $P(X=0)$ **Dados do problema**

- $P(X = 0) = 0.9$: fração de plantões sem alerta
- $t = 8$: duração do plantão (h)

Fórmula usada

$$\mu = -\ln P(X = 0)$$

$$P(X = 1) = e^{-\mu} \mu$$

Substituição e cálculo, passo a passo

1. Na Poisson, $P(X = 0) = e^{-\lambda t}$. Iguale ao observado: $e^{-\lambda t} = 0.9$.
2. Aplique $\ln$ dos dois lados: $-\lambda t = \ln 0.9 = -0.1054$, logo $\mu = \lambda t = 0.1054$ alertas por plantão.
3. $P(X = 1) = \frac{e^{-\mu} \mu^1}{1!}$, e $e^{-\mu}$ já é conhecido: vale 0.9.

$$4. \quad P(X = 1) = 0.9 \times 0.1054 = 0.0948$$

Resposta: 0.0948

Exercício 3.1: Perda de Pacotes com Distribuição Binomial**Resolução Passo a Passo:**

1. **Modelagem:** Seja X o número de pacotes perdidos na rajada. Como cada pacote se perde independentemente com $p = 0.04$, temos $X \sim B(n = 8, p = 0.04)$.

$$P(X = k) = \binom{8}{k} (0.04)^k (0.96)^{8-k}$$

2. **(a) Para $k = 1$:**

$$P(X = 1) = \binom{8}{1} (0.04)^1 (0.96)^7 = 8 \times 0.04 \times (0.96)^7$$

Calculando $(0.96)^7 \approx 0.751447$:

$$P(X = 1) = 0.32 \times 0.751447 \approx 0.2405 \quad (24.05\%)$$

3. **(b) No máximo 1 perda ($P(X \leq 1) = P(X = 0) + P(X = 1)$):**

$$P(X = 0) = \binom{8}{0} (0.04)^0 (0.96)^8 = (0.96)^8 \approx 0.721389 \quad (72.14\%)$$

Somando:

$$P(X \leq 1) = 0.721389 + 0.240463 = 0.961852 \approx 0.9619 \quad (96.19\%)$$

Interpretação: um único pacote de paridade leva a recuperação sem retransmissão de 72% para 96% das rajadas.

Exercício 3.2: Erros de Leitura em Disco por Processo de Poisson**Resolução Passo a Passo:**

1. **(a) Ajuste da taxa λ para 500 TB:**

Como a taxa é proporcional ao volume lido (estacionariedade):

$$\lambda_{500} = 0.4 \times \left(\frac{500}{100} \right) = 0.4 \times 5 = 2.0 \text{ erros}$$

Logo, $X \sim \text{Poisson}(\lambda = 2.0)$.

2. **(b) Probabilidade de exatamente 2 erros ($P(X = 2)$):**

$$P(X = 2) = \frac{e^{-2} \cdot 2^2}{2!} = \frac{4e^{-2}}{2} = 2e^{-2}$$

Como $e^{-2} \approx 0.135335$:

$$P(X = 2) = 2 \times 0.135335 = 0.2707 \quad (27.07\%)$$

3. **(c) Probabilidade de pelo menos 1 erro ($P(X \geq 1)$):**

Pelo evento complementar:

$$P(X \geq 1) = 1 - P(X = 0) = 1 - e^{-2}$$

$$P(X \geq 1) = 1 - 0.135335 = 0.8647 \quad (86.47\%)$$

Interpretação: é por isso que volumes grandes usam RAID 6 (duas paridades) em vez de RAID 5: durante a reconstrução, a chance de encontrar pelo menos um erro de leitura é alta.

Exercício 3.3: Aproximação Poisson para Transações Fraudulentas**Resolução Passo a Passo:****1. (a) Critérios de aplicabilidade:**

$n = 1500 \geq 100$ (número de ensaios muito grande).

$p = 0.002 \leq 0.05$ (probabilidade muito pequena).

Parâmetro $\lambda = np = 1500 \times 0.002 = 3.0 \leq 10$.

As condições para a convergência da Binomial para a Poisson estão satisfeitas.

2. (b) Cálculo via Poisson($\lambda = 3.0$):

$$P(X = 4) = \frac{e^{-3.0} \cdot 3^4}{4!} = \frac{81 \cdot e^{-3}}{24} = 3.375 \cdot e^{-3}$$

Sabendo que $e^{-3} \approx 0.049787$:

$$P(X = 4) = 3.375 \times 0.049787 = 0.16803 \approx 0.1680 \quad (16.80\%)$$

Módulo 4: Variáveis Aleatórias Contínuas (VAC)**Exercício 4.1 • Probabilidade Pontual em VAC****Substituição e cálculo, passo a passo**

1. Em uma VAC, probabilidade é área sob f . Um único ponto tem largura zero, logo área zero.
2. $f(4) = 1/9$ é uma *densidade* (altura), não uma probabilidade.
3. Consequência: $P(X \leq 4) = P(X < 4) = 4/9$.

Resposta: 0

Exercício 4.2 • Constante de Normalização de uma FDP**Dados do problema**

- $b = 3$: limite superior do suporte (ms)
- $f(x) = k(9 - x^2)$: forma da densidade em $0 \leq x \leq 3$

Fórmula usada

$$\int_{-\infty}^{\infty} f(x) dx = 1$$

Substituição e cálculo, passo a passo

1. Exija área total 1: $\int_0^3 k(9 - x^2) dx = 1$.
2. Primitiva: $9x - \frac{x^3}{3}$. Em $x = 3$: $27 - \frac{27}{3} = \frac{54}{3}$; em 0 vale 0.
3. Logo $k \cdot \frac{54}{3} = 1 \implies k = \frac{3}{54} = 0.0556$.

Resposta: 0.0556

Exercício 4.3 • Obtendo a FDA de uma VAC**Dados do problema**

- $m = 2$: expoente da densidade
- $b = 1$: limite superior do suporte (s)
- $k = 3/1$: constante de normalização (já dada)

Fórmula usada

$$F(x) = \int_0^x f(t) dt$$

Substituição e cálculo, passo a passo

1. Integre a potência: $\int_0^x t^2 dt = \frac{x^3}{3}$.
2. $F(x) = \frac{3}{1} \cdot \frac{x^3}{3} = \frac{x^3}{1} = \left(\frac{x}{1}\right)^3$ para $0 \leq x \leq 1$.
3.
$$F(0.4) = \left(\frac{0.4}{1}\right)^3 = 0.4000^3 = 0.0640$$
4. Erro comum: usar $f(0.4)$, que é densidade, no lugar de $F(0.4)$.

Resposta: 0.0640**Exercício 4.4 • Esperança de uma VAC****Dados do problema**

- $m = 1$: expoente da densidade
- $b = 1$: limite superior do suporte (s)
- $k = 2/1$: constante de normalização (já dada)

Fórmula usada

$$E[X] = \int x f(x) dx$$

Substituição e cálculo, passo a passo

1. $x f(x) = \frac{2}{1} x^2$.
2. $\int_0^1 x^2 dx = \frac{1^3}{3} = \frac{1}{3}$.
3.
$$E[X] = \frac{2}{1} \cdot \frac{1}{3} = \frac{2 \times 1}{3} = 0.6667 \text{ s}$$

Resposta: 0.6667 s

Exercício 4.5 • Mediana de uma VAC**Dados do problema**

- $m = 2$: expoente da densidade
- $b = 1$: limite superior do suporte (s)
- $k = 3/1$: constante de normalização (já dada)

Fórmula usada

$$F(Md) = 0.5$$

Substituição e cálculo, passo a passo

1. Integrando f : $F(x) = (x/1)^3$.
2. Imponha $F(Md) = 0.5$: $(Md/1)^3 = 0.5$.
3. Tire a raiz de ordem 3: $Md/1 = 0.5^{1/3} = 0.7937$.
4.
$$Md = 1 \times 0.7937 = 0.7937 \text{ s}$$
5. Como a densidade cresce com x , a mediana fica acima do ponto médio 0.5.

Resposta: 0.7937 s

Exercício 4.6 • Percentil por Inversão da FDA**Dados do problema**

- $a = 4$: menor tamanho possível (MB)
- $k = 2$: expoente da cauda
- $p = 0.9$: fração acumulada desejada

Fórmula usada

$$F(x_p) = p \implies x_p = a(1 - p)^{-1/k}$$

Substituição e cálculo, passo a passo

1. Imponha $F(x_p) = 0.9$: $1 - (4/x_p)^2 = 0.9$.
2. Isole a potência: $(4/x_p)^2 = 0.10$.
3. Raiz 2: $4/x_p = 0.10^{1/2} = 0.3162$.

$$4. \quad x_p = \frac{4}{0.3162} = 12.6491 \text{ MB}$$

Resposta: 12.6491 MB

Exercício 4.7 • Quartil Inferior de uma VAC**Dados do problema**

- $m = 3$: expoente da densidade
- $b = 6$: limite superior (min)

Fórmula usada

$$F(Q) = 0.25$$

Substituição e cálculo, passo a passo

1. FDA: $F(x) = (x/6)^4$.
2. Resolvendo $F(x_p) = p$: $x_p = 6p^{1/4}$.
3. $0.25^{1/4} = 0.7071$.

$$4. \quad Q_1 = 6 \times 0.7071 = 4.2426$$

Resposta: 4.2426 min

Exercício 4.1: Normalização de FDP Polinomial e Probabilidade**Resolução Passo a Passo:**

1. (a) Cálculo de k pela integral unitária $\int_{-\infty}^{\infty} f(x)dx = 1$:

$$\int_{-1}^1 k(1 - x^2) dx = 1$$

Como $1 - x^2$ é uma função par, podemos simplificar:

$$2k \int_0^1 (1 - x^2) dx = 2k \left[x - \frac{x^3}{3} \right]_0^1 = 2k \left(1 - \frac{1}{3} \right) = 2k \left(\frac{2}{3} \right) = \frac{4}{3}k = 1$$

$$\implies k = \frac{3}{4} = 0.75$$

Portanto, a FDP é: $f(x) = \frac{3}{4}(1 - x^2)$ para $-1 \leq x \leq 1$.

2. (b) Cálculo da probabilidade $P(0 \leq X \leq 0.5)$:

$$P(0 \leq X \leq 0.5) = \int_0^{0.5} \frac{3}{4}(1 - x^2) dx = \frac{3}{4} \left[x - \frac{x^3}{3} \right]_0^{0.5}$$

Substituindo $x = 0.5 = 1/2$:

$$x - \frac{x^3}{3} = \frac{1}{2} - \frac{(1/8)}{3} = \frac{1}{2} - \frac{1}{24} = \frac{12 - 1}{24} = \frac{11}{24}$$

$$P(0 \leq X \leq 0.5) = \frac{3}{4} \times \frac{11}{24} = \frac{1}{4} \times \frac{11}{8} = \frac{11}{32} = 0.34375 \quad (34.38\%)$$

Exercício 4.2: Obtenção da FDA e Mediana**Resolução Passo a Passo:****1. (a) Obtenção da FDA $F(x) = \int_0^x f(t)dt$:**- Para $x < 0$: $F(x) = 0$.- Para $0 \leq x \leq 1$:

$$F(x) = \int_0^x 2(1-t) dt = 2 \left[t - \frac{t^2}{2} \right]_0^x = 2x - x^2$$

- Para $x > 1$: $F(x) = 1$.**2. (b) Cálculo da mediana m ($F(m) = 0.50$):**

$$2m - m^2 = 0.50 \implies m^2 - 2m + 0.50 = 0$$

Aplicando a fórmula quadrática:

$$m = \frac{-(-2) \pm \sqrt{(-2)^2 - 4(1)(0.5)}}{2(1)} = \frac{2 \pm \sqrt{4-2}}{2} = \frac{2 \pm \sqrt{2}}{2} = 1 \pm \frac{\sqrt{2}}{2}$$

Como o suporte é restrito a $[0, 1]$, descartamos a raiz maior que 1:

$$m = 1 - \frac{\sqrt{2}}{2} \approx 1 - 0.7071 = 0.2929$$

A mediana é aproximadamente **0.293**, refletindo a concentração de massa nos valores menores de x .**Exercício 4.3: Esperança e Variância de um Tempo de Processamento****Resolução Passo a Passo:****1. Cálculo de $E[T]$:**

$$E[T] = \int_0^1 t \cdot f(t) dt = \int_0^1 t \cdot (3t^2) dt = 3 \int_0^1 t^3 dt = 3 \left[\frac{t^4}{4} \right]_0^1 = \frac{3}{4} = 0.75 \text{ s}$$

2. Cálculo do segundo momento $E[T^2]$:

$$E[T^2] = \int_0^1 t^2 \cdot f(t) dt = 3 \int_0^1 t^4 dt = 3 \left[\frac{t^5}{5} \right]_0^1 = \frac{3}{5} = 0.60$$

3. Cálculo da variância $Var(T)$:

$$Var(T) = E[T^2] - (E[T])^2 = \frac{3}{5} - \left(\frac{3}{4}\right)^2 = \frac{3}{5} - \frac{9}{16}$$

Igualando os denominadores (MMC = 80):

$$Var(T) = \frac{48 - 45}{80} = \frac{3}{80} = 0.0375 \text{ s}^2$$

$$\sigma_T = \sqrt{0.0375} \approx 0.1936 \text{ s}$$

Módulo 5: Modelos Contínuos de Probabilidade

Exercício 5.1 • Uniforme Contínua: Intervalo

Dados do problema

- $a = 8$: menor tempo possível (s)
- $b = 28$: maior tempo possível (s)

Fórmula usada

$$P(c < X < d) = \frac{d - c}{b - a}$$

Substituição e cálculo, passo a passo

1. A densidade é constante: $f(x) = \frac{1}{28-8} = \frac{1}{20}$.
2. A área é um retângulo: base $17 - 16 = 1$ vezes altura $1/20$.

$$3. \quad P = \frac{1}{20} = 0.0500$$

Resposta: 0.0500

Exercício 5.2 • Regra Empírica 68-95-99,7

Dados do problema

- $\mu = 160$: tempo médio (ms)
- $\sigma = 4$: desvio padrão (ms)
- $N = 500$: execuções do benchmark

Fórmula usada

$$P(\mu - k\sigma < X < \mu + k\sigma) = 0.6827, 0.9545, 0.9973 \quad (k = 1, 2, 3)$$

Substituição e cálculo, passo a passo

1. Escreva o intervalo em desvios padrão: $160 \pm 8 = \mu \pm 2\sigma$ (pois $8/4 = 2$).
2. Pela regra empírica, 95.45% ficam dentro; fora: $1 - 0.9545 = 0.0455$.

$$3. \quad 500 \times 0.0455 = 22.7 \text{ execuções}$$

Resposta: 22.7 execuções

Exercício 5.3 • Normal: Padronização**Dados do problema**

- $\mu = 65$: tempo médio de resposta (ms)
- $\sigma = 1.5$: desvio padrão (ms)
- $x = 66.88$: valor de referência (ms)

Fórmula usada

$$z = \frac{x - \mu}{\sigma}$$

$$P(X > x) = 1 - \Phi(z)$$

Substituição e cálculo, passo a passo

$$1. \quad z = \frac{66.88 - 65}{1.5} = \frac{1.88}{1.5} = 1.25$$

(o valor está 1.25 desvios padrão acima da média).

2. $\Phi(1.25) = 0.8944$ (tabela Z: linha 1.2, coluna 0.05)
3. Queremos a área à direita: $P = 1 - 0.8944 = 0.1056$.

Resposta: 0.1056

Exercício 5.4 • Exponencial: Vida Mediana**Dados do problema**

- $MTTF = 1/\lambda = 4750$: vida média (h)
- $\lambda = 0.000211$: taxa de falha (1/h)

Fórmula usada

$$F(t_{0.5}) = 1 - e^{-\lambda t_{0.5}} = 0.5 \implies t_{0.5} = \frac{\ln 2}{\lambda}$$

Substituição e cálculo, passo a passo

1. Imponha $1 - e^{-\lambda t} = 0.5$, ou seja, $e^{-\lambda t} = 0.5$.
2. Aplique $\ln$: $-\lambda t = \ln 0.5 = -0.6931$, logo $t = 0.6931/\lambda = 0.6931 \times 4750$.

$$3. \quad t_{0.5} = 3292.4 \text{ h}$$

4. A mediana é menor que a média: a exponencial é assimétrica à direita.

Resposta: 3292.4 h

Exercício 5.5 • Exponencial: Falta de Memória**Dados do problema**

- $MTTF = 1/\lambda = 1750$: vida média (h)
- $\lambda = 0.000571$: taxa de falha (1/h)
- $s = 1000$: horas já operadas
- $t = 1600$: horas adicionais

Fórmula usada

$$P(T > s + t \mid T > s) = P(T > t) = e^{-\lambda t}$$

Substituição e cálculo, passo a passo

1. Pela falta de memória, só importam as 1600 h adicionais; as 1000 h já operadas não entram.
2. Expoente: $\lambda t = 1600/1750 = 0.9143$, e $e^{-0.9143} = 0.4008$.

$$3. \quad P = 0.4008$$

4. Conferência pela definição: $\frac{e^{-2600/1750}}{e^{-1000/1750}} = \frac{0.2263}{0.5647} = 0.4008$.

Resposta: 0.4008**Exercício 5.6 • Percentil da Normal (Problema Inverso)****Dados do problema**

- $\mu = 3000$: vida média (h)
- $\sigma = 130$: desvio padrão (h)
- $p = 0.9$: área desejada à esquerda

Fórmula usada

$$x_p = \mu + z_p \sigma, \quad \Phi(z_p) = p$$

Substituição e cálculo, passo a passo

1. "Superada por 10%" significa 90% abaixo: queremos $P(X \leq x) = 0.9$.
2. Na tabela Z, procure no *corpo* o valor mais próximo de 0.9: $z_{0.9} = 1.282$.
3. Converta para a escala de X :

$$x = 3000 + 1.282 \times 130 = 3000 + 166.7 = 3166.7 \text{ h}$$

Resposta: 3166.7 h

Exercício 5.7 • Orçamento de Latência (Soma de Normais)**Dados do problema**

- $k = 4$: etapas em sequência
- $\mu = 3.5$: tempo médio de cada etapa (ms)
- $\sigma = 0.06$: desvio padrão de cada etapa (ms)
- $L = 14.18$: orçamento de tempo (ms)

Fórmula usada

$$\mu_T = k\mu, \quad \sigma_T = \sqrt{k} \sigma$$

$$P(T > L) = 1 - \Phi\left(\frac{L - \mu_T}{\sigma_T}\right)$$

Substituição e cálculo, passo a passo

1. Média da soma: $\mu_T = 4 \times 3.5 = 14.00$ ms.
2. Variância da soma: $4 \times 0.06^2 = 0.01440$, logo $\sigma_T = \sqrt{0.01440} = 0.1200$ ms.

$$3. \quad z = \frac{14.18 - 14.00}{0.1200} = 1.5$$

$$4. \quad \Phi(1.50) = 0.9332 \text{ (tabela Z: linha 1.5, coluna 0.00)}$$

$$5. \quad P(T > 14.18) = 1 - 0.9332 = 0.0668$$

6. Erro comum: usar $\sigma_T = 4 \times 0.06 = 0.24$ (soma dos desvios).

Resposta: 0.0668

Exercício 5.8 • Aproximação Normal da Binomial**Dados do problema**

- $n = 80$: requisições
- $p = 0.4$: probabilidade de cada requisição precisar de retry
- $k = 34$: limite de interesse

Fórmula usada

$$\mu = np, \quad \sigma = \sqrt{np(1-p)}$$

$$P(X \leq k) \approx \Phi\left(\frac{k + 0.5 - \mu}{\sigma}\right)$$

Substituição e cálculo, passo a passo

1. Verifique as condições: $np = 32.0 \geq 5$ e $n(1-p) = 48.0 \geq 5$.
2. $\mu = 32.0$; $\sigma^2 = 80 \times 0.4 \times 0.60 = 19.20$, logo $\sigma = 4.3818$.
3. Correção de continuidade: a barra de $k = 34$ vai até 34.5.

$$4. \quad z = \frac{34.5 - 32.0}{4.3818} = 0.57$$

$$5. \quad \Phi(0.57) = 0.7157 \text{ (tabela Z: linha 0.5, coluna 0.07)}$$

$$6. \quad P(X \leq 34) \approx 0.7157.$$

Resposta: 0.7157

Exercício 5.9 • Confiabilidade de Sistema em Série (Exponencial)**Dados do problema**

- $MTTF_1 = 1750$: vida média do componente 1 (h)
- $MTTF_2 = 2500$: vida média do componente 2 (h)
- $MTTF_3 = 3500$: vida média do componente 3 (h)
- $t = 200$: tempo de missão (h)

Fórmula usada

$$\lambda_{sis} = \sum_i \lambda_i$$

$$R_{sis}(t) = e^{-\lambda_{sis}t}$$

Substituição e cálculo, passo a passo

1. Taxas: $\lambda_i = 1/MTTF_i$: $\lambda_1 = 1/1750 = 0.000571$; $\lambda_2 = 1/2500 = 0.000400$; $\lambda_3 = 1/3500 = 0.000286$.
2. Em série, as taxas se somam: $\lambda_{sis} = 0.000571 + 0.000400 + 0.000286 = 0.001257$ /h.
3. Expoente: $0.001257 \times 200 = 0.2514$.
4. $R_{sis}(200) = e^{-0.2514} = 0.7777$

Resposta: 0.7777**Exercício 5.1: SLO de Latência com a Normal Padrão****Resolução Passo a Passo:****1. Padronização dos limites de especificação:**- Limite Inferior: $x_1 = 24.92$ ms

$$z_1 = \frac{24.92 - 25.00}{0.05} = \frac{-0.08}{0.05} = -1.60$$

- Limite Superior: $x_2 = 25.10$ ms

$$z_2 = \frac{25.10 - 25.00}{0.05} = \frac{+0.10}{0.05} = +2.00$$

2. (a) Cálculo da probabilidade de conformidade:

$$P(24.92 \leq X \leq 25.10) = P(-1.60 \leq Z \leq 2.00) = \Phi(2.00) - \Phi(-1.60)$$

Pela simetria da Normal: $\Phi(-1.60) = 1 - \Phi(1.60) = 1 - 0.9452 = 0.0548$.

$$P(24.92 \leq X \leq 25.10) = 0.9772 - 0.0548 = 0.9224 \quad (92.24\%)$$

3. (b) Janelas abaixo do mínimo:

$$P(X < 24.92) = P(Z < -1.60) = \Phi(-1.60) = 0.0548 \quad (5.48\%)$$

Exercício 5.2: Vida de Servidores e Falta de Memória**Resolução Passo a Passo:**

1. (a) **Confiabilidade em $t = 10$ meses:**

$$R(10) = P(T > 10) = e^{-\lambda t} = e^{-0.05 \times 10} = e^{-0.5}$$

Como $e^{-0.5} \approx 0.60653$:

$$P(T > 10) \approx 0.6065 \quad (60.65\%)$$

2. (b) **Probabilidade condicional com base no histórico:**

Pela propriedade de falta de memória da distribuição exponencial:

$$P(T > 15 + 10 \mid T > 15) = P(T > 10) = e^{-0.5} \approx 0.6065 \quad (60.65\%)$$

Interpretação: O fato de o servidor já ter funcionado 15 meses não alterou a chance de durar mais 10 meses: no modelo exponencial não há desgaste acumulado.

Exercício 5.3: Distribuição Uniforme em Sistemas Automatizados**Resolução Passo a Passo:**

1. (a) **Média e Desvio Padrão para $a = 2$ e $b = 8$:**

$$E[Y] = \frac{a + b}{2} = \frac{2 + 8}{2} = 5.0 \text{ segundos}$$

$$Var(Y) = \frac{(b - a)^2}{12} = \frac{(8 - 2)^2}{12} = \frac{36}{12} = 3.0 \text{ s}^2$$

$$\sigma_Y = \sqrt{3.0} \approx 1.732 \text{ segundos}$$

2. (b) **Probabilidade de $Y > 6.5$ segundos:**

$$P(Y > 6.5) = \frac{b - 6.5}{b - a} = \frac{8 - 6.5}{8 - 2} = \frac{1.5}{6} = \frac{1}{4} = 0.25 \quad (25.0\%)$$

Módulo 6: Estatística Descritiva**Exercício 6.1 • Classificação de Variáveis****Substituição e cálculo, passo a passo**

- 1.º: o valor vem de contar ou medir? Se sim, quantitativa; se for uma categoria, qualitativa.
- 2.º (quantitativa): contagem é discreta; medição é contínua. 2.º (qualitativa): há ordem natural? Se sim, ordinal; senão, nominal.
3. Resposta: **Quantitativa contínua.**
4. Admite média, desvio padrão e histograma.

Resposta: Quantitativa contínua

Exercício 6.2 • Mediana de uma Amostra**Dados do problema**

- $n = 5$: número de requisições medidas
- $x_i = 74, 78, 72, 79, 77$: tempos de resposta medidos (ms)

Fórmula usada

$$\tilde{x} = x_{\left(\frac{n+1}{2}\right)}$$

Substituição e cálculo, passo a passo

1. Ordene: 72; 74; 77; 78; 79.
2. Posição central: $(n + 1)/2 = 3$.
3. n ímpar: o valor na posição 3 é $\tilde{x} = 77$.
4. Erro comum: tomar o valor central sem ordenar.

Resposta: 77.00 ms

Exercício 6.3 • Desvio Padrão pela Fórmula Computacional**Dados do problema**

- $n = 16$: número de medições
- $\sum x_i = 1232$: soma das latências (ms)
- $\sum x_i^2 = 94897.75$: soma dos quadrados das latências (ms²)

Fórmula usada

$$s^2 = \frac{\sum x_i^2 - \frac{(\sum x_i)^2}{n}}{n - 1}$$

Substituição e cálculo, passo a passo

1. Quadrado da soma dividido por n : $\frac{1232^2}{16} = \frac{1517824.00}{16} = 94864.0000$.
2. Numerador: $94897.75 - 94864.0000 = 33.7500$ (é a soma dos quadrados dos desvios).

$$3. \quad s^2 = \frac{33.7500}{15} = 2.2500, \quad s = 1.5000 \text{ ms}$$

4. Útil em sistemas embarcados: basta acumular n , $\sum x$ e $\sum x^2$, sem guardar os dados.

Resposta: 1.5000 ms

Exercício 6.4 • Cercas de Tukey**Dados do problema**

- $Q_1 = 18$: primeiro quartil (ms)
- $Q_3 = 23$: terceiro quartil (ms)

Fórmula usada

$$AIQ = Q_3 - Q_1$$

$$L_S = Q_3 + 1.5 AIQ$$

Substituição e cálculo, passo a passo

1. $AIQ = 23 - 18 = 5$ ms.
2. $1.5 \times 5 = 7.5$ ms.

3. $L_S = 23 + 7.5 = 30.50$ ms

4. Valores acima desse limite são marcados como possíveis outliers.

Resposta: 30.50 ms

Exercício 6.5 • Largura de Classe do Histograma**Dados do problema**

- $n = 80$: número de medições
- $x_{min} = 39$: menor valor (ms)
- $x_{max} = 101$: maior valor (ms)

Fórmula usada

$$k = 1 + 3.322 \log_{10} n$$

$$h = \left\lceil \frac{x_{max} - x_{min}}{k} \right\rceil$$

Substituição e cálculo, passo a passo

1. $\log_{10} 80 = 1.9031$.

2. $k = 1 + 3.322 \times 1.9031 = 7.32 \approx 7$

3. Amplitude: $A = 101 - 39 = 62$ ms.

4. $h = \frac{62}{7} = 8.86 \rightarrow 9$ ms

(arredonda-se para cima para que as classes cubram todos os dados).

Resposta: 9 ms

Exercício 6.6 • Média de Dados Agrupados**Dados do problema**

- $h = 9$: largura das classes (min)
- $f_i = 9, 8, 15, 12$: frequências das classes
- $n = 44$: total de observações

Fórmula usada

$$\bar{x} \approx \frac{\sum f_i x_i}{n}$$

Substituição e cálculo, passo a passo

1. Pontos médios (média dos limites de cada classe): 29.5; 38.5; 47.5; 56.5.
2. Produtos $f_i x_i$: $9 \times 29.5 = 265.5$; $8 \times 38.5 = 308$; $15 \times 47.5 = 712.5$; $12 \times 56.5 = 678$.
3. Soma: $\sum f_i x_i = 1964$; total $n = 44$.

$$4. \quad \bar{x} = \frac{1964}{44} = 44.64 \text{ min}$$

Resposta: 44.64 min**Exercício 6.1: Análise Completa de uma Amostra de Latências****Resolução Passo a Passo:****1. (a) Média Amostral $\bar{x}$:**

$$\bar{x} = \frac{60 + 64 + 62 + 68 + 56}{5} = \frac{310}{5} = 62.0 \text{ ms}$$

2. (b) Variância Amostral s^2 ($n = 5 \Rightarrow n - 1 = 4$):Desvios em relação à média ($x_i - \bar{x}$):

$$(60 - 62) = -2 \Rightarrow (-2)^2 = 4$$

$$(64 - 62) = +2 \Rightarrow (+2)^2 = 4$$

$$(62 - 62) = 0 \Rightarrow 0^2 = 0$$

$$(68 - 62) = +6 \Rightarrow 6^2 = 36$$

$$(56 - 62) = -6 \Rightarrow (-6)^2 = 36$$

Soma dos quadrados dos desvios:

$$\sum (x_i - \bar{x})^2 = 4 + 4 + 0 + 36 + 36 = 80$$

$$s^2 = \frac{80}{5 - 1} = \frac{80}{4} = 20.0 \text{ ms}^2$$

$$s = \sqrt{20.0} \approx 4.472 \text{ ms}$$

3. (c) Coeficiente de Variação (CV):

$$CV = \frac{s}{\bar{x}} \times 100\% = \frac{4.472}{62.0} \times 100\% \approx 7.21\%$$

Exercício 6.2: Identificação de Outliers pelo Critério de Tukey**Resolução Passo a Passo:****1. Cálculo do Intervalo Interquartil (IQR):**

$$IQR = Q_3 - Q_1 = 60 - 30 = 30 \text{ min}$$

2. Cálculo do Limite Superior do Boxplot (LS):

$$LS = Q_3 + 1.5 \times IQR = 60 + (1.5 \times 30) = 60 + 45 = 105 \text{ min}$$

3. Avaliação do valor observado (110 min):

Como $110 > LS = 105 \text{ min}$, o valor está situado além do 'bigode' superior.

Conclusão: Sim, o incidente de 110 minutos é classificada como um **outlier superior**, indicando um evento atípico (provavelmente uma falha em cascata ou um rollback demorado, que merece um post-mortem).

Exercício 6.3: Comparação de Variabilidade Relativa via CV**Resolução Passo a Passo:****1. Cálculo do CV do Serviço A:**

$$CV_A = \frac{s_A}{\bar{x}_A} \times 100\% = \frac{0.40}{20.0} \times 100\% = 2.0\%$$

2. Cálculo do CV do Serviço B:

$$CV_B = \frac{s_B}{\bar{x}_B} \times 100\% = \frac{0.50}{10.0} \times 100\% = 5.0\%$$

Conclusão: Embora em termos absolutos o desvio padrão do Serviço A ($0.40 \text{ s} = 400 \text{ ms}$) seja muito maior que o do Serviço B (0.50 ms), em termos relativos o **Serviço B possui dispersão 2.5 vezes maior** ($5.0\% > 2.0\%$), apresentando menor precisão relativa.

Módulo 7: Estimação e Teorema Central do Limite (TCL)

Exercício 7.1 • Viés de um Estimador

Dados do problema

- $w_1, w_2, w_3 = 1, 1, 1$: pesos das observações
- $d = 5$: divisor
- $\mu = 90$: média verdadeira

Fórmula usada

$$E[T] = \frac{w_1 + w_2 + w_3}{d} \mu$$

$$\text{viés} = E[T] - \mu$$

Substituição e cálculo, passo a passo

1. Linearidade: $E[T] = \frac{1E[X_1] + 1E[X_2] + 1E[X_3]}{5} = \frac{3}{5}\mu$.
2. Com $\mu = 90$: $E[T] = 0.6000 \times 90 = 54.0000$.
3. $\text{viés} = 54.0000 - 90 = -36.0000$
4. T seria não tendencioso se os pesos somassem exatamente 5.

Resposta: -36.0000

Exercício 7.2 • Erro Padrão da Média

Dados do problema

- $\sigma = 20$: desvio padrão das latências (ms)
- $n = 16$: tamanho da amostra

Fórmula usada

$$\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$$

Substituição e cálculo, passo a passo

1. $\sqrt{16} = 4.0000$.
2. $\sigma_{\bar{X}} = \frac{20}{4.0000} = 5.0000 \text{ ms}$
3. A média oscila menos que as requisições individuais.

Resposta: 5.0000 ms

Exercício 7.3 • Teorema Central do Limite**Dados do problema**

- $\mu = 55$: tamanho médio das respostas (KB)
- $\sigma = 7$: desvio padrão de cada resposta (KB)
- $n = 100$: respostas na amostra
- $c = 56.4$: valor de referência para a média (KB)

Fórmula usada

$$\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$$

$$P(\bar{X} > c) \approx 1 - \Phi\left(\frac{c - \mu}{\sigma/\sqrt{n}}\right)$$

Substituição e cálculo, passo a passo

1. Com $n = 100 \geq 30$, o TCL garante $\bar{X}$ aproximadamente normal, com média 55.
2. Erro padrão: $\sigma_{\bar{X}} = \frac{7}{\sqrt{100}} = \frac{7}{10} = 0.7000$ KB.
3.
$$z = \frac{56.4 - 55}{0.7000} = 2$$
4. $\Phi(2.00) = 0.9772$ (tabela Z: linha 2.0, coluna 0.00)
5.
$$P(\bar{X} > 56.4) = 1 - 0.9772 = 0.0228$$
6. Erro comum: usar σ no lugar de $\sigma/\sqrt{n}$.

Resposta: 0.0228**Exercício 7.4 • IC para a Média (σ conhecido)****Dados do problema**

- $\bar{x} = 205$: média da amostra (ms)
- $\sigma = 15$: desvio padrão conhecido (ms)
- $n = 49$: tamanho da amostra
- $1 - \alpha = 0.95$: nível de confiança

Fórmula usada

$$E = z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$$

$$IC = [\bar{x} - E; \bar{x} + E]$$

Substituição e cálculo, passo a passo

1. Confiança 95%: $\alpha = 0.05$, $\alpha/2 = 0.025$, e $z_{\alpha/2} = 1.96$ (deixa 0.025 na cauda direita).
2. Erro padrão: $\frac{15}{\sqrt{49}} = \frac{15}{7} = 2.1429$.
3. Margem: $E = 1.96 \times 2.1429 = 4.2000$.
4.
$$LS = 205 + 4.2000 = 209.20 \text{ ms}$$

(o IC completo é $[200.80; 209.20]$).**Resposta:** 209.20 ms

Exercício 7.5 • Variância de um Estimador**Dados do problema**

- $w_1, w_2, w_3 = 3, 1, 3$: pesos
- $d = 7$: divisor (soma dos pesos)
- $\sigma^2 = 8$: variância de cada observação

Fórmula usada

$$\text{Var} \left(\sum \frac{w_i}{d} X_i \right) = \frac{\sum w_i^2}{d^2} \sigma^2$$

Substituição e cálculo, passo a passo

1. Cada coeficiente é w_i/d , e entra **ao quadrado** na variância (observações independentes).

$$2. \quad \text{Var}(T) = \frac{3^2 + 1^2 + 3^2}{7^2} \sigma^2 = \frac{19}{49} \times 8 = 3.1020$$

Resposta: 3.1020

Exercício 7.6 • IC com t de Student (σ desconhecido)**Dados do problema**

- $n = 8$: execuções na amostra
- $\bar{x} = 11.1$: média da amostra (ms)
- $s = 3.6$: desvio padrão amostral (ms)
- $t_{0.025; 7} = 2.365$: quantil da t para 95%

Fórmula usada

$$E = t_{\alpha/2; n-1} \frac{s}{\sqrt{n}}$$

Substituição e cálculo, passo a passo

1. σ desconhecido e n pequeno: usa-se t com $gl = n - 1 = 7$.
2. Erro padrão estimado: $\frac{3.6}{\sqrt{8}} = \frac{3.6}{2.8284} = 1.2728$.
3. $E = 2.365 \times 1.2728 = 3.0102 \text{ ms}$
4. IC: $11.1 \pm 3.0102 \text{ ms}$. Com $z = 1.96$ a margem seria 2.4947, otimista demais.

Resposta: 3.0102 ms

Exercício 7.7 • Limite Superior do IC para a Variância**Dados do problema**

- $n = 25$: medições de atraso
- $s = 0.4$: desvio padrão amostral (ms)
- $\chi_{0.975;24}^2 = 12.401$: quantil pequeno
- $\chi_{0.025;24}^2 = 39.364$: quantil grande

Fórmula usada

$$\left[\frac{(n-1)s^2}{\chi_{\alpha/2; n-1}^2}, \frac{(n-1)s^2}{\chi_{1-\alpha/2; n-1}^2} \right]$$

Substituição e cálculo, passo a passo

1. $s^2 = 0.4^2 = 0.1600$; $(n-1)s^2 = 24 \times 0.1600 = 3.8400$.
2. O limite superior divide pelo **menor** quantil (12.401): dividir por número menor dá resultado maior.

$$LS = \frac{3.8400}{12.401} = 0.3097$$

3. IC completo: $[0.0976; 0.3097]$ ms², assimétrico em torno de $s^2 = 0.1600$.

Resposta: 0.3097 ms²

Exercício 7.8 • Tamanho de Amostra para Proporção**Dados do problema**

- $E = 0.03$: margem desejada (proporção)
- $z_{\alpha/2} = 2.576$: valor da normal para 99%
- $\hat{p} = 0.3$: estimativa piloto

Fórmula usada

$$n = \frac{z_{\alpha/2}^2 \hat{p}(1 - \hat{p})}{E^2}$$

Substituição e cálculo, passo a passo

1. Use a estimativa piloto $\hat{p} = 0.3$.
2. Numerador: $2.576^2 \times 0.3 \times 0.7 = 6.6358 \times 0.21 = 1.3935$.
3. Denominador: $0.03^2 = 0.0009$.

$$4. \quad n = \frac{1.3935}{0.0009} = 1548.35 \rightarrow 1549$$

(arredondado para cima).

Resposta: 1549 usuários

Exercício 7.1: Aplicação do Teorema Central do Limite**Resolução Passo a Passo:**

1. **Verificação do TCL:** Como $n = 64 \geq 30$, pelo Teorema Central do Limite a distribuição da média amostral $\bar{X}$ aproxima-se de uma Normal:

$$\bar{X} \sim N\left(\mu = 12, \sigma_{\bar{X}}^2 = \frac{4^2}{64} = \frac{16}{64} = 0.25\right)$$

2. **Cálculo do Erro Padrão:**

$$\sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}} = \frac{4}{\sqrt{64}} = \frac{4}{8} = 0.50 \text{ min}$$

3. **Padronização Z :**

$$z = \frac{\bar{x} - \mu}{\sigma_{\bar{X}}} = \frac{11.25 - 12.0}{0.50} = \frac{-0.75}{0.50} = -1.50$$

4. **Probabilidade:**

$$P(\bar{X} < 11.25) = P(Z < -1.50) = \Phi(-1.50) = 0.0668 \quad (6.68\%)$$

Exercício 7.2: IC para a Vida Média de SSDs com σ Conhecido**Resolução Passo a Passo:**

1. **Cálculo da Margem de Erro (E):**

$$E = z_{\alpha/2} \cdot \frac{\sigma}{\sqrt{n}} = 1.96 \times \frac{200}{\sqrt{100}} = 1.96 \times \frac{200}{10} = 1.96 \times 20 = 39.2 \text{ horas}$$

2. **Construção do Intervalo:**

$$IC(\mu, 95\%) = [\bar{x} - E ; \bar{x} + E]$$

$$IC(\mu, 95\%) = [5000 - 39.2 ; 5000 + 39.2] = [4960.8 ; 5039.2] \text{ horas}$$

Interpretação: Afirmamos com 95% de confiança estatística que a verdadeira média populacional de vida útil desses SSDs situa-se entre 4960.8 e 5039.2 horas.

Exercício 7.3: Dimensionamento do Tamanho Amostral Mínimo**Resolução Passo a Passo:****1. Fórmula do tamanho amostral:**

$$n = \left(\frac{z_{\alpha/2} \cdot \sigma}{E} \right)^2$$

2. Substituição numérica:

$$n = \left(\frac{2.576 \times 0.10}{0.02} \right)^2 = (2.576 \times 5)^2 = (12.88)^2 = 165.894$$

3. Arredondamento conservador: Como o tamanho amostral deve ser um número inteiro que garanta o erro máximo pretendido, arredondamos sempre para cima:

$$n = 166 \text{ VMs}$$

Módulo 8: Testes de Hipótese**Exercício 8.1 • Formulação das Hipóteses****Substituição e cálculo, passo a passo**

1. H_0 sempre contém a igualdade: é o valor afirmado, presumido verdadeiro.
2. H_1 traduz a suspeita que se quer demonstrar; a palavra-chave do enunciado ("menor", "aumentou", "alterou") define o sinal.
3. Aqui: $H_0 : \mu = 48$ vs $H_1 : \mu \neq 48$.

Resposta: $H_0 : \mu = 48$ vs $H_1 : \mu \neq 48$

Exercício 8.2 • Erros Tipo I e Tipo II**Substituição e cálculo, passo a passo**

1. Identifique a verdade (H_0 verdadeira ou falsa) e a decisão (rejeitou ou não).
2. Tipo I (α): rejeitar H_0 verdadeira (falso alarme).
3. Tipo II (β): não rejeitar H_0 falsa (problema que passa despercebido).
4. Aqui: **Decisão correta (nível de confiança).**

Resposta: Decisão correta (nível de confiança)

Exercício 8.3 • Decisão pelo p-valor**Substituição e cálculo, passo a passo**

1. Regra: rejeita-se H_0 se $p \leq \alpha$. Aqui $0.08 \leq 0.1$.
2. Decisão: rejeitar H_0 . O único erro possível ao rejeitar é o Tipo I (se H_0 for, na verdade, verdadeira).

Resposta: Rejeitar H_0 ; risco de Erro Tipo I.

Exercício 8.4 • Teste Z para a Média**Dados do problema**

- $\mu_0 = 200$: temperatura de referência da CPU sob carga (H_0)
- $\sigma = 6$: desvio padrão conhecido ($^{\circ}\text{C}$)
- $n = 16$: leituras do sensor
- $\bar{x} = 202.25$: média das leituras ($^{\circ}\text{C}$)

Fórmula usada

$$z_{calc} = \frac{\bar{x} - \mu_0}{\sigma / \sqrt{n}}$$

Substituição e cálculo, passo a passo

1. Sinal (numerador): $202.25 - 200 = 2.25$ $^{\circ}\text{C}$.
2. Ruído (erro padrão): $\frac{6}{\sqrt{16}} = \frac{6}{4} = 1.5000$ $^{\circ}\text{C}$.

$$3. \quad z_{calc} = \frac{2.25}{1.5000} = 1.5000$$

4. Decisão a 5% (bilateral, crítico ± 1.96): $|z| \leq 1.96$, não se rejeita H_0 .

Resposta: 1.5000**Exercício 8.5 • Qui-Quadrado de Aderência****Dados do problema**

- $N = 180$: lançamentos
- $O_i = 37, 32, 40, 30, 26, 15$: frequências observadas das faces 1 a 6
- $k = 6$: categorias (faces)

Fórmula usada

$$E_i = N \cdot \frac{1}{6}$$

$$\chi^2 = \sum_{i=1}^6 \frac{(O_i - E_i)^2}{E_i}$$

Substituição e cálculo, passo a passo

1. Sob H_0 (dado honesto), cada face tem probabilidade $1/6$: $E_i = 180/6 = 30$.
2. Diferenças $O_i - E_i$: 7; 2; 10; 0; -4; -15.
3. Termos $(O_i - E_i)^2 / E_i$: 1.633; 0.133; 3.333; 0.000; 0.533; 7.500.
4. $\chi^2_{calc} = 1.633 + 0.133 + 3.333 + 0.000 + 0.533 + 7.500 = 13.1333$
5. Com $gl = 6 - 1 = 5$, crítico 11.070: rejeita-se H_0 .

Resposta: 13.1333

Exercício 8.6 • Cálculo do p-valor**Dados do problema**

- $z_{calc} = 0.85$: estatística observada
- $H_1 = \mu \neq \mu_0$: bilateral

Fórmula usada

$$p = 2[1 - \Phi(|z|)]$$

Substituição e cálculo, passo a passo

1. $\Phi(0.85) = 0.8023$ (tabela Z: linha 0.8, coluna 0.05)
2. Bilateral: contam as duas caudas além de ± 0.85 . Uma cauda: $1 - 0.8023 = 0.1977$; duas:

$$p = 2 \times 0.1977 = 0.3953$$

3. A 5%: $p > 0.05$, não se rejeita H_0 .

Resposta: 0.3953

Exercício 8.7 • Teste Qui-Quadrado para a Variância**Dados do problema**

- $n = 20$: medições de latência
- $s = 2.21$: desvio padrão amostral (ms)
- $\sigma_0 = 1.7$: jitter máximo exigido (H_0 , ms)

Fórmula usada

$$\chi_{calc}^2 = \frac{(n-1)s^2}{\sigma_0^2}, \quad gl = n - 1$$

Substituição e cálculo, passo a passo

1. $s^2 = 2.21^2 = 4.8841$ e $\sigma_0^2 = 1.7^2 = 2.89$.
2. Razão: $s^2/\sigma_0^2 = 1.6900$ (perto de 1 se H_0 for verdadeira).

$$3. \quad \chi_{calc}^2 = 19 \times 1.6900 = 32.1100$$

4. Crítico unilateral a 5% com $gl = 19$: 30.144. Rejeita-se H_0 .

Resposta: 32.1100

Exercício 8.8 • Teste z para Proporção**Dados do problema**

- $p_0 = 0.02$: taxa máxima de erro do SLA (H_0)
- $n = 200$: requisições na amostra
- $x = 6$: requisições com erro

Fórmula usada

$$\hat{p} = \frac{x}{n}$$

$$z_{calc} = \frac{\hat{p} - p_0}{\sqrt{p_0(1 - p_0)/n}}$$

Substituição e cálculo, passo a passo

1. $\hat{p} = 6/200 = 0.0300$.
2. Erro padrão sob H_0 (usa p_0): $\sqrt{\frac{0.02 \times 0.98}{200}} = \sqrt{0.0000980} = 0.00990$.
3.
$$z_{calc} = \frac{0.0300 - 0.02}{0.00990} = 1.0102$$
4. Unilateral a 5% (crítico 1.645): $z_{calc} \leq 1.645$, não se rejeita H_0 .

Resposta: 1.0102**Exercício 8.9 • Poder do Teste****Substituição e cálculo, passo a passo**

1. Fórmula (subtópico 8.2): $\beta = \Phi\left(z_\alpha - \frac{(\mu_1 - \mu_0)\sqrt{n}}{\sigma}\right)$; quanto menor o argumento, menor β e maior o poder.
2. Aumentar n ou $\mu_1 - \mu_0$, ou diminuir σ , diminui o argumento; aumentar α diminui z_α .
3. Correta: Reduzir o ruído das medições (menor σ), por exemplo isolando a máquina de benchmark.
4. Diminuir α sem aumentar n aumenta β .

Resposta: Reduzir o ruído das medições (menor σ), por exemplo isolando a máquina de benchmark.

Exercício 8.10 • Frequência Esperada sob Poisson**Dados do problema**

- $n = 80$: dias observados
- $\hat{\lambda} = 1.9$: média estimada de crashes/dia
- $k = 0$: número de crashes da classe

Fórmula usada

$$P(X = k) = \frac{e^{-\hat{\lambda}} \hat{\lambda}^k}{k!}$$

$$E_k = n P(X = k)$$

Substituição e cálculo, passo a passo

$$1. e^{-1.9} = 0.1496; 1.9^0 = 1.0000; 0! = 1.$$

$$2. P(X = 0) = \frac{0.1496 \times 1.0000}{1} = 0.1496$$

$$3. E_0 = 80 \times 0.1496 = 11.97 \text{ dias}$$

4. Como λ foi estimado dos dados, o teste perde 1 grau de liberdade: $gl = k - 1 - 1$.

Resposta: 11.97 dias

Exercício 8.1: Teste Z Bicaudal para a Latência Média**Resolução Passo a Passo:****1. Hipóteses Formais:**

$H_0 : \mu = 1000$ ms (a latência não mudou)

$H_1 : \mu \neq 1000$ ms (a migração alterou a latência)

2. Cálculo da Estatística z_{calc} :

$$z_{\text{calc}} = \frac{\bar{x} - \mu_0}{\sigma / \sqrt{n}} = \frac{1008 - 1000}{20 / \sqrt{25}} = \frac{8}{20/5} = \frac{8}{4} = +2.00$$

3. Regra de Decisão com $\alpha = 0.05$:

A região crítica é $|z| \geq 1.96$. Como $|z_{\text{calc}}| = 2.00 > 1.96$, o ponto cai na Região Crítica de Rejeição.

4. Conclusão: Rejeita-se H_0 ao nível de significância de 5%. Há evidência estatística de que a migração alterou a latência média (para pior), e vale investigar antes de liberar para todos os usuários.

Exercício 8.2: Interpretação de p-valor e Risco de Erro**Resolução Passo a Passo:****1. (a) Decisão pelo p-valor:**

Comparando com o nível $\alpha = 0.01$:

$$p\text{-valor} = 0.003 < \alpha = 0.01$$

Portanto, a decisão formal é **Rejeitar H_0** . A diferença entre os algoritmos é estatisticamente significativa ao nível de 1%.

2. (b) Identificação do risco de erro:

Como decidimos por *rejeitar* H_0 , o único erro possível é o **Erro Tipo I (α)**: a possibilidade de termos rejeitado uma hipótese nula que, na realidade última da população, seja verdadeira (falso alarme).

Exercício 8.3: Teste Qui-Quadrado de Aderência para Distribuição Uniforme**Resolução Passo a Passo:****1. Cálculo das frequências esperadas sob a hipótese de uniformidade:**

Como são $k = 4$ faixas equiprováveis e $N = 100$:

$$E_i = \frac{100}{4} = 25, \quad \forall i \in \{1, 2, 3, 4\}$$

2. Cálculo dos desvios quadráticos ponderados:

$$\text{Faixa 1: } \frac{(18-25)^2}{25} = \frac{(-7)^2}{25} = \frac{49}{25} = 1.96$$

$$\text{Faixa 2: } \frac{(32-25)^2}{25} = \frac{(+7)^2}{25} = \frac{49}{25} = 1.96$$

$$\text{Faixa 3: } \frac{(22-25)^2}{25} = \frac{(-3)^2}{25} = \frac{9}{25} = 0.36$$

$$\text{Faixa 4: } \frac{(28-25)^2}{25} = \frac{(+3)^2}{25} = \frac{9}{25} = 0.36$$

3. Soma da estatística Qui-Quadrado:

$$\chi_{\text{calc}}^2 = 1.96 + 1.96 + 0.36 + 0.36 = 4.64$$

Graus de liberdade: $gl = k - 1 = 4 - 1 = 3$.

Módulo 9: Controle Estatístico de Processo (CEP / SPC)**Exercício 9.1 • Causas Comuns vs. Especiais****Substituição e cálculo, passo a passo**

1. Pergunte: a fonte é permanente e faz parte do sistema (comum) ou é esporádica, identificável e atribuível a um evento (especial)?
2. Causas comuns são muitas, pequenas e permanentes. Causas especiais geram sinais no gráfico.
3. Reajustar o sistema por causa de variação comum (tampering) aumenta a variabilidade.

Resposta: Causa comum: inerente ao processo; só muda com alteração do sistema.

Exercício 9.2 • Limites de 3σ para Médias**Dados do problema**

- $\mu = 80$: latência média (ms)
- $\sigma = 2.5$: desvio das requisições individuais (ms)
- $n = 6$: tamanho do subgrupo

Fórmula usada

$$\sigma_W = \sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}$$

$$LSC = \mu + 3\sigma_W$$

Substituição e cálculo, passo a passo

1. A estatística plotada é $\bar{X}$, não a requisição individual: $\sigma_W = \frac{2.5}{\sqrt{6}} = \frac{2.5}{2.4495} = 1.0206$ ms.
2. $3\sigma_W = 3.0619$ ms.

$$3. \quad LSC = 80 + 3.0619 = 83.0619 \text{ ms}$$

4. Erro comum: usar σ das requisições individuais.

Resposta: 83.0619 ms

Exercício 9.3 • LIC do Gráfico $\bar{X}$ **Dados do problema**

- $n = 8$: tamanho do subgrupo
- $\bar{\bar{x}} = 23.5$: média das médias (ms)
- $\bar{R} = 2.6$: amplitude média (ms)
- $A_2, D_3, D_4 = 0.373, 0.136, 1.864$: constantes da tabela para $n = 8$

Fórmula usada

$$LIC = \bar{\bar{x}} - A_2 \bar{R}$$

Substituição e cálculo, passo a passo

1. Meia largura: $A_2 \bar{R} = 0.373 \times 2.6 = 0.9698$ ms.
2. $LIC = 23.5 - 0.9698 = 22.5302$ ms
3. $A_2 \bar{R}$ já incorpora $3\hat{\sigma}/\sqrt{n}$, com $\hat{\sigma} = \bar{R}/d_2$.

Resposta: 22.5302 ms

Exercício 9.4 • LSC do Gráfico p**Dados do problema**

- $\bar{p} = 0.1$: taxa de erro média
- $n = 50$: requisições por janela

Fórmula usada

$$\sigma_p = \sqrt{\frac{\bar{p}(1 - \bar{p})}{n}}$$

$$LSC = \bar{p} + 3\sigma_p$$

Substituição e cálculo, passo a passo

1. $\bar{p}(1 - \bar{p}) = 0.1 \times 0.90 = 0.0900$; dividido por 50: 0.001800.
2. $\sigma_p = \sqrt{0.001800} = 0.04243$.
3. $LSC = 0.1 + 3 \times 0.04243 = 0.1 + 0.1273 = 0.2273$

Resposta: 0.2273

Exercício 9.5 • Índice Cpk**Dados do problema**

- $LIE = 44.5$: limite inferior de especificação (ms)
- $LSE = 45.5$: limite superior de especificação (ms)
- $\mu = 45.111$: período médio da tarefa (ms)
- $\sigma = 0.222$: desvio padrão (jitter) (ms)

Fórmula usada

$$C_{pu} = \frac{LSE - \mu}{3\sigma}, \quad C_{pl} = \frac{\mu - LIE}{3\sigma}$$

$$C_{pk} = \min(C_{pu}, C_{pl})$$

Substituição e cálculo, passo a passo

1. Meia largura natural: $3\sigma = 3 \times 0.222 = 0.666$ ms.
2. Lado superior: $C_{pu} = \frac{45.5 - 45.111}{0.666} = \frac{0.389}{0.666} = 0.584$.
3. Lado inferior: $C_{pl} = \frac{45.111 - 44.5}{0.666} = \frac{0.611}{0.666} = 0.917$.
4. $C_{pk} = \min(0.584; 0.917) = 0.584$, menor que $C_p = 0.751$ porque o processo está descentrado.
5. Não atinge o mínimo usual de 1.33.

Resposta: 0.584**Exercício 9.6 • Limite Superior do Gráfico S****Dados do problema**

- $n = 10$: tamanho do subgrupo
- $\bar{s} = 0.8$: desvio padrão médio dos subgrupos (ms)
- $B_4 = 1.716$: constante da tabela para $n = 10$

Fórmula usada

$$LSC_S = B_4 \bar{s}$$

Substituição e cálculo, passo a passo

1. $LSC_S = 1.716 \times 0.8 = 1.3728$ ms
2. Os fatores B_3 e B_4 já incluem a correção de c_4 e os 3σ (ver 9.6).

Resposta: 1.3728 ms

Exercício 9.7 • Cp a partir do Gráfico de Controle**Dados do problema**

- $n = 5$: tamanho do subgrupo
- $\bar{R} = 3.3$: amplitude média (ms)
- $d_2 = 2.326$: constante da tabela para $n = 5$
- $\text{tol} = 3.5$: tolerância $\pm$ (ms)

Fórmula usada

$$\hat{\sigma} = \frac{\bar{R}}{d_2}$$

$$C_p = \frac{LSE - LIE}{6\hat{\sigma}}$$

Substituição e cálculo, passo a passo

1.
$$\hat{\sigma} = \frac{\bar{R}}{d_2} = \frac{3.3}{2.326} = 1.4187 \text{ ms}$$
2. Largura da especificação: $LSE - LIE = 2 \times 3.5 = 7 \text{ ms}$.
3. $6\hat{\sigma} = 6 \times 1.4187 = 8.5125 \text{ ms}$.
4.
$$C_p = \frac{7}{8.5125} = 0.822$$
5. Erro comum: usar $\bar{R}$ no lugar de σ .

Resposta: 0.822**Exercício 9.8 • LIC do Gráfico c****Dados do problema**

- $\bar{c} = 10.5$: média de bugs por release

Fórmula usada

$$LIC = \bar{c} - 3\sqrt{\bar{c}}$$

Substituição e cálculo, passo a passo

1. Contagem de ocorrências (bugs) segue Poisson, cuja variância é igual à média: $\sigma = \sqrt{10.5} = 3.2404$.
2. $3\sigma = 9.7211$.
3.
$$LIC = 10.5 - 9.7211 = 0.7789$$

Resposta: 0.7789 bugs**Exercício 9.9 • Regras de Sensibilidade (Western Electric)****Substituição e cálculo, passo a passo**

1. Verifique, nesta ordem: algum valor com $|z| > 3$? Dois de três seguidos acima de 2 (ou abaixo de -2)? Oito seguidos com o mesmo sinal? Seis seguidos sempre subindo ou sempre descendo?
2. Resposta: **8 pontos consecutivos do mesmo lado da linha central.**

Resposta: 8 pontos consecutivos do mesmo lado da linha central

Exercício 9.1: Determinação dos Limites de Controle $\bar{X}$ e R **Resolução Passo a Passo:****1. Limites do Gráfico da Média ($\bar{X}$):**

$$LC = \bar{\bar{X}} = 100.00 \text{ ms}$$

$$LSC = \bar{\bar{X}} + A_2 \bar{R} = 100.0 + (0.577 \times 2.4) = 100.0 + 1.3848 = 101.385 \text{ ms}$$

$$LIC = \bar{\bar{X}} - A_2 \bar{R} = 100.0 - (0.577 \times 2.4) = 100.0 - 1.3848 = 98.615 \text{ ms}$$

2. Limites do Gráfico da Amplitude (R):

$$LC = \bar{R} = 2.40 \text{ ms}$$

$$LSC = D_4 \bar{R} = 2.114 \times 2.4 = 5.074 \text{ ms}$$

$$LIC = D_3 \bar{R} = 0 \times 2.4 = 0.00 \text{ ms}$$

Exercício 9.2: Capacidade de uma Tarefa de Tempo Real (C_p e C_{pk})**Resolução Passo a Passo:****1. (a) Cálculo do Índice de Capacidade Potencial C_p :**

$$C_p = \frac{LSE - LIE}{6\sigma} = \frac{30.6 - 29.4}{6 \times 0.10} = \frac{1.2}{0.6} = 2.00$$

2. (b) Cálculo do Índice de Capacidade Real C_{pk} :

Avaliação da folga superior:

$$C_{pu} = \frac{LSE - \mu}{3\sigma} = \frac{30.6 - 30.15}{3 \times 0.10} = \frac{0.45}{0.30} = 1.50$$

Avaliação da folga inferior:

$$C_{pl} = \frac{\mu - LIE}{3\sigma} = \frac{30.15 - 29.4}{3 \times 0.10} = \frac{0.75}{0.30} = 2.50$$

$$C_{pk} = \min(C_{pu}, C_{pl}) = \min(1.50, 2.50) = 1.50$$

Interpretação: Como $C_p = 2.00 > C_{pk} = 1.50$, o processo possui dispersão excelente (nível 6-sigma potencial), mas está ligeiramente descentralizado para a direita ($\mu = 30.15 > 30.0$), aproximando-se do limite superior. Ajustando o ponto de trabalho para a meta 30.0 ms, o processo atingirá $C_{pk} = 2.00$.

Exercício 9.3: Gráfico p para a Taxa de Erro de uma API**Resolução Passo a Passo:****1. Desvio padrão da proporção σ_p :**

$$\sigma_p = \sqrt{\frac{\bar{p}(1 - \bar{p})}{n}} = \sqrt{\frac{0.05 \times 0.95}{200}} = \sqrt{\frac{0.0475}{200}} = \sqrt{0.0002375} \approx 0.01541$$

2. Margem 3σ :

$$3\sigma_p = 3 \times 0.01541 = 0.04623$$

3. Limites de Controle:

$$LC = 0.050 \quad (5.0\%)$$

$$LSC = 0.050 + 0.04623 = 0.09623 \approx 9.62\%$$

$$LIC = \max(0, 0.050 - 0.04623) = 0.00377 \approx 0.38\%$$

Tabela da Distribuição Normal Padrão $Z \sim N(0, 1)$

Valores acumulados de probabilidade $\Phi(z) = P(Z \leq z)$ para $z \geq 0$. Para $z < 0$, utilize a relação de simetria: $\Phi(-z) = 1 - \Phi(z)$.

Z	.00	.01	.02	.03	.04	.05	.06	.07
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292
1.5	0.9332	0.9345	0.9357	0.9370	0.9382	0.9394	0.9406	0.9418
1.6	0.9452	0.9463	0.9474	0.9484	0.9495	0.9505	0.9515	0.9525
1.7	0.9554	0.9564	0.9573	0.9582	0.9591	0.9599	0.9608	0.9616
1.8	0.9641	0.9649	0.9656	0.9664	0.9671	0.9678	0.9686	0.9693
1.9	0.9713	0.9719	0.9726	0.9732	0.9738	0.9744	0.9750	0.9756
2.0	0.9772	0.9778	0.9783	0.9788	0.9793	0.9798	0.9803	0.9808

Z	.00	.01	.02	.03	.04	.05	.06	.07
2.1	0.9821	0.9826	0.9830	0.9834	0.9838	0.9842	0.9846	0.9850
2.2	0.9861	0.9864	0.9868	0.9871	0.9875	0.9878	0.9881	0.9884
2.3	0.9893	0.9896	0.9898	0.9901	0.9904	0.9906	0.9909	0.9911
2.4	0.9918	0.9920	0.9922	0.9925	0.9927	0.9929	0.9931	0.9932
2.5	0.9938	0.9940	0.9941	0.9943	0.9945	0.9946	0.9948	0.9949
2.6	0.9953	0.9955	0.9956	0.9957	0.9959	0.9960	0.9961	0.9962
2.7	0.9965	0.9966	0.9967	0.9968	0.9969	0.9970	0.9971	0.9972
2.8	0.9974	0.9975	0.9976	0.9977	0.9977	0.9978	0.9979	0.9979
2.9	0.9981	0.9982	0.9982	0.9983	0.9984	0.9984	0.9985	0.9985
3.0	0.9987	0.9987	0.9987	0.9988	0.9988	0.9989	0.9989	0.9989
3.1	0.9990	0.9991	0.9991	0.9991	0.9992	0.9992	0.9992	0.9992
3.2	0.9993	0.9993	0.9994	0.9994	0.9994	0.9994	0.9994	0.9995
3.3	0.9995	0.9995	0.9995	0.9996	0.9996	0.9996	0.9996	0.9996
3.4	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997	0.9997

Tabela de Valores Críticos da Distribuição t de Student

Valores críticos $t_{\alpha/2,\nu}$ para intervalos de confiança e testes bicaudais com ν graus de liberdade.

GRAUS DE LIBERDADE (ν)	$t_{0.10}$ (80% BICAUDAL)	$t_{0.05}$ (90% BICAUDAL)	$t_{0.025}$ (95% BICAUDAL)	$t_{0.005}$ (99% BICAUDAL)
1	3.078	6.314	12.706	63.657
2	1.886	2.920	4.303	9.925
3	1.638	2.353	3.182	5.841
4	1.533	2.132	2.776	4.604
5	1.476	2.015	2.571	4.032
10	1.372	1.812	2.228	3.169
15	1.341	1.753	2.131	2.947
20	1.325	1.725	2.086	2.845
25	1.316	1.708	2.060	2.787
30	1.310	1.697	2.042	2.750
∞ (Normal Z)	1.282	1.645	1.960	2.576

Constantes de Shewhart para Gráficos de Controle (CEP)

Fatores para construção de limites 3σ em gráficos $\bar{X}$ e R para subgrupos de tamanho n .

TAMANHO DO SUBGRUPO (n)	A_2 (GRÁFICO $\bar{X}$)	D_3 (LIC GRÁFICO R)	D_4 (LSC GRÁFICO R)	d_2 (ESTIMAÇÃO σ)
2	1.880	0.000	3.267	1.128
3	1.023	0.000	2.574	1.693
4	0.729	0.000	2.282	2.059
5	0.577	0.000	2.114	2.326
6	0.483	0.000	2.004	2.534
7	0.419	0.076	1.924	2.704
8	0.373	0.136	1.864	2.847
9	0.337	0.184	1.816	2.970
10	0.308	0.223	1.777	3.078

Formulário (Resumo dos 9 Módulos)

MÓDULO 1: PROBABILIDADE FUNDAMENTAL

- $P(A \cup B) = P(A) + P(B) - P(A \cap B)$
- $P(A|B) = \frac{P(A \cap B)}{P(B)}$
- Independência: $P(A \cap B) = P(A) \cdot P(B)$
- Probabilidade Total: $P(B) = \sum P(A_i)P(B|A_i)$
- Bayes: $P(A_j|B) = \frac{P(A_j)P(B|A_j)}{\sum P(A_i)P(B|A_i)}$
- Sistemas em série: $R_s = \prod R_i$
- Sistemas em paralelo: $R_p = 1 - \prod (1 - R_i)$

MÓDULO 2: VARIÁVEIS ALEATÓRIAS DISCRETAS

- $\sum p(x) = 1, \quad p(x) \geq 0$
- $F(x) = P(X \leq x) = \sum_{t \leq x} p(t)$
- $E[X] = \mu = \sum xp(x)$
- $Var(X) = \sigma^2 = E[X^2] - (E[X])^2$
- $E[aX + b] = aE[X] + b$
- $Var(aX + b) = a^2 Var(X)$
- $\sigma = \sqrt{Var(X)}$

MÓDULO 3: MODELOS DISCRETOS

- Uniforme: $P(X = x) = \frac{1}{k}, \quad E[X] = \frac{a+b}{2}$
- Binomial: $P(X = k) = \binom{n}{k} p^k (1-p)^{n-k}$
- $E[X]_{Bin} = np, \quad Var(X)_{Bin} = np(1-p)$
- Poisson: $P(X = k) = \frac{e^{-\lambda} \lambda^k}{k!}$
- $E[X]_{Poi} = \lambda, \quad Var(X)_{Poi} = \lambda$
- Aproximação: $\lambda = np \quad (n \geq 20, p \leq 0.05)$

MÓDULO 4: VARIÁVEIS ALEATÓRIAS CONTÍNUAS

- $\int_{-\infty}^{+\infty} f(x)dx = 1, \quad f(x) \geq 0$
- $P(a \leq X \leq b) = \int_a^b f(x)dx$
- $F(x) = \int_{-\infty}^x f(t)dt \implies f(x) = F'(x)$
- $E[X] = \int xf(x)dx$
- $E[X^2] = \int x^2 f(x)dx$
- $Var(X) = E[X^2] - (E[X])^2$
- Mediana: $F(m) = 0.50$

MÓDULO 5: MODELOS CONTÍNUOS

- Uniforme: $f(x) = \frac{1}{b-a}$, $Var(X) = \frac{(b-a)^2}{12}$
- Normal: $Z = \frac{X-\mu}{\sigma} \sim N(0, 1)$
- Simetria: $\Phi(-z) = 1 - \Phi(z)$
- Exponencial: $f(x) = \lambda e^{-\lambda x}$, $F(x) = 1 - e^{-\lambda x}$
- $E[X]_{Exp} = \frac{1}{\lambda} = \text{MTTF}$, $Var(X) = \frac{1}{\lambda^2}$
- Confiabilidade: $R(t) = e^{-\lambda t}$

MÓDULO 6: ESTATÍSTICA DESCRITIVA

- Média: $\bar{x} = \frac{1}{n} \sum x_i$
- Variância: $s^2 = \frac{1}{n-1} \sum (x_i - \bar{x})^2$
- Desvio padrão: $s = \sqrt{s^2}$
- Coef. Variação: $CV = \frac{s}{\bar{x}} \times 100\%$
- $IQR = Q_3 - Q_1$
- Limites Boxplot: $[Q_1 - 1.5IQR; Q_3 + 1.5IQR]$

MÓDULO 7: ESTIMAÇÃO E TCL

- TCL ($n \geq 30$): $\bar{X} \sim N(\mu, \sigma^2/n)$
- Erro Padrão: $SE = \frac{\sigma}{\sqrt{n}}$
- IC (σ conhe.): $\bar{x} \pm z_{\alpha/2} \frac{\sigma}{\sqrt{n}}$
- IC (σ desconh.): $\bar{x} \pm t_{\alpha/2, n-1} \frac{s}{\sqrt{n}}$
- Tamanho amostral: $n = \left(\frac{z_{\alpha/2} \sigma}{E} \right)^2$
- IC Proporção: $\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$

MÓDULO 8: TESTES DE HIPÓTESE

- Estatística Z : $z_{\text{calc}} = \frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}$
- Estatística t : $t_{\text{calc}} = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$
- Regra: Se $p\text{-valor} \leq \alpha \implies$ Rejeita H_0
- Erro I: Rejeitar H_0 verdadeira (α)
- Erro II: Não rejeitar H_0 falsa (β)
- Poder do teste: $1 - \beta$
- Qui-Quadrado: $\chi^2_{\text{calc}} = \sum \frac{(O_i - E_i)^2}{E_i}$ ($gl = k - 1 - m$)

MÓDULO 9: CONTROLE ESTATÍSTICO (CEP)

- Limites 3σ : $LC = \mu$, $LSC = \mu + 3\sigma$, $LIC = \mu - 3\sigma$
- Gráfico $\bar{X}$: $LSC = \bar{\bar{X}} + A_2\bar{R}$, $LIC = \bar{\bar{X}} - A_2\bar{R}$
- Gráfico R : $LSC = D_4\bar{R}$, $LIC = D_3\bar{R}$
- Gráfico p : $\bar{p} \pm 3\sqrt{\frac{\bar{p}(1-\bar{p})}{n}}$
- Capacidade: $C_p = \frac{LSE - LIE}{6\sigma}$
- Capacidade real: $C_{pk} = \min\left(\frac{LSE - \mu}{3\sigma}, \frac{\mu - LIE}{3\sigma}\right)$